Ответы и официальные разборы

Том 2. Официальные оригиналы

Оригинальная вёрстка сохранена вместе с формулами, рисунками и авторскими пояснениями. В сборниках могут встречаться и условия, и ответы, и критерии оценивания.

Соответствие отдельной задаче проверяйте по олимпиаде, году, классу, номеру и варианту. Если этих данных недостаточно, документ не объявляется точным решением конкретной задачи.

Оглавление PDF содержит начала документов. Ссылки на источники и номера страниц находятся в каталоге библиотеки.

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ

Т БАНК

Разбор вопросов

1. По выборке из 144 значений посчитали выборочную дисперсию. После этого все значения увеличили в 10 раз. Как изменится выборочная дисперсия, если вычислить ее по новым значениям выборки?

   А. Не изменится

   Б. Увеличится в 10 раз

   В. Увеличится в 100 раз

   Г. Изменится в 0,1 раза

   Д. Нет верного варианта ответа среди вышеперечисленных

   Решение:

   Выборочная дисперсия — это мера разброса данных относительно выборочного среднего. Она вычисляется по формуле:

   $s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$

   Рассмотрим, что произойдет, если все значения выборки увеличить в 10 раз, то есть заменить x_i на $10x_i$. Новое среднее будет:

   $\overline{10x} = 10\bar{x}$

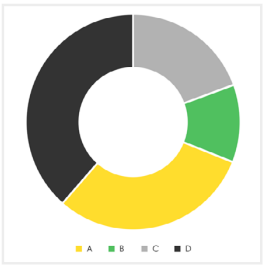
   Тогда новая дисперсия:

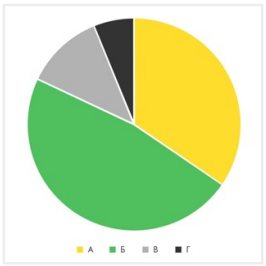
   $s^2_{\text{нов}} = \frac{1}{n-1}\sum_{i=1}^{n}(10x_i - 10\bar{x})^2 = \frac{1}{n-1}\sum_{i=1}^{n}[10(x_i - \bar{x})]^2 = \frac{1}{n-1}\sum_{i=1}^{n}100(x_i - \bar{x})^2 = 100 \cdot s^2$

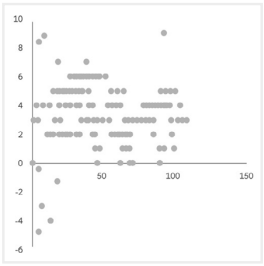
   Таким образом, выборочная дисперсия увеличится в 100 раз.

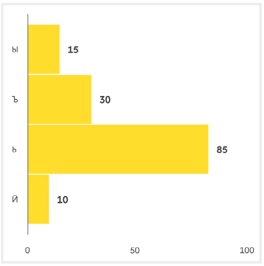
   Ответ: В — Увеличится в 100 раз

2. Сопоставьте названия типов визуализации с графиками:

   1. 

   2. 

3. 

4. 

1. Кольцевая диаграмма
2. Секторная диаграмма
3. Диаграмма рассеяния
4. Гистограмма

Решение:

Диаграммы в данной задаче можно сопоставить по визуальным признакам:

Кольцевая диаграмма — изображает, например, доли в виде кольца (1)

Секторная диаграмма — представляет собой круг, разделенный на сектора. В англоязычной литературе и на слэнге известна как pie chart (2)

Диаграмма рассеяния — обычно по координатной плоскости рассеяны точки, соответствующие значениям двух признаков (3)

Гистограмма — иногда можно встретить название столбчатой диаграммы. Представляет собой столбцы чаще вертикальные, но иногда горизонтальные как в варианте (4)

3. Исследователи проверили гипотезу о среднем значении с использованием Z-теста. Уровень значимости установлен равным 0,01. Как интерпретировать такое значение уровня значимости?

А. Вероятность того, что альтернативная гипотеза верна, равна 1%

Б. Допустимая вероятность отвержения альтернативной гипотезы, если она на самом деле верна, равна 1%.

В. Если нулевая гипотеза не верна, в 1% случаев мы допускаем, что можем ошибочно принять ее при многократном повторении теста на семплированных данных из одной генеральной совокупности

Г. Вероятность ошибки первого рода равна 1%

Д. Если тест показал p-value = 0,1, вероятность того, что нулевая гипотеза верна, равна 1%

Решение:

В задании указан выбранный уровень значимости, который в статистике показывает вероятность совершения ошибки 1 рода (то есть принятие нулевой гипотезы, когда она не верна). Таким образом, вариант Г должен быть выбран верным.

Далее рассмотрим каждый из вариантов ответа последовательно.

В варианте ответа А делается предположение об априорной вероятности верности альтернативной гипотезы - об этом мы никакой информации не имеем, соответственно, вариант А не верен.

В варианте Б говорится об ошибке 2 рода, о чем в условии задания также не сказано, следовательно, вериант Б неверен.

В варианте В также говорится об ошибке 2 рода, следовательно, вериант Б неверен.

В варианте Д говорится об априорной вероятности верности нулевой гипотезы, о чем информации в условии задания нет.

Ответ: Г — Вероятность ошибки первого рода равна 1%

4. Сотрудники отдела прогнозирования и анализа данных изучили ежемесячные данные по ценам на рис и гречку за 2021 год. Средние цены оказались одинаковыми. Значения дисперсий: 64 ₽^{2} для риса и 82 ₽^{2} для гречки. Какое из утверждений верное?

   A. Цена риса в 2021 году была более изменчива, чем цена гречки

   B. Цена гречки в 2021 году была более изменчива, чем цена риса

   C. Ежемесячные цены на рис и гречку всегда одинаковы

   D. Стандартные отклонения цен на рис и гречку одинаковы

   Решение:

   Задача на интерпретацию второго центрального момента случайной величины — дисперсии (в теории вероятностей) и её выборочной оценки (математическая статистика). Дисперсия отражает разброс показателя (накопленное квадратичное отклонение от среднего) и всегда относительна. У какой цены значение выборочной дисперсии больше, у той больше разброс, а значит и изменчивость. Информация о средних здесь не обязательно, хотя и полезна на случай, если хочется проверить ответ через определение выборочной дисперсии.

   $$\widehat{\sigma}^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{X})^2, \text{ где n – объем выборки}$$

   Ответ: В — Цена гречки в 2021 году была более изменчива, чем цена риса

5. Влад построил 80%-й доверительный интервал для средней цены пары кроссовок «Майк» и получил оценку от 7 000 до 15 000 ₽. Какая гипотеза не отвергнется на 20%-м уровне значимости при использовании двусторонней альтернативной гипотезы?

   A. Дисперсия цены пары кроссовок «Майк» равна 4 000 ₽

   B. Средняя цена пары кроссовок «Майк» равна 2 700 ₽

   C. Средняя цена пары кроссовок «Майк» равна 9 535 ₽

   D. Стандартное отклонение цены пары кроссовок «Майк» равно 4 000 ₽

Решение:

В условии задания не указана к какому распределению принадлежит средняя цена кроссовок, поэтому формула, по которой получен доверительный интервал не может быть однозначно идентифиирована и вычислена дисперсию/стандартное отклонение. Ответы А и Г не верны.

На 20% уровне значимости не отвергнется гипотеза, согласно которой истинное значение средней цены принадлежит указанному интервалу, в вариантах ответа только одна цена входит в этот интервал: 7 000 < 9 535 < 15 000.

Ответ: В — Средняя цена пары кроссовок «Майк» равна 9 535 ₽

6. В автошколе после тестирования инструктор оценил среднее значение баллов за тест, набранных 10 сдавшими, и получил 85 баллов. Оказалось, что 5 работ инструктор забыл внести в ведомость. После их внесения среднее по всем 15 работам оказалось равно 90 баллам. Максимум за тест можно было набрать 100 баллов. Что можно сказать о добавленных пяти работах?

   A. Инструктор забыл добавить работы учеников, набравших максимум баллов

   B. Инструктор неправильно рассчитал среднее

   C. Среднее число баллов в добавленных пяти работах равно 99

   D. Стандартное отклонение набранных баллов одним учеником в среднем равно 10 баллам

   Решение:

   Задача на знание определения выборочного среднего и умение работать с ним.

   $\frac{1}{10}\sum_{i=1}^{10} x_i = 85$, **следовательно сумма по десяти работам равна** $\sum_{i=1}^{10} x_i = 850$

   $\frac{1}{15}\sum_{i=1}^{15} x_i = 90$, **следовательно сумма по 15 работам равна** $\sum_{i=1}^{15} x_i = 1350$

   Разность сумм равно 500, что является суммой набранных баллов по 5 работам. Так как максимум равен 100 баллам, то очевидно, что работы забытые инструктором набрали максимум баллов.

   Ответ: А — Инструктор забыл добавить работы учеников, набравших максимум баллов

7. Сопоставьте следующие данные о сотрудниках, собранные в рамках опроса, и типы признаков, которыми могут быть описаны эти данные.

Переменная	**Тип признака**
Должность (менеджер/разработчик/аналитик)	Дискретный
Процент надбавки от фиксированной заработной платы	Категориальный
Количество рабочих дней в командировках	Порядковый
Уровень стресса (целое число от 1 до 10)	Непрерывный

Решение:

Должность является текстовой переменной, которая характеризует «класс» или категорию наблюдения, которая не может быть описана числом, поэтому должность — это категориальная переменная.

Количество рабочих дней в командировках может быть измерено только целым числом, то есть дискретно.

Уровень стресса задается целыми числами, которые характеризуют силу стресса, то есть является порядковой переменной.

Следовательно, оставшийся «Процент надбавки от фиксированной заработной платы» — это непрерывная переменная.

Ответ: Должность: категориальный. Процент: непрерывный.
Количество рабочих дней: дискретный. Уровень стресса: порядковый.

8. Алексей из Москвы провел опрос среди своих подписчиков в соцсети, чтобы узнать, будут ли они покупать новый кофейный напиток. Всего у Алексея 1 000 подписчиков, 850 из которых живут в Москве. Результаты опроса такие:

   — 620 человек ответили «Да, куплю»

   — 150 человек сказали «Нет»

   — 230 человек затруднились с ответом

   Какие выводы можно сделать по результатам этого опроса?

   A. В среднем в России 62% потребителей готовы купить новый кофейный напиток

   B. В среднем в России 15% потребителей готовы купить новый кофейный напиток

   C. В Москве примерно 73% потребителей готовы купить новый кофейный напиток

   D. Полученных данных недостаточно для запуска продаж по всей стране

   Решение:

   Алексей опросил преимущественно жителей Москвы (из 1000 опрошенных 850 из Москвы). Результаты опроса, которые получил Алексей смещены в сторону предпочтений москвичей. В вариантах ответа предлагается проецировать результаты на всю страну, что некорректно, так как выборка относительно всей страны оказалась нерепрезентативной. Вариант C отражает долю опрошенных ответивших «Да, куплю» среди числа подписчиков из Москвы (850). Это некорректно, так как для принятия решения по Москве нас интересовали бы только жители Москвы, а среди ответивших «Да, куплю» вполне могли оказаться жители других регионов.

   Ответ: D — Полученных данных недостаточно для запуска продаж по всей стране

9. У Кати есть 10 000 ₽, и она думает об открытии депозита на 6 месяцев под годовую ставку 20%. Сотрудники банка предложили ей инновационный продукт, ежемесячная доходность которого будет такая: +10%, +1%, –3%, +12%, +1%, –2%. Куда стоит вложить средства Кате? Предполагается, что процентный доход ежемесячно выплачивается после начисления (капитализация процентного дохода отсутствует).

A. Стоит выбрать инновационный продукт: так Катя сможет заработать через полгода больше, чем на вкладе в депозит

B. Стоит открыть депозит: он принесет больший доход, чем инновационный продукт

C. Все равно, куда вкладываться

D. Недостаточно информации для принятия решения, так как нужно учитывать капитализацию

Решение:

Рассчитаем какой доход получит Катя от двух этих вариантов.

Инновационный продукт: 10+1–3+12+1–2 = 19%

Вклад: 20/2=10% (так как 20% это годовая ставка, а Катя положит деньги на 6 месяцев, то есть на полгода)

При этом в варианте Г не стоит принимать во внимание капитализацию, так как и в инновационном продукте, и во вкладе указано, что капитализации нет.

Ответ: А — Стоит выбрать инновационный продукт, так Катя сможет заработать через полгода больше, чем на вкладе в депозит.

10. Производители чехлов для смартфонов последние 8 лет по негласному соглашению выпускали преимущественно черные чехлы. В результате доля черных чехлов в поставках ретейлерам составила 85%, а на все остальные цвета (белый, синий, красный и др.) пришлось только 15%. Конверсия в покупку чехлов каждого цвета одинаковая. Аналитики рынка опубликовали исследование с несколькими утверждениями. Какие из этих утверждений можно считать достоверными на основе приведенных данных?

A. Покупатели предпочитают черные чехлы для смартфонов всем другим цветам

B. Доля синих чехлов составляет 2% или более

C. Потребителям не нравятся яркие чехлы для телефонов

D. Большинство проданных чехлов черного цвета

E. Нет верных ответов среди вышеперечисленных вариантов

Решение:

Утверждения A и C предлагают гипотезы относительно потребительских предпочтений покупателей. Они неверны, так как в самой задаче ничего о предпочтениях не сказано. Мы знаем лишь факт, связанный с производителем, что длительное время по каким-то причинам выпускались преимущественно черные чехлы. Для варианта B у нас нет никакой подтверждающей информации о доле синих чехлов. Вариант D оказывается верным, так как это факт, следующий из условий сложившихся на рынке чехлов вследствие ограничений производителя.

Ответ: D

11. На космической станции связи работают два робота-оператора: R2 и D2. R2 тратит 2 минуты, чтобы обработать один запрос. D2 тратит на один запрос 6 минут. Их рабочая смена длится 4 часа. Сколько в среднем длится обработка запроса на космической станции?

    А. 3 минуты

    Б. 3 минуты 30 секунд

    В. 3 минуты

    Г. 5 минут

    Решение:

    4 часа = 4*60 мин =240 мин - длительность смены каждого из роботов в минутах

    Суммарно робота отрабатывают за одну смену 480 мин, по 240 мин каждый

    Так как R2 обрабатывает один запрос за 6 мин, то за свое время смены он обработает 240/2 = 120 клиентов. А робот D2 соответственно 240/6=40 клиентов.

    Суммарно за смену роботы выполнят запросы 120+40 = 160 клиентов за суммарно 480 минут. То есть в среднем по 480/160 = 3 мин / клиента.

    Ответ: В — 3 минуты

12. В сказочной стране Конфетляндии у волшебника есть 15 волшебных конфет, выстроенных в ряд так, что каждая следующая конфета весит на 1 г больше предыдущей. Известно, что средний вес первых 11 конфет равен 10 г, а средний вес последних 11 конфет — 14 г. Найдите вес самой тяжелой конфеты в этом ряду.

    Решение:

    Пусть вес первой конфеты a грамм. Тогда вес второй $a+1$, третьей $a+2$, и так до 15-й: $a+14$.

    Для первых 11 конфет: a, $a+1$, $a+2$, ..., $a+10$

    Известно, что их средний вес 10 г, а значит:

    $$\frac{a+(a+1)+...+(a+10)}{11}=10$$

    Откуда:

    $$\frac{11a+55}{11}=10$$

    $a=5$

    Значит, первая конфета весит 5 г.

    Для последних 11 конфет (с номерами с 5-й по 15-ю): $a+4$, $a+5$,..., $a+14$

    Подставим $a=5$:

    9, 10, 11 ,..., 19

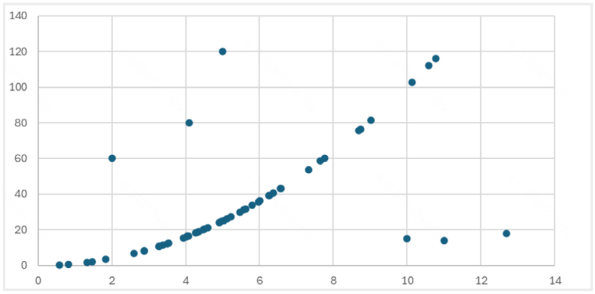
Средний вес этих 11 конфет по условию 14 г. Проверим:

Среднее: 154/11=14 — верно.

Тогда самая тяжелая конфета — это 15-я конфета: a+14=5+14=19 грамм.

Ответ: 19

13. Директор цеха по производству шпулек составил график зависимости оплаты труда сотрудников всех профессий в цеху (в тысячах рублей по вертикальной оси) от длины рабочей смены (в часах по горизонтальной оси). Выберите верные утверждения, которые соответствуют построенному графику.



А. Между длиной рабочей смены и оплатой есть линейная отрицательная связь.

Б. Коэффициент корреляции Спирмена между длиной рабочей смены и оплатой нулевой.

В. В цеху трое перерабатывают и им недоплачивают.

Г. Зависимость между оплатой труда и длительностью рабочей смены можно описать нелинейной функцией, исключив выбросы

Решение:

Рассмотрим последовательно варианты ответов.

Между длиной рабочей смены и оплатой на графике видна положительная взаимосвязь, которая к тому же нелинейна. Поэтому вариант А неверен.

Коэффициент корреляции Спирмена будет положительным, поскольку на графике явно видна положительная взаимосвязь. Вариант Б также неверен.

В условии указано, что на графике отображены представители всех профессий. Мы можем предположить, что верхние 3 выбивающиеся наблюдения — это представители более высокооплачиваемых профессий (директора, ведущие мастера и тд), а оставшиеся 3 наблюдения — представители профессий с более низкой квалификацией (например, стажеры, подмастерье и тд). Поэтому нельзя сделать вывод, что они недорабатывают или перерабатывают, поскольку иначе в этом выводе не учитывается квалификация сотрудников. Вариант В неверен.

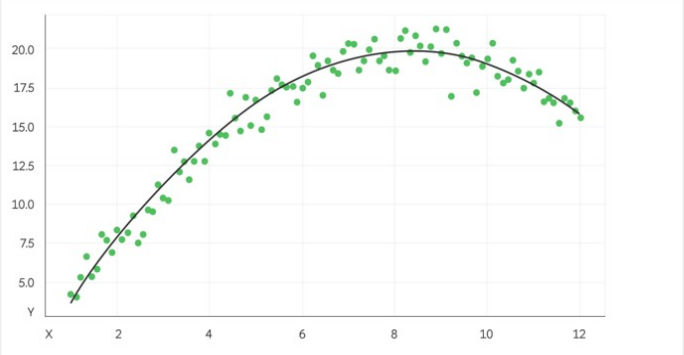
Вариант Г верен, так как исключив 6 выбирающихся наблюдений, функция действительно имеет нелинейный вид.

Ответ: Г — Зависимость между оплатой труда и длительностью рабочей смены можно описать нелинейной функцией, исключив выбросы.

14. Аграрная компания провела исследование, чтобы определить, как количество внесенных удобрений (килограмм на гектар) влияет на урожайность винограда (килограмм с гектара). Для анализа данных оценили квадратичную регрессионную модель:

    Урожайность = $-0{,}3 \times \text{Удобрения}^2 + 5 \times \text{Удобрения} - 1$

    Коэффициент детерминации $R^2 = 0{,}82$. Определите оптимальное количество удобрений, при котором урожайность достигает максимума, согласно оцененной модели. На графике зеленым цветом показаны фактические данные, черным — оцененная зависимость.

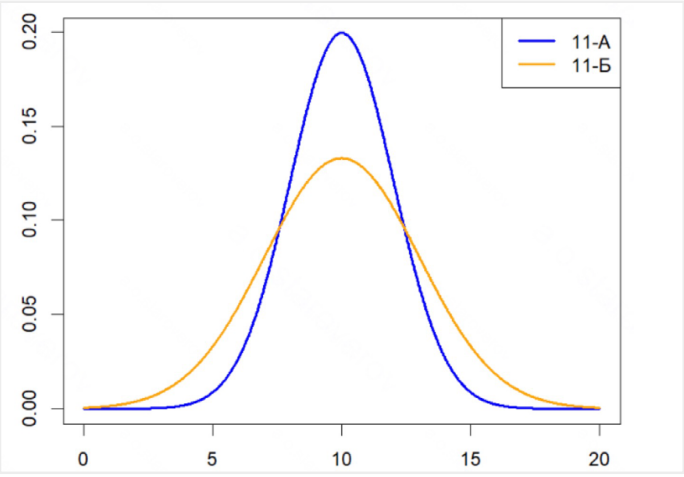


Решение:

Из условия следует, что зависимость между урожайностью и удобрениями квадратичная: Урожайность = $-0{,}3 \times \text{Удобрения}^2 + 5 \times \text{Удобрения} - 1$.
Найденная вершина параболы по абсциссе и будет ответом: $-5 / (-2 * 0.3) = 8.33$

Ответ: 8

15. Дима построил распределения количества игр в библиотеке магазина «Стем» для учащихся 11 «А» и 11 «Б». Получился такой график распределений.



Что из этого графика может заключить Дима об учащихся?

А. В обоих классах среднее число игр у одного учащегося равно 10

Б. В 11 «Б» разброс числа игр у учащихся меньше, чем в 11 «А»

В. Медиана в 11 «А» равна моде в 11 «Б»

Г. Больше половины учащихся 11 «А» обладают 8 и более играми.

Решение:

Рассмотрим все варианты ответов по порядку.

Вариант А верен, поскольку на графиках показаны два нормальных распределения со средним значением в 10.

Вариант Б не верен, поскольку распределение в классе А более сконцентрированное, а значит, в нем дисперсия (разброс) меньше, чем у класса Б.

Вариант В верен, поскольку представленные распределения являются симметричными относительно среднего значения, а значит, медиана в обоих распределениях равна 10. Также по графикам видно, что мода (самое популярное значение в выборке) приходится также на 10.

Вариант Г верен, поскольку медиана распределения приходится на 10, значит, что половина учеников имеет 10 игр и больше. Так как 8< 10, то больше половины учащихся имеют 8 игр и больше.

Ответ: А — В обоих классах среднее число игр у одного учащегося равно 10. В — Медиана в 11 «А» равна моде в 11 «Б». Г — Больше половины учащихся 11 «А» обладают 8 и более играми.

16. Любителей творчества Чарльза Диккенса спросили: сколько чашек чая выпивает мисс Хэвишем в зависимости от количества гостей на ее знаменитых чаепитиях? В результате получилась следующая таблица с усредненными значениями

Количество гостей	**Среднее количество выпитых чашек чая (оцененное по данным опроса)**
Мало	5 чашек
Средне	4 чашки
Много	3 чашки
Очень много	2 чашки

При помощи каких статистических инструментов можно подтвердить или опровергнуть наличие зависимости между количеством выпитых чашек чая и количеством гостей на чаепитии у мисс Хэвишем?

A. Коэффициент корреляции Спирмена

B. F-тест на равенство дисперсий

C. Z-тест

D. U-тест Манна — Уитни

Решение:

В таблице приведены два признака: порядковый (количество гостей) и количественный (среднее количество выпитых чашек). Из всех предложенных вариантов только коэффициент корреляции Спирмена предлагает рецепт по расчету корреляции между порядковыми и количественными признаками с дальнейшей проверкой гипотезы о независимости признаков.

17. Исследователь получил набор данных о вкусовых предпочтениях мороженого анкетируемых со следующими переменными: цвет упаковки, возраст потребителя, уровень дохода и предпочитаемый вкус мороженого. Какие из этих переменных имеет смысл использовать в качестве зависимых, а какие в качестве независимых?

    А. Цвет упаковки как независимая переменная, а остальные как зависимые

    Б. Возраст потребителя как зависимая переменная, а остальные как независимые

    В. Уровень дохода как независимая переменная, а остальные как зависимые

    Г. Предпочитаемый вкус мороженого как зависимая переменная, а остальные как независимые

    Решение:

    В качестве зависимой переменной (таргета/целевой переменной/...) в исследовании стоит выбирать те переменные, которые не оказывают влияние на другие, но при этом должен существовать механизм, по которому на них будут оказывать влияние независимые переменные.

    В данном случае логичнее предположить, что на предпочтение определенного мороженного могут влиять цвет упаковки, возраст потребителя и его уровень дохода.

    Ответ: Г — Предпочитаемый вкус мороженого как зависимая переменная, а остальные как независимые.

18. Специалист по флоре тропического леса хочет визуализировать распределение различных видов растений в исследуемой области. Какой тип визуализации лучше всего подходит для этой задачи?

    A. Тепловая карта

    B. Линейный график

    C. Диаграмма Венна

    D. Столбчатая диаграмма

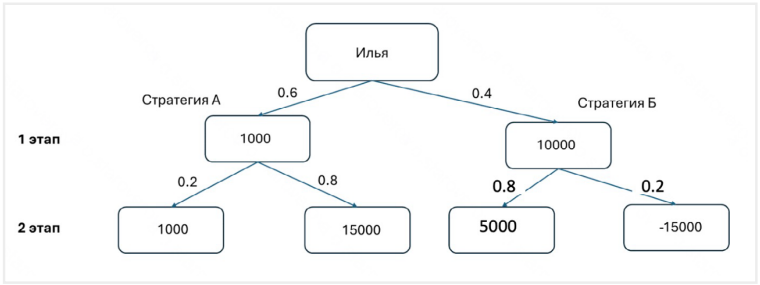
    Решение:

    Ключевым словосочетанием является «хочет визуализировать распределение». Распределение хорошо представлять при помощи гистограммы (столбчатой диаграммы), но если вчитаться в задание, то мы имеем дело с пространственными данными о произрастании растений в географической области. Тепловая карта как нельзя лучше подходит для такого и широко используется географами и биологами.

19. Илья руководит стартапом по анализу данных. Ему нужно выбрать одну из дальнейших стратегий развития стартапа: А или Б. Обычно руководители стартапов с вероятностью 0,6 выбирают стратегию А и с вероятностью 0,4 — стратегию Б.

    Каждая стратегия состоит из двух этапов. Стратегия А на первом этапе принесет 1 000 бонусов, а на втором — с вероятностью 0,2 еще 1 000 бонусов или с вероятностью 0,8 еще 15 000 бонусов. Стратегия Б на первом этапе принесет 10 000 бонусов, а на втором — с вероятностью 0,8 еще 5 000 бонусов или с вероятностью 0,2 Илья потеряет 15 000 бонусов.

    Какую стратегию стоит выбрать Илье?



А. А

Б. Стратегии равноценны

В. Б

Г. Недостаточно информации для принятия решения

Решение:

Посчитаем математическое ожидание бонусов при выборе каждой из стратегий.

Для стратегии А: 1 000+ (0.2 * 1 000 + 0.8*15 000) = 1 000 + 200 + 12 000 = 13 200

Для стратегии Б: 10 000 + (0.8 * 5 000 + 0.2 * (–15 000)) = 10 000 + 4 000 – 3 000 = 11 000

То, какие стратегии обычно выбирают руководители («Обычно руководители стартапов с вероятностью 0,6 выбирают стратегию А и с вероятностью 0,4 — стратегию Б»), никак не влияет на прибыльность указанных стратегий.

13 200 > 11 000, значит, стратегия А предпочтительнее, и следует выбрать ее

Ответ: А — А

20. Владелец небольшого кафе фиксировал количество посетителей каждый год в течение последних 4 лет и получил такие данные по годам: 1 200 посетителей, 1 500, 1 800, 2 250. Чему равен средний темп прироста числа посетителей кафе за год в процентах? Укажите ответ одним числом без дополнительных знаков и символов, округлите ответ до целого.

Решение:

Обозначим данные по годам:

Год 1: $N_0 = 1\,200$

Год 2: $N_1 = 1\,500$

Год 3: $N_2 = 1\,800$

Год 4: $N_3 = 2\,250$

Годовые темпы прироста равны:

$$k_1 = \frac{1\,500}{1\,200} = 1.25$$

$$k_2 = \frac{1\,800}{1\,500} = 1.2$$

$$k_3 = \frac{2\,250}{1\,800} = 1.25$$

Средний темп роста за период находится по формуле среднего геометрического годовых коэффициентов роста:

$$\bar{k} = \sqrt[3]{k_1 \cdot k_2 \cdot k_3}\sqrt[3]{1.25 * 1,2 * 1,25} \approx 1.234$$

Средний годовой темп прироста в %

$$\bar{r} = (\bar{k} - 1) \times 100\% \approx (1.234 - 1) \times 100\% \approx 23.4\%$$

Округляем до целого: 23%.

Ответ: 23

21. Аналитики исследовали, каких домашних животных предпочитают жители города. Получилась такая таблица сопряженности, отражающая связь между типом жилья и предпочтением вида питомца.

Тип жилья	Кошки	Собаки	Рыбки
Квартира	250	180	120
Частный дом	150	320	80

Известно также, что все жители города держат какого-нибудь питомца!

Какие выводы можно сделать на основе этих данных?

А. Вероятность, что случайно выбранный житель держит собаку, выше, чем вероятность, что он держит кошку

Б. Среди жителей частных домов больше тех, кто держит рыбок, чем среди жителей квартир

В. Кошки и рыбки одинаково популярны среди всех жителей

Г. Больше половины жителей квартир предпочитают держать кошек

Д. Вероятность держать собаку выше среди жителей частных домов, чем среди жителей квартир

Решение:

Проверим каждый вариант ответов.

А. Вероятность, что случайный житель держит собаку = (180+320)/(250+150+180+320+120+ 80) = 500/1100 ~= 0.45. Вероятность, что случайный житель держит кошку = (250+150) / 1100 ~= 0.36. Вариант А верен.

Б. Доля тех кто держит рыбок в частных домах = 80 / (150+320+80) = 80/550 ~= 0.145. Доля тех кто держит рыбок в квартирах = 120/(250+180+120) = 120/550 ~= 0.218. Вариант Б не верен.

В. Держат кошек 250+150 = 400 человек, а держат рыбок 120+80 = 200 человек. Вариант В не верен.

Г. Держат кошку среди жителей квартир 250 чел, всего в квартирах живет 550 человек; 250/550 это меньше 50%, следовательно ответ Г неверен

Д. Вероятность держать собаку среди жителей частный домов = 320/(150+320+80) = 320/550 ~= 0.58. Вероятность держать собаку среди жителей квартир = 180/550 ~= 0.32. 0.58> 0.32, следовательно вариант Д верен.

Ответ: А — Вероятность, что случайно выбранный житель держит собаку, выше, чем вероятность, что он держит кошку. Д — Вероятность держать собаку выше среди жителей частных домов, чем среди жителей квартир.

22. Леша — профессиональный киберспортсмен и ежедневно участвует в онлайн-турнирах. Вероятность того, что его аккаунт не будет взломан при попытке взлома, составляет 0,98. Раз в 4 дня фиксируется попытка взлома аккаунтов всех участников турнира. Через сколько дней вероятность того, что аккаунт Алексея будет взломан, станет выше, чем вероятность, что этого не произойдет?

    Укажите ответ одним числом без дополнительных знаков и символов, округлив в случае необходимости до целого значения.

    Решение:

    Вероятность не быть взломанным при одной попытке взлома:

    $p = 0.98$

    Вероятность быть взломанным при одной попытке:

    $q = 1 - p = 0.02$

    Попытка взлома происходит раз в 4 дня.

    Значит, через n дней будет $[n/4]$ попыток взлома.

    Пусть $k = [n/4]$ — количество попыток взлома.

Вероятность не быть взломанным ни разу за k попыток:

$P_{\text{не взломан}} = p^k = 0.98^k$

Вероятность быть взломанным хотя бы раз:

$P_{\text{взломан}} = 1 - 0.98^k$

Нужно найти минимальное n, при котором:

$P_{\text{взломан}} > P_{\text{не взломан}}$

То есть:

$1 - 0.98^k > 0.98^k$

$1 > 2 * 0.98^k$

$0.98^k < 0.5$

$k * \ln(0.98) < \ln(0.5)$

$$k > \frac{\ln(0.5)}{\ln(0.98)}$$

$$k > \frac{(-0.693147)}{(-0.0202027)} \approx 34.309$$

То есть $k \geq 35$.

$k = 35$ попыток взлома.

Если попытка в день 4, 8, 12, ..., то k-я попытка в день $4k$.

Дл я$k = 35$ день последней попытки 4×35=140.

В этот день вероятность взлома станет больше 0.5? Проверим:

После 34 попыток: $0.98^{34} \approx 0.503$, $P_{\text{взлом}} \approx 0.497$ — еще не больше.

После 35 попыток: $0.98^{35} \approx 0.493$, $P_{\text{взлом}} \approx 0.507$ — стало больше.

Ответ: 140

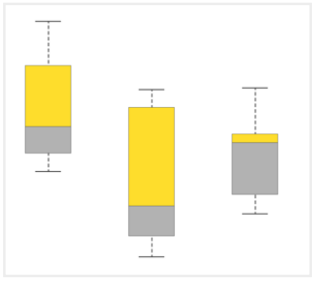
23. В выборке из 100 значений медиана равна 50, а среднее — 45. Вася может увеличить X чисел в выборке на 50. Какого минимального X достаточно, чтобы среднее стало равно медиане, равной 50?

Решение:

Запишем изначальное среднее как M = 45, а новое M` = 50. Тогда M=4 500/100, M`=5 000/100. M`–M= 500. Так как изменять каждое из значений можно только на 50, то мы должны изменить X=500/50 = 10 значений, чтобы приравнять M`=M = 5 000/100.

Ответ: 10

24. Перед вами графики Boxplot для трех выборок с параметром длины усов = 1,5 × IQR. Выберите верные утверждения.



— Дисперсия второй выборки больше, чем двух других

— Медианное значение в третьей выборке наименьшее из представленных графиков

— В выборках нет выбросов, превышающих 1,5 × IQR

— Максимальное значение из всех значений по трем выборкам находится в первой выборке

Ответ: Дисперсия второй выборки больше, чем двух других. В выборках нет выбросов, превышающих 1,5 × IQR. Максимальное значение из всех значений по трем выборкам находится в первой выборке

25. 100 ученикам школы задали два вопроса:

1) Занимаетесь ли вы спортом?

2) Играете ли вы на музыкальных инструментах?

По результатам опроса 50 учеников занимаются спортом; 45 учеников играют на музыкальных инструментах; 25 учеников не занимаются ни спортом, ни музыкой.

Сколько учеников и занимаются спортом, и играют на музыкальных инструментах?

Решение:

Если из 100 человек опрошенных 25 точно не занимаются ни спортом, ни музыкой, то 100-25=75 человек занимаются хотя бы одним из этих занятий. При этом ответили хотя про одно из увлечений положительно 50+45 = 95 опрошенных из 75 возможных, кто хотя бы чем-то занимается. Значит, что 95-75=20 опрошенных занимаются одновременно и музыкой, и спортом.

Ответ: 20

26. Компания проводит онлайн-продажи, и каждый клиент проходит несколько этапов:

1. Посещение сайта.
2. Добавление товара в корзину.
3. Оформление заказа.
4. Оплата заказа.

Аналитики собрали следующую информацию за один день:

— На сайт зашло 5 000 пользователей.

— Из всех, кто заходил на сайт, 20% пользователей оформили заказ.

— 500 клиентов оплатили заказ.

— Из всех, кто добавил товар в корзину, только 50% его оплатили.

Рассчитайте долю оформивших заказ клиентов среди пользователей, добавивших товар в корзину. Ответ округлите до второго знака после запятой.

Решение:

Пусть x — число добавивших в корзину.

Из условия: «Из всех, кто добавил товар в корзину, только 50% его оплатили»

Значит, оплатившие = 0.5 * x.

Но оплативших 500, поэтому:

0.5x = 500, следовательно x = 1 000

То есть 1 000 человек добавили товар в корзину.

Мы знаем, что оформили заказ 1 000 человек.

Все 1 000 оформивших заказ — это подмножество тех, кто добавил в корзину.

Тогда:

Добавили в корзину: 1 000 чел.

Оформили заказ: 1 000 чел.

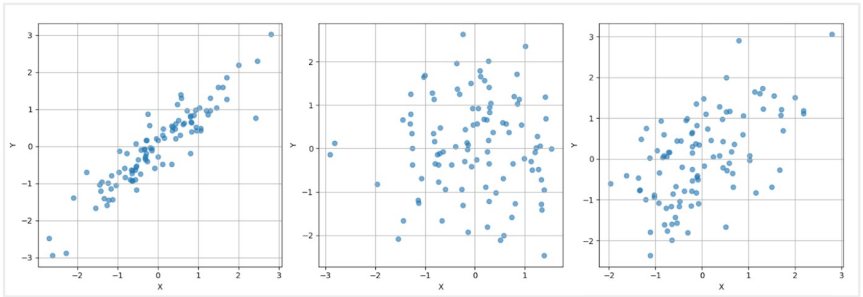
Доля:

1000/1000=1.00

То есть 100%.

Ответ: 1 или 100

27. Даны три диаграммы рассеяния. Сопоставьте их с коэффициентами корреляции, которые получены на этих выборках. В ответ запишите буквы в порядке расположения картинок.



А. –0,4

Б. 0

В. 0,9

Г. 0,4

Решение:

Первый график иллюстрирует ярко выраженную положительную взаимосвязь между переменными, которая почти складывается в линию. Из предложенных вариантов корреляция 0,9 больше всего подходит для его описания.

Второй график не отображает вообще никакой направленности взаимосвязи: при изменении значений по X, значения по Y распределяются точно так же. Такой график иллюстрирует корреляцию = 0.

Третий график иллюстрирует средне выраженную положительную взаимосвязь, для такой свзаимосвязи подходит коэффициент корреляции = 0,4.

Ответ: 1. В. 0,9. 2. Б. 0. 3. Г. 0,4.

28. Перед вами иллюстрация половозрастной пирамиды России с указанием работающего (занятого) населения. Выберите верные утверждения для этой картинки.



— Доля занятых женщин в возрасте 30—34 года ниже, чем у мужчин в том же возрасте

— Среди мужчин трудовых мигрантов меньше, чем среди женщин

— Максимальная доля работающего населения среди мужчин приходится на возрастную группу от 30 до 34 лет

— В возрасте 75—79 лет количество женщин примерно вдвое больше, чем мужчин

— После 75 лет население состоит из женщин более чем на 50%

Ответ: Доля занятых женщин в возрасте 30—34 года ниже, чем у мужчин в том же возрасте. Максимальная доля работающего населения среди мужчин приходится на возрастную группу от 30 до 34 лет. В возрасте 75—79 лет количество женщин примерно вдвое больше, чем мужчин. После 75 лет население состоит из женщин более чем на 50%

29. Выберите все варианты ответов, в которых перечислены корректные методы борьбы с выбросами в данных.

А. Удаление 20% значений

Б. Стандартизация данных

В. Удаление значений, которые отклоняются сильнее чем 1,5 × IQR

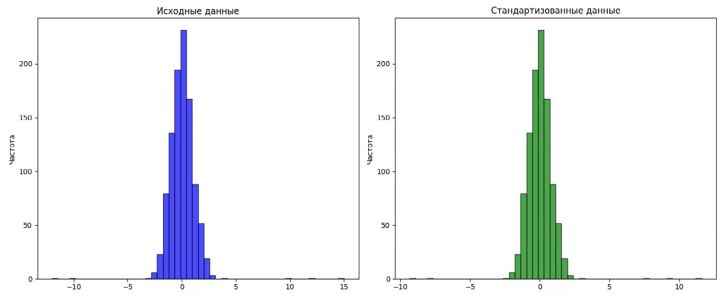
Г. Использование T-тестов вместо Z-тестов

Решение:

Рассмотрим каждый вариант ответов.

А. Удаление 20% значений без уточнения конкретного способа выбора этих 20% никак не повлияет на распределение данных и не поможет бороться с выбросами. Этот вариант ответа не верен.

Б. Стандартизация данных влияет на масштаб данных, но не помогает бороться с выборосами, например как на картинке ниже:



Соответственно вариант Б не верен.

В. Удаление значений, которые отклоняются сильнее чем 1,5 × IQR — это стандартный метод борьбы с выбросами, так как позволяет найти сильно отклоняющиеся значения от основной масса данных. Этот ответ верен.

Г. Z-тест, также как и t-тест чувствительны к выбросами, выбор между этими статистическими методами определяется знанием дисперсии генеральной совокупности, а не наличием выбросов в данных.

Ответ: В — Удаление значений, которые отклоняются сильнее чем 1,5 × IQR.

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ

Т БАНК

Разбор вопросов

№ 1

Лара Крофт исследует древние храмы, где 80% ловушек срабатывают в помещениях с мозаикой на полу, а 20% срабатывают в помещениях без мозаики. Известно, что в этих храмах мозаика встречается в 30% помещений. Какой вывод верен?

а) Вероятность встретить ловушку в комнате с мозаикой выше, чем в комнатах без мозаики

б) Ловушки не размещают в комнатах без мозаики

в) Наличие мозаики не влияет на вероятность нахождения ловушки

г) Данных недостаточно

Разбор задачи:

Согласно условию:

P(срабатывание | мозаика) = 0.8

P(срабатывание | нет мозаики) = 0.2

P(мозаика) = 0.3

Проверка утверждений:

а) Вероятность встретить ловушку в комнате с мозаикой выше, чем в комнатах без мозаики

Сравниваем условные вероятности:

P(срабатывание | мозаика) = 0.8

P(срабатывание | нет мозаики) = 0.2

0.8 > 0.2 —> утверждение верно.

б) Ловушки не размещают в комнатах без мозаики

Это означало бы P(срабатывание | нет мозаики) = 0, но по условию она равна 0.2 —> ловушки есть —> утверждение неверно.

в) Наличие мозаики не влияет на вероятность нахождения ловушки

Если бы не влияло, P(срабатывание | мозаика) ≠ P(срабатывание | нет мозаики).

Но эти вероятности по условию не равны, значит, утверждение неверно.

г) Данных недостаточно

Для ответа на вопрос данных достаточно

Ответ: а № 2

В музее хранились только подлинные предметы. Воры украли некоторые экспонаты и заменили их фальшивыми. После кражи 90% от всех золотых предметов остались подлинными, а 20% от всех керамических предметов — фальшивыми.

Изначально в музее хранились только золотые и керамические предметы, причем золотых предметов было в 3 раза больше, чем керамических.

Какая доля музейных экспонатов оказалась фальшивой? Ответ запишите в процентах и округлите до десятых.

Разбор задачи:

Введем переменные. Пусть x — количество керамических предметов.
Тогда золотых предметов — 3x.

Общее количество предметов: 3x + x = 4x.

Найдем количество фальшивых предметов:

Фальшивых золотых: 10% от 3x = 0.1 * 3x = 0.3x.

Фальшивых керамических: 20% от x = 0.2 * x = 0.2x.

Общее количество фальшивых: 0.3x + 0.2x = 0.5x.

Найдем долю фальшивых от общего числа:

Доля = (Количество фальшивых) / (Общее количество) = (0.5x) / (4x) = 0.5 / 4 = 0.125 = 12.5%.

Ответ: 12.5%

№ 3

Лара взламывает сейф с украденными артефактами. Она знает:

- пароль к сейфу состоит из четырех цифр (от 0 до 9);
- для него используются только четные цифры, ни одна из них не встречается дважды, а сумма первых двух цифр равна сумме последних двух.

Сколько возможных комбинаций у такого замка?

Разбор задачи:

Всего чётных цифр 5. Нужно отобрать такие числа, которые давали бы одинаковые

суммы и при этом не повторялись. Методом перебора получим, что одинаковые суммы из разных чисел дают следующие пары:

- 0 и 6, 2 и 4
- 0 и 8, 2 и 6
- 2 и 8, 4 и 6

Каждая пара дает 8 комбинаций. На примере первой пары:

- 0624
- 6024
- 0642
- 6042
- 2406
- 2460
- 4206
- 4260

Аналогично для других наборов чисел. Так как возможных вариантов наборов чисел всего три, то общее количество комбинаций будет 8x3 = 24

Ответ: 24

№ 4

В банке работают три независимые команды аналитиков по 50 человек.
Среди сотрудников каждой команды 20% — стажеры, 30% — начинающие сотрудники и 50% — опытные аналитики. Стажер выполняет одну задачу за час, начинающий сотрудник — за 45 минут, опытный сотрудник — за полчаса. Коллеги могут делить задачи между собой, то есть каждому сотруднику может быть поручено выполнение не только целой задачи (нескольких целых задач), но и частей каких-то задач (например, половины задачи или десятой части задачи и т. д.).

Рабочий день каждой команды начинается, когда все сотрудники одномоментно приступают к выполнению своих задач, при этом они работают одновременно, без перерывов, и рабочий день команды считается законченным, когда последний сотрудник выполнит свою последнюю задачу.

В первой команде все задачи распределяются равномерно между всеми сотрудниками — чтобы все сделали равное число задач.

Во второй команде каждый опытный сотрудник выполняет по 6 задач, а оставшиеся задачи делятся равномерно между оставшимися сотрудниками.

В третьей команде задачи распределяются так, чтобы все сотрудники закончили выполнять свои задачи одновременно.

Сегодня каждой команде поступило 200 задач. Сколько часов будет длиться рабочий день каждой команды? Ответ запишите через точку с запятой в порядке возрастания

номеров команд.

Разбор задачи:

Команда 1: Равномерное распределение

Время работы будет определяться самым медленным сотрудником, то есть стажером. При этом каждый сотрудник, в том числе стажер, получит 200/50 = 4 задачи. При скорости 1 задача в час стажер выполнит 4 задачи за 4 часа.

Команда 2: Опытные — по 6 задач, остальное — поровну другим

Количество опытных работников в команде составляет 50% от 50 человек, следовательно, в команде 50*50% = 25 опытных сотрудников. Им достанется 25*6 = 150 задач, остальные 50 задач распределятся равномерно между оставшимися 25 сотрудниками. Следовательно, все начинающие сотрудники и стажеры получат по 2 задачи. Время работы в этой группе сотрудников также будет определяться самым медленным сотрудником. Стажер в этой команде сделает две задачи за два часа.

При этом опытным сотрудникам на 6 задач понадобится 6*0.5ч = 3 часа. Значит, рабочий день команды будет длиться 3 часа.

Команда 3: Все заканчивают одновременно

За час опытный сотрудник выполнит 2 задачи, начинающий - 4/3 задачи, стажёр - 1 задачу. Значит, при полной загрузке (чтобы никто не простаивал) 50 человек, из которых 10 стажёров, 15 начинающих и 25 опытных, за час способны выполнить: 2 * 25 + 4/3 * 15 + 1 * 10 = 80 задач.

На 200 задач у них уйдёт 200/80 = 2.5 часа.

Ответ: 4; 3; 2.5

№ 5

Учительница собрала данные о времени, которое ученики 10-го класса тратят на выполнение домашнего задания по математике (в минутах). Гистограмма по этим данным показала, что распределение времени совпадает с нормальным. Среднее значение — 60 минут, стандартное отклонение — 15 минут.

Какова вероятность, что случайно выбранный ученик тратит на домашнее задание больше 75 минут?

а) 0

б) ~0.03

в) ~0.16

г) ~0.32

Если учительница 50 раз подряд возьмет 25 случайных учеников и усреднит их время выполнения домашнего задания по математике, то как будет распределено среднее значение?

а) Нормально с $\mu = 60$, $\sigma = 15$

б) Нормально с $\mu = 60$, $\sigma = 3$

в) Равномерно

г) Экспоненциально

Учительница также собрала данные о времени выполнения домашнего задания по обществознанию. Оказалось, все ученики тратят на домашнее задание от 10 до 20 минут и любое время в этом интервале равновероятно. Какое это распределение?

а) Нормальное

б) Равномерное

в) Экспоненциальное

г) Биномиальное

Разбор задачи:

Стандартное отклонение (σ) — это мера «разброса» данных вокруг среднего. В нашей задаче это значение уже дано — 15 минут.

68% всех данных лежат в пределах одного стандартного отклонения от среднего, значит 68% учеников тратят на домашнюю работу [60– 15; 60 + 15] = [45; 75] —> от 45 до 75 минут.

Так как распределение симметрично, оставшиеся 100% – 68% = 32% учеников делятся поровну между двумя «хвостам» колокола:

Левый хвост (те, кто делает быстрее 45 минут) — ≈16.6%.

Правый хвост (те, кто делает дольше 75 минут) — ≈16.6%.

Среднее будет равно 60, σ считается по формуле (σ/sqrt(n))

$\sigma = 15 / \text{sqrt}(25) = 15/5 = 3$

Равную вероятность на любом участке интервала имеет только равномерное распределение

Ответ: в; б; б

№ 6

В задаче идентификации рака важно не пропустить больных.

Модель может выдавать следующие результаты:

- True Positive (TP) — пациент болен, модель правильно это определила.
- True Negative (TN) — пациент здоров, и модель это подтвердила.
- False Negative (FN) — пациент болен, но модель пропустила болезнь.
- False Positive (FP) — пациент здоров, но модель ошибочно определила, что он болен.

С помощью этих результатов можно посчитать следующие метрики:

- Accuracy — общая доля верных прогнозов (TP + TN) / (TP + TN + FP + FN).
- Recall — доля верно обнаруженных реальных больных TP / (TP + FN).
- Precision — доля истинно положительных срабатываний TP / (TP + FP).
- F1-score — гармоническое среднее между Recall и Precision 2 × ((Precision × Recall) / (Precision + Recall)).

Какую метрику нужно оптимизировать?

а) Accuracy

б) Recall

в) Precision

г) F1-score

Разбор задачи:

По условию задачи нам необходимо минимизировать False Negative. Именно Recall напрямую показывает, насколько хорошо модель находит всех больных, минимизируя пропуски (FN).

Ответ: б

№ 7

В задаче рекомендации фильмов важно предлагать пользователям только те фильмы, что им действительно понравятся.

Модель может выдавать следующие результаты:

- True Positive (TP) — фильм пользователю понравится, и модель правильно это предсказала (рекомендовала его).
- True Negative (TN) — фильм пользователю не понравится, и модель правильно это предсказала (не рекомендовала его).
- False Negative (FN) — фильм пользователю понравится, но модель ошиблась и не рекомендовала его (упущенная возможность).
- False Positive (FP) — фильм пользователю не понравится, но модель ошиблась и рекомендовала его (неудачная рекомендация).

С помощью этих результатов можно посчитать следующие метрики:

- Accuracy — общая доля верных прогнозов (TP + TN) / (TP + TN + FP + FN).
- Recall — доля понравившихся пользователю фильмов, которые модель смогла обнаружить и рекомендовать TP / (TP + FN).
- Precision — доля удачных рекомендаций среди всех рекомендованных моделью фильмов TP / (TP + FP).
- F1-score — гармоническое среднее между Precision и Recall. 2 × ((Precision × Recall) /

(Precision + Recall)).

Значения параметров модели: FP = 50, FN = 30, TP = 70, TN = 150. Чему равен Accuracy? Ответ округлите до сотых.

Разбор задачи:

Подставим значения в формулу Accuracy (TP + TN) / (TP + TN + FP + FN):

(70 + 150) / (50 +30 + 70 + 150) = 220 / 300 = 0.7333

Округлив это значение до сотых, получим 0.73

Ответ: 0.73

№ 8

Тимлид руководит коллективом из 50 человек: ежедневно он раздает всем сотрудникам одинаковое количество сопоставимых по сложности задач. Эти задачи необходимо выполнить до конца рабочего дня, если сотрудник заканчивает выполнение задач раньше — он может уйти домой, время окончания работы над задачами фиксируется. Тимлид решил проверить, что влияет на продуктивность его сотрудников. Он собрал данные за один день работы всех его сотрудников:

- hours — время в часах, за которое были выполнены все задачи (чем быстрее были выполнены задачи, тем продуктивнее сотрудник), зависимая переменная.
- age — возраст.
- gender — пол сотрудника (gender = 1 для мужчин, gender = 0 для женщин).
- experience — опыт работы в годах.
- coffee — количество перерывов на кофе за день.
- friend — присутствие друга за соседним рабочим столом (friend = 1, если рядом сидит друг; friend = 0, если рядом сидит просто коллега, а не друг).

По собранным данным тимлид оценил линейную регрессию с hours в качестве зависимой переменной и собрал результаты в таблицу. Все коэффициенты оказались статистически значимыми.

Переменная	**Оценка коэффициента**
age	-0.7
age^2	0.01
gender	-1.5
experience	-0.1
coffee	0.25
friend	2.1

gender * friend	-0.7
constant	5.2

Заполните пропуски или выберите верные варианты в утверждениях о коллективе тимлида, которые следуют из результатов оцененной им регрессии (каждый вывод ниже делается при прочих равных, то есть в предположении неизменных остальных переменных):

A. _____ лет — это возраст, при котором сотрудники наиболее продуктивны

B. Более высокую производительностью показывают мужчины / женщины

C. Каждый дополнительный год опыта позволяет сотруднику выполнять задачи на _____ минут / минуты быстрее

D. Каждый дополнительный перерыв на кофе увеличивает время выполнения задач на _____ минут / минуты

E. Если рабочее место сотрудника находится рядом с другом, то его продуктивность увеличивается / уменьшается

F. Присутствие друга рядом сильнее / слабее влияет на продуктивность женщин, чем на продуктивность мужчин

Разбор задачи:

Зависимость от возраста — квадратичная (в регрессии есть и возраст, и его квадрат), она выглядит как парабола ветвями вверх. Минимальные затраты времени (= максимальная продуктивность) достигаются в вершине параболы:
в 0.7 / 0.02 = 35 лет.

При прочих равных, мужчина тратит на выполнение задач на 1.5 часа меньше, чем женщина. Значит, мужчины более производительны.

Каждый дополнительный год опыта уменьшает время выполнения на 0.1 часа = на 6 минут.

Каждый дополнительный перерыв на кофе увеличивает время выполнения на 0.25 часа = на 15 минут.

Присутствие друга увеличивает время выполнения задач — значит, продуктивность из-за присутствия друга уменьшается.

Присутствие друга увеличивает время выполнения задач на 2.1 – 0.7 * gender, то есть, на 2.1 для женщин и на 1.4 - для мужчин. Значит, на продуктивность женщин присутствие рядом друга влияет сильнее.

Ответ: A. 35; B. Мужчины; C. 6; D. 15; E. уменьшается ; F. сильнее

№ 9

Продажи обогревателей зимой в 3 раза выше, чем летом. Это пример:

а) Тренда

б) Сезонности

в) Шума

г) Аномалии

Разбор задачи:

Разберем каждый из терминов:

Тренд — это долгосрочное устойчивое направление изменения (рост или падение) данных. Не подходит, так как изменение является неустойчивым, зависит от сезона

Сезонность — регулярные и предсказуемые колебания, которые повторяются с фиксированным периодом (например, ежегодно). Верный ответ

Шум — случайные, несистематические колебания данных. Не подходит, так как такие колебания неслучайны

Аномалия — редкое, резкое отклонение от обычной модели данных. Для этого примера не подойдет, так как это стабильное и предсказуемое изменение

Ответ: б

№ 10

Зоопарк хочет оптимизировать закупку корма для животных. Вам нужно собрать модель, которая предсказывает необходимую суточную порцию корма (в кг) для животного на основе его характеристик.

В вашем распоряжении есть датасет со следующими признаками:

- weight — вес животного (в кг).
- age — возраст животного (в годах).
- activity_level — уровень активности (категориальный признак: 1 — низкий, 2 — средний, 3 — высокий).
- metabolic_rate — уровень метаболизма (категориальный признак: 1 — низкий, 2 — средний, 3 — высокий).
- ambient_temperature — средняя температура в вольере (в °C).
- Целевая переменная daily_food_intake — суточная норма корма (в кг).

Вы построили линейную регрессию на данных о млекопитающих и получили следующие коэффициенты:

- intercept (свободный член) = 0.5.
- Коэффициент для weight = 0.02.
- Коэффициент для age = –0.1.
- Коэффициент для activity_level = 0.3.

- Коэффициент для metabolic_rate = 0.4.
- Коэффициент для ambient_temperature = –0.05.

Разбор задачи:

Вопрос 1. Какую суточную норму корма (в кг) предскажет модель для молодого леопарда со следующими параметрами? Ответ округлите до сотых.

weight = 50 кг

age = 2 года

activity_level = 3 (высокий)

metabolic_rate = 3 (высокий)

ambient_temperature = 25 °C

Отдел закупок должен заказать корм на месяц (30 дней) для этого леопарда, основываясь на прогнозе модели. Известно, что модель на тестовых дневных данных давала прогнозы с MSE = 0.25.

Чтобы избежать ситуации нехватки корма, отдел закупок решил заказать количество корма, которое с вероятностью 95% покроет потребности животного с учетом погрешности модели.

Вопрос 2. Какой минимальный запас корма (в кг) необходимо заказать, если за основу взять типичную величину ошибки прогноза? Учтите, что заказывать можно только целое число килограммов корма. Распределение расходов корма считайте нормальным, ошибки в разные дни независимы.

Для ответа на первый вопрос подставим данные в условии значения в формулу:

daily_food_intake = 0.5 + 0.02*50 + (–0.1)*2 + 0.3*3 + 0.4*3 + (–0.05)*25=0.5 + 1.0 – 0.2 + 0.9 + 1.2 – 1.25 = 2.15

Чтобы ответить на второй вопрос, нужно выполнить следующие шаги:

1. Посчитать среднее суммарное потребление за 30 дней:

   Mean_total = 30 * 2.15 = 64.5 кг

2. Найти стандартную ошибку прогноза на один день:

   RMSE = sqrt(MSE) = sqrt(0.25) = 0.5 кг

3. Найти стандартную ошибку суммарного потребления за 30 дней. Поскольку ошибки независимы, дисперсии суммируются:

   Variance_total = 30 * (0.5)^2 = 30 * 0.25 = 7.5

   SD_total = sqrt(Variance) = sqrt(7.5) ≈ 2.7386 кг

4. Найти запас с учетом погрешности:

   Z-значение для 95% вероятности ≈ 1.645 (односторонний квантиль нормального распределения)

Total_food = Mean_total + z * SD_total

Total_food = 64.5 + 1.645 * 2.7386 ≈ 64.5 + 4.505 ≈ 69.005 кг

Так как мы можем заказывать только целое число килограммов, то это значение нужно округлить вверх. При округлении вниз вероятность покрыть потребности леопарда будет меньше 95%, и условие не выполнится.

Ответ: 2.15; 70

№ 11

Интернет-магазин хочет предсказать время выполнения заказа (в минутах) от момента оформления до момента доставки. В распоряжении есть исторические данные.

Признаки:

- product_count — количество товаров в заказе (шт.).
- distance — расстояние до клиента (км).
- is_weekend — выходной день (0 — нет, 1 — да).

Целевая переменная: delivery_time — время выполнения заказа (минуты).

После построения линейной регрессии получилось следующее уравнение:

delivery_time = 17 + 2,3 × product_count + 7 × distance + 14 × is_weekend

Как интерпретировать коэффициент 7 для признака distance, если все коэффициенты значимы на 5% уровне значимости?

а) Расстояние определяет 7% времени доставки

б) При увеличении расстояния на 7 км время доставки увеличивается в среднем на 1 минуту

в) При увеличении расстояния на 1 км время доставки увеличивается в среднем на 7 минут

г) При увеличении расстояния в четыре раза время доставки увеличится в двадцать восемь раз

Разбор задачи:

а) Неверно. Коэффициент 7 не является процентом.

б) Неверно. Это обратная интерпретация. Коэффициент 7 означает, что при увеличении расстояния на 1 км время увеличивается на 7 минут, а не наоборот.

в) Верно. При увеличении расстояния на 1 км время доставки увеличивается в среднем на 7 минут (при прочих равных условиях).

г) Неверно. Модель линейная, поэтому при увеличении расстояния в 4 раза, время доставки увеличится на 7 * 4 = 28 минут, а не в 28 раз.

Ответ: В № 12

Магазин тестирует скидки:

А. 5%: +10% продаж.

Б. 10%: +25% продаж.

В. 15%: +30% продаж.

Какая скидка дает максимальную прибыль, если наценка — 300%?

Разбор задачи:

Нужно для каждого варианта скидки найти итоговую прибыль. Если наценка равна 300%, значит, себестоимость = 1, а полная цена товара: 1+3 = 4.

Прибыль без скидки с одной единицы: 4 – 1 = 3.

Общая формула прибыли на единицу:

Прибыль = (Цена со скидкой - Себестоимость) × Рост продаж

1. Скидка 5%:

   Цена со скидкой: 4 × 0.95 = 3.8

   Прибыль с 1 шт.: 3.8 – 1 = 2.8

   Рост продаж: 1.1

   Относительная прибыль: 2.8 × 1.1 = 3.08

2. Скидка 10%:

   Цена со скидкой: 4 × 0.9 = 3.6

   Прибыль с 1 шт.: 3.6 – 1 = 2.6

   Рост продаж: 1.25

   Относительная прибыль: 2.6 × 1.25 = 3.25

3. Скидка 15%:

   Цена со скидкой: 4 × 0.85 = 3.4

   Прибыль с 1 шт.: 3.4 – 1 = 2.4

   Рост продаж: 1.3

   Относительная прибыль: 2.4 × 1.3 = 3.12

Скидка 10% дает наибольшую относительную прибыль, значит следует выбрать ее.

Ответ: Б

№ 13

Университет собрал данные об обучении за последний семестр:

- Student_id — ID студента.
- Gender — пол студента.
- Type — тип обучения (local / exchange).
- Age — возраст студента.
- Department — направление обучения.
- Attendance — посещаемость (в %).
- Total_Score — общий балл.
- Grade — оценка.
- Study_Hours_per_Week — среднее количество часов обучения в неделю.
- Scholarship — стипендия (да/нет).
- Sleep_Hours_per_Night — среднее количество часов сна.

Различается ли общий балл у студентов между местными студентами и студентами, приехавшими учиться по обмену? Рассчитайте модуль разницы средних и напишите, является ли она статистически значимой.

Различается ли доля студентов со стипендией между местными студентами и студентами, приехавшими учиться по обмену? Рассчитайте модуль разницы долей и напишите, является ли она статистически значимой.

Для всех вопросов $\alpha = 0.05$. Ответ округлите до сотых.

Разбор задачи:

Для ответа на первый вопрос нужно для начала разделить группы студентов на отдельный таблицы: в одной таблице будут местные студенты, в другой — студенты, приехавшие учиться по обмену. Затем найти средние значения с помощью формулы СРЗНАЧ. Либо изначально использовать СРЗНАЧЕСЛИ, и в условии к каждой группе использовать значения колонки Type.

Модуль разницы между этими значениями составляет 0.04.

Чтобы найти разницу доли студентов со стипендией и без между указанными группами, нужно определить долю студентов со стипендией в каждой группе. Это можно сделать функцией СЧЁТЕСЛИ/СЧЁТ, либо преобразовать значения в столбце Scholarship в 1/0 и найти среднее значение.

Модуль разницы между этими значениями также составит 0.04

Определить статзначимость можно с помощью функции ТТЕСТ на подготовленном датасете. При значении менее 0.05 (данный в условии уровень значимости) результат будет являться статистически значимым. При значении p value более 0.05 результат будет статистически незначимым.

Результат будет статзначимым для первого вопроса и нестатзначимым для второго вопроса.

Ответ: 0.04; нет; 0.04; да

№ 14

Перед вами график мировых цен на сахар. Соотнесите возможные события с отмеченными точками на графике, которые могли стать причиной такого движения цены.



1. 2021	а) Опасения по поводу сокращения производства в Бразилии
2. 2023	б) Богатый урожай в основных странах-изготовителях
3. 2025	в) Запрет экспорта на сахар из Индии — второго по величине экспортера сахара

Разбор задачи:

У нас на графике есть два участка с ростом цены (1 и 2) и один с падением (3). Разберем возможное влияние каждого события. Событие а) влияет на рост спроса, а следовательно, повышение цены. Событие б) влечет за собой рост предложения, а следовательно снижение цены. Событие в) сокращает предложение, и, следовательно, повышает цену на рынке.

Таким образом, у нас однозначно складывается пара 3б. Осталось разобраться, какое из событий влияет на цену сильнее. Здесь можно рассуждать следующими способами:

1. В одном случае у нас описываются опасения, а в другом фактический запрет. Реальные мировые изменения, предположительно, больше повлияют на мировые цены, чем слухи и опасения
2. При поиске новостей про экспорт сахара из Индии можно найти дату этого запрета, которая и укажет на нужный нам период — 2023

Ответ: 1а, 2в, 3б

№ 15

Вам представлен набор данных о кассовых сборах фильмов, а также дополнительная информация о каждом фильме. Кинокомпании используют такие данные для прогнозирования успеха новых проектов. В заданиях ниже вам предстоит исследовать взаимосвязь между различными факторами. *(датасет в папке)*

1. Рассчитайте следующие показатели для фильмов, произведенных в Канаде:
   - Медианный бюджет фильмов.
   - Средний рейтинг фильмов и стандартное отклонение. Ответ округлите до сотых.
   - Доля прибыльных фильмов (gross > budget) в группе с бюджетом ниже медианы. Ответ округлите до процентов (0.174096 → 17). В расчет берите только фильмы, у которых есть оба показателя.
   - Компания с наибольшей средней прибылью на фильм. Прибыль можно рассчитать, только если есть данные и по бюджету, и по сборам.
2. Выполните корреляционный анализ для фильмов, произведенных в Канаде. Рассчитайте:
   - Коэффициент корреляции между бюджетом и сборами.
   - Коэффициент корреляции между рейтингом и прибылью.

Разбор задачи:

Ключевым шагом здесь будет собрать в новую таблицу только фильмы, которые относятся к указанной стране, иначе формулы, даже при активном фильтре, будут учитывать все значения таблицы.

- Медиану ищем с помощью формулы МЕДИАНА
- Средний рейтинг и стандартное отклонение — с помощью формул СРЗНАЧ и СТАНДОТКЛОН
- Чтобы найти долю прибыльных фильмов, нужно:
  a. Посчитать прибыль каждого фильма, причем учесть, что обе переменные непустые
  b. Найти количество прибыльных фильмов с помощью функции СЧЁТЕСЛИМН. Условия внутри формулы должны проверять, что бюджет фильма ниже найденной в первом пункте медианы, поле budget непустое, поле gross непустое, поле profit (gross-budget) больше нуля
  c. Найти количество всех фильмов с помощью функции СЧЁТЕСЛИМН. Условия внутри формулы должны проверять, что бюджет фильма ниже найденной в первом пункте медианы, поле budget непустое, поле gross непустое
  d. Разделить пункт b на пункт c
- Компанию с наибольшей прибылью ищем с помощью СРЗНАЧЕСЛИМН, где проверяем, что поле budget непустое, поле gross непустое, и что фильмы выпущены именно этой компанией. Среди полученных значений найти максимум и найти компанию, которой принадлежит максимальное значение

- Корреляцию можно найти с помощью формулы КОРРЕЛ

Ответ: 14000000; 6.13; 0.98; 55%; Twentieth Century Fox; 0.39; 0.17

№ 16

Вы разрабатываете модель для автоматической модерации комментариев на платформе. Модель должна уметь:

- Находить все оскорбительные сообщения (минимизировать пропуски).
- Не блокировать нормальные комментарии (минимизировать ложные срабатывания).

Для вас протестировали три модели с разными характеристиками:

Модель	**TP (Заблокировано оскорбительных)**	**FP (Заблокировано нейтральных)**	**TN (Пропущено нейтральных)**	**FN (Пропущено оскорбительных)**
А	241	95	858	43
Б	270	238	715	14
В	199	29	924	85

1. Какую модель следует выбрать для детской платформы, если более важно минимизировать количество оскорбительных комментариев?
2. Какую модель следует выбрать для соцсети, если нужно минимизировать число жалоб и известно, что:
   - Каждая ложная блокировка (FP) приводит к 1 жалобе пользователя.
   - Каждый пропущенный оскорбительный комментарий (FN) — к 3 жалобам.

Разбор задачи:

В условии сказано, что нам нужно минимизировать количество оскорбительных комментариев, значит, нужно минимизировать пропуски оскорблений, то есть FN.

Считаем долю FN для каждой модели:

Модель А: FN = 43 / 1237 = 0,0348

Модель Б: FN = 14 / 1237 = 0,0113

Модель В: FN = 85 / 1237 = 0,0687

Наименьшая доля пропусков оскорбительных комментариев у модели Б

При выборе модели для соцсети нам нужно минимизировать число жалоб на блокировки, причем каждый FP дает 1 жалобу, каждый FN дает 3 жалобы.

Общие жалобы = 1 * FP + 3 * FN

Считаем для каждой модели:

Модель А: (1*95 + 3*43) / 1237 = (95 + 129) / 1237 = 0,181 жалоб / пользователя

Модель Б: (1*238 + 3*14) / 1237 = (238 + 42) / 1237 = 0,226 жалоб / пользователя

Модель В: (1*29 + 3*85) / 1237 = (29 + 255) / 1237 = 0,2296 жалоб / пользователя

Наименьшее число жалоб у модели А

Ответ: Б; А

№ 17

Вам предоставлен датасет с логами действий пользователей в мобильном приложении.

Выделите сессии пользователя по правилу: если более 30 минут не было никаких действий, то создается новая сессия. Для каждого пользователя пронумеруйте сессии, используя это правило.

Найдите пользователя с максимальным числом сессий. В ответе запишите ID пользователя.

Разбор задачи:

Сначала нужно преобразовать поле с датой и временем. Для этого можно воспользоваться функциями ЛЕВСИМВ, ПРАВСИМВ и их комбинациями, чтобы достать год, месяц, день, часы, минуты и секунды события.

Затем отсортировать таблицу по юзеру и дате-времени логов юзера. Для каждого юзера пронумеровать сессии, проверяя разницу времени между новым событием и предыдущим событием. Если разница больше 30 минут, то прибавляем единицу к текущему количеству сессий.

После этого находим максимальное количество сессий на клиента (в этой задаче самое большое количество сессий - 8), и найти юзера, которому принадлежит это количество сессий. Это будет пользователь с id 44686.

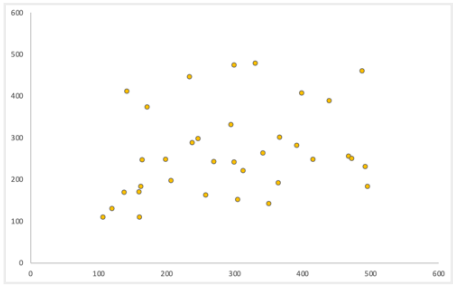
Ответ: 44686

№ 18

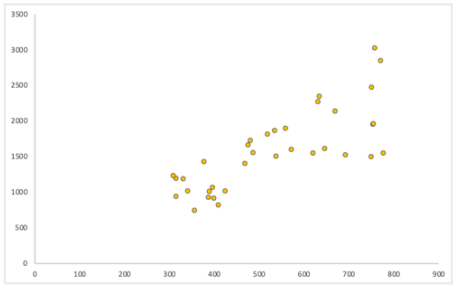
Соотнесите коэффициент корреляции и диаграмму рассеяния.

1. –0.97
2. 0.26
3. –0.12
4. 0.72

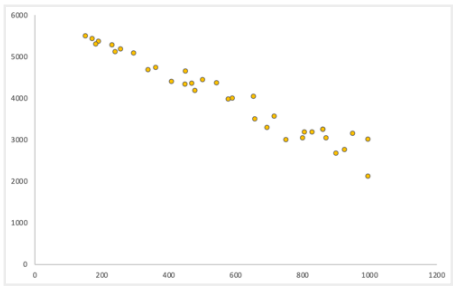
А)



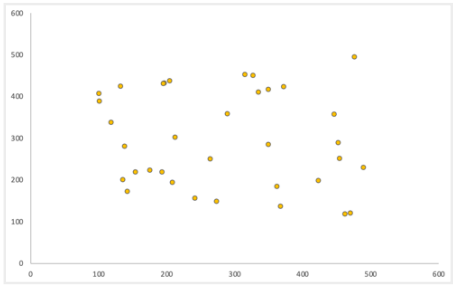
Б)



В)



Г)



Разбор задачи:

Чтобы соотнести график и коэффициент корреляции, нужно учитывать следующие особенности:

- Положительная корреляция имеет положительный наклон
- Чем коэффициент корреляции ближе к единице, тем более кучно расположены точки

Таким образом, коэффициенты 2 и 3 нам нужно распределить между А и Г, при этом на графике А общий наклон положительный, а на графике Г — отрицательный.

Коэффициенты 1 и 4 нужно распределить между графиками Б и В, при этом прямая на графике В имеет отрицательный наклон, а на графике Б — положительный

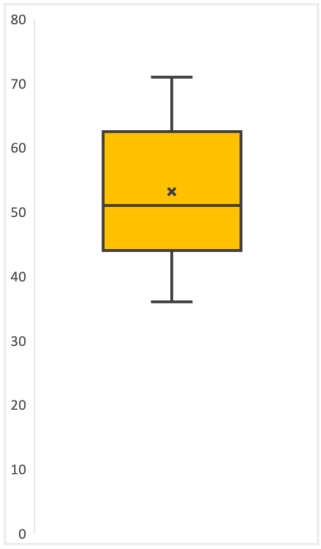
Ответ: 1В 2А 3Г 4Б

№ 19

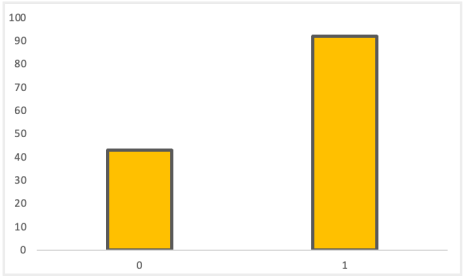
Вы редактировали журнал «Наглядная статистика» и обнаружили, что заголовки явно не соответствуют графикам. Соотнесите график и его правильный заголовок:

1. Средний чек в театре
2. Распределение школьников по итогам тура олимпиады (прошел в финал / не прошел в финал)
3. Стоимость загородного дома (в млн рублей) в зависимости от его площади
4. Вес учащихся 9 класса

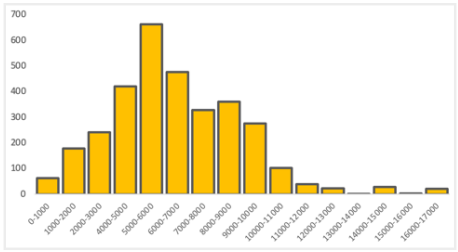
А)



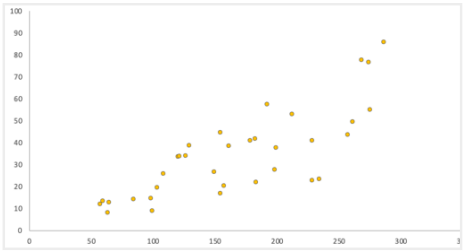
В)



Б)



Г)



Разбор задачи:

Распределим названия графиков между графиками.

1. Средний чек в театре — график А не подходит из-за низкий значений для стоимости билета в театр. Под такое описание подходят графики Б и Г.
   Посмотрим остальные пункты.

2. Распределение школьников по итогам тура олимпиады (прошел в финал / не прошел в финал) — биноминальное распределение, значит, нам подходит только график В
3. Стоимость загородного дома (в млн рублей) в зависимости от его площади. В теории мог бы подойти и график А, и график Г. Посмотрим на оставшийся пункт, чтобы методом исключения распределить оставшиеся пункты
4. Вес учащихся 9 класса — учитывая подписи осей, нам подходит только график А. Значения на графике Б слишком большие для килограммов и слишком маленькие для граммов, аналогично не подходят значения на графике Г.

Значит, для стоимости загородного дома остается Г, а для среднего чека — Б. Значения на этих график совпадают с реалистичными представлениями о распределении данных.

Ответ: 1Б 2В 3Г 4А

№ 20

В парке развлечений два самых популярных аттракциона — «Космическая гонка» и «Супергигант». Они абсолютно одинаковы по своим характеристикам (спрос, время ожидания, длина очереди и т. д.). Цена билета на каждый — 250 ₽ в любое время. Среднее число посетителей в месяц — 12 000 на каждый аттракцион.

Если клиенты попадают на аттракцион во время пиковой нагрузки, им приходится ждать в очереди 80 минут. Обычное время ожидания — 20 минут.

Распределение посещаемости на каждом аттракционе выглядит так:

- Пиковая нагрузка (30% времени): 5 000 посетителей.
- Обычное время (70% времени): 7 000 посетителей.

Чтобы оптимизировать доход и управлять спросом, администрация хочет сравнить две стратегии ценообразования:

- «Космическая гонка» — фиксированный повышенный тариф (400 ₽ всегда).
- «Супергигант» — динамический тариф: обычное время — 300 ₽, час пик — 500 ₽.

Если время ожидания превышает 60 минут, парк выдает клиенту ваучер на напиток стоимостью 100 ₽ и на хот-дог стоимостью 200 ₽, при этом вероятность приобретения напитка за ваучер — 90%, а хот-дога — 60%.

Показатель	**Было (250 ₽ всегда, «Космическая гонка» и «Супергигант» вместе)**	**«Космическая гонка» (400 ₽ всегда)**	**«Супергигант» (300/500 ₽)**
Цена в час пик	250	400	500
Цена в обычное время	250	400	300
Прокатившихся в час пик	10 000	4 700	4 200

Прокатившихся в обычное время	14 000	6 200	6 600
Среднее время ожидания (час пик)	80 мин., равномерно распределено от 60 до 100 мин.	60 мин., равномерно распределено от 40 до 80 мин.	40 мин., равномерно распределено от 20 до 60 мин.
Время ожидания (обычное время)	20 мин.	15 мин.	20 мин.

Если время ожидания превышает 60 минут, парк выдает клиенту ваучер на напиток стоимостью 100 ₽ и на хот-дог стоимостью 200 ₽, при этом вероятность приобретения напитка за ваучер — 90%, а хот-дога — 60%.

Вопрос 1. Какой вариант тарификации оптимальный с точки зрения дохода?

а) Динамический

б) Фиксированный повышенный

Сколько денег дополнительно получит парк по сравнению со старым тарифом, если внедрить его на оба аттракциона?

Анализ финансовой отчетности показал, что выручка от старого тарифа не покрывала ежемесячные фиксированные издержки на содержание аттракционов и парк терпел убытки. Оба новых тарифа позволяют выйти на положительный доход, но для администрации критически важно оставить конверсию в поездку максимальной.

За конверсию принимаем долю прокатившихся на аттракционах людей относительно спроса при старом тарифе.

Вопрос 2. Какой вариант новой тарификации следует выбрать для обоих аттракционов при уровне значимости 95%? Укажите вариант тарифа:

а) Фиксированный повышенный тариф

б) Динамический тариф

в) Разницы нет

Вопрос 3. А при уровне значимости 99%?

а) Фиксированный повышенный тариф

б) Динамический тариф

в) Разницы нет

Вопрос 4. Укажите Z статистику, используемую для принятия решения. Ответ округлите до сотых. При расчетах не округляйте промежуточные результаты до получения финального ответа.

Разбор задачи:

Вопрос 1. Посчитаем прибыль по каждому из тарифов:

Старый тариф (250₽ всегда)

Выручка с билетов:

(10 000 чел. + 14 000 чел.) × 250 = 6 000 000 ₽

Затраты на ваучеры:

Напиток: 100 ₽ × 90% = 90 ₽

Хот-дог: 200 ₽ × 60% = 120 ₽

Итого: 210 ₽ на человека, которому выдали ваучер.

Время ожидания в пик: равномерно от 60 до 100 мин, значит, все клиенты в час пик получат ваучеры

10 000 чел. × 210 = 2 100 000 ₽

Общая прибыль: 3 900 000 ₽

Фиксированный повышенный (400 ₽ всегда)

Выручка с билетов:

(4 700 чел + 6 200 чел.). × 400 = 4 360 000 ₽

Затраты на ваучеры:

Время ожидания в пик: равномерно от 40 до 80 мин, значит, половина клиентов в час пик получит ваучеры

(4 700 чел / 2) × 210 = 2 350 × 210 = 493 500 ₽

Прибыль с аттракциона: 3 866 500 ₽

Динамический (пик 500 ₽, обычное 300 ₽)

Выручка с билетов:

4 200 чел. × 500 + 6 600 чел. × 300 = 2 100 000 ₽ + 1 980 000 ₽

Затрат на ваучеры в этом случае нет.

Прибыль с аттракциона будет составлять 4 080 000 ₽.

Динамический тариф дает максимальную прибыль из всех предложенных вариантов тарификации. При масштабировании этого тарифа на оба аттракциона парк будет получать 4 080 000 ₽ x 2 = 9 160 000 ₽

Разница между внедрением нового тарифа на оба аттракциона и старым тарифом составляет 9 160 000 ₽ - 3 900 000 ₽ = 4 260 000 ₽

Вопросы 2–4. Для ответа на эти вопросы нам нужно сравнить конверсии в двух вариантах новых тарифов.

При фиксированном повышенном тарифе на аттракционах прокатятся 10 900 человек из 12 000 максимально возможных. При динамическом тарифе аттракцион посетят 10 800 человек из максимально возможных 12 000. Рассчитаем Z значение для этих показателей по формуле:

(p1 – p2) / sqrt (p1*(1–p1) / N + p2*(1–p2) / N)

Получим Z значение равное 2.18.

Чтобы понять статистическую значимость, нужно сравнить полученное значение с числом из таблицы напротив соответствующего уровня значимости.

Критические значения Z:

95% уровень значимости (двусторонний 1,96) → Z > 1,96 → разница значима на уровне 95%

99% уровень значимости (двусторонний 2,576) → Z < 2,576 → разница незначима на уровне 99%

Получается, что в первом случае нужно оставить фиксированный тариф, так как он дает большую конверсию. Во втором случае разница между конверсиями не является статистически значимой, но при этом динамический тариф дает большую прибыль, следовательно, во втором случае стоит выбрать динамический тариф

Ответ: а; 4260000; а; б; 2.18/2.19

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ

Т БАНК

Задания

1. Про время ожидания транспорта

Вася добирается до школы в несколько этапов. Выходя из дома, он сразу оказывается у автобусной остановки и начинает ждать свой автобус. Зайдя в него, он ровно за 15 минут прибывает на станцию метро. Пересадка у Васи проходит мгновенно: он сразу спускается на перрон и начинает ждать поезд. Поезд везет его ровно 8 минут до станции возле школы. Оттуда Вася идет пешком 3 минуты — и вот он уже у дверей школы.

Вася давно наблюдает за расписанием и заметил закономерность: когда он подходит к остановке автобуса, то автобус приезжает равновероятно через 1, 2, 3, 4, 5, 6 или 7 минут. А когда Вася подходит к остановке поезда, тот приезжает равновероятно через 1, 2 или 3 минуты.

а) Найдите вероятность, что, подойдя к остановке автобуса сегодня, Вася будет ждать автобус не меньше 5 минут.

б) Найдите вероятность, что суммарное время ожидания транспорта у Васи сегодня будет не больше 4 минут.

в) Друг Васи Саша имеет очень точные часы, и он поделился с Васей, что на самом деле и автобус, и поезд приезжают не в целые минуты от ожидания, как посчитал Вася, а равновероятно в течение этого времени (то есть непрерывно в течение диапазона от 0 до 7 и от 0 до 3 минут соответственно). При этом остальные подсчеты Васи (про время пешком и на транспорте) оказались верны. Сегодня Вася дошел до автобусной остановки чуть позже обычного. Посчитайте, какова вероятность, что он успеет добраться до школы менее чем за 32 минуты.

Примечание: Для решения этой задачи не используйте интегралы, такие решения не будут засчитаны.

Решение:

1. 3 / 7
2. 6 / 21 = 2 / 7
3. x + 15 + y + 8 + 3 = 32

x+y = 6, следовательно y = 6 – x, рисуем график этой функции

Рисуем графики функций x = 7 и y = 3 — это ограничения по времени ожидания каждого из видов транспорта.

Считаем долю площади трапеции под y = 6 – x при ограничении y <= 3 от всего прямоугольника. Получаем 13,5 / 21 ~ 0,623.

2. Про регрессию и ее свойства

Вы исследуете влияние качества картографической прометки и навигации на рейтинг туристических маршрутов, чтобы подтвердить необходимость развития прометки для улучшения туристического опыта в регионе. Рейтинг туристических маршрутов — это усредненная оценка маршрута среди туристов, оставивших о нем отзыв. Качество картографической прометки и навигации — это обобщенный индекс, включающий наличие точек маршрута на общедоступных онлайн- и оффлайн-картах, наличие указателей по пути маршрута и опросов туристов на маршруте об удобстве и достаточности навигации.

В датасете, с которым вы будете работать, есть следующие переменные:

- map_quality — качество картографической прометки и навигации (далее — «Прометка»);
- landmarks_n — количество уникальных природных и искусственных достопримечательностей на маршруте («Достопримечательности»);
- rent_cost — средняя стоимость аренды жилья вдоль маршрута (тыс. руб./ночь) («Стоимость аренды»);
- route_rating — рейтинг туристического маршрута («Рейтинг»).

Выполните следующие задания по данному датасету.

1. Выполните предварительный анализ данных: постройте графики распределения для каждой переменной (прикрепите их к вашему решению), а также проанализируйте попарные связи между переменными (графически и численно, прикрепите результаты к решению). Какие из переменных наиболее вероятно влияют на исследуемую зависимую переменную и из чего следует этот вывод?
2. Оцените последовательно три регрессионные модели:

   Модель 1: $\text{Рейтинг} = \beta_0 + \beta_1 \cdot \text{Прометка} + \varepsilon$

   Модель 2: $\text{Рейтинг} = \beta_0 + \beta_1 \cdot \text{Прометка} + \beta_2 \cdot \text{Достопримечательности} + \varepsilon$

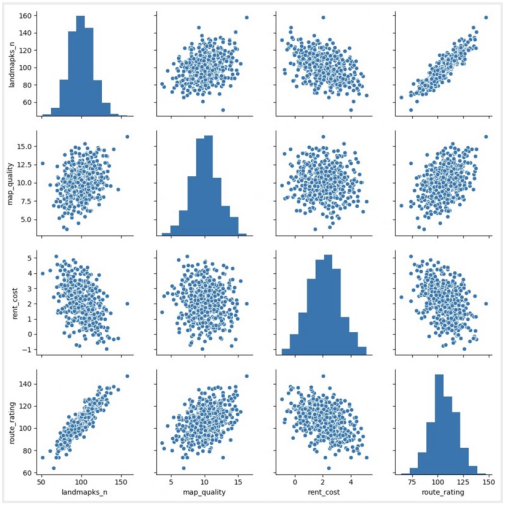
   Модель 3: $\text{Рейтинг} = \beta_0 + \beta_1 \cdot \text{Прометка} + \beta_2 \cdot \text{Достопримечательности} + \beta_3 \cdot \text{Стоимость аренды} + \varepsilon$

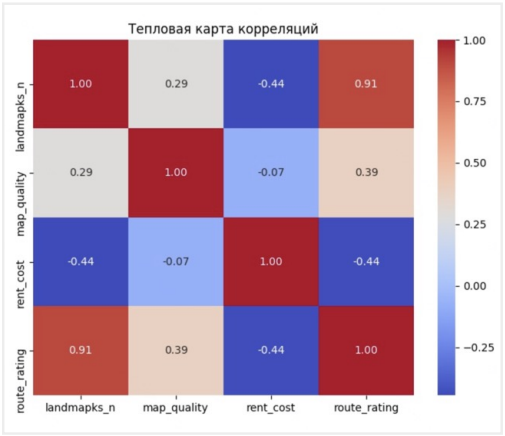
   Представьте результат в виде перечисления оцененных коэффициентов для каждой из моделей. Приведите также t-статистики и p-value, используемые для проверки значимости коэффициентов.
3. Прокомментируйте изменение коэффициентов b_0 и b_1 в трех моделях последовательно: почему значения этих коэффициентов изменяются именно таким образом?
4. Прокомментируйте изменение значения R^2 в трех последовательных моделях: почему значение R^2 изменяется именно таким образом?
5. Стандартизуйте исследуемые объясняющие переменные (независимые). На стандартизированных данных постройте аналогичные три модели из п. 2.

Представьте результат в виде перечисления оцененных коэффициентов для каждой из моделей. Приведите также t-статистики и p-value, используемые для проверки значимости коэффициентов.

6. Как изменилась интерпретация коэффициентов b_0 и b_1 во всех трех моделях по сравнению с предыдущим случаем (до стандартизации)? Поменялась ли динамика этих коэффициентов? Объясните, почему так произошло.
7. Как соотносятся R^2 моделей на исходных и стандартизированных данных? Почему так происходит?
8. Как добавление переменной количества достопримечательностей на маршруте изменило оценку влияния качества прометки на рейтинг маршрута? Какой теоретический механизм взаимодействия может объяснять это изменение?
9. Сгенерируйте 100 дополнительных колонок со случайными данными в вашем датасете. Оцените модель с 103 независимыми переменными на рейтинг маршрута. Улучшились ли метрики качества модели? Означает ли это, что модель правда стала лучше?

Решение:

1. 



Наибольшее потенциальное влияние среди представленных переменных на рейтинг маршрута оказывает количество достопримечательностей на маршруте, так как: 1) коэффициент корреляции между этими переменными наибольший, 2) на графиках видно наличие линейной взаимосвязи между этими двумя переменными, и отсутствие других значимых попарных взаимосвязей.

2. Модель 1:

   const — 82.2426

   map_quality — 2.3840

   Модель 2:

   const — 23.6367

   map_quality — 0.8391

   landmarks_n — 0.7409

   Модель 3:

   const — 26.7211

   map_quality — 0.8608

   landmarks_n — 0.7201

   rent_cost — −0.5842

3. tbd
4. tbd
5. Модель 1:

   const — 106.2469

   map_quality — 4.8516

   Модель 2:

   const — 106.2469

   map_quality — 1.7075

   landmarks_n — 10.8936

   Модель 3:

   const — 106.2469

   map_quality — 1.7518

   landmarks_n — 10.5891

   rent_cost — −0.6570

6. tbd
7. tbd

8. tbd
9.

1) видим стат. значимые фичи, например:

   random_feature_68 с p-value 0.028

   random_feature_42 с p-value 0.011

   random_feature_21 с p-value 0.023

   переменные перед нашими фичами почти не изменились:

   const — 106.3819

   map_quality — 1.7663

   landmarks_n — 10.5046

   rent_cost — –0.7293

2) R-squared: 0.880

   Хотя был R-squared: 0.847

   То есть добавление рандомных фичей увеличило R2 почти на 4%.

3. Про фонтаны

В далеком городе Энске есть три района (Левобережный, Правобережный и Нагорье) и 500 человек жителей: в файле fountains.xlsx вам доступны координаты их домов (переменные **x** и **y**) и район, к которому относится дом (переменная **location**).

Сейчас в Энске активно обсуждается вопрос строительства фонтанов. Известно, что полезность любого жителя города от фонтана рядом с его домой рассчитывается по формуле $U_i = \frac{10}{2 + dist_i}$, где $dist_i$ — дистанция до ближайшего фонтана. Для расчета этой дистанции используется обычное евклидово расстояние: расстояние между точками (x_1, y_1) и (x_2, y_2) равняется $\sqrt{(x_1 – x_2)^2 + (y_1 – y_2)^2}$.

Известно также, что жители готовы платить за такое удовольствие, как фонтан рядом с домом! Как и в случае с полезностью, чем ближе фонтан к дому, тем больше готовность платить: сумма P_i, которую готов заплатить за фонтан i-й житель, рассчитывается по формуле $P_i = \frac{A_i}{2 + dist_i}$, где A_i — параметр, $dist_i$ — расстояние до ближайшего фонтана.

1) Мэрия Энска рассматривает три схемы установки фонтанов, все координаты здесь и далее записаны как **(x, y)**:

   Один фонтан с координатами **(5; 3,5)**

   Два фонтана с координатами **(2; 2)**; **(8; 2)**

   Три фонтана с координатами **(2; 2)**; **(8; 2)**; **(5; 5)**

   Рассчитайте среднюю полезность жителей города от каждой из трех схем. Какая из этих схем максимизирует среднюю полезность?

2) Мэрия не может решить, какую схему выбрать, поэтому выносит этот вопрос на голосование. На голосование приходят все жители города, при этом каждый из них голосует за тот вариант, который принесет ему больше всего полезности. Если два варианта эквивалентны — он голосует за тот, при котором фонтанов будет меньше (потому что установка фонтанов стоит денег и при прочих равных жители предпочтут сэкономить общественные деньги). Сколько голосов наберёт каждая из схем? Какой вариант победит?

3) Энск-2 из параллельной вселенной ничем не отличается от предыдущего Энска, но мэрия там решает отдать установку фонтанов во власть рынка! Специально аккредитованная компания выбирает схему (те же варианты, что в п. 1), собирает со всех жителей города деньги в соответствии с их готовностью платить и устанавливает фонтаны! Какую схему выберет эта компания, если $A_i = 20$ для всех жителей города, себестоимость установки одного фонтана равна 1500, а компания (что логично) максимизирует свою прибыль? Рассчитывайте прибыль для каждой схемы и выберите оптимальную.

4) Энск-3 из еще одной параллельной вселенной тоже очень похож на предыдущие два Энска, в нем фонтаны тоже устанавливает коммерческая компания, но мэрия строго велела установить ровно три фонтана! Второе отличие: в Энске-3 в Нагорье живёт местная элита и их параметр A_i выше, чем у других жителей города. У всех жителей Левобережного и Правобережного $A_i = 20$, у всех жителей Нагорья A_i одинаковый, но его размер они могут выбрать сами.

   Базовая схема установки фонтанов в Энске-3 — это «Три фонтана с координатами **(2; 2)**; **(8; 2)**; **(5; 5)**», но жители Нагорья очень хотят, чтобы все фонтаны были в их районе! Им нравится схема «три фонтана с координатами **(5; 5,5)**; **(4,5; 4,5)**; **(5,5; 4,5)**».

   Компания по установке фонтанов выберет тот вариант (из этих двух), который обеспечит ей максимальную прибыль. Все жители города по-прежнему платят по формуле $P_i = \frac{A_i}{2 + dist_i}$. Какое значение параметра A_i должны выбрать жители Нагорья, чтобы победила та схема, которая им нравится?

Решение:

Общий комментарий по всем пунктам задачи: ответы принимаются только при наличии решения (кода, эксель-файла с расчётами, какого-то другого описания пути получения решения), цифры без обоснования (даже верные) оцениваются в 0 баллов.

Вопрос 1 — средние полезности

1 фонтан	2.064462
2 фонтана	3.089928
3 фонтана	3.503346

Вопрос 2 — голосование

Схема	Голосов
1	15

2	392
3	93

Побеждает вариант 2.

Вопрос 3 — про прибыли

	Выручка	Прибыль
1 фонтан	2064.462	564.4617
2 фонтана	3089.928	89.92847
3 фонтана	3503.346	-996.654

Побеждает вариант с 1 фонтаном.

Вопрос 4 — элитное Нагорье

Ответ: 409.37 (можно принять на полный балл 409 или 410)

4. Про географию и цены на недвижимость

Датасет с некоторыми промежуточными столбцами

Датасет в том виде, который даем участникам

Гендальф планирует возвращение на родину и изучает рынок недвижимости Валинора. На листе «Квартиры по городам» представлены данные о стоимости и площади квартир в различных городах Валинора.

apartment_id — идентификатор каждой отдельной квартиры

city_id — идентификатор каждого отдельного города

city_name — название каждого отдельного города

area — площадь квартиры в квадратных метрах

price — стоимость квартиры в золотых монетах

На листе «Города» приведены координаты расположения городов на карте Валинора. Валинор — относительно небольшая страна, поэтому можно считать, что все города расположены в одной плоскости X—Y.

city_id — идентификатор каждого отдельного города

city_name — название каждого отдельного города

x — координата города по оси X

y — координата города по оси Y

Помогите Гендальфу, выполнив следующие пункты задачи.

1) Приведите график, который мог бы визуализировать расположение всех городов Валинора на плоскости X—Y и отражал бы среднюю стоимость квартир в этих городах.

2) Гендальф заработал довольно много золотых за время своих приключений в Средиземье, в связи с чем рассматривает покупку недвижимости в Старом городе (это название города из датасета). Рассчитайте корреляцию между эвклидовым расстоянием от Старого города до всех остальных городов Валинора и средней стоимостью квартир в этих городах.

3) Гендальфу известно, что посреди Валинора ровно на прямой $X = 0$ возвышается длинный горный хребет, разделяющий страну на левую и правую части. В таком случае ему будет сложно навещать своих друзей, проживающих в правой части Валинора. Рассчитайте корреляцию между расстоянием от Старого города до городов Валинора, находящихся в левой части страны ($X < 0$), и средней стоимостью квартир в этих городах.

4) Во время посиделок в таверне Элронд напомнил Гендальфу, что горы не представляют большой проблемы, так как Гендальф может всегда перемещаться между любыми городами напрямую по воздуху на орлах. Кроме того, Старый город и Серебряный Лист являются самыми развитыми городами Валинора и в них установлен телепорт, связывающий их напрямую. То есть между этими городами всегда можно перемещаться напрямую, затрачивая на это 0 минут!

   Для выполнения данного пункта вам понадобится третий лист датасета «Матрица со временем пути». Каждый элемент этой матрицы a_{ij} показывает время, затрачиваемое на самую короткую возможную дорогу между городами i и j в минутах.

   Используя эту матрицу, рассчитайте корреляцию между временем пути от Старого города до всех остальных городов Валинора и средней стоимостью квартир в этих городах.

Внимательно посмотрите на свои результаты из пунктов 1—4 и ответьте на следующие вопросы:

A) Какая закономерность для средней стоимости квартир наблюдается в городах Валинора?

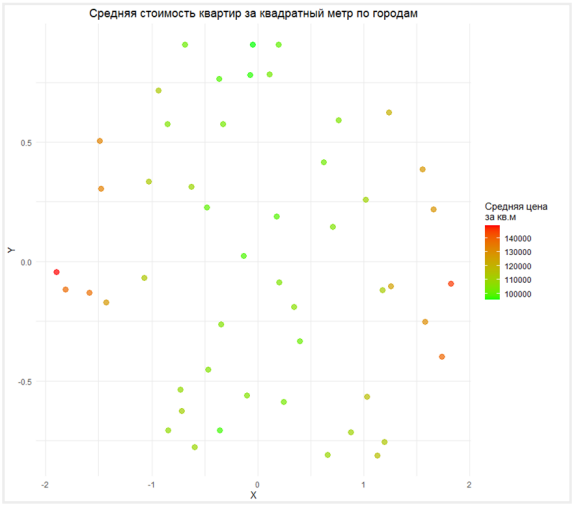
B) Из-за чего может наблюдаться подобная закономерность? Можете считать, что с точки зрения социально-экономических процессов города Валинора функционируют так же, как и города какой-то страны в реальной жизни.

C) Почему в пунктах 2—4 могли получиться разные результаты?

D) В процессе решения этой задачи мы использовали несколько разных способов измерения «дистанции» (силы связи из-за особенностей географического положения) между городами: просто расстояние по карте и время в пути. Предложите еще какой-нибудь разумный способ определения «дистанции» между городами, который мог бы описывать наблюдаемую зависимость.

Решение:

Вопрос 1 — карта (график).



Вопрос 2 — корреляция между ценами и расстоянием

Ответ_1: 0.1191375 или округлённые варианты, например 0.119, 0.1191, 0.11914, 0.119147

или

Ответ_2: 0.0877331 или округлённые варианты, например, 0.088, 0.0877, 0.08773, 0.087733

Вопрос 3 — корреляция между ценами и расстоянием при условии X < 0

Ответ_1: -0.8716399 или округлённые варианты, например -0.87, -0.872, -0.8716, -0.871614

или

Ответ_2: -0.9410586 или округлённые варианты, например, -0.94, -0.941, -0.9411, -0.94106, -0.941059

Вопрос 4 — корреляция между ценами и временем пути из матрицы

Ответ_1: -0.8529438 или округлённые варианты, например, -0.853, -0.8529, -0.85294, -0.852944

Ответ_2: -0.9288044 или округлённые варианты, например, -0.93, -0.929, -0.9288, -0.928804

Вопрос А) — про закономерность для стоимости квартир

Очевидное падение стоимости с увеличением расстояния от Старого Города (city_id = 13)

В правой части карты тоже есть кластер с высокими ценами на недвижимость, и для него наблюдается аналогичная ситуация. Соответственно цены на квартиры в рассматриваемом городе выше/ниже, чем ближе/дальше он находится от условных от левого и правого края карты.

Вопрос B) — про закономерность для стоимости квартир

Много рабочих мест в Старом Городе, высокий уровень зарплат, более развитая инфраструктура, лучше социальное обеспечение, всё это стимулирует граждан рассматривать приобретение квартиры непосредственно в нём или в городах, которые лежат неподалёку. Серебряный Лист также является важным экономическим центром.

Вопрос C) — почему получились разные корреляции в разных пунктах

Здесь необходимо прокомментировать особенности расчёта в каждом из трёх пунктов 2–4.

2. Мы смотрим корреляцию расстояния от Старого Города до других городов и цен на квартиры, сначала она отрицательная (больше расстояние – меньше цена). Затем, приближаясь к правому краю, цена вновь начинает расти, хотя расстояние по-прежнему увеличивается, то есть корреляция становится положительной. В связи с этим, итоговая корреляция получилась небольшая. В целом, главное сказать, что для городов в левой части корреляция отрицательная, а для городов в правой части — положительная. Количество городов в левой и правой части почти одинаковое (если быть точным, то в левой части их 26, а в правой 24). Из-за чего слагаемые в выборочной корреляции почти полностью взаимно уничтожаются. Падение цен с расстоянием для крайнего правого города (Серебряного Листа) происходит очень похожим образом (или симметрично) Старому Городу. Таким образом, с учётом того, что характер зависимости аналогичный, слагаемые в выборочной корреляции почти полностью взаимно уничтожаются.

3. Мы смотрим корреляцию расстояния от Старого Города до других городов и цен на квартиры, сначала она отрицательная (больше расстояние — меньше цена). Затем, начиная с центра карты ($X = 0$) цена вновь начинает расти, хотя расстояние по-прежнему увеличивается, то есть корреляция становится положительной. Но мы ограничили выборку только левой частью карты ($X < 0$), в связи с чем итоговая корреляция получилась сильная и отрицательная.

4. Для начала следует сказать, что время пути по смыслу эквивалентно расстоянию из предыдущих ситуаций.

   Добавление телепорта между городами меняет кратчайшее расстояние/время пути между городами по сравнению с предыдущими пунктами задачи (без подробностей как именно или с ошибками в описании того, как именно).

   Матрица показывает кратчайшее время пути из Старого Города в любой другой, следовательно, её элементы, отвечающие за время пути до городов из левой части карты ($X < 0$), отражают время полёта на орлах (эквивалент обычного расстояния из пунктов 1)-2)).

   Матрица показывает кратчайшее время пути из Старого Города в любой другой, следовательно, с учётом телепорта её элементы, отвечающие за время пути до городов из правой части карты ($X > 0$), отражают использование телепорта (0 минут пути) + время полёта на орлах из Серебряного Листа в город назначения.

Корреляция для городов в левой части карты всё так же остаётся сильной и отрицательной по аналогии с ситуациями из предыдущих пунктов. За счёт телепорта расстояние/время пути из Старого Города до городов с дорогой недвижимостью, расположенных близко к Серебряному Листу, но далеко от Старого Города, тоже становится маленьким. Таким образом, для городов из правой части мы тоже будем видеть отрицательную корреляцию между временем пути и ценами на квартиры. Следовательно, итоговая корреляция будет сильная и отрицательная.

Вопрос D) — предложите ещё какой-нибудь способ определения дистанции

В условии мы сказали, что можно считать, что города Валинора функционируют примерно так же, как и города в реальной жизни, поэтому здесь могут быть очень разные варианты ответа. Для референса можно представить ситуацию Москвы — Московской области или любую другую «Региональный центр — его область»

Но какой есть важный момент. На самом деле время пути и расстояние в целом покрывает практически любой чисто «географический» вариант ответа, а мы хотим увидеть что-то альтернативное.

1. Например, это может быть история про миграционные потоки. Сколько человек туда-сюда ежедневно ездят на работу. Чем больше, тем меньше «расстояние» между городами. Эту же идею можно оформить в виде какого-нибудь индекса транспортной доступности, который рассчитывается на основе количества рейсов по всем доступным видам транспорта в день.
2. Ещё можно предложить объём торговли между городами: чем больше, тем меньше расстояние.
3. На самом деле подойдёт разность адекватных социальных/экономических/демографических показателей городов. Например, воображаемый аналог ВВП для города (в России, насколько мне известно, такое не считают, а в США вроде есть), уровень дохода горожан, население/плотность населения и т.д.

5. Про парадокс Симпсона

У Даши есть набор из 100 наблюдений по некоторым показателям X и Y, по которым она оценивает модель линейной регрессии. Ответьте на следующие вопросы.

1. Даша оценила три модели, используя разные подвыборки и полную выборку по переменным X и Y:

$$
\begin{aligned}
\hat{Y}_i &= \hat{\beta}_0 + \hat{\beta}_1 X_i, \quad i = 1, \ldots, 50 \tag{1} \\
\hat{Y}_i &= \hat{\alpha}_0 + \hat{\alpha}_1 X_i, \quad i = 51, \ldots, 100 \tag{2} \\
\hat{Y}_i &= \hat{\gamma}_0 + \hat{\gamma}_1 X_i, \quad i = 1, \ldots, 100 \tag{3}
\end{aligned}
$$

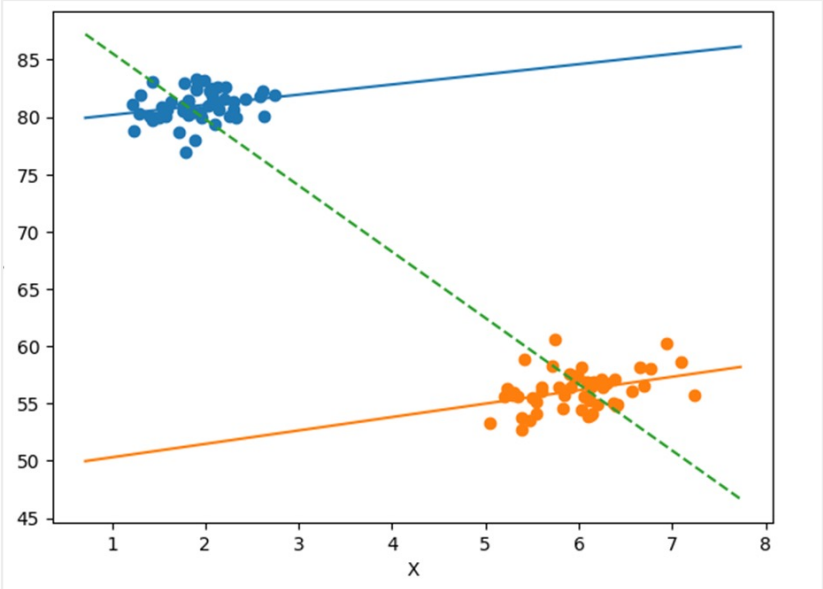
   При этом оказалось, что $\hat{\beta}_1 > 0$, $\hat{\alpha}_1 > 0$, а $\hat{\gamma}_1 < 0$. Приведите диаграмму рассеяния по переменным X и Y, отражающую набор наблюдений, по которым Даша могла получить такие оценки коэффициентов.

2. Предложите реальную пару показателей X и Y, для которых Даша могла бы получить подобную зависимость в пункте 1. Что в таком случае могут представлять собой полная выборка и подвыборки, чем эти подвыборки могут отличаться друг от друга? Обоснуйте, почему для этих показателей могла бы наблюдаться такая зависимость.

3. Даша еще раз внимательно посмотрела на свои результаты в пункте 1 и заметила, что для оценок коэффициентов в моделях (1)-(2) дополнительно выполняется неравенство $\hat{\alpha}_1 > \hat{\beta}_1$. Используя свой пример показателей из пункта 2, объясните, чем может быть обусловлена такая зависимость. Запишите уравнение линейной регрессии, которое бы описывало такую зависимость одновременно для всех наблюдений (X_i, Y_i) , где $i = 1, \ldots , 100$.

Решение:

Вопрос 1 — привести пример диаграммы рассеяния, иллюстрирующей парадокс Симпсона



Вопрос 2 — привести пример показателей X и Y

Например, X — часы подготовки к экзамену за неделю, Y — балл экзамена. Подвыборки — группы разной сложности курса/учителя.

Группа 1 (легкий курс): студенты в среднем тратят меньше часов (X), но имеют высокий базовый уровень Y (экзамен проще). Внутри группы: больше часов — выше балл — положительный наклон.

Группа 2 (сложный курс): студенты в среднем тратят больше часов, но базовый уровень Y ниже (экзамен сложный). Внутри группы: больше часов — выше балл — положительный наклон.

В целом по всем 100 наблюдениям: из-за сдвига средних (сложный курс «живёт» при больших X, но даёт меньшие Y) агрегированная линия может стать отрицательной.

Вопрос 3 — оказалось, что коэффициент наклона у одной из подвыборок больше

На сложном курсе (группа 2) маржинальная отдача часа подготовки выше — каждый дополнительный час заметнее повышает шанс разобрать трудные темы.

В идеале здесь должна была бы быть короткая фраза, поясняющая, почему разбор трудных тем даёт больший прирост к оценке (например, что они весят больше баллов в экзамене).

$Y_i = \delta 0 + \delta 1 * X_i + \delta 2 * D_i + \delta 3 * (X_i * D_i) + \varepsilon_i$

$D_i = 1$ для наблюдений из подвыборки 2, Иначе $D_i = 0$

6. Про RLMS и рисование графиков

В этой задаче вам предстоит немного поработать с данными обследования РМЭЗ НИУ ВШЭ. РМЭЗ — это серия ежегодных общенациональных репрезентативных опросов, проводимая с 1994 года, по которой можно изучать огромный спектр вопросов о жизни людей в России. Вы будете работать с самой свежей волной опроса — за 2024 год.

Для решения этой задачи вам будут нужны два файла: RLMS_ind.xlsx и RLMS_HH.xlsx.

Вам также пригодятся описания переменных базы данных по индивидам и базы данных по домохозяйствам.

В файле RLMS_ind.xlsx содержится небольшая часть базы данных по индивидам:

- **idind, ccid_i** — идентификационные номера индивида
- **ccid_h** — идентификационный номер домохозяйства
- **cch4** — номер члена семьи
- **wage** — заработная плата человека по основному месту работы (переменная ccj10 из исходной базы данных)
- **educ** — уровень образования человека (переменная **cc_diplom** из исходной базы данных)
- **gender** — пол человека (переменная **cch5** из исходной базы данных)
- **age** — возраст человека (переменная **cc_age** из исходной базы данных)

В файле RLMS_HH.xlsx содержится полная база данных по домохозяйствам со всеми переменными, которые в ней есть. Описания переменных, которые будут нужны в процессе решения задачи, следует искать в документации (описании базы данных по домохозяйствам).

Начнем с того, что удалим из базы по индивидам все наблюдения, для которых нет информации о зарплате (в поле wage стоит пустое значение или респондент не ответил по той или иной причине). Обратите внимание на то, как в RLMS кодируются варианты «затрудняюсь ответить», «отказ от ответа» и «нет ответа».

1) Рассчитайте, чему равна средняя зарплата респондента, и нарисуйте гистограмму зарплаты.

2) Рассчитайте среднюю зарплату респондентов в зависимости от уровня образования. Запишите ее в таблицу и визуализируйте. Обратите внимание, что в данных уровень образования кодируется цифрой, но расшифровка доступна в описании базы по индивидам. При построении графика используйте не кодировку уровня образования (число), а текстовое описание (расшифровку).

Для решения следующих пунктов вам будет нужно объединить два файла базы данных. Вы можете сделать это по переменной ccid_h.

3) Для каждого индивида из вашей базы данных подтяните количество членов его семьи (переменная **cc_nfm**). Каков средний размер семьи в нашей выборке? Визуализируйте распределение размера семьи.

4) Визуализируйте связь дохода и размера семьи при помощи диаграммы рассеяния. Рассчитайте корреляцию этих двух переменных и проверьте ее статистическую значимость. Какой вывод о наличии связи дохода человека и размера его семьи можно сделать на основе этих расчетов? Поясните.

5) Изменится ли ответ на предыдущий вопрос, если рассматривать отдельно мужчин, отдельно женщин? Если рассматривать только людей в возрасте от 40 лет (40 и старше)?

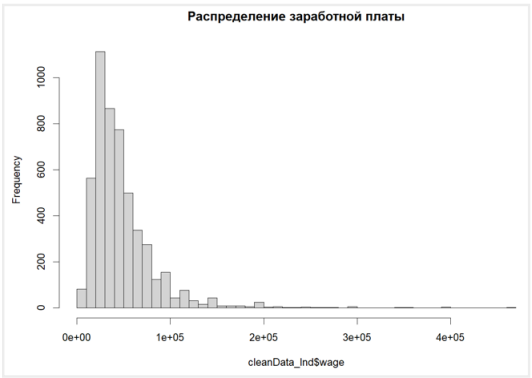
Для решения следующего пункта вам надо будет изучать родственные связи респондентов в нашей выборке. В этом вам помогут переменные из файла по домохозяйствам вида ccbX.9.Y (где X и Y — номера членов семьи из переменной cch4) и кодификатор родственных связей**.**

К примеру: у вас есть два индивида из одного домохозяйства (с одним значением ccid_h): один с номером 3, другой — с номером 5 (это значения переменной cch4). Значит, чтобы выяснить их родственные связи, нужно смотреть на переменную ccb5.9.3: «кем 5-й член семьи приходится 3-му члену семьи». Пусть там стоит 9 — это значит (в соответствии с кодификатором), что 5-й член семьи — внук или внучка 3-го члена семьи! Чтобы узнать более подробную информацию об этом 5-м члене семьи, достаточно найти его id в переменной ccidind5 и подробнее изучить уже по файлу базы данных по индивидам.

6) Найдите индивида с самым высоким доходом. Сколько человек живет с ним в одном домохозяйстве? Какого они пола (переменные вида **ccbX.4**), возраста (года рождения содержатся в **ccbX.5**) и кем они приходятся нашему герою?

Решение:

1)



2) [1] "educ = 4 ; mean wage = 43912.0746164575"

[1] "educ = 6 ; mean wage = 59949.2265676756"

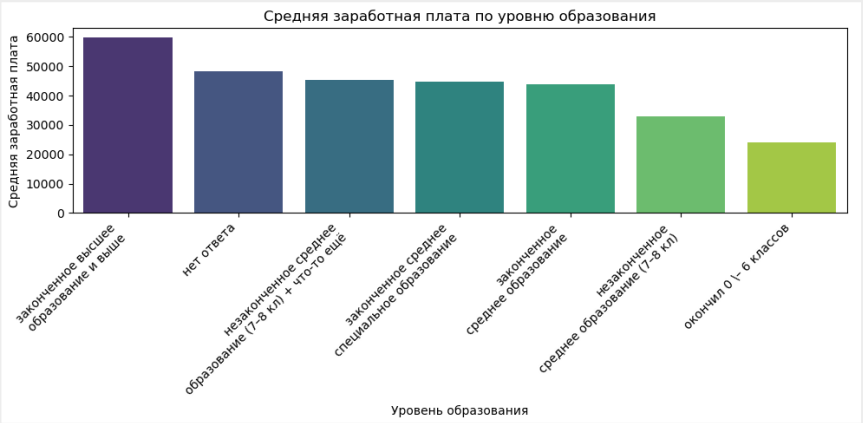
[1] "educ = 5 ; mean wage = 44748.0083333333"

[1] "educ = 2 ; mean wage = 32908"

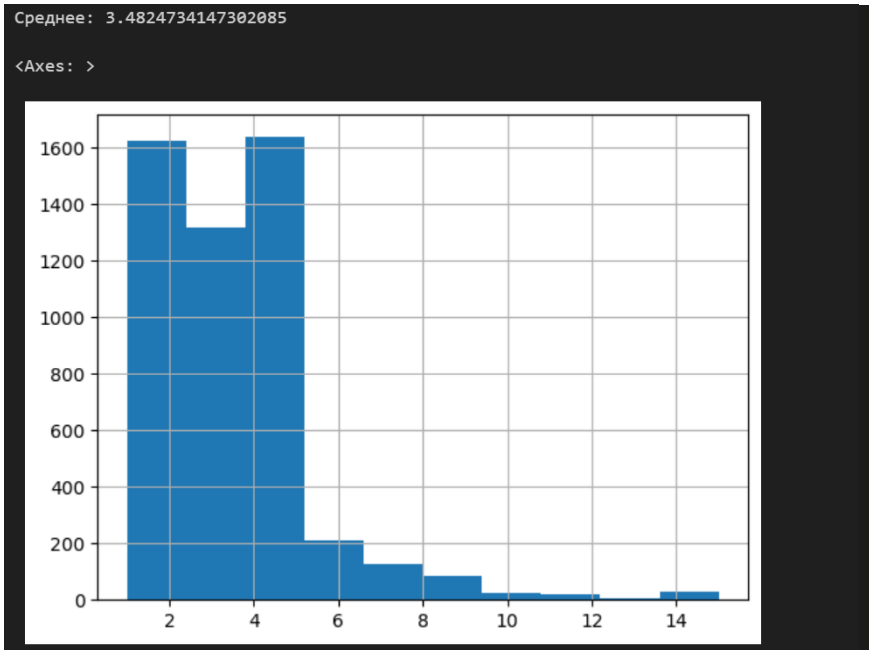
[1] "educ = 3 ; mean wage = 45497.2146892655"

[1] "educ = 1 ; mean wage = 24214.2857142857"

[1] "educ = 99999999 ; mean wage = 48352.9411764706"



3)



4)

Pearson's product-moment correlation

data: tmp3$wage and tmp3$cc_nfm

t = 1.1748, df = 5076, p-value = 0.2401

alternative hypothesis: true correlation is not equal to 0

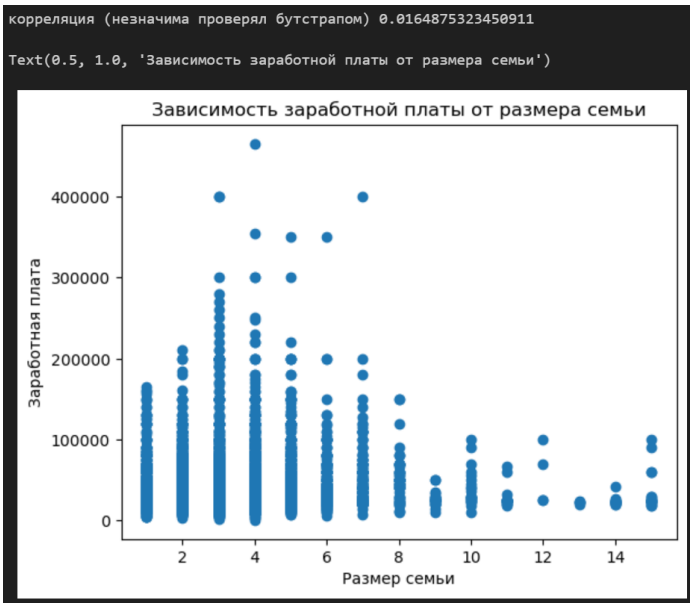
95 percent confidence interval:

-0.01102303 0.04397315

sample estimates:

cor

0.01648753



5)

```
> cor.test(tmp3$wage[tmp3$gender == 1], tmp3$cc_nfm[tmp3$gender == 1])
```

Pearson's product-moment correlation

data: tmp3$wage[tmp3$gender == 1] and tmp3$cc_nfm[tmp3$gender == 1]

t = 1.5713, df = 2406, p-value = 0.1162

alternative hypothesis: true correlation is not equal to 0

95 percent confidence interval:

-0.007936831 0.071870845

sample estimates:

cor

0.03201804

> cor.test(tmp3$wage[tmp3$gender == 2], tmp3$cc_nfm[tmp3$gender == 2])

Pearson's product-moment correlation

data: tmp3$wage[tmp3$gender == 2] and tmp3$cc_nfm[tmp3$gender == 2]

t = -2.1788, df = 2668, p-value = 0.02943

alternative hypothesis: true correlation is not equal to 0

95 percent confidence interval:

-0.079951319 -0.004217971

sample estimates:

cor

-0.04214518

Для людей за 40 тоже значима:

> cor.test(tmp3$wage[tmp3$age >= 40], tmp3$cc_nfm[tmp3$age >= 40])

Pearson's product-moment correlation

data: tmp3$wage[tmp3$age >= 40] and tmp3$cc_nfm[tmp3$age >= 40]

t = 2.5841, df = 3114, p-value = 0.009808

alternative hypothesis: true correlation is not equal to 0

95 percent confidence interval:

0.01116199 0.08123984

sample estimates:

cor

0.04625783

6)

> max(cleanData_Ind$wage)

[1] 465000

> highestWage_n <- which(cleanData_Ind$wage == max(cleanData_Ind$wage))

> hisHH_id <- cleanData_Ind[highestWage_n,]$ccid_h

> hisHH_id

[1] 13811087

Женщина, 1989 г.р. — возраст ≈ 35–36 лет — вероятно супруга (код родства ожидается 1 — муж/жена, в выгрузке код не указан).

Женщина, 1956 г.р. — возраст ≈ 68–69 лет — тёща (код 11).

Женщина, 2014 г.р. — возраст ≈ 10–11 лет — дочь (код 4).

17 / 17

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ

Т БАНК

Блок I — Постановка задачи (МАХ 6 Б)

Критерий	0 баллов	1 балл	2 балла	3 балла	Вес
Разведывательный анализ и анализ структуры данных	Разведывательного анализа нет или он проведен некорректно	Проанализированы: ▸ Распределения и статистики (средние / пропуски / ...) используемых в дальнейшем анализе показателей ▸ Выбросы в данных	То же, что на 1 балл, плюс сделано одно из двух: ▸ Обоснованные выводы о взаимосвязях основных переменных ▸ Показано как выявленные нюансы базы данных влияют на дальнейшее исследование, сделаны выводы из разведывательного анализа	То же, что на 1 балл, плюс сделано два из двух: ▸ Обоснованные выводы о взаимосвязях основных переменных ▸ Показано как выявленные нюансы базы данных влияют на дальнейшее исследование, сделаны выводы из разведывательного анализа	1
Гипотеза	Нет гипотезы или гипотеза не соответствует исследовательскому вопросу	Есть гипотеза, она соответствует исследовательскому вопросу	Есть четко сформулированная гипотеза (о форме и/или направлении связи между показателями), она соответствует исследовательскому вопросу	То же, что на 2 балла, плюс логичное обоснование, почему описанная зависимость может существовать в описанных данных	1

Блок II — Анализ (MAX 13 Б)

Критерий	0 баллов	1 балл	2 балла	3 балла	Вес
Математическая модель исследования	Нет математической модели, или любой из методов применен с критичными ошибками или необоснованно, или не проверяется исследовательская гипотеза	Построена матмодель/ модели, проверяющая сформулированную исследовательскую гипотезу	То же, что на 1 балл, плюс проверена статистическая значимость	То же, что на 2 балла, плюс проверена устойчивость полученных результатов: исследованы взаимосвязи с другими переменными (например, контрольными), ИЛИ проведена проверка результатов на содержательно разных подвыборках	2
Визуализация	В работе нет визуализации или она не относится к исследованию	Визуализация есть. Иллюстрация только одного типа, ИЛИ иллюстрации невозможно проинтерпретировать без пояснений	В работе есть иллюстрации (несколько разного типа), они считываются без пояснений	То же, что на 2 балла, плюс проиллюстрированы все обсуждаемые закономерности в данных, включая матмодель	1
Интерпретация	Интерпретация не представлена	Интерпретация результатов опирается именно на результат работы модели/матметодов, но в ней есть существенные недочеты	Интерпретация результатов опирается именно на результат работы модели/матметодов и в ней нет существенных недочётов	Не ставится	2

Блок III — Выводы (MAX 10 Б)

Критерий	0 баллов	1 балл	2 балла	3 балла	Вес
Выводы и рекомендации	В работе не описаны или не опираются на проведенный анализ перспективы, ограничения, практическая польза исследования	Выполнено и опирается на проведённый анализ одно из трёх: - Описана реально применимая практическая польза и/или policy implication - Обсуждаются альтернативные направления влияния, которые могли привести к тем же выводам из модели - Описаны другие ограничения, релевантные исследованию	Выполнено и опирается на проведённый анализ два из трёх: - Описана реально применимая практическая польза и/или policy implication - Обсуждаются альтернативные направления влияния, которые могли привести к тем же выводам из модели - Описаны другие ограничения, релевантные исследованию	Выполнено и опирается на проведённый анализ три из трёх: - Описана реально применимая практическая польза и/или policy implication - Обсуждаются альтернативные направления влияния, которые могли привести к тем же выводам из модели - Описаны другие ограничения, релевантные исследованию	2
Теоретическая обоснованность исследования	В работе НЕ обсуждается теоретическая обоснованность исследования	Выполнено одно из двух: - Обоснован выбор модели и проверены критерии применимости выбранной модели - Представлены похожие/противоречащие выводы других релевантных исследований из актуальных источников. Показано, как выводы нового исследования соотносятся с результатами предыдущих	Выполнено два из двух: - Обоснован выбор модели и проверены критерии применимости выбранной модели - Представлены похожие/противоречащие выводы других релевантных исследований из актуальных источников. Показано, как выводы нового исследования соотносятся с результатами предыдущих	Не ставится	2

Блок IV — Представление исследования (MAX 6 Б)

Критерий	0 баллов	1 балл	2 балла	3 балла	Вес
Командная работа	Командная работа не видна (не все участвовали в работе, или каждый участник знает только свою часть решения)	Командная работа видна, но участники не знают общей картины и только частично разбираются в решении команды	Командная работа видна, все участники хорошо разбираются в решении команды	Не ставится	1
Логика и полнота повествования	Нет логически выстроенного повествования, Или устно на защите рассказано много важных для исследования деталей, которых в презентации нет.	Выполнено одно из двух: ▸ Логика прослеживается на протяжении всего повествования ▸ В презентации представлены все важные для исследования результаты	Выполнено два из двух: ▸ Логика прослеживается на протяжении всего повествования ▸ В презентации представлены все важные для исследования результаты	Не ставится	1
Общее впечатление от исследования	В Исследовании нет элементов, которые превосходят ожидания от максимума баллов по какому-либо из критериев	Исследование превосходит ожидания от максимума баллов по какому-либо из критериев	Не ставится	Не ставится	2

Дополнительный регламент:

Загрузка презентаций:

- Если презентация не загружена до 10:00 16 декабря, назначается штраф — 10 баллов от полученных на защите
- Презентация может быть загружена после дедлайна (в период до 10:15) и использована на защите, чтобы получить баллы и полноценный фидбэк комиссии
- Если презентация не загружена до 10:15, защита может состояться, но оценивается в 0 баллов

Воспроизводимость. Предоставление расчетов: загрузите расчеты и почищенные датасеты. Дедлайн загрузки — 10:30

Ограничений на баллы в завсисмости от баллов за другие критерии не предусмотрено

Процедура подсчета итогового балла за Проектный тур:

1. Каждый эксперт из комиссии выставляет команде баллы по каждому из критериев.
2. По каждому критерию, кроме Общего впечатления, рассчитывается медианный балл среди баллов выставленных членами комиссии
3. По критерию Общее впечатление рассчитывается средний балл.
4. Полученные медианные и средние баллы по критериям подставляются в формулу:
   Оценка = сумма ([медианной или средней оценке за критерий] * вес критерия) по всем критериям во всех блоках.
5. Итоговая оценка за проектный тур = Оценка/35 * 100, с округлением до сотых.

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ

Т БАНК

1. (6 баллов) Среднее арифметическое значение 10 последовательных натуральных чисел равно 6,5

   Найдите наименьшее число этой последовательности

   Решение:

   Пусть наименьшее число X, тогда сумма арифметической прогрессии с разностью d = 1 и n = 10 равна S = (2 * X + 1 *(10 — 1)) * 10 / 2 = 6,5 * 10 = 65

   Тогда X = 2

2. (2 балла) В отделе работает 20 аналитиков. Раз в год компания выделяет лучших и повышает им зарплату. Этот год был не исключением, зарплату повысили двоим сотрудникам: самому низкооплачиваемому сотруднику подняли зарплату на 10 000 рублей, а самому высокооплачиваемому — на 90 000 рублей

   Выберите верные утверждения:

   - Средняя зарплата в отделе выросла на 5 000 рублей (+)
   - Медианная зарплата не изменилась
   - Распределение зарплат в отделе сместилось влево
   - Дисперсия зарплат увеличилась в 2 раза

3. (6 баллов) Петя выписал на доске 10 чисел: [2, 4, 6, 8, 10, 12, 14, 16, 18, 20]. Потом пришел Вася и стёр с доски 2 числа. Известно, что сумма этих чисел изменилась на 12. Чему равно среднее значение оставшихся на доске чисел?

   Решение:

   Сумма исходных чисел равна 110. Так как сумма изменилась на 12, а количество чисел уменьшилось на 2, то среднее значение будет равно (110 – 12) / (10 – 2) = 12,25

4. (8 баллов) В классе из 20 человек провели контрольную работу по математике. Каждый ученик мог получить оценку от 2 до 5. Какой может быть максимальная дисперсия у оценок за контрольную работу?

   Решение:

   Максимум дисперсии будет достигнут, если половина напишет на 2, а вторая половина на 5. Среднее значение оценок в этом случае равно 3.5, а дисперсия равна 2.25

5. (4 балла) Независимая компания проводила опрос качества работы мобильных операторов связи среди абонентов. Анкета состояла из 6 вопросов, которые относились к 3-м группам:

   - 1-й и 2-й вопросы о качестве мобильного интернета
   - 3-й и 4-й вопросы о качестве работы поддержки
   - 5-й и 6-й вопросы об удовлетворенности покрытием связи

   На каждый вопрос можно было дать ответ в виде оценки от 1 до 10

   Опрос прошли 1 000 человек

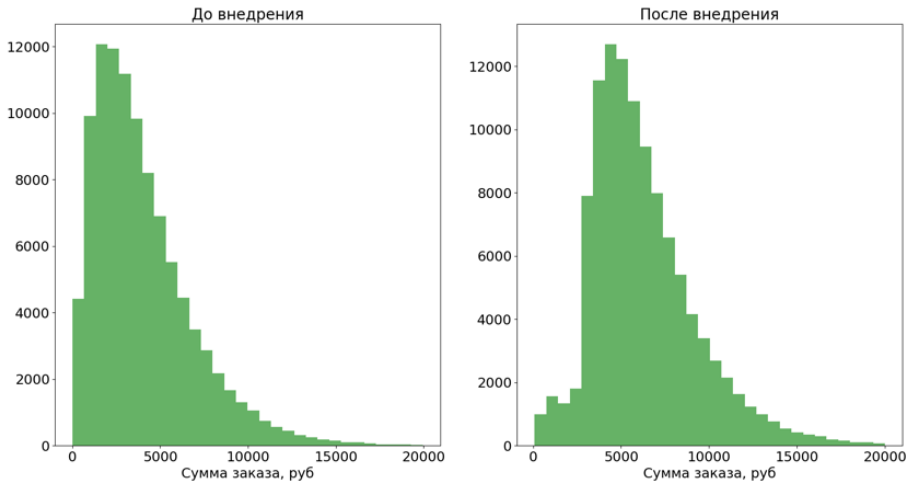
   В таблице указаны значения оценок по каждому вопросу, усредненные по респондентам

Компания	**Вопрос 1**	**Вопрос 2**	**Вопрос 3**	**Вопрос 4**	**Вопрос 5**	**Вопрос 6**
Telephone	5	6	5	3	4	8
SimCards	7	5	6	9	5	6
MobTelecom	9	9	7	5	3	7

   Выберите утверждения, соответствующие результатам опроса:

   - Лучшим оператором по медианной оценке по всем воросам стал SimCards
   - MobTelecom является лучшим оператором по качеству мобильного интернета (+)
   - SimCards имеет худшее покрытие связи по сравнению с другими операторами
   - Средняя оценка качества работы поддержки у оператора Telephone на 2 единицы меньше, чем у MobTelecom (+)

6. (2 балла) В сервисе по доставке продуктов внедрили рекомендательную систему, которая на моменте совершения оплаты предлагает доложить в корзину дополнительные релевантные товары. Перед вами распределение суммы заказа до внедрения рекомендательной системы и после

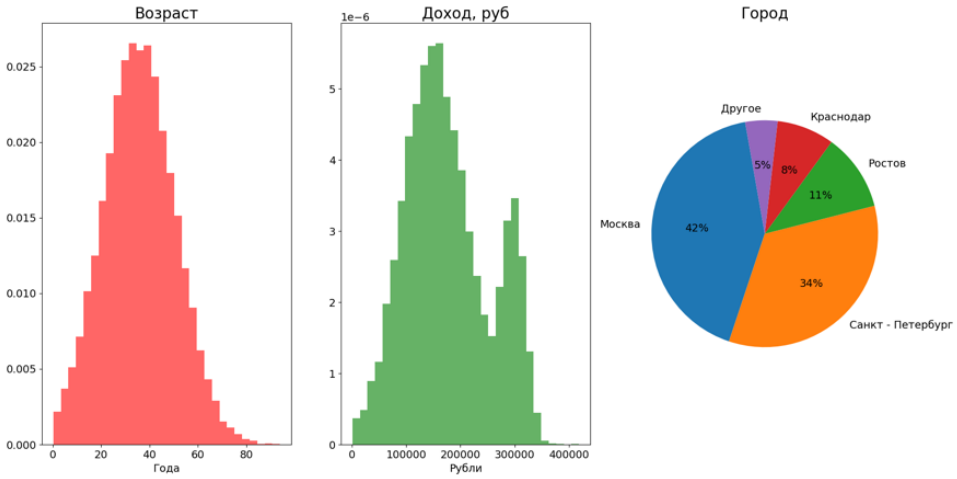


Выберите верные утверждения:

- Количество покупок с чеком до 500 рублей увеличилось
- Средняя сумма заказа в сервисе увеличилась (+)
- Медиана суммы заказа не изменилась
- Максимальное значение суммы заказа выросло

7. (4 балла) Аналитики провели анализ пользователей социальной сети «Галактика».

На графиках ниже представлены распределения по возрасту, доходу и городу проживания пользователей социальной сети.



Проанализируйте полученные графики и выберите верные утверждения, следующие из них:

- Пользователей из Москвы столько же, сколько из Санкт-Петербурга и Краснодара вместе (+)
- Средний возраст аудитории составляет 48 лет
- Мода заработка находится от 145 до 155 тысяч рублей в месяц (+)
- В социальной сети не могут регистрироваться пользователи моложе 18 лет
- В Москве самая большая заработная плата

8. (6 баллов) Совет директоров хочет выйти на новый рынок в Китае. Для этого они запросили информацию по 3 крупнейшим компаниям на этом рынке с целью их покупки. Ваша задача — проанализировать эти компании и определить, какая из них принесет наибольшую прибыль (в млн $) через 5 лет, предполагая, что темпы роста капитала не изменятся.

Название	**Капитал, млн $**	**Ежегодный прирост капитала за последние 5 лет, %**	**Доля прибыли от капитала, %**
Engine Motors	15	5	4
Speed Cross	18	3	6
Fast Fuel	10	6	7

Выберите верное название компании:

- Engine Motors
- Speed Cross (+)
- Fast Fuel

Решение:

Прибыль компании через 5 лет рассчитывается по формуле:
Прибыль = Капитал ×(1 + Рост капитала)^5×Доля прибыли

9. (4 балла) Вы работаете в сервисе доставки готовой еды, и вам поручили проанализировать показатели потенциальных партнеров для их подключения к сервису.

   Ниже представлено дерево метрик:



Название	Средний чек заказа	Количество заказов в месяц	Количество клиентов в месяц
Fast and Cheap	400	1 000	500
Избушка	650	800	600
Суши Роллы	900	400	300

   Выберите верные утверждения:

   - Fast and Cheap имеет наибольший оборот
   - Среднее количество заказов на клиента одинаково в Избушке и в Суши Роллы (+)
   - В Fast and Cheap количество заказов на клиента в два раза больше, чем в Избушке
   - Оборот Избушки примерно на 44% больше, чем компании Суши Роллы (+)

10. (2 балла) Василий устроился работать аналитиком в инвестиционный фонд на зарплату в 150 тыс. рублей в месяц. На жизнь он тратит 2 тыс. рублей в день, а остальное вкладывает под 10% годовых. Сколько Василий заработает с помощью инвестиций с первой зарплаты через год, если он устроился в июне (в нем 30 дней)?

    Проценты в банке начисляются единожды по истечению срока вклада

Решение:

Вложенная сумма равна 150 – 2 * 30 = 90, следовательно заработает 9 тысяч рублей

11. (4 балла) Компания X подключила удаленный колл-центр из 10 человек для продажи своих услуг по телефону. Команде колл-центра за месяц удалось совершить 2 000 звонков, 5% из которых заканчивались продажей. Компанию X не устроил этот результат, и они предложили к текущей команде колл-центра добавить столько же менеджеров по продажам, но более высокой квалификации. У квалифицированного сотрудника вероятность продажи по телефону повышается в 2 раза. Сколько продаж совершит компания X в следующем месяце при условии, что количество звонков увеличится пропорционально количеству сотрудников и они распределяются поровну между квалифицированными и неквалифицированными сотрудниками? Предполагается, что один звонок, если он успешный, соответствует одной продаже.

    Решение:

    Количество продаж = 2 000 * 0.05 + 2 000 * 0.1 = 300

12. (2 балла) Вы с коллегами решили организовать стартап по доставке еды. Проанализировав конкурентов, вы обнаружили, что средний чек одной доставки составляет 1 000 рублей, один клиент заказывает в среднем 2 раза в месяц, а прибыль составляет 30% от полученных средств (учитываются только производственные издержки).

    Однако для привлечения клиентов нужно инвестировать средства в маркетинг.

    Для этого вы купили рекламу в социальных сетях за 10 млн рублей, которую увидят 2 млн человек. Какую ожидаемую прибыль с учетом инвестиций в маркетинг вы получите в первый месяц работы, если человек оформляет заказ после просмотра рекламы с вероятностью 5%?

    Решение:

    Количество клиентов: 2 млн * 5% = 100K -> оборот 100K*1K*2*30% = 60 млн

    Прибыль за вычетом маркетингового бюджета составляет 50 млн.

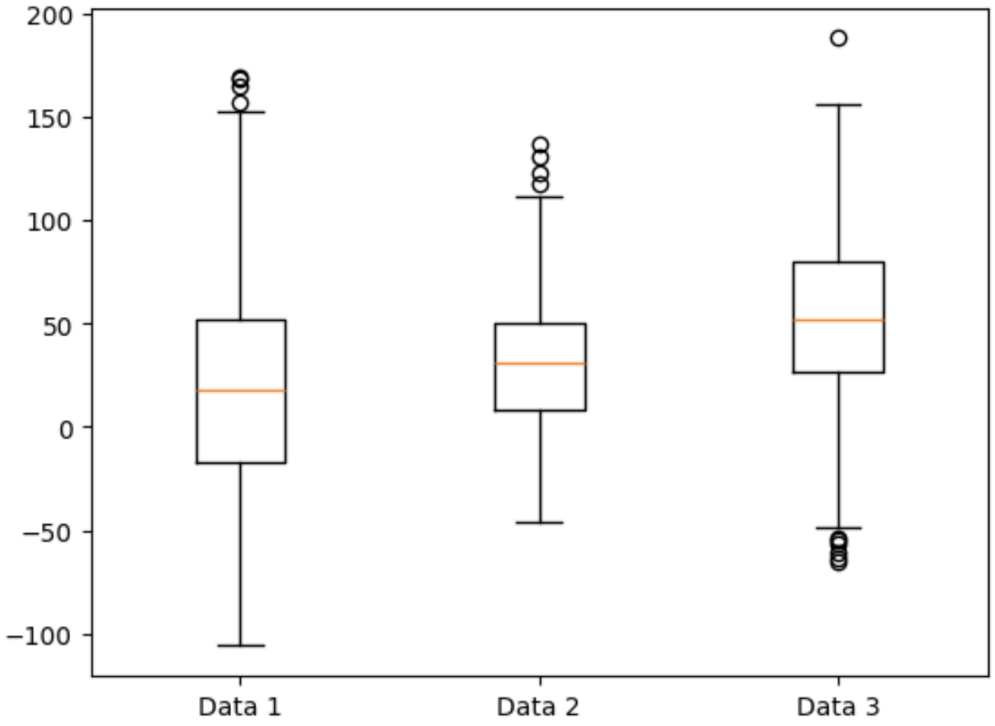
13. (6 баллов) Известно, что в компании Гамма количество клиентов прирастает ежегодно на 5%. Через сколько лет количество клиентов удвоится, при условии, что темпы роста сохранятся? Ответ округлите до целого числа.

    Решение:

    Пусть n — количество лет, а количество текущих клиентов X.
    Тогда $2X = X*(1 + 0.05)^n$.

    $2 = 1.05^n$ -> $n = \log_{1.05} 2 \approx 14$

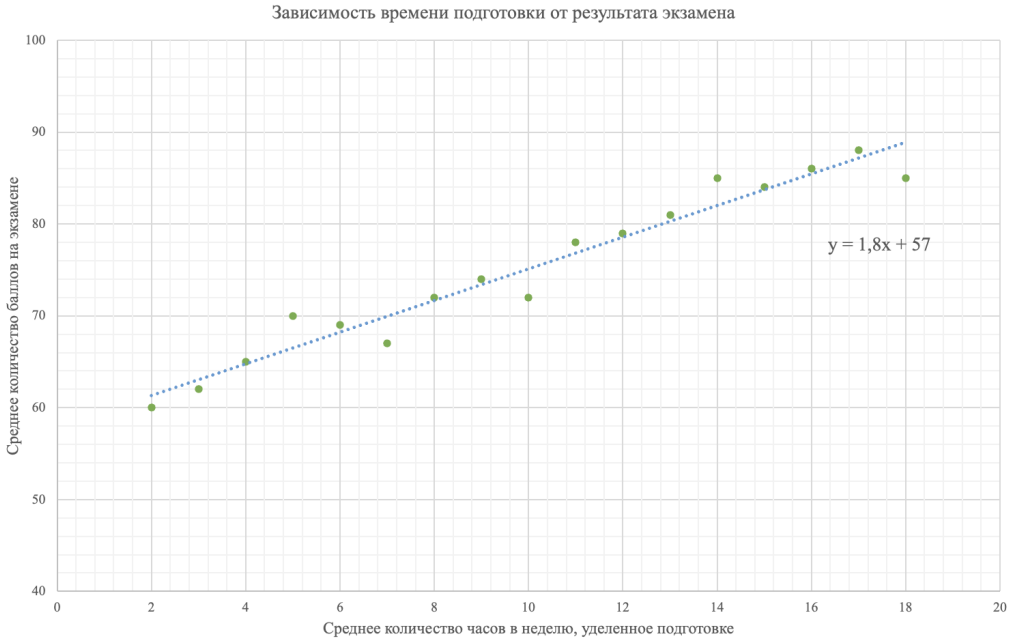
14. (4 балла) Перед вами диаграммы, нарисованные по трём разным наборам данных:



Выберите верные ответы:

- Данные 2 имеют наименьшую дисперсию (+)
- Во 2-м наборе данных среднее выше, чем медиана (+)
- В 3-м наборе данных среднее выше, чем медиана
- Данные 1 имеют наименьшее стандартное отклонение

15. (6 балла) Отдел эффективности образования поставил перед школой задачу повысить средний балл учеников за экзамены. Для этого учителя собрали данные со всех учеников в школе и провели исследование зависимости между временем, затраченным на подготовку, и баллами на экзамене.

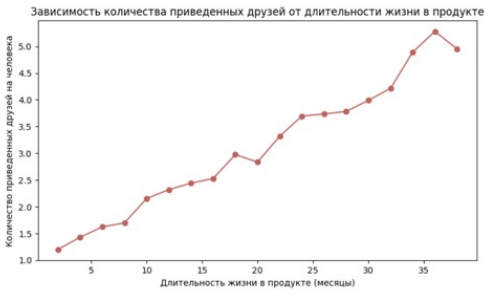


Определите, какое количество часов в неделю необходимо было затратить на подготовку, чтобы претендовать на 100 баллов на экзамене? Ответ округлите до целого числа

Решение:

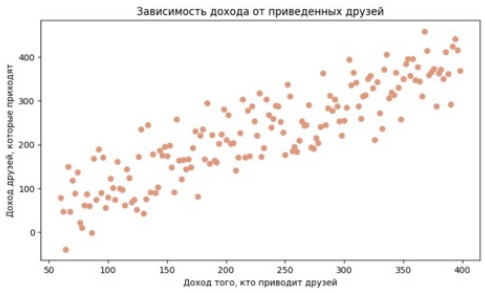
Из уравнения следует, что 100 баллов было бы получено если потратить (100 – 57) / 1.8 = 24

16. (4 балла) Команда маркетинговых аналитиков проанализировала результаты работы акции «Приведи друга» и получила следующие результаты. На графиках, где по оси X находится дата, каждое деление по оси — это начало периода









Выберите утверждения, которые следуют из графиков:

- Наличие подписки у клиента повышает вероятность приведения друга
- Летом количество приведенных друзей меньше, чем осенью (+)
- Чем выше доход у клиента, тем в среднем выше доход у его друзей (+)
- За год человек в среднем приводит 3 друзей

17. (6 баллов) Известно, что если компания выпускает на рынок продукт, то он с вероятностью 70% начинает приносить прибыль на горизонте 5 лет. В компании решили выпустить 3 продукта. Какова вероятность, что хотя бы один из них начнет приносить прибыль на горизонте 5 лет? Каждый продукт развивается независимо от других. Ответ округлите до сотых

    Решение:

    Вероятность неуспеха 30%. Тогда вероятность, что хотя бы 1 продукт будет принесет прибыль равна 1 – 0.3^3 = 0.97

18. (4 балла) Маркетологи в компании «Мастер на все руки» провели анализ акций, которые они проводили в последнее время. Выяснилось, что по акции «Купи молоток и получи пилу в подарок» за покупками в следующем месяце вернулось 30% клиентов, а по акции «Время красить забор» — 25%. При этом акция «Купи молоток и получи пилу в подарок» была доступна только 40% клиентов, остальным была доступна акция «Время красить забор». Каждому клиенту доступна только 1 акция. Какая доля клиентов вернулась за покупками в следующем месяце благодаря маркетинговым акциям? Ответ дайте в процентах

    Решение:

    0,4 * 0,3 + 0,6*0,25 = 0,27 = 27%

19. (6 баллов) В кофейне при покупке двух напитков дают подарок, состоящий из 2 элементов. В качестве элемента подарка могут быть:

    - промокод на скидку в онлайн-кинотеатре
    - купон на следующую покупку
    - печенье с предсказанием
    - браслет
    - многоразовая кружка для кофе

- упаковка мармеладных конфет

Элементы в подарок попадают случайно, при этом повторяться в подарке они не могут. Какова вероятность, что в подарок достанется кружка для кофе?

Решение:

Всего вариантов: 6 * 5 / 2 = 15

Вариантов с кружкой: 5

Вероятность: 1/3

20. (2 балла) В сервисе Т-мобайл хотят запустить розыгрыш повышенного кэшбэка, который имеет следующие условия:

    - если последняя цифра номера телефона заканчивается нулем, то ты получаешь 20% кэшбэка в следующем месяце
    - если последняя цифра 1, то получаешь 1% кэшбэка
    - если последняя цифра 2 — получаешь 2% кэшбэка

    и так далее

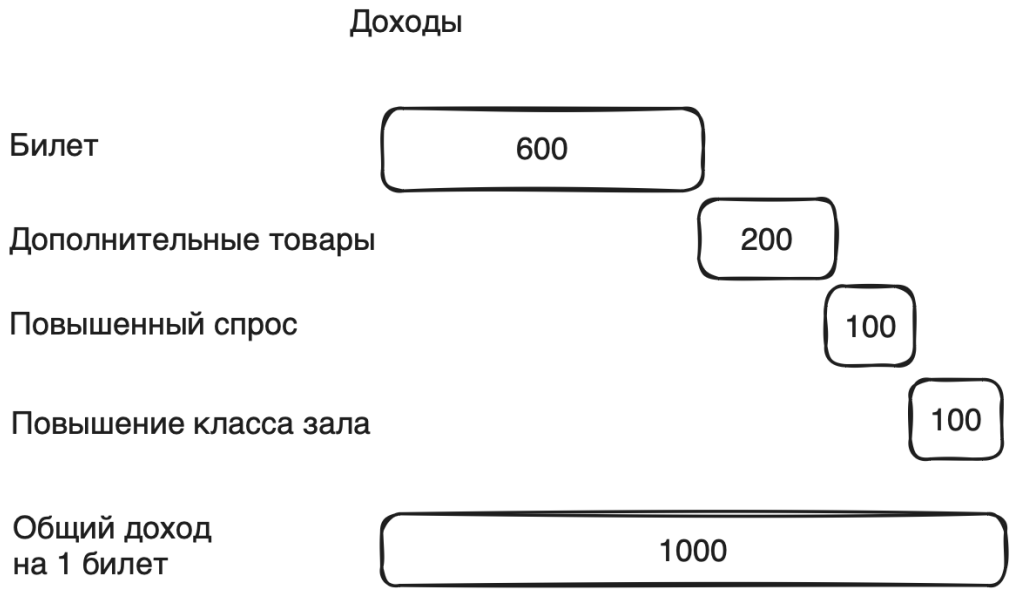
    Сколько в среднем процентов кэшбэка мы заплатим каждому пользователю?

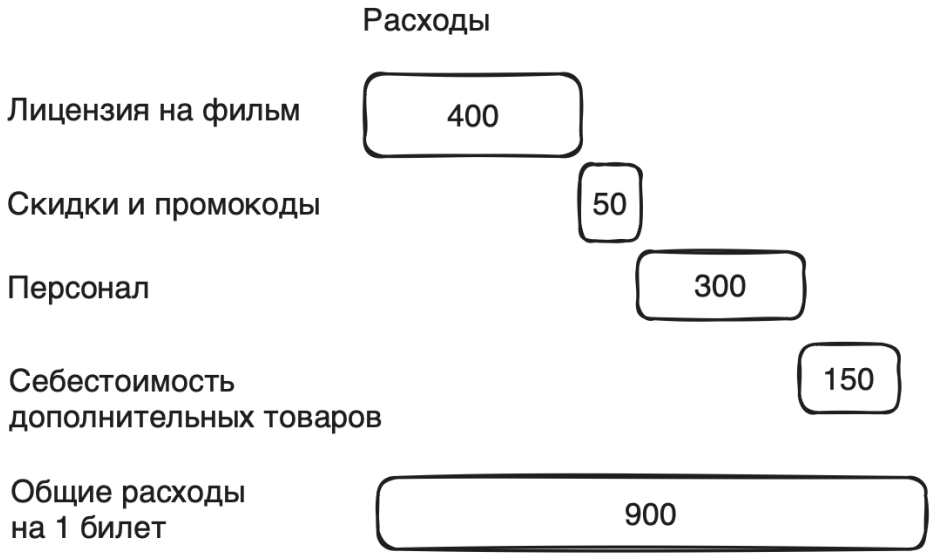
    Выдача телефонных номеров происходит случайным образом. Ответ округлите до десятых

    Решение:

    1/10 — вероятность встретить каждую конкретную цифру —> в среднем мы будем выдавать 1/10 (1 + ... + 9 + 20) = 6.5%

21. (4 балла) Сеть кинотеатров «Синема» проанализировала средние доходы и расходы от продажи 1 билета в кино:





На сколько процентов необходимо сократить расходы на персонал, чтобы увеличить прибыль кинотеатра на 30%, при условии что все остальные статьи доходов и расходов останутся без изменения?

Решение:

Текущая прибыль составляет 100 рублей. Увеличенная прибыль — 130 рублей. Следовательно необходимо снизить расходы на персонал на 30 рублей, что равно 10%.

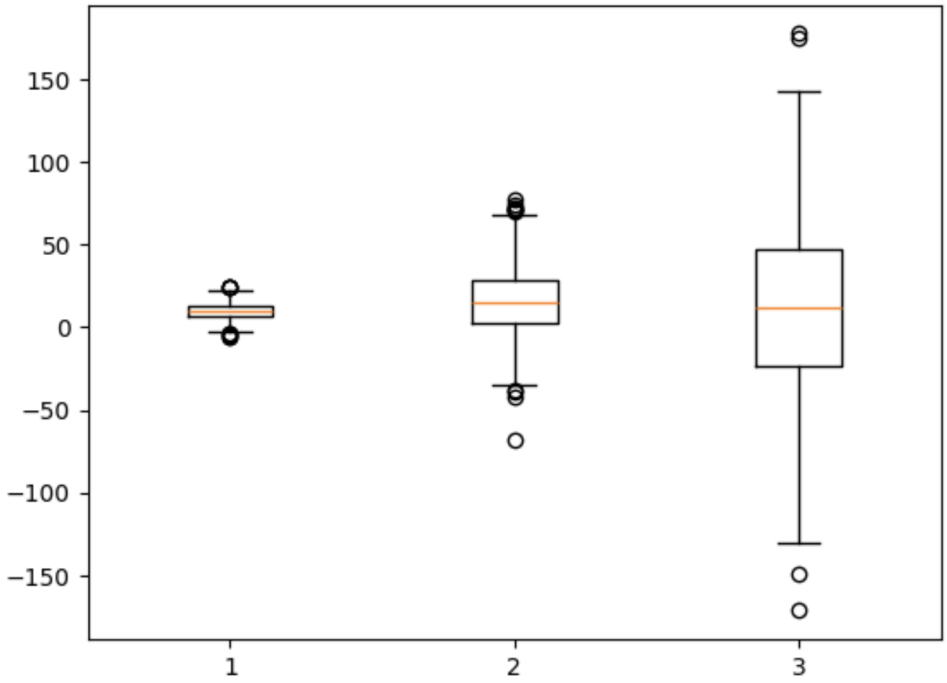
22. (6 баллов) Сервис такси “Покатушки” выявил зависимость прибыли (Y), получаемой с заказа, от тарифа за километр, у.е. (X): $y = -2x^2+20x+300$

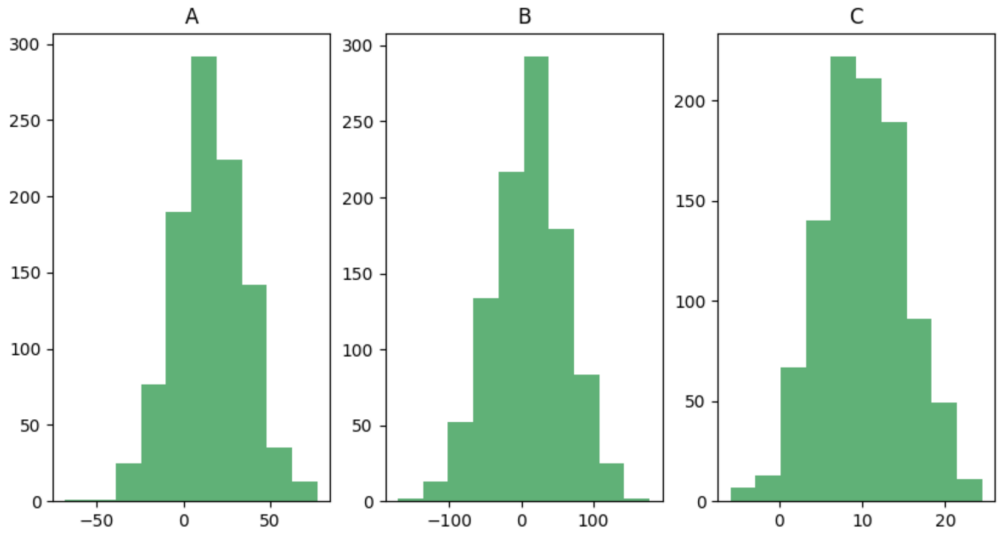
Какое наибольшее значение прибыли в у.е. может получить сервис от одного заказа?

Решение:

Наибольшее значение $x = 5 \longrightarrow y = -2 * 25 + 20 * 5 + 300 = 350$

23. (2 балла) Для трех наборов данных построили боксплоты и гистограммы. Сопоставьте боксплоты с гистограммами





Ответ: A2, B3, C1

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ

Т БАНК

1. (6 баллов) Среднее арифметическое значение 20 последовательных натуральных чисел равно 19,5

   Найдите наименьшее число этой последовательности

   Решение:

   Пусть наименьшее число X, тогда сумма арифметической прогрессии с разностью d = 1 и n = 20 равна S = (2 * X + 1 *(20 – 1)) * 20 / 2 = 19,5 * 20

   Тогда X = 10

2. (2 балла) В отделе работает 20 аналитиков. Раз в год компания выделяет лучших и повышает. Этот год был не исключением, повысили двоих: самому низкооплачиваемому сотруднику подняли зарплату на 20 000 рублей, а самому высокооплачиваемому на 120 000 рублей

   Выберите верные утверждения:

   - Средняя зарплата в отделе выросла на 7 000 рублей (+)
   - Медианная зарплата не изменилась
   - Распределение зарплат в отделе сместилось вправо
   - Дисперсия зарплат увеличилась в 2.5 раза

3. (6 баллов) Петя выписал на доске 10 чисел: [1, 3, 5, 7, 9, 11, 13, 15, 17, 19]. Потом пришел Вася и стер 2 числа. Известно что сумма этих чисел изменилась на 20. Чему равно среднее значение оставшихся чисел на доске?

   Решение:

   Сумма исходных чисел равна 100. Так как сумма изменилась на 20, а количество чисел уменьшилось на 2, то среднее значение будет равно (100 – 20) / (10 – 2) = 10

4. (8 баллов) В классе из 10 человек провели контрольную работу по математике. Каждый мог получить оценку от 2 до 5. Какая может быть максимальная дисперсия у оценок за контрольную работу?

   Решение:

   Максимум дисперсии будет достигнут, если половина напишет на 2, а вторая половина на 5. Среднее значение оценок в этом случае равно 3.5, а дисперсия равна 2.25

5. (4 балла) Независимая компания проводила опрос качества работы мобильных операторов связи среди абонентов . Анкета состояла из 6 вопросов, которые относились к 3 группам:

   - 1 и 2 вопросы о качестве мобильного интернета
   - 3 и 4 вопросы о качестве работы поддержки
   - 5 и 6 вопросы об удовлетворенности покрытием связи

   На каждый вопрос можно было дать ответ в виде оценки от 1 до 10

   Опрос прошли 1 000 человек

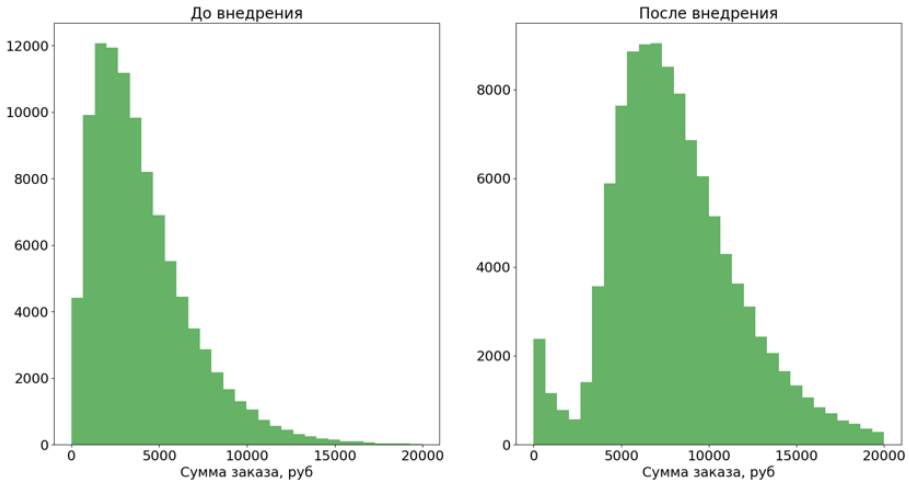
   В таблице указаны значения оценок по каждому вопросу, усредненные по респондентам

Компания	**Вопрос 1**	**Вопрос 2**	**Вопрос 3**	**Вопрос 4**	**Вопрос 5**	**Вопрос 6**
Telephone	5	5	6	9	4	8
SimCards	8	6	5	7	4	6
MobTelecom	7	6	7	5	5	6

   Выберите утверждения, соответствующие результатам опроса:

   - Средняя оценка удовлетворенности покрытием связи у оператора SimCards выше, чем у Telephone
   - Наибольшую среднюю оценку по всем вопросам имеет оператор MobTelecom
   - Лучшее качество мобильного интернета по мнению респондентов имеет SimCards (+)
   - Пользователи больше удовлетворены работой поддержки у оператора Telephone, чем у SimCards (+)

6. (2 балла) В сервисе по доставке продуктов внедрили рекомендательную систему, которая на моменте совершения оплаты предлагает доложить в корзину дополнительные релевантные товары. Перед вами распределение суммы заказа до внедрения и после

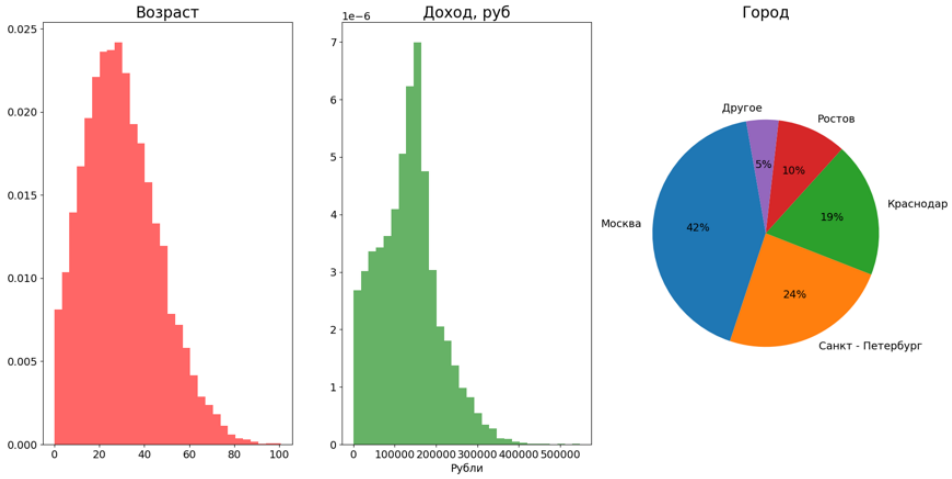


Выберите верные утверждения:

- Количество покупок с чеком до 1 500 рублей уменьшилось (+)
- Средняя сумма покупок в сервисе не изменилась
- Минимальное значение суммы покупок выросло
- Клиенты стали больше покупать дешевые товары

7. (4 балла) Аналитики провели анализ пользователей социальной сети «Галактика».

На графиках ниже представлены распределения по возрасту, доходу и городу проживания пользователей социальной сети.



Проанализируйте полученные графики и выберите верные утверждения, следующие из них:

- Пользователей из Москвы столько же, сколько из Санкт-Петербурга и Краснодара вместе
- Средний возраст аудитории составляет 30 лет (+)
- Мода заработка находится от 145 до 155 тысяч рублей в месяц (+)
- В социальной сети не могут регистрироваться пользователи старше 60 лет
- Жители Санкт-Петербурга имеют наибольший возраст

8. (6 баллов) Совет директоров хочет выйти на новый рынок в Китае. Для этого они запросили информацию по 3-м крупнейшим компаниям на этом рынке с целью их покупки. Ваша задача проанализировать эти компании и определить какая из предложенных компаний принесет наибольшую прибыль через 10 лет, предполагая, что темпы роста капитала не изменятся?

Название	**Капитал, млн $**	**Ежегодный прирост капитала за последние 5 лет, %**	**Доля прибыли от капитала, %**
Engine Motors	10	6	7
Speed Cross	13	4	10
Fast Fuel	11	6	6

Выберите верное название компании:

- Engine Motors
- Speed Cross (+)
- Fast Fuel

Решение: Прибыль компании через 10 лет рассчитывается по формуле:
Прибыль = Капитал ×(1 + Рост капитала)^{10}×Доля прибыли

9. (4 балла) Вы работаете в сервисе доставки готовой еды и вам поручили проанализировать показатели потенциальных партнеров для подключения в сервис

Ниже представлено дерево метрик



Название	Средний чек заказа	Количество заказов в месяц	Количество клиентов в месяц
Fast and Cheap	400	1000	500
Избушка	650	800	600
Суши Роллы	600	1000	300

Выберите верные утверждения:

- Клиенты Суши Роллы имеют более высокое количество заказов на клиента среди остальных доставок (+)
- Оборот Избушки на 20% больше, чем у Fast and Cheap
- Доставке Fast and Cheap нужно увеличить средний чек в 1,5 раза, чтобы иметь такой же оборот, как и у Суши Роллы (+)
- Избушка имеет наименьший оборот среди остальных доставок

10. (2 балла) Василий устроился работать аналитиком в инвестиционный фонд на зарплату в 110 тыс рублей в месяц. На жизнь он тратит 3 тысячи рублей в день, а остальное вкладывает под 10% годовых. Сколько Василий заработает с помощью инвестиций с первой зарплаты через год, если он устроился в июне (в нем 30 дней)?

Проценты в банке начисляются единожды по истечению срока вклада

Решение:

Вложенная сумма равна 110 – 3 * 30 = 20, следовательно заработает 2 тысяч рублей

11. (4 балла) Компания X подключила удаленный колл-центр из 20 человек для продажи своих услуг по телефону. Команде колл-центра за месяц удалось совершить 1 000 звонков, 2% из которых заканчивались продажей. Компанию X не устроил этот результат и они предложили к текущей команде колл центра добавить столько же продажников, но более высокой квалификации. У квалифицированного сотрудника вероятность продажи по телефону повышается в 3 раза. Сколько продаж совершит компания X в следующем месяце при условии, что количество звонков увеличится пропорционально количеству сотрудников и они распределяются поровну между квалифицированными и неквалифицированными сотрудниками? Предполагается, что один звонок, если он успешный, соответствует одной продаже.

    Решение:

    Количество продаж = 1 000 * 0.02 + 1 000 * 0.06 = 80

12. (2 балла) Вы с коллегами решили организовать стартап по доставке еды. Проанализировав конкурентов, вы обнаружили, что средний чек одной доставки составляет 500 рублей, а один клиент заказывает в среднем 2 раза в месяц, а прибыль составляет 30% от полученных средств (учитываются только производственные издержки).

    Однако для привлечения клиентов нужно инвестировать средства в маркетинг.

    Для этого вы купили рекламу в социальных сетях за 20 млн рублей, которую увидят 2 млн человек. Какую ожидаемую прибыль с учетом инвестиций в маркетинг вы получите в первый месяц работы, если человек оформляет заказ после просмотра рекламы с вероятностью 5%?

    Ответ: 10 млн

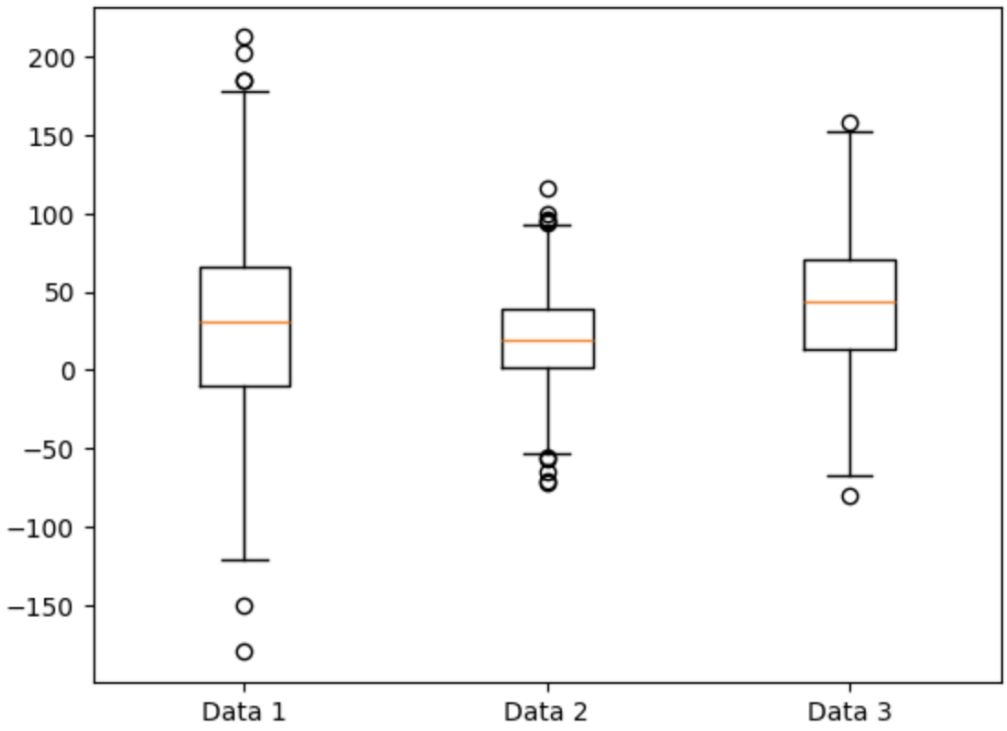
13. (6 баллов) Известно, что в компании Гамма количество клиентов прирастает ежегодно на 3%. Через сколько лет количество клиентов удвоится, при условии, что темпы роста сохранятся? Ответ округлите до целого числа.

    Решение:

    Пусть n — количество лет, а количество текущих клиентов X.
    Тогда $2X = X*(1 + 0.03)^n$.

    $2 = 1.03^n \text{ —> } n = \log_{1.03} 2 \approx 23$

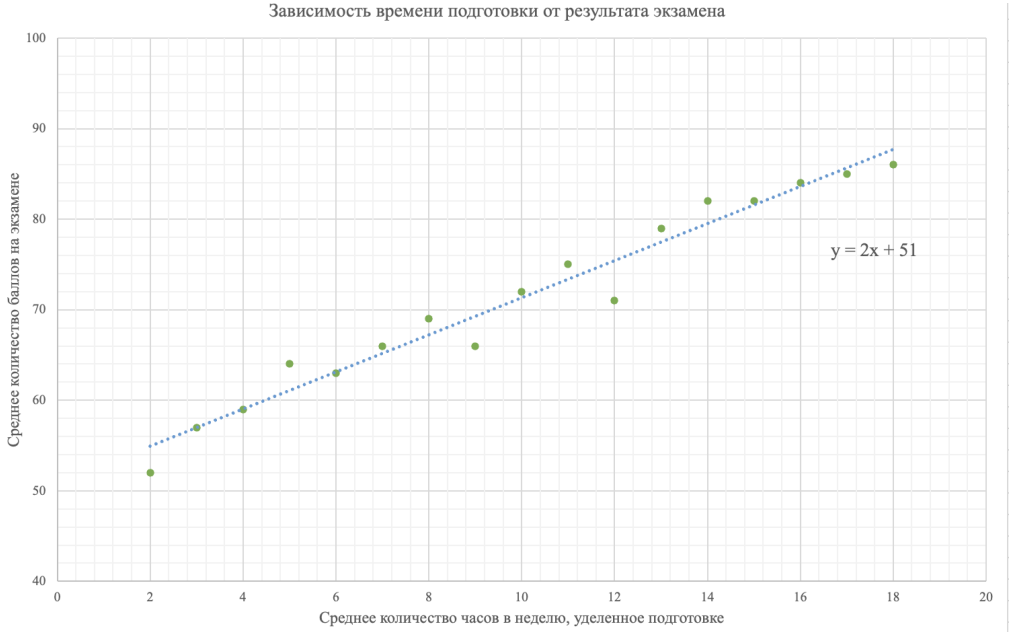
14. (4 балла) Перед вами диаграммы, нарисованные по трем разным наборам данных.



Выберите верные ответы:

- Данные 2 имеют наименьшую дисперсию (+)
- Во 2м наборе данных медиана выше, чем в 1 наборе данных
- В 3м наборе данных наибольшее минимальное значение
- Максимальное значение в 1 наборе больше, чем в 3 наборе (+)

15. (6 балла) Отдел эффективности образования поставил перед школой задачу повысить средний балл учеников за экзамены. Для этого учителя собрали данные со всех учеников в школе и провели исследование зависимости между временем, затраченным на подготовку, и баллами на экзамене

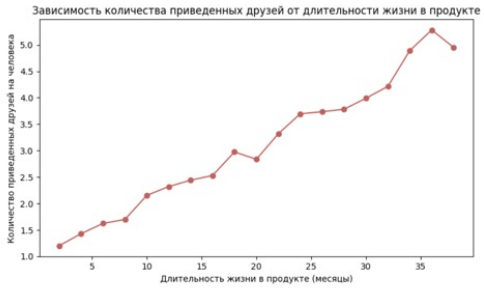


Определите какое количество часов в неделю необходимо было затратить, чтобы претендовать на 100 баллов на экзамене? Ответ округлите до целого числа

Решение:

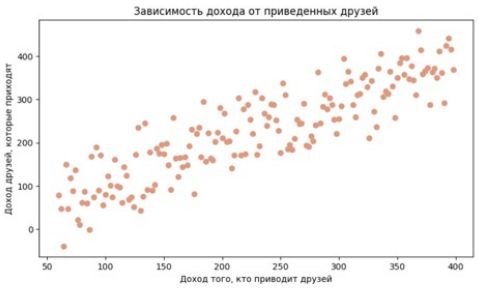
Из уравнения следует, что 100 баллов будет получено если будет затрачено (100 – 51) / 2 = 25

16. (4 балла) Команда маркетинговых аналитиков проанализировала результаты работы акции «Приведи друга» и получила следующие результаты. Каждое деление по оси X — это начало периода









Выберите утверждения, которые следуют из графиков

- Доход клиента не влияет на доход его друзей
- В начале года меньше всего приводили новых клиентов
- В мае количество приведенных друзей у премиум клиентов имеем наименьшее значение (+)
- Чем дольше человек пользуется продуктом, тем больше он успевает привести друзей по акции (+)

17. (6 баллов) Известно, что если компания выпускает на рынок продукт, то он с 50% вероятностью начинает приносить прибыль на горизонте 5 лет. В компании решили выпустить 2 продукта. Какова вероятность, что хотя бы один из них начнет приносить прибыль на горизонте 5 лет? Ответ округлите до сотых

    Решение:

    Вероятность неуспеха 50%. Тогда вероятность, что хотя бы 1 продукт будет принесет прибыль равна $1 - 0.3^2 = 0.75$

18. (4 балла) Маркетологи в компании “Мастер на все руки” провели анализ акций, которые они проводили в последнее время. Выяснилось, что по акции “Купи молоток и получи пилу в подарок” за покупками в следующем месяце вернулось 40% клиентов, а по акции “Время красить забор” — 30%. При этом акция “Купи молоток и получи пилу в подарок” была доступна только 60% клиентам, остальным была доступна акция “Время красить забор”. Каждому клиенту доступна только 1 акция. Какая доля клиентов вернулась за покупками в следующем месяце благодаря маркетинговым акциям? Ответ дайте в процентах

    Решение:

    0,6 * 0,4 + 0,4*0,3 = 0,36 = 36%

19. (6 баллов) В кофейне при покупке двух напитков дают подарок состоящий из 2-х элементов. В качестве подарка могут быть:

    - купон на следующую покупку
    - печенье с предсказанием
    - браслет
    - многоразовую кружку для кофе
    - упаковка мармеладных конфет

Элементы в подарок попадают случайно.

При этом элементы в подарке повторятся не могут.

Какова вероятность, что в подарок достанется кружка для кофе?

Решение:

Всего вариантов: 5 * 4 / 2 = 10

Вариантов с кружкой: 4

Вероятность: 0.4

20. (2 балла) В сервисе Т-мобайл хотят запустить розыгрыш повышенного кэшбэка, который имеет следующие условия:

    - если последняя цифра номера телефона заканчивается нулем, то ты получаешь 30% кэшбэка в следующем месяце
    - если последняя цифра 1, то получаешь 1% кэшбэка
    - если последняя цифра 2 — получаешь 2% кэшбэка

    и так далее

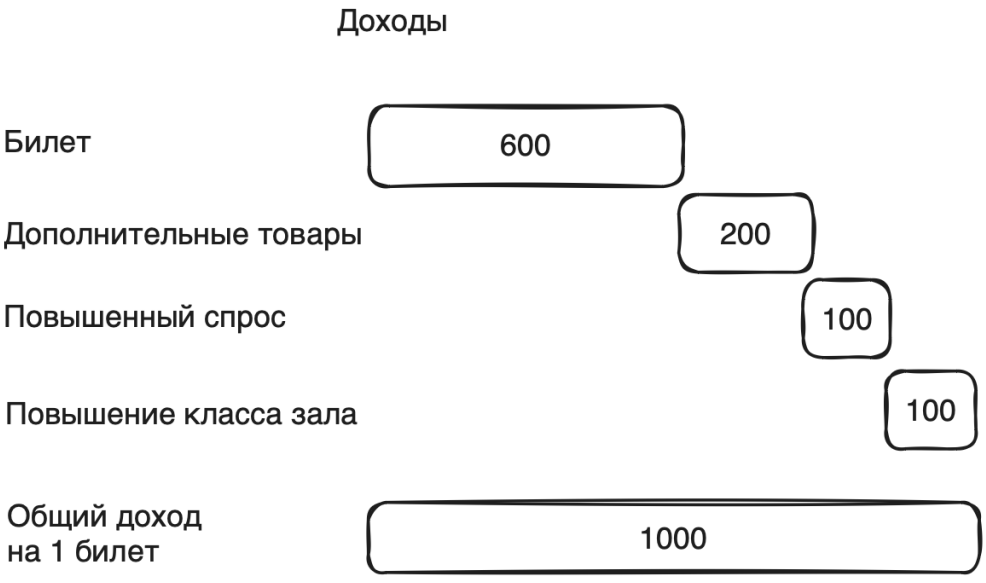
    Сколько в среднем процентов кэшбэка мы заплатим каждому пользователю?

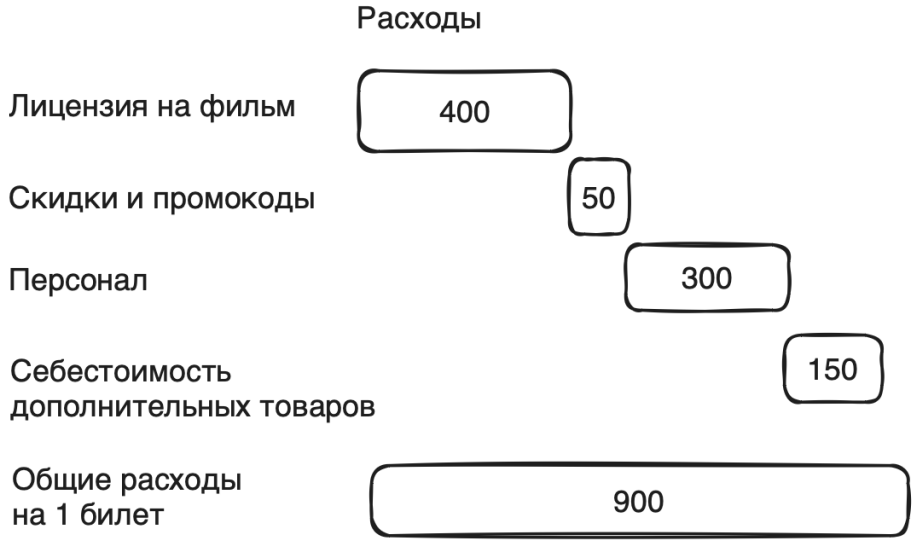
    Выдача телефонных номеров происходит случайным образом. Ответ округлите до десятых

    Решение:

    1/10 — вероятность встретить каждую конкретную цифру —> в среднем мы будем выдавать 1/10 (1 + ... + 9 + 30) = 7.5%

21. (4 балла) Сеть кинотеатров “Синема” проанализировала средние доходы и расходы от продажи 1 билета в кино





На сколько % необходимо сократить расходы на лицензии фильмов, чтобы увеличить прибыль кинотеатра на 20%, при условии что все остальные статьи доходов и расходов останутся без изменения?

Решение:

Текущая прибыль составляет 100 рублей. Увеличенная прибыль — 120 рублей. Следовательно необходимо снизить расходы на лицензии на 20 рублей, что равно 5%.

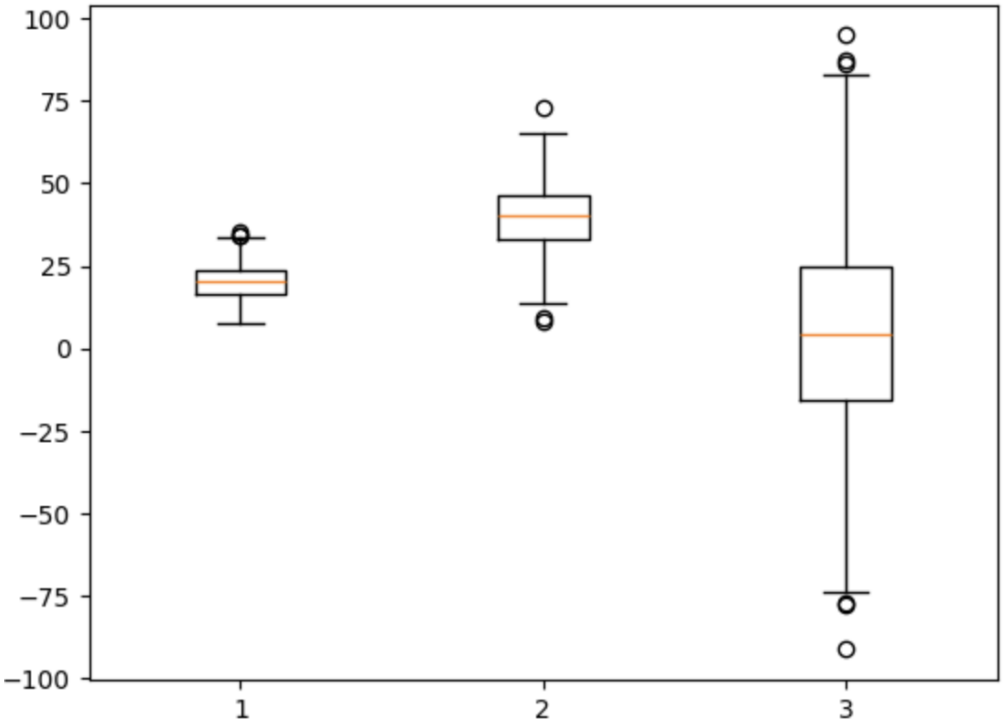
22. (6 баллов) Сервис такси «Покатушки» выявил зависимость прибыли (Y), получаемой с заказа от тарифа за километр, у.е. (X): $y = -x^2+10x+400$

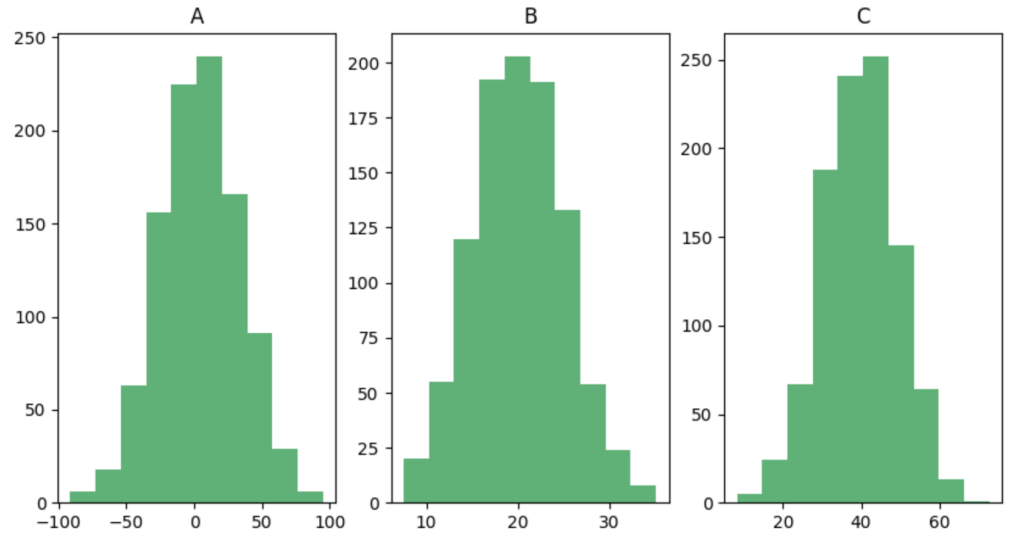
Какое наибольшее значение прибыли в у.е. может получить сервис от одного заказа?

Решение:

Наибольшее значение $x = 5 \rightarrow y = — 25 + 10 * 5 + 400 = 425$

23. (2 балла) Для трех наборов данных построили боксплоты и гистограммы. Сопоставьте боксплоты с гистограммами





Ответ: A3, B1, C2

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ

Т БАНК

1. (6 баллов) Среднее арифметическое значение 10 последовательных натуральных чисел равно 9,5

   Найдите наименьшее число этой последовательности

   Решение:

   Пусть наименьшее число X, тогда сумма арифметической прогрессии с разностью d = 1 и n = 10 равна S = (2 * X + 1 *(10 – 1)) * 10 / 2 = 9,5 * 10 = 65

   Тогда X = 5

2. (2 балла) В отделе работает 40 аналитиков. Раз в год компания выделяет лучших и повышает. Этот год был не исключением, повысили двоих: самому низкооплачиваемому сотруднику подняли зарплату на 10 000 рублей, а самому высокооплачиваемому на 20 000 рублей

   Выберите верные утверждения:

   - Средняя зарплата в отделе выросла на 750 рублей (+)
   - Распределение зарплат в отделе сместилось влево
   - Дисперсия зарплат увеличилась в 4 раза
   - Медианная зарплата уменьшилась в 2 раза

3. (6 баллов) Петя выписал на доске 20 чисел: [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20]. Потом пришел Вася и стер 4 числа. Известно что сумма этих чисел изменилась на 50. Чему равно среднее значение оставшихся чисел на доске?

   Решение:

   Сумма исходных чисел равна 210. Так как сумма изменилась на 50, а количество чисел уменьшилось на 4, то среднее значение будет равно (210 – 50) / (20 – 4) = 10

4. (8 баллов) В классе из 60 человек провели контрольную работу по математике. Каждый мог получить оценку от 2 до 5. Какая может быть максимальная дисперсия у оценок за контрольную работу?

   Решение:

   Максимум дисперсии будет достигнут, если половина напишет на 2, а вторая половина на 5. Среднее значение оценок в этом случае равно 3.5, а дисперсия равна 2.25

5. (4 балла) Независимая компания проводила опрос качества работы мобильных операторов связи среди абонентов . Анкета состояла из 6 вопросов, которые относились к 3 группам:

   - 1 и 2 вопросы о качестве мобильного интернета
   - 3 и 4 вопросы о качестве работы поддержки
   - 5 и 6 вопросы об удовлетворенности покрытием связи

   На каждый вопрос можно было дать ответ в виде оценки от 1 до 10

   Опрос прошли 1000 человек

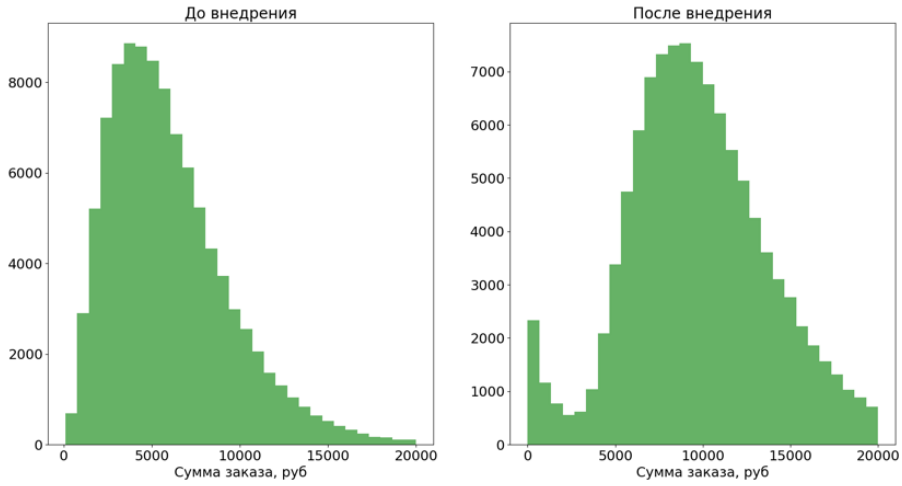
   В таблице указаны значения оценок по каждому вопросу, усредненные по респондентам

Компания	**Вопрос 1**	**Вопрос 2**	**Вопрос 3**	**Вопрос 4**	**Вопрос 5**	**Вопрос 6**
Telephone	5	6	5	3	4	7
SimCards	7	4	8	9	6	6
MobTelecom	5	7	7	5	3	7

   Выберите утверждения, соответствующие результатам опроса:

   - Средняя оценка удовлетворенности покрытием связи у оператора SimCards выше, чем у Telephone (+)
   - Лучшее качество мобильного интернета по мнению респондентов имеет SimCards
   - MobTelecom имеет худшее по мнению респондентов покрытие связи по сравнению с другими операторами (+)
   - Лучшим оператором по медианной оценке стал SimCards (+)

6. (2 балла) В сервисе по доставке продуктов внедрили рекомендательную систему, которая на моменте совершения оплаты предлагает доложить в корзину дополнительные релевантные товары. Перед вами распределение суммы заказа до внедрения и после

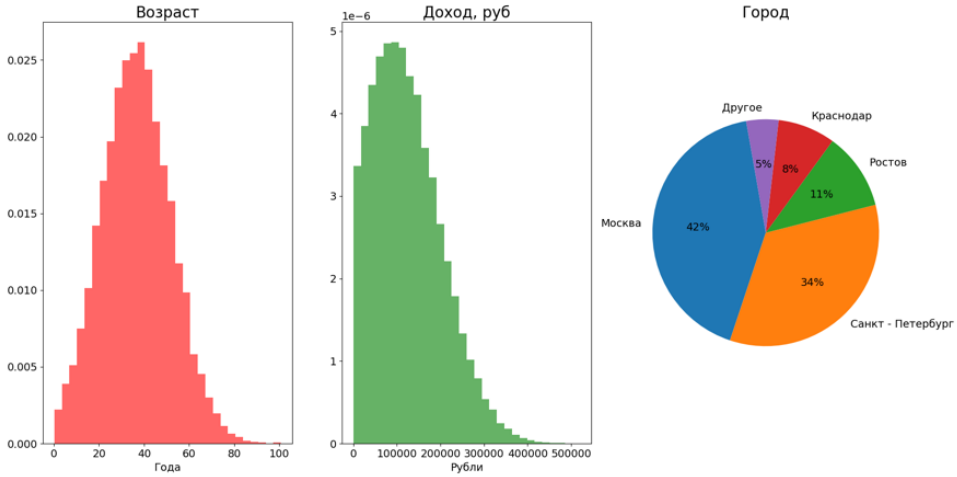


Выберите верные утверждения:

- Количество покупок с чеком от 1 000 до 3 000 рублей увеличилось
- Клиенты стали больше покупать на суммы от 10 000 рублей (+)
- Медиана суммы покупок уменьшилась
- Максимальное значение суммы покупок уменьшилось

7. (4 балла) Аналитики провели анализ пользователей социальной сети “Галактика”.

На графиках ниже представлены распределения по возрасту, доходу и городу проживания пользователей социальной сети.



Проанализируйте полученные графики и выберите верные утверждения, следующие из них:

- Пользователей из Москвы столько же, сколько из Санкт-Петербурга и Краснодара вместе (+)
- Средний возраст аудитории составляет 45 лет (+)
- Мода заработка находится от 65 до 75 тысяч рублей в месяц
- Минимальный возраст аудитории — 14 лет
- В Ростове самая большая заработная плата

8. (6 баллов) Совет директоров хочет выйти на новый рынок в Китае. Для этого они запросили информацию по 3-м крупнейшим компаниям на этом рынке с целью их покупки. Ваша задача проанализировать эти компании и определить какая из предложенных компаний принесет наибольшую прибыль через 5 лет, предполагая, что темпы роста капитала не изменятся?

Название	**Капитал, млн $**	**Ежегодный прирост капитала за последние 5 лет, %**	**Доля прибыли от капитала, %**
Engine Motors	12	5	15
Speed Cross	11	7	5
Fast Fuel	14	6	7

Выберите верное название компании:

- Engine Motors (+)
- Speed Cross
- Fast Fuel
- Решение:
- Прибыль компании через 5 лет рассчитывается по формуле:
  Прибыль = Капитал ×(1 + Рост капитала)^5×Доля прибыли

9. (4 балла) Вы работаете в сервисе доставки готовой еды и вам поручили проанализировать показатели потенциальных партнеров для подключения в сервис

   Ниже представлено дерево метрик



Название	Средний чек заказа	Количество заказов в месяц	Количество клиентов в месяц
Fast and Cheap	400	2 000	1 000
Избушка	650	800	600
Суши Роллы	900	400	300

Выберите верные утверждения:

- Fast and Cheap имеет наибольший оборот (+)
- Среднее количество заказов на клиента одинаково в Избушке и в Суши Роллы (+)
- Доставке Суши Роллы нужно увеличить средний чек в 1,5 раза, чтобы иметь такой же оборот, как и у Избушки
- Оборот Избушки на 20% меньше, чем компании Fast and Cheap

10. (2 балла) Василий устроился работать аналитиком в инвестиционный фонд на зарплату в 100 тыс рублей в месяц. На жизнь он тратит 1 тысячи рублей в день, а остальное вкладывает под 5% годовых. Сколько Василий заработает с помощью инвестиций с первой зарплаты через год, если он устроился в июне (в нем 30 дней)?

    Проценты в банке начисляются единожды по истечению срока вклада

Решение:

Вложенная сумма равна 100 – 1 * 30 = 70 тыс, следовательно заработает 3.5 тысяч рублей

11. (4 балла) Компания X подключила удаленный колл-центр из 50 человек для продажи своих услуг по телефону. Команде колл-центра за месяц удалось совершить 20 000 звонков, 3% из которых заканчивались продажей. Компанию X не устроил этот результат и они предложили к текущей команде колл центра добавить столько же продажников, но более высокой квалификации. У квалифицированного сотрудника вероятность продажи по телефону повышается в 2 раза. Сколько продаж совершит компания X в следующем месяце при условии, что количество звонков увеличится пропорционально количеству сотрудников и они распределяются поровну между квалифицированными и неквалифицированными сотрудниками? Предполагается, что один звонок, если он успешный, соответствует одной продаже.

    Решение:

    Количество продаж = 20 000 * 0.03 + 20 000 * 0.06 = 1 800

12. (2 балла) Вы с коллегами решили организовать стартап по доставке еды. Проанализировав конкурентов, вы обнаружили, что средний чек одной доставки составляет 500 рублей, а один клиент заказывает в среднем 3 раза в месяц, а прибыль составляет 30% от полученных средств (учитываются только производственные издержки).

    Однако для привлечения клиентов нужно инвестировать средства в маркетинг.

    Для этого вы купили рекламу в социальных сетях за 20 млн рублей, которую увидят 2 млн человек. Какую ожидаемую прибыль с учетом инвестиций в маркетинг вы получите в первый месяц работы, если человек оформляет заказ после просмотра рекламы с вероятностью 10%?

    Ответ: 80 млн

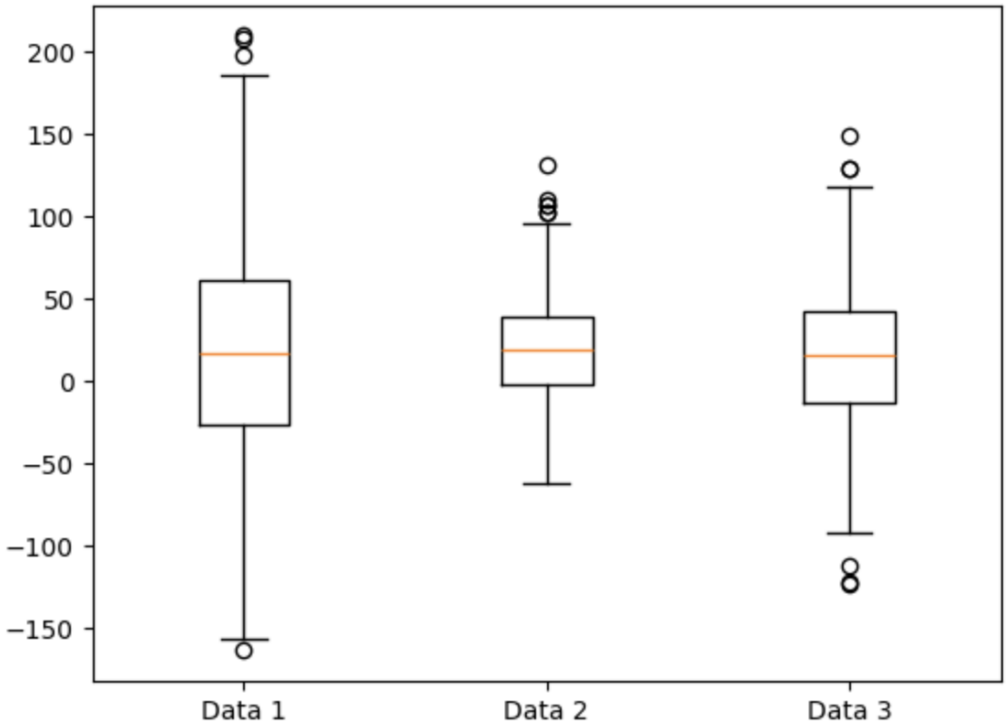
13. (6 баллов) Известно, что в компании Гамма количество клиентов прирастает ежегодно на 4%. Через сколько лет количество клиентов утроится, при условии, что темпы роста сохранятся? Ответ округлите до целого числа.

    Решение:

    Пусть n — количество лет, а количество текущих клиентов X. Тогда $3X = X*(1 + 0.04)^n$.

    $3 = 1.04^n$ -> $n = \log_{1.04} 3 \approx 28$

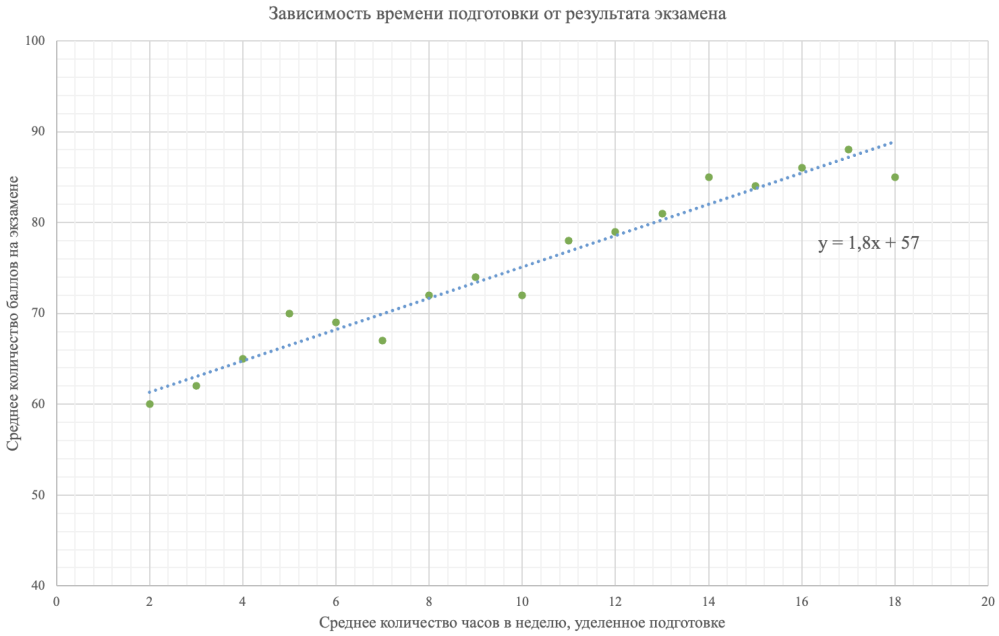
14. (4 балла) Перед вами диаграммы, нарисованные по трем разным наборам данных.



Выберите верные ответы:

- Данные 3 имеют наибольшую дисперсию
- В 1м наборе данных медиана меньше, чем во 2 наборе (+)
- В 3м самое маленькое минимальное значение относительно остальных наборов данных
- Данные 1 имеют наименьшую дисперсию

15. (6 балла) Отдел эффективности образования поставил перед школой задачу повысить средний балл учеников за экзамены. Для этого учителя собрали данные со всех учеников в школе и провели исследование зависимости между временем, затраченным на подготовку, и баллами на экзамене

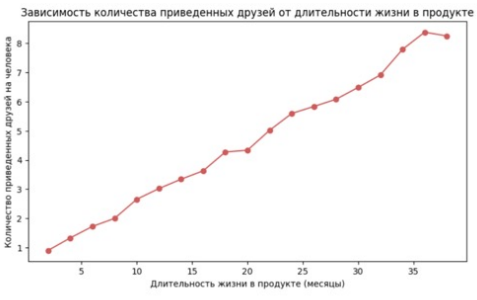


На сколько часов больше нужно было заниматься в неделю, чтобы повысить свой результат на 10 баллов? Ответ округлите до целого значения.

Решение:

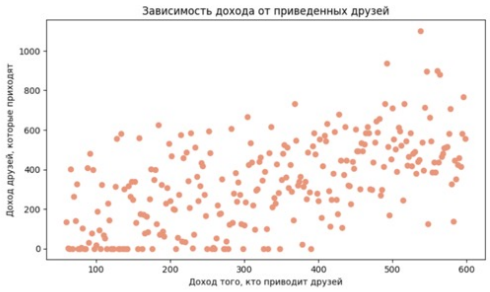
1,8*h=10, нужно заниматься больше на 6 ч.

16. (4 балла) Команда маркетинговых аналитиков проанализировала результаты работы акции “Приведи друга” и получила следующие результаты. Каждое деление по оси X — это начало периода









Выберите утверждения, которые следуют из графиков

- В мае клиенты без подписки привели больше друзей, чем премиум клиенты (+)
- Летом количество приведенных друзей меньше, чем осенью (+)
- Чем выше доход у клиента, тем ниже доход у его друзей
- За год человек в среднем приводит 3 друзей

17. (6 баллов) Известно, что если компания выпускает на рынок продукт, то он с 60% вероятностью начинает приносить прибыль на горизонте 10 лет. В компании решили выпустить 4 продукта. Какова вероятность, что хотя бы один из них начнет приносить прибыль на горизонте 10 лет? Ответ округлите до сотых

    Решение:

    Вероятность неуспеха 40%. Тогда вероятность, что хотя бы 1 продукт будет принесет прибыль равна $1 - 0.4^4 = 0.97$

18. (4 балла) Маркетологи в компании “Мастер на все руки” провели анализ акций, которые они проводили в последнее время. Выяснилось, что по акции “Купи молоток и получи пилу в подарок” за покупками в следующем месяце вернулось 20% клиентов, а по акции “Время красить забор” — 50%. При этом акция “Купи молоток и получи пилу в подарок” была доступна только 60% клиентам, остальным была доступна акция “Время красить забор”. Каждому клиенту доступна только 1 акция. Какая доля клиентов вернулась за покупками в следующем месяце благодаря маркетинговым акциям? Ответ дайте в процентах

    Решение:

    0,6 * 0,2 + 0,4*0,5 = 0,32 = 32%

19. (6 баллов) В кофейне при покупке двух напитков дают подарок состоящий из 2-х элементов. В качестве подарка могут быть:

    - промокод на скидку в онлайн — кинотеатре
    - купон на следующую покупку
    - печенье с предсказанием
    - браслет
    - многоразовую кружку для кофе
    - упаковка мармеладных конфет

- купон на упаковку бесплатного поп-корна

Элементы в подарок попадают случайно.

При этом элементы в подарке повторятся не могут.

Какова вероятность, что в подарок достанется браслет?

Ответ округлите до десятых

Решение:

Всего вариантов: 7 * 6 / 2 = 21

Вариантов с кружкой: 6

Вероятность: 0.3

20. (2 балла) В сервисе Т-мобайл хотят запустить розыгрыш повышенного кэшбэка, который имеет следующие условия:

    - если последняя цифра номера телефона заканчивается нулем, то ты получаешь 15% кэшбэка в следующем месяце
    - если последняя цифра 1, то получаешь 1% кэшбэка
    - если последняя цифра 2 — получаешь 2% кэшбэка

    и так далее

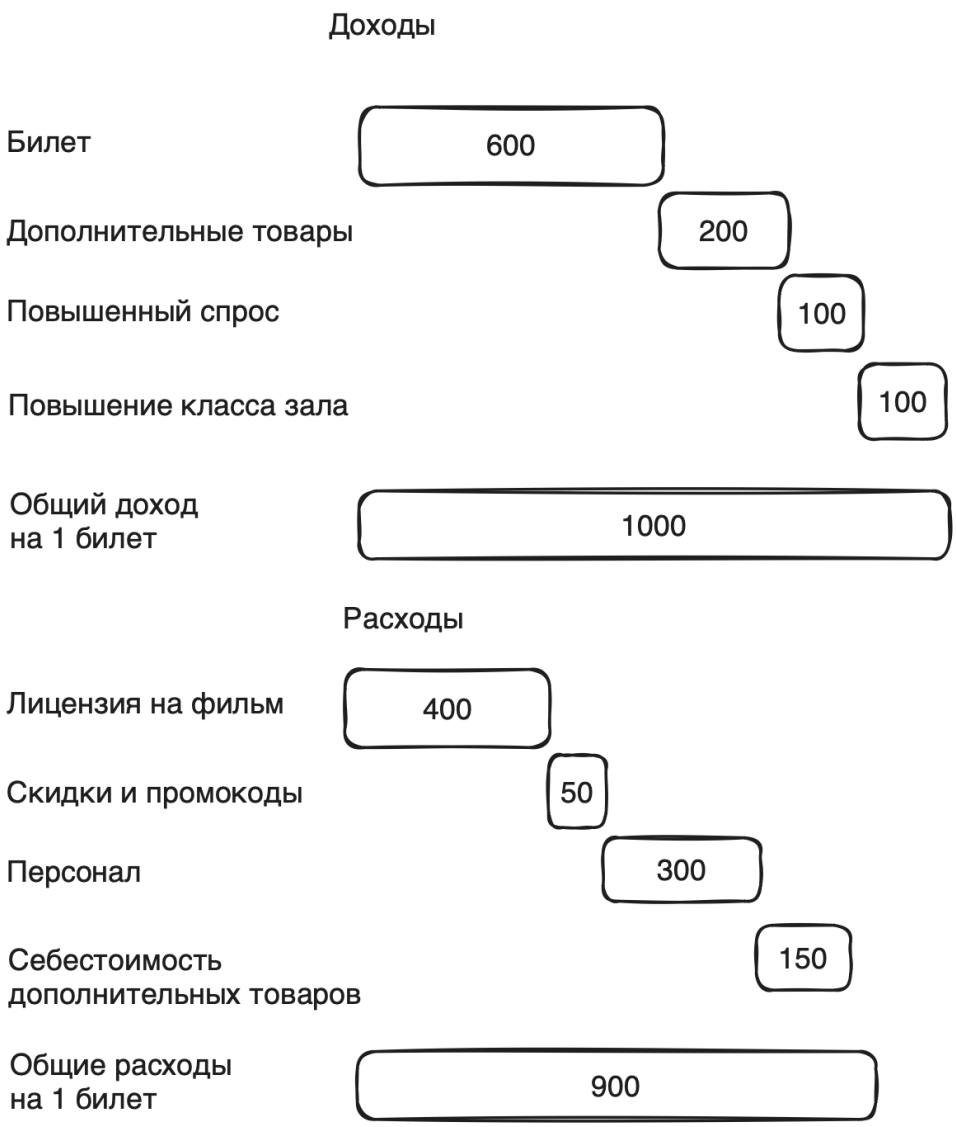
    Сколько в среднем процентов кэшбэка мы заплатим каждому пользователю?

    Выдача телефонных номеров происходит случайным образом. Ответ округлите до десятых

    Решение:

    1/10 — вероятность встретить каждую конкретную цифру -> в среднем мы будем выдавать 1/10 (1 + ... + 9 + 15) = 6.0%

21. (4 балла) Сеть кинотеатров “Синема” проанализировала средние доходы и расходы от продажи 1 билета в кино



На сколько % необходимо сократить расходы на персонал, чтобы увеличить прибыль кинотеатра на 50%, при условии что все остальные статьи доходов и расходов останутся без изменения? Ответ округлите до 2 знака после запятой

Решение:

Текущая прибыль составляет 100 рублей. Увеличенная прибыль — 150 рублей. Следовательно необходимо снизить расходы на персонал на 50 рублей, что равно 16.67%.

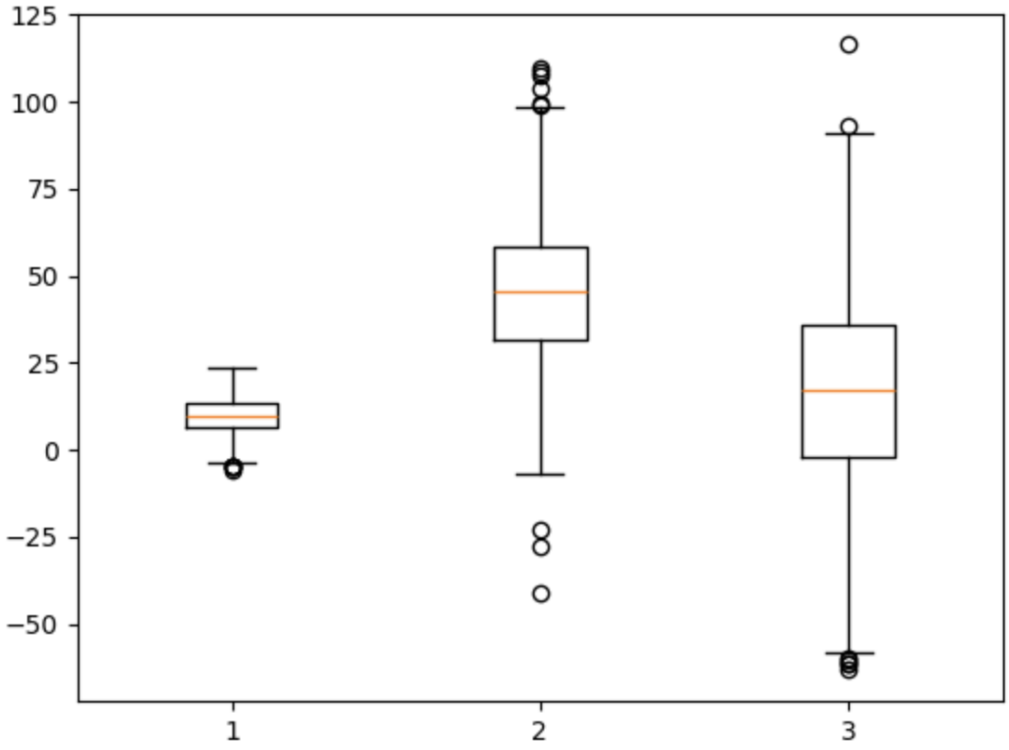
22. (6 баллов) Сервис такси “Покатушки” выявил зависимость прибыли (Y), получаемой с заказа от тарифа за километр, у.е. (X): $y = -3x^2+30x+500$

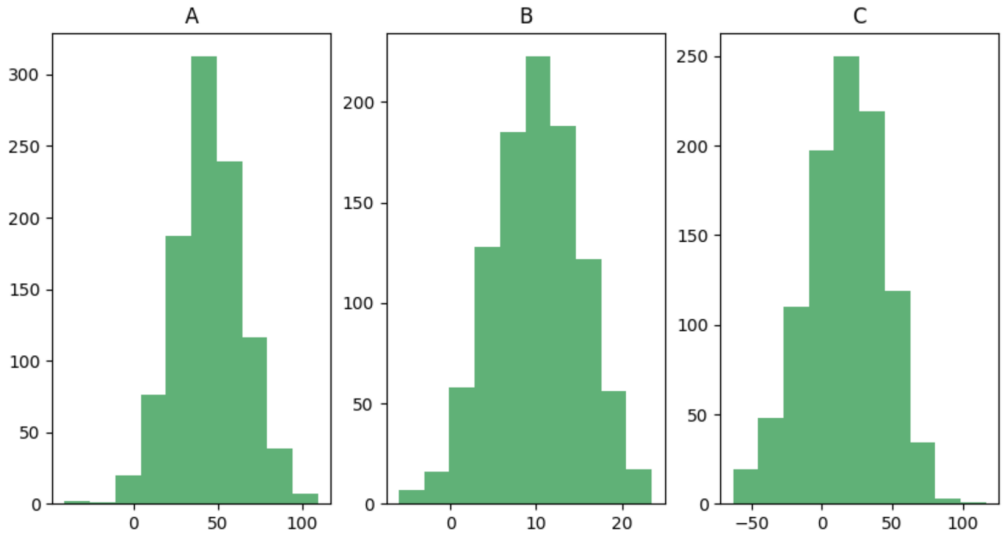
Какое наибольшее значение прибыли в у.е может получить сервис от одного заказа?

Решение:

Наибольшее значение x = 5 -> y = -3 * 25 + 30 * 5 + 500 = 575

23. (2 балла) Для трех наборов данных построили боксплоты и гистограммы. Сопоставьте боксплоты с гистограммами





Ответ: A2, B1, C3

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ

Т БАНК

1. (6 баллов) Среднее арифметическое значение 10 последовательных натуральных чисел равно 6,5

   Найдите наименьшее число этой последовательности

   Решение:

   Пусть наименьшее число X, тогда имеем арифметическую прогрессию с разностью d = 1 и n = 10. Сумма прогрессии S = (2 * X + 1 *(10 — 1)) * 10 / 2 = 6,5 * 10 = 65

   Из этого уравнения находим X = 2

2. (2 балла) В отделе работает 20 аналитиков. Раз в год компания выделяет лучших и повышает им зарплату. Этот год был не исключением, зарплату повысили двоим сотрудникам: самому низкооплачиваемому сотруднику подняли зарплату на 1 0000 рублей, а самому высокооплачиваемому — на 90 000 рублей

   Выберите верные утверждения:

   - Средняя зарплата в отделе выросла на 5 000 рублей (+)
   - Медианная зарплата не изменилась
   - Распределение зарплат в отделе сместилось влево
   - Дисперсия зарплат увеличилась в 2 раза

   Решение:

   1. Средняя зарплата в отделе выросла на 5 000 рублей — верно, так как рост среднего значения можно определить как (10 000 + 90 000)/20 = 5 000
   2. Медианная зарплата не изменилась — неверно, так как после повышения человек, который имеет наименьшее значение мог иметь зарплату выше, чем изначальная медиана, а значит медианная зарплата вырастит
   3. Распределение зарплат в отделе сместилось влево — неверно, так как изменению подверглось только 2 значения, остальные 18 точек остались без изменения
   4. Дисперсия зарплат увеличилась в 2 раза — неверно, так как не можем сделать такой вывод из исходных данных

3. (6 баллов) Петя выписал на доске 10 чисел: [2, 4, 6, 8, 10, 12, 14, 16, 18, 20]. Потом пришел Вася и стёр с доски 2 числа. Известно, что сумма этих чисел изменилась на 12. Чему равно среднее значение оставшихся на доске чисел?

Решение:

Сумма исходных чисел равна 110. Так как сумма изменилась на 12, а количество чисел уменьшилось на 2, то среднее значение будет равно $(110 – 12) / (10 – 2) = 12{,}25$

4. (8 баллов) В классе из 20 человек провели контрольную работу по математике. Каждый ученик мог получить оценку от 2 до 5. Какой может быть максимальная дисперсия у оценок за контрольную работу?

Решение:

Дисперсия отражает разброс данных относительно среднего значения, следовательно, чтобы была максимальная дисперсия, необходимо, чтобы оценки максимально отличались от среднего значения. Это будет справедливо для оценок 2 и 5, так как они наиболее сильно будут обстоять от среднего значения. При этом пропорция между этими оценками должна быть одинаковая, чтобы эти оценки были равноудалены от среднего значения.

Максимум дисперсии будет достигнут, если половина напишет на 2, а вторая половина на 5. Среднее значение оценок в этом случае равно 3.5, а дисперсия равна 2.25

5. (4 балла) Независимая компания проводила опрос качества работы мобильных операторов связи среди абонентов. Анкета состояла из 6 вопросов, которые относились к 3-м группам:

   - 1-й и 2-й вопросы о качестве мобильного интернета
   - 3-й и 4-й вопросы о качестве работы поддержки
   - 5-й и 6-й вопросы об удовлетворенности покрытием связи

   На каждый вопрос можно было дать ответ в виде оценки от 1 до 10

   Опрос прошли 1 000 человек

   В таблице указаны значения оценок по каждому вопросу, усредненные по респондентам

Компания	**Вопрос 1**	**Вопрос 2**	**Вопрос 3**	**Вопрос 4**	**Вопрос 5**	**Вопрос 6**
Telephone	5	6	5	3	4	8
SimCards	7	5	6	9	5	6
MobTelecom	9	9	7	5	3	7

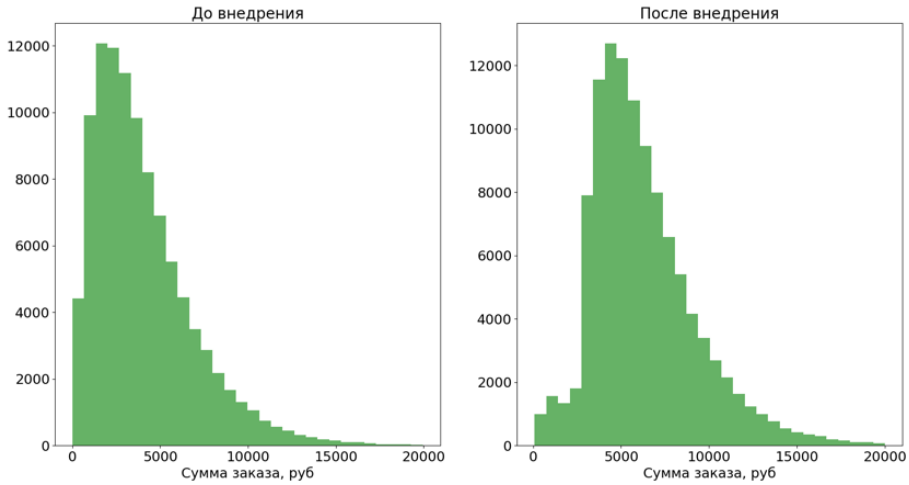
   Выберите утверждения, соответствующие результатам опроса:

   - Лучшим оператором по медианной оценке по всем воросам стал SimCards
   - MobTelecom является лучшим оператором по качеству мобильного интернета (+)
   - SimCards имеет худшее покрытие связи по сравнению с другими операторами
   - Средняя оценка качества работы поддержки у оператора Telephone на 2 единицы меньше, чем у MobTelecom (+)

Решение:

- Лучшим оператором по медианной оценке по всем воросам стал SimCards — неверно, так как лучшим оператором по медианной оценке является MobTelecom
- MobTelecom является лучшим оператором по качеству мобильного интернета — верное утверждение. У MobTelecom среднее значение по критериям качество мобильного интернета равно 9, у Telephone — 5.5, у SimCards — 6
- SimCards имеет худшее покрытие связи по сравнению с другими операторами — неверное, так как наименьшую среднее значение по критериям покрытия связи имеет оператор MobTelecom
- Средняя оценка качества работы поддержки у оператора Telephone на 2 единицы меньше, чем у MobTelecom — верное утверждение. У MobTelecom — 6, а у Telephone — 4

6. (2 балла) В сервисе по доставке продуктов внедрили рекомендательную систему, которая на моменте совершения оплаты предлагает доложить в корзину дополнительные релевантные товары. Перед вами распределение суммы заказа до внедрения рекомендательной системы и после



Выберите верные утверждения:

- Количество покупок с чеком до 500 рублей увеличилось
- Средняя сумма заказа в сервисе увеличилась (+)
- Медиана суммы заказа не изменилась
- Максимальное значение суммы заказа выросло

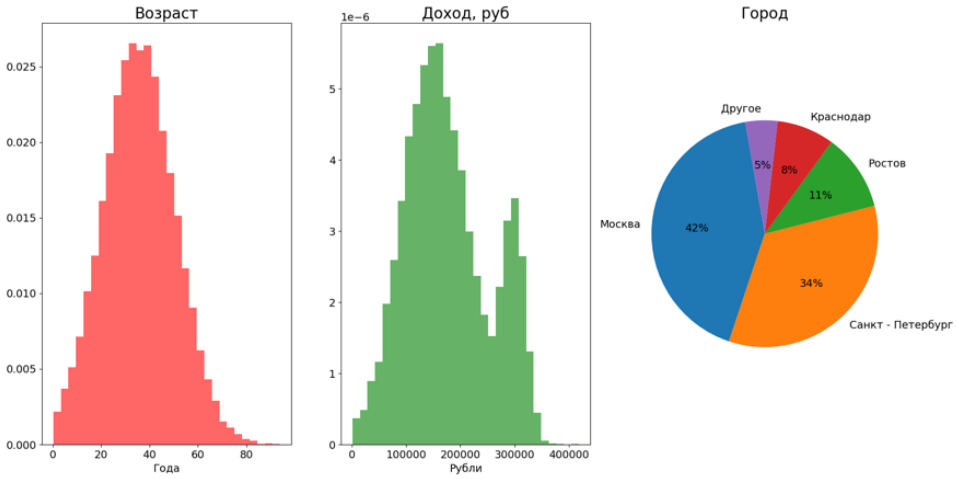
Решение:

- Количество покупок с чеком до 500 рублей увеличилось — неверно, так как по графику видно уменьшение количества таких покупок
- Средняя сумма заказа в сервисе увеличилась — верное утверждение
- Медиана суммы заказа не изменилась — неверное утверждение, так как медиана увеличилась

- Максимальное значение суммы заказа выросло — неверное утверждение, так как в обоих случаях максимальное значение составляет 20 000

7. (4 балла) Аналитики провели анализ пользователей социальной сети «Галактика».

   На графиках ниже представлены распределения по возрасту, доходу и городу проживания пользователей социальной сети.



   Проанализируйте полученные графики и выберите верные утверждения, следующие из них:

   - Пользователей из Москвы столько же, сколько из Санкт-Петербурга и Краснодара вместе (+)
   - Средний возраст аудитории составляет 48 лет
   - Мода заработка находится от 145 до 155 тысяч рублей в месяц (+)
   - В социальной сети не могут регистрироваться пользователи моложе 18 лет
   - В Москве самая большая заработная плата

   Решение:

   - Пользователей из Москвы столько же, сколько из Санкт-Петербурга и Краснодара вместе — верное утверждение. Пользователей из Санкт-Петербурга и Краснодара — 42, что совпадает с количеством в Москве
   - Средний возраст аудитории составляет 48 лет — неверное утверждение, так как по графику средний возраст составляет примерно 40 — 42 года
   - Мода заработка находится от 145 до 155 тысяч рублей в месяц — верное утверждение
   - В социальной сети не могут регистрироваться пользователи моложе 18 лет — неверное утверждение, так как по графику видно, что есть люди меньше 18 лет
   - В Москве самая большая заработная плата — неверное утверждение, так как такой вывод нельзя сделать по данным графикам

8. (6 баллов) Совет директоров хочет выйти на новый рынок в Китае. Для этого они запросили информацию по 3 крупнейшим компаниям на этом рынке с целью их покупки. Ваша задача — проанализировать эти компании и определить, какая из них принесет наибольшую прибыль (в млн $) через 5 лет, предполагая, что темпы роста капитала не изменятся.

Название	**Капитал, млн $**	**Ежегодный прирост капитала за последние 5 лет, %**	**Доля прибыли от капитала, %**
Engine Motors	15	5	4
Speed Cross	18	3	6
Fast Fuel	10	6	7

Выберите верное название компании:

- Engine Motors
- Speed Cross (+)
- Fast Fuel

Решение:

- Прибыль компании через 5 лет рассчитывается по формуле:
  Прибыль = Капитал $\times(1 + \text{Рост капитала})^5 \times$ Доля прибыли

В соответствии с этой формулой получим следующие значения

Engine Motors: 0,77 млн

Speed Cross: 1,25 млн

Fast Fuel: 0,94 млн

9. (4 балла) Вы работаете в сервисе доставки готовой еды, и вам поручили проанализировать показатели потенциальных партнеров для их подключения к сервису.

Ниже представлено дерево метрик:



Название	Средний чек заказа	Количество заказов в месяц	Количество клиентов в месяц
Fast and Cheap	400	1 000	500
Избушка	650	800	600
Суши Роллы	900	400	300

Выберите верные утверждения:

- Fast and Cheap имеет наибольший оборот
- Среднее количество заказов на клиента одинаково в Избушке и в Суши Роллы (+)
- В Fast and Cheap количество заказов на клиента в два раза больше, чем в Избушке
- Оборот Избушки примерно на 44% больше, чем компании Суши Роллы (+)

Решение:

- Fast and Cheap имеет наибольший оборот — неверное утверждение, так как наибольший оборот имеет Избушка
- Среднее количество заказов на клиента одинаково в Избушке и в Суши Роллы — верное утверждение, так как 800 / 600 = 400 / 300 = 1.33
- В Fast and Cheap количество заказов на клиента в два раза больше, чем в Избушке — неверное утверждение, так как в Fast and Cheap — 1000 / 500 = 2 заказа на клиента, а в Избушке — 1.33
- Оборот Избушки примерно на 44% больше, чем компании Суши Роллы — верное утверждение, так как оборот Избушки равен 520 тыс, а оборот Суши Роллы — 360 тыс. (520 / 360 — 1) * 100% = 44%

10. (2 балла) Василий устроился работать аналитиком в инвестиционный фонд на зарплату в 150 тыс. рублей в месяц. На жизнь он тратит 2 тыс. рублей в день, а остальное вкладывает под 10% годовых. Сколько Василий заработает с помощью инвестиций с первой зарплаты через год, если он устроился в июне (в нем 30 дней)?

    Проценты в банке начисляются единожды по истечению срока вклада

    Решение:

    Вложенная сумма равна 150 — 2 * 30 = 90, следовательно заработает 0.1 * 90 = 9 тысяч рублей

11. (4 балла) Компания X подключила удаленный колл-центр из 10 человек для продажи своих услуг по телефону. Команде колл-центра за месяц удалось совершить 2 000 звонков, 5% из которых заканчивались продажей. Компанию X не устроил этот результат, и они предложили к текущей команде колл-центра добавить столько же менеджеров по продажам, но более высокой квалификации. У квалифицированного сотрудника вероятность продажи по телефону повышается в 2 раза. Сколько продаж совершит компания X в следующем месяце при условии, что количество звонков увеличится пропорционально количеству сотрудников и они распределяются поровну между квалифицированными и неквалифицированными сотрудниками? Предполагается, что один звонок, если он успешный, соответствует одной продаже.

Решение:

Количество продаж от исходных менеджеров — 2 000 * 0.05 = 100

Количество продаж от менеджеров с более высокой квалификацией — 2 000 * 0.1 = 200

Итого 300

12. (2 балла) Вы с коллегами решили организовать стартап по доставке еды. Проанализировав конкурентов, вы обнаружили, что средний чек одной доставки составляет 1 000 рублей, один клиент заказывает в среднем 2 раза в месяц, а прибыль составляет 30% от полученных средств (учитываются только производственные издержки).

    Однако для привлечения клиентов нужно инвестировать средства в маркетинг.

    Для этого вы купили рекламу в социальных сетях за 10 млн рублей, которую увидят 2 млн человек. Какую ожидаемую прибыль с учетом инвестиций в маркетинг вы получите в первый месяц работы, если человек оформляет заказ после просмотра рекламы с вероятностью 5%?

    Решение:

    Количество клиентов: 2 млн * 5% = 100K -> оборот 100K*1K среднего чека * 2 заказа в месяц * 30% доли прибыли = 60 млн

    Прибыль за вычетом маркетингового бюджета составляет 50 млн.

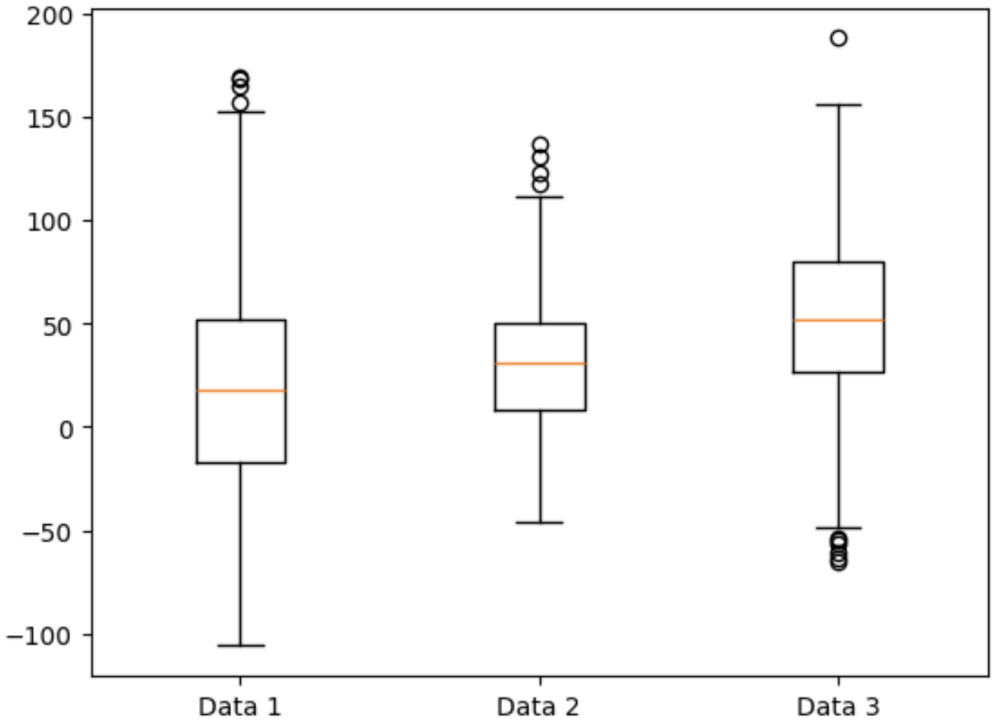
13. (6 баллов) Известно, что в компании Гамма количество клиентов прирастает ежегодно на 5%. Через сколько лет количество клиентов удвоится, при условии, что темпы роста сохранятся? Ответ округлите до целого числа.

    Решение:

    Пусть n — количество лет, а количество текущих клиентов X.
    Тогда $2X = X*(1 + 0.05)^n$.

    $2 = 1.05^n$ -> $n = \log_{1.05} 2 \approx 14$

14. (4 балла) Перед вами диаграммы, нарисованные по трём разным наборам данных:



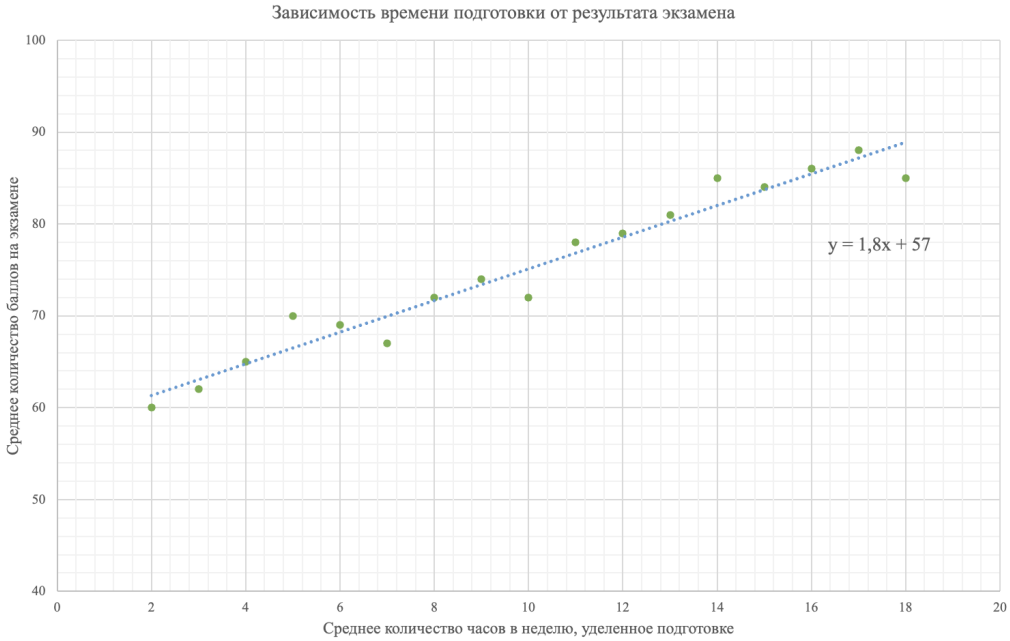
Выберите верные ответы:

- Данные 2 имеют наименьшую дисперсию (+)
- Во 2-м наборе данных среднее выше, чем медиана (+)
- В 3-м наборе данных среднее выше, чем медиана (-)
- Данные 1 имеют наименьшее стандартное отклонение

Решение:

- Данные 2 имеют наименьшую дисперсию — верное утверждение, так как данные 2 имеют наименьшую длину усов
- Во 2-м наборе данных среднее выше, чем медиана — верное утверждение, так как есть выбросы в большую сторону, которые увеличат среднее значение
- В 3-м наборе данных среднее выше, чем медиана — неверное утверждение, так как есть выбросы в меньшую сторону, что свидетельствует о том, что среднее значение будет ниже, чем медиана
- Данные 1 имеют наименьшее стандартное отклонение — неверное утверждение, так как стандартное отклонение является корнем из дисперсии. Следовательно наименьшее стандартное отклонение имеют тот же набор данных, которые имеют наименьшую дисперсию

15. (6 балла) Отдел эффективности образования поставил перед школой задачу повысить средний балл учеников за экзамены. Для этого учителя собрали данные со всех учеников в школе и провели исследование зависимости между временем, затраченным на подготовку, и баллами на экзамене.

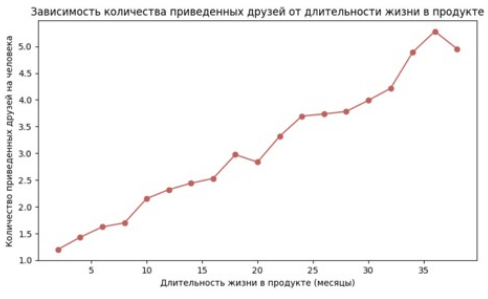


Определите, какое количество часов в неделю необходимо было затратить на подготовку, чтобы претендовать на 100 баллов на экзамене? Ответ округлите до целого числа

Решение:

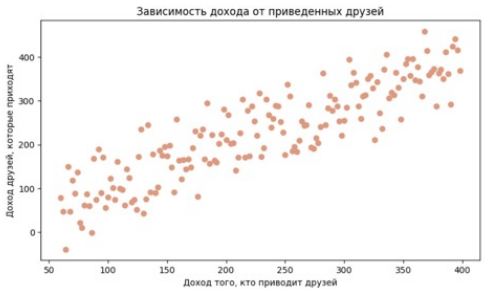
Из уравнения регрессии следует, что 100 баллов было бы получено если потратить (100 — 57) / 1.8 = 24

16. (4 балла) Команда маркетинговых аналитиков проанализировала результаты работы акции «Приведи друга» и получила следующие результаты. На графиках, где по оси X находится дата, каждое деление по оси — это начало периода









Выберите утверждения, которые следуют из графиков:

- Наличие подписки у клиента повышает вероятность приведения друга
- Летом количество приведенных друзей меньше, чем осенью (+)
- Чем выше доход у клиента, тем в среднем выше доход у его друзей (+)
- За год человек в среднем приводит 3 друзей

Решение:

- Наличие подписки у клиента повышает вероятность приведения друга — неверное утверждение, так как не из одного графика не можем сделать такой вывод
- Летом количество приведенных друзей меньше, чем осенью- верное утверждение, на правом верхнем графике можно увидеть эту зависимость
- Чем выше доход у клиента, тем в среднем выше доход у его друзей — верное утверждение, на правом нижнем графике видна эта зависимость
- За год человек в среднем приводит 3 друзей — верное утверждение. Из левого верхнего графика можно сделать такой вывод

17. (6 баллов) Известно, что если компания выпускает на рынок продукт, то он с вероятностью 70% начинает приносить прибыль на горизонте 5 лет. В компании решили выпустить 3 продукта. Какова вероятность, что хотя бы один из них начнет приносить прибыль на горизонте 5 лет? Каждый продукт развивается независимо от других. Ответ округлите до сотых

    Решение:

    Вероятность неуспеха 30%. Тогда вероятность, что хотя бы 1 продукт будет принесет прибыль равна 1 — 0.3^3 = 0.97

18. (4 балла) Маркетологи в компании «Мастер на все руки» провели анализ акций, которые они проводили в последнее время. Выяснилось, что по акции «Купи молоток и получи пилу в подарок» за покупками в следующем месяце вернулось 30% клиентов, а по акции «Время красить забор» — 25%. При этом акция «Купи молоток и получи пилу в подарок» была доступна только 40% клиентов, остальным была доступна акция «Время красить забор». Каждому клиенту доступна только 1 акция. Какая доля клиентов вернулась за покупками в следующем месяце благодаря маркетинговым акциям? Ответ дайте в процентах

Решение:

0,4 * 0,3 = 0,12 — доля клиентов, которая вернулась по акции «Купи молоток и получи пилу в подарок»

0,6*0,25 = 0,15 — доля клиентов, которая вернулась по акции «Время красить забор»

Итого 0,27 или 27%

19. (6 баллов) В кофейне при покупке двух напитков дают подарок, состоящий из 2 элементов. В качестве элемента подарка могут быть:

    - промокод на скидку в онлайн-кинотеатре
    - купон на следующую покупку
    - печенье с предсказанием
    - браслет
    - многоразовая кружка для кофе
    - упаковка мармеладных конфет

    Элементы в подарок попадают случайно, при этом повторяться в подарке они не могут. Какова вероятность, что в подарок достанется кружка для кофе?

    Решение:

    Всего вариантов: 6 * 5 / 2 = 15

    Вариантов с кружкой: 5

    Вероятность: 5/15 = 1/3 = 0,33

20. (2 балла) В сервисе Т-мобайл хотят запустить розыгрыш повышенного кэшбэка, который имеет следующие условия:

    - если последняя цифра номера телефона заканчивается нулем, то ты получаешь 20% кэшбэка в следующем месяце
    - если последняя цифра 1, то получаешь 1% кэшбэка
    - если последняя цифра 2 — получаешь 2% кэшбэка

    и так далее

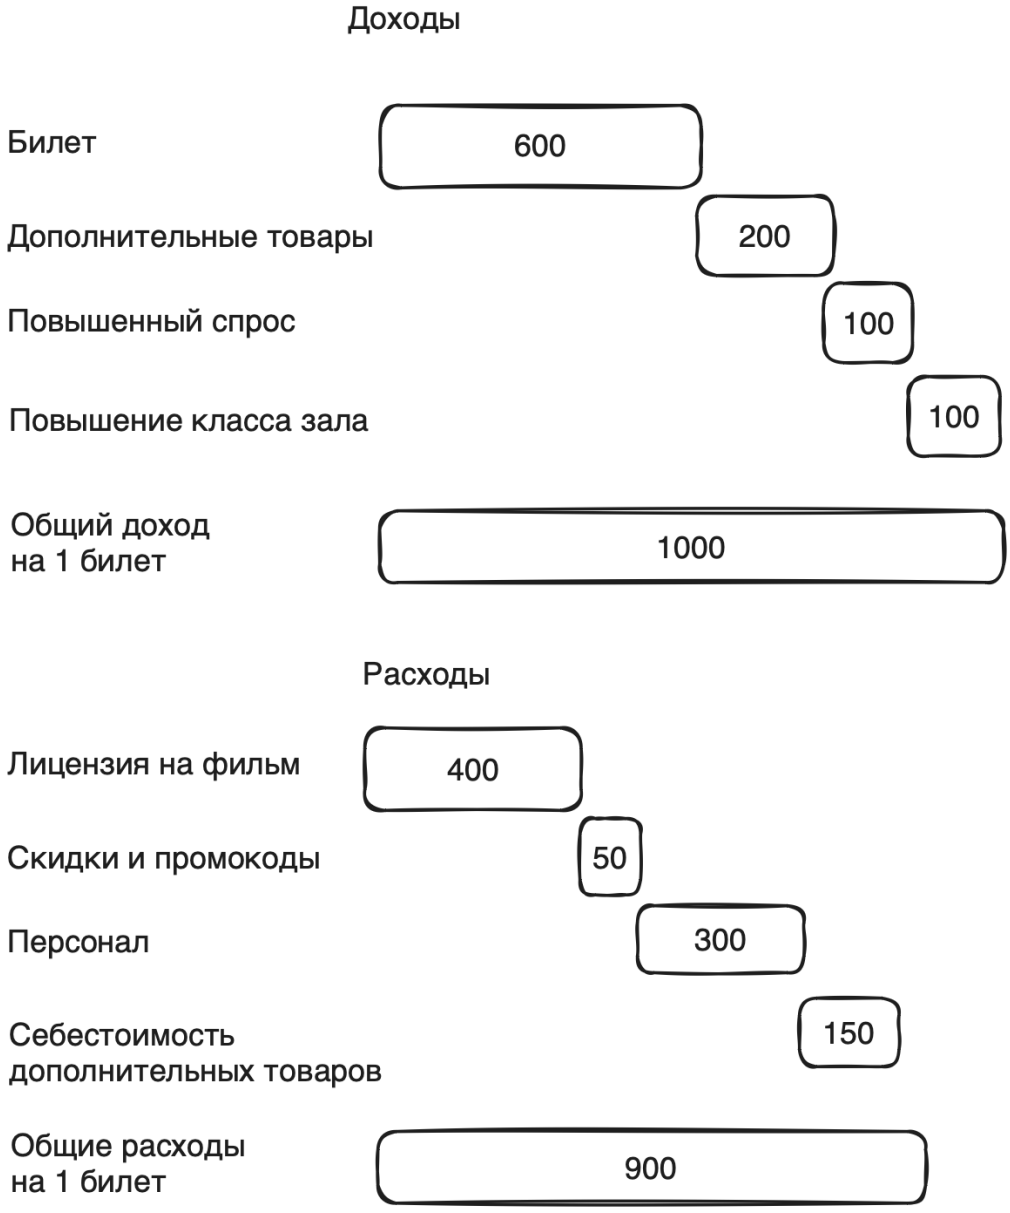
    Сколько в среднем процентов кэшбэка мы заплатим каждому пользователю?

    Выдача телефонных номеров происходит случайным образом. Ответ округлите до десятых

    Решение:

    1/10 — вероятность встретить каждую конкретную цифру -> в среднем мы будем выдавать 1/10 (1 + … + 9 + 20) = 6.5%

21. (4 балла) Сеть кинотеатров «Синема» проанализировала средние доходы и расходы от продажи 1 билета в кино:



На сколько процентов необходимо сократить расходы на персонал, чтобы увеличить прибыль кинотеатра на 30%, при условии что все остальные статьи доходов и расходов останутся без изменения?

Решение:

Текущая прибыль составляет 100 рублей. Увеличенная прибыль — 130 рублей. Следовательно необходимо снизить расходы на персонал на 30 рублей, что равно 10%.

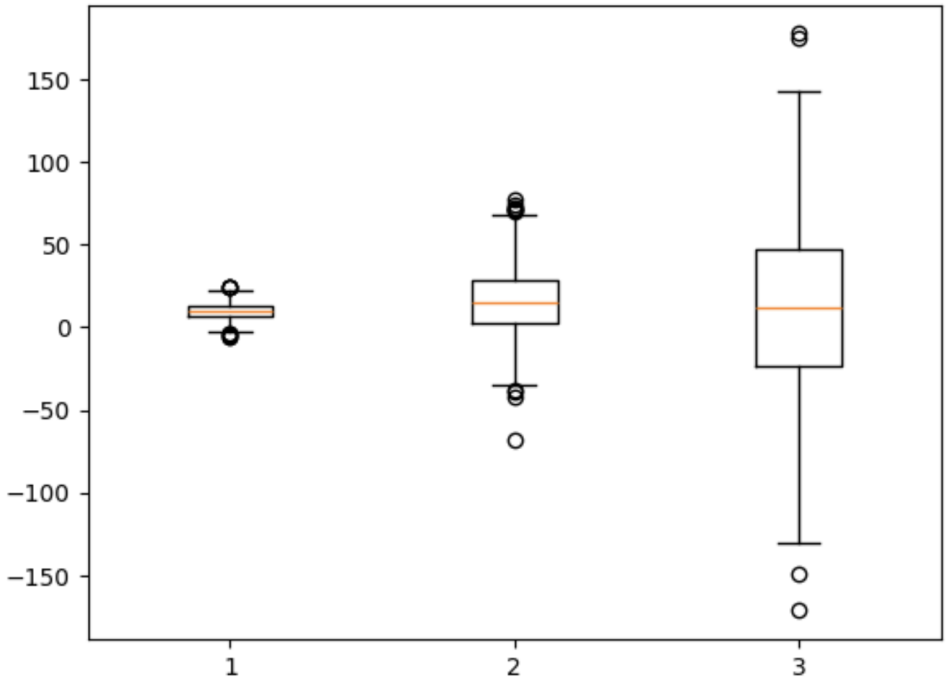
22. (6 баллов) Сервис такси «Покатушки» выявил зависимость прибыли (Y), получаемой с заказа, от тарифа за километр, у.е. (X): $y = -2x^2+20x+300$

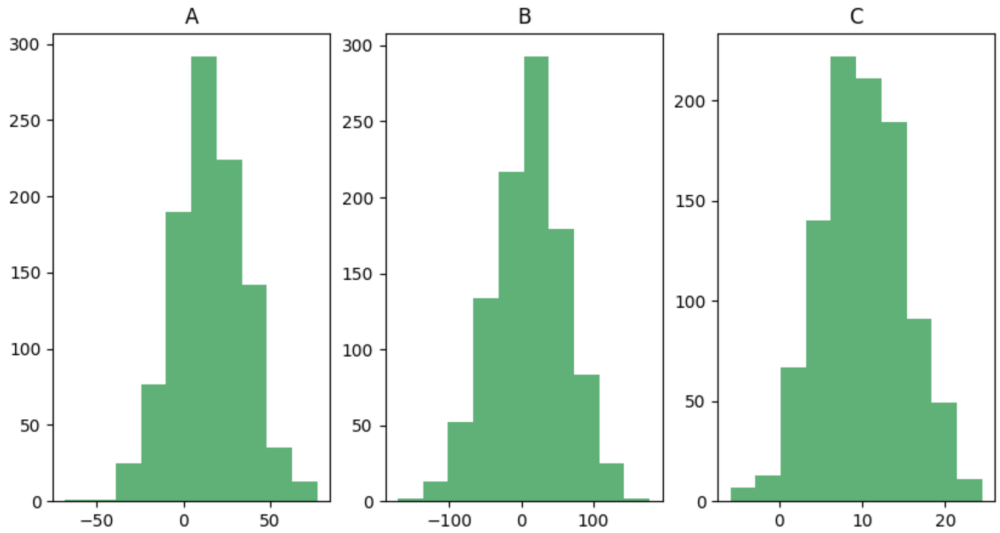
    Какое наибольшее значение прибыли в у.е. может получить сервис от одного заказа?

    Решение:

    Наибольшее значение x = -20 / (-2*2) = 5 -> y = -2 * 25 + 20 * 5 + 300 = 350

23. (2 балла) Для трех наборов данных построили боксплоты и гистограммы. Сопоставьте боксплоты с гистограммами





Ответ: A2, B3, C1

Решение:

Ключем к решению задачи является разброс данных. Наименьший разброс имеет 1 боксплот, следовательно ему соответствует гистограмма C

3 боксплот имеет самый большой разброс, следовательно ему соответствует гистограмма B 2 боксплоту соответствует гистограмма A

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ

Т БАНК

1. (2 балла) Вы работаете помощником следователя в небольшом городе. Недавно вам передали ряд дел об ограблениях. Вы составили статистику по этим делам и выяснили, что в половине ограбленных домов имеется домашнее животное. Также вы знаете, что в вашем городе домашние питомцы имеются в 80% домов. Какой вывод вы можете сделать исходя из этой информации?

   а) Преступник чаще грабит дома, в которых есть домашние животные

   б) Преступник реже грабит дома, в которых есть домашние животные (+)

   в) Преступник одинаково часто грабит дома, где есть домашние животные и где их нет

   г) Предоставленной информации недостаточно, чтобы сделать любой из перечисленных выше ответов

2. (4 балла) Офлайн-магазин электроники продает телефоны и аксессуары для них. В магазине можно купить любое количество телефонов и/или аксессуаров. Известно, что за сентябрь аксессуаров (в штуках) было продано больше, чем телефонов. При этом 1% от всех товаров вернули. Выберите одно или несколько верных утверждений, которые следуют из этой информации:

   а) В сентябре вернули не более 1% аксессуаров

   б) В сентябре был хотя бы один покупатель, который приобрел в магазине и телефон, и аксессуар

   в) В сентябре был хотя бы один покупатель, который приобрел в магазине телефон без аксессуара

   г) Аксессуаров без телефонов купили больше, чем телефонов без аксессуаров

   д) Среди других утверждений нет таких, которые следуют из приведенной в условии информации (+)

3. (2 балла) Вам стало интересно узнать, сколько читают ученики старших классов в вашей школе. Вы создали небольшой опрос и планируете свои дальнейшие действия. Для этих целей вы решили в течение недели общаться со всеми старшеклассниками, которые ходят на литературный кружок. В результате полученная вами оценка количества часов чтения, скорее всего:

   а) Будет завышена (+)

   б) Будет занижена

   в) Будет близка к истинному значению

   г) Может быть как завышена, так и занижена

4. (4 балла) В городе Монетск каждый житель является клиентом по крайней мере одного из двух банков-конкурентов: банка А или банка Б. Аналитикам банка А Пете и Свете поручили посчитать, какой процент жителей города Монетск одновременно является и клиентами банка А, и клиентами банка Б.

   Петя запустил в приложении банка А опрос, доступный клиентам-жителям Монетска. Света опрашивала людей, выходящих из разных отделений банка Б в городе Монетск. И Петя, и Света задавали один и тот же вопрос: «Являетесь ли вы клиентом банка-конкурента?» (т.е. банка Б для клиентов банка А — и наоборот). Оба опроса проводились одновременно и длились неделю. В Петином опросе приняли участие 12095 человек, из них 9434 являются, по их словам, клиентами банка Б. В опросе Светы приняли участие 2274 человека, из них 978 являются, по их словам, клиентами банка А.

   В результате Петя сделал вывод, что 78% жителей является клиентами обоих банков, а Света — что таких жителей 43%. Выберите одно или несколько верных утверждений, которые следуют из этой информации:

   а) Оценка Пети ближе к истинному значению, чем оценка Светы

   б) Оценка Светы ближе к истинному значению, чем оценка Пети

   в) Истинное значение больше, чем оценки Светы и Пети

   г) Истинное значение находится между оценками Светы и Пети

   д) Недостаточно данных, чтобы сделать выводы (+)

5. (5 баллов) Некоторые пассажиры, купившие авиабилеты, не пользуются ими из-за опоздания на рейс или изменения планов. Понимая это, авиакомпании иногда специально продают больше билетов, чем есть мест в самолете, — это называется овербукинг.

   Компания «Птичка Airlines» продала 190 билетов на рейс со 188 местами. За 15 минут до окончания регистрации трое из 190 пассажиров не зарегистрированы на рейс — Елена С., Владислав П. и Ирина К. По статистике предыдущих перелетов Елена С. придет на регистрацию с вероятностью 90%, Владислав П. — 50%, Ирина К. — 40%. Какова вероятность того, что кому-то из пришедших на регистрацию пассажиров не хватит мест? Дайте ответ в процентах. Если ответ представлен в виде дроби, округлите его до целого числа. Единицы измерения указывать не нужно.

   Ответ: 65

6. (5 баллов) Компания, занимающаяся продажей и доставкой цветов, решила подарить пяти своим самым активным пользователям 8 одноразовых промокодов: 7 промокодов на скидку 15% и 1 промокод — на 25%. Каждый промокод должен быть отправлен ровно одному пользователю. При этом один пользователь может как не получить ничего, так и получить несколько промокодов. Также компания приняла решение не отправлять все 7 промокодов на 15% одному пользователю. Сколько существует способов раздать все 8 промокодов? В ответе единицы измерения указывать не нужно.

   Примечание: Промокоды на 15% считайте одинаковыми: формально это разный набор букв и цифр, но важен именно эффект промокода, а не уникальное сочетание символов.

   Ответ: 1625

7. (5 баллов) Лена работает маркетологом в банке. Один из продуктов банка — платная подписка, дающая различные бонусы клиенту. Лена решила прорекламировать подписку клиентам без подписки, которые больше всего похожи на клиентов с подпиской. Для этого она случайным образом выбрала группу А из 1000 клиентов с подпиской и группу Б из 100 000 клиентов без подписки. Далее Лена рассчитала значения 8 параметров для каждого из клиентов в каждой из групп: возраст, доход в рублях в месяц и т.д. Все параметры — целые неотрицательные числа. Оказалось, что не существует двух клиентов из выбранных 101 000 с полностью совпадающим набором значений этих 8 параметров.

   Дальше Лена объединила выборки А и В и произвела стандартизацию значений каждого из 8 параметров для всех 101 000 клиентов по формуле:

$$x_{new} = \frac{x - m}{\sqrt{D}}$$

   Здесь x — значение параметра, m — среднее арифметическое значений параметра, D — дисперсия значений параметра, а x_{new} — стандартизированное значение параметра.

   Так Лена получила для каждого клиента X из группы А значения стандартизированных 8 параметров x_1, x_2, ..., x_8, а для каждого клиента Y из группы В — значения y_1, y_2, ...,y_8. Наконец, для каждого клиента X из группы А Лена решила найти «наиболее похожего» клиента Y из группы В. «Наиболее похожий» на X клиент из группы В — такой, для которого принимает наименьшее значение (среди всех клиентов в группе В с их набором y_1, y_2, ..., y_8) сумма:

   $S = |x_1 - y_1| + |x_2 - y_2| + \cdots + |x_8 - y|$

   Выберите одно или несколько верных утверждений:

   а) Один и тот же клиент из группы В мог оказаться «наиболее похожим» на нескольких клиентов из группы А. (+)

   б) Все значения всех параметров из групп А и В после стандартизации будут лежать в интервале [–1; 1].

   в) Может найтись клиент из группы А, для которого сумма значений всех параметров после стандартизации окажется равна 0. (+)

   г) Некоторые клиенты из группы В могли не оказаться «наиболее похожими» ни на кого из клиентов из группы А. (+)

   д) Среди других утверждений нет верных.

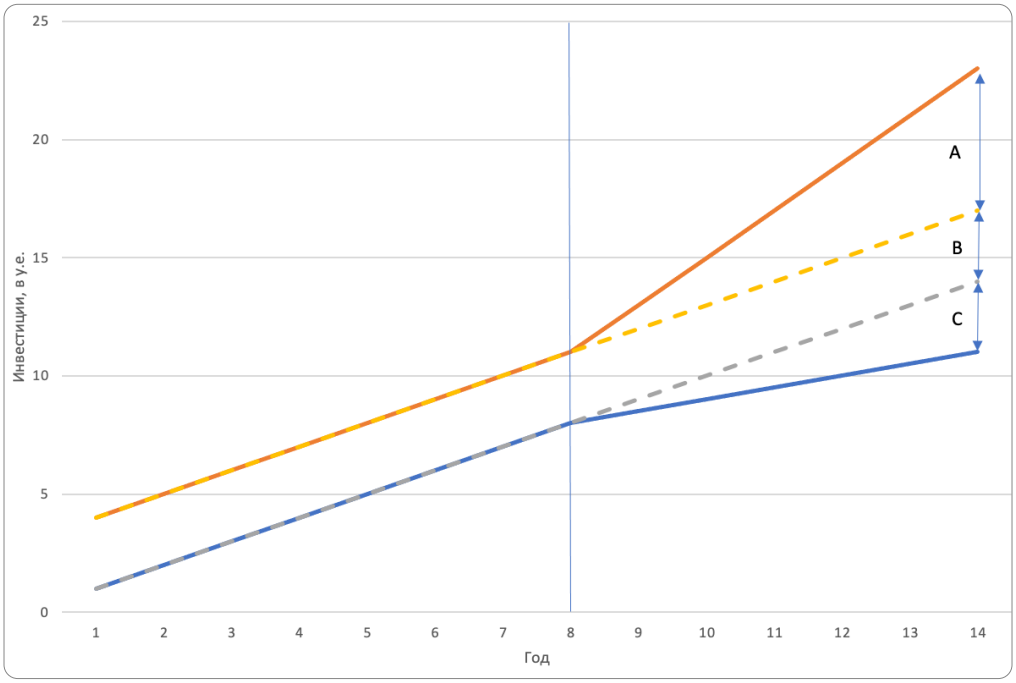
8. (4 балла) Вы являетесь главным экономистом в одной далекой-далекой стране, где есть два очень похожих друг на друга региона — Север и Юг. В 8-й год правительство Севера решает снизить налоги на инвестиции, на Юге этого не происходит. В это же время и Север, и Юг сталкиваются с резким ужесточением требований для выдачи кредитов на инвестиции, что оказывает сдерживающий эффект на оба региона.

   В 14-м году вас просят оценить эффект от снижения налогов. Собранные данные показывают, что инвестиции ведут себя, как показано на рисунке ниже. Оранжевая линия — фактическая динамика инвестиций на Севере, синяя — на Юге. Желтая

и серая пунктирные линии показывают, как вели бы себя инвестиции, если бы в 8-м году ничего не менялось.

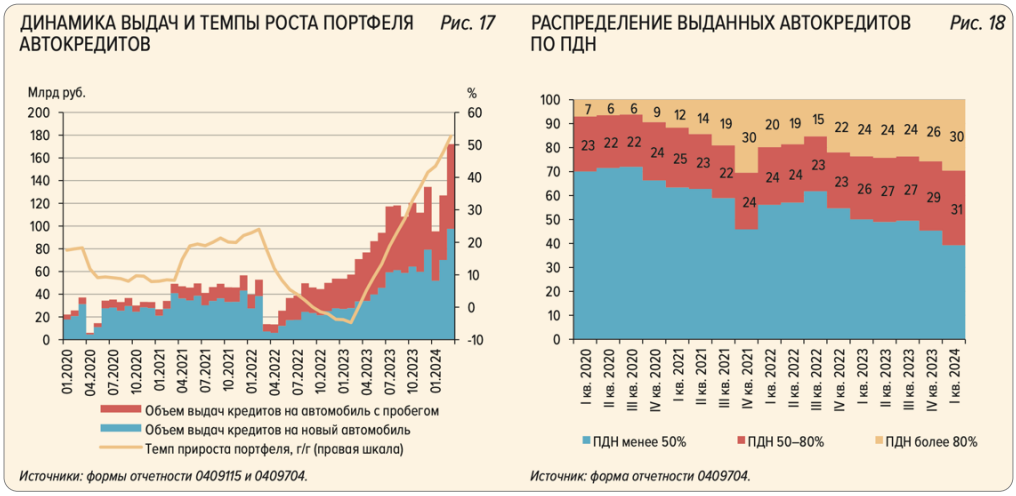
Величина отрезка A составляет 6 условных единиц (у.е.), отрезка B — 3 у.е., отрезка C — 3 у.е. Чему будет равен эффект от снижения налогов в условных единицах?

Запишите ответ в виде числа. Если ответ представлен в виде дроби, округлите его до целого. Единицы измерения указывать не нужно.



Ответ: 9

9. (5 баллов)



На рисунке представлены два графика из Обзора финансовой стабильности ЦБ РФ за 4-й квартал 2023 и 1-й квартал 2024 года (cbr.ru/Collection/Collection/File/49151/4_q_2023_1_q_2024.pdf).

На левом графике представлены объемы выдач кредитов на автомобили с 2020 года, а также темп прироста общего портфеля автокредитов. На правом графике представлено распределение кредитов по величине показателя долговой нагрузки (ПДН) — это отношение между суммой ежемесячных платежей человека по всем кредитам к ежемесячному доходу. Чем выше данный показатель, тем больше шанс, что заемщик не сможет вернуть взятый кредит.

Выберите одно или несколько верных утверждений, которые можно сделать на основе данных графиков

а) В первом квартале 2023 года портфель автокредитов снижался (+)

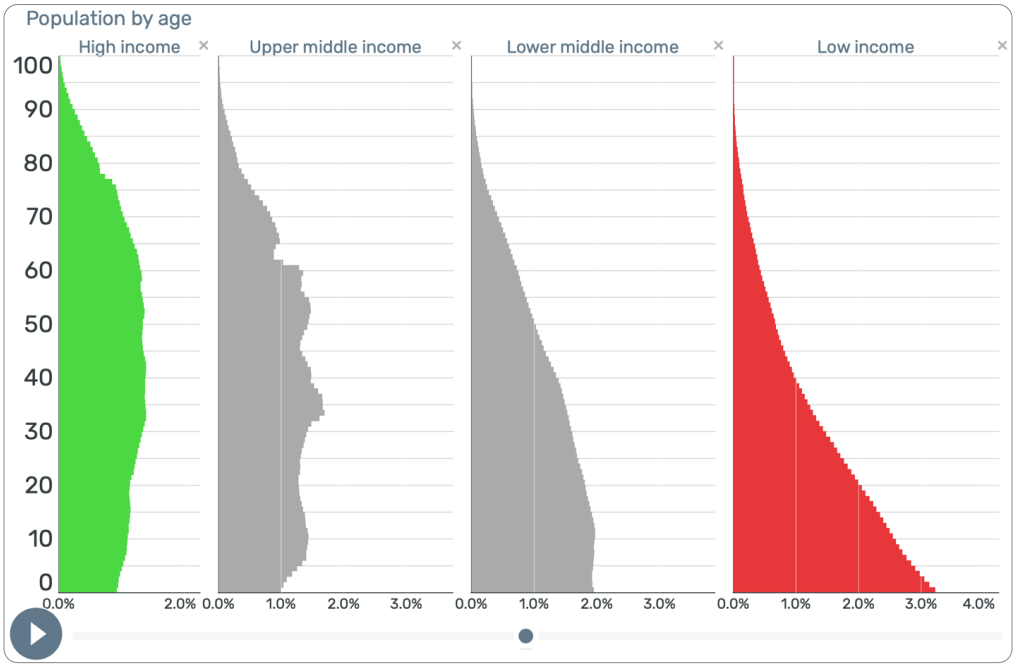
б) За 2022-2023 гг. рискованность выданных автокредитов выросла (+)

в) В январе 2021 года доля кредитов, выданных на автомобили с пробегом, в общем объеме выдач была выше, чем доля этих кредитов в январе 2023-го

г) Объем выдач кредитов на новые автомобили вырос с 2022 года (+)

д) Среди других утверждений нет верных.

10. (5 баллов) На графиках представлены возрастные пирамиды (гистограммы, отражающие процент населения в каждой возрастной группе; в данном случае их 100 — одна группа соответствует каждому возможному значению возраста от 0 до 100) для четырех групп стран (на основе классификации Всемирного банка blogs.worldbank.org/en/opendata/new-world-bank-group-country-classifications-income-level-fy24), слева для самых богатых стран, справа — для самых бедных. Данные представлены на 2023 год.



Выберите одно или несколько верных утверждений на основе данных графиков:

а) В самых богатых странах происходит снижение отношения числа детей до 10 лет к численности взрослых в возрасте 30-40 лет в течение последних 10 лет (+)

б) В странах с самым высоким уровнем дохода в среднем самое молодое население

в) В странах с высоким доходом в ближайшие годы необходимо уделить большое внимание постройке новых школ для обеспечения всех детей возможностью для обучения

г) В странах с доходом ниже среднего люди в среднем моложе, чем в странах с низким доходом.

д) Среди других утверждений нет верных.

11. (5 баллов) Компании часто берут кредиты в виде кредитных линий. В этом случае по договору с банком они могут в любой момент получить деньги, но только в определенных пределах. Обычно эти пределы восстанавливаются, если компания вовремя возвращает деньги. Исследования показывают, что в кризисные времена компании начинают чаще пользоваться этим видом кредитования.

Группа ученых решила выяснить, как активно российские компании использовали кредитные линии во время пандемии. Для этого они собрали данные о всех кредитах, которые компании получили в период пандемии, а также за несколько лет до этого для сравнения. Также кредиты разделили на две группы: старые кредитные линии и новые кредиты. Затем рассчитали долю кредитов первой группы в общем объеме займов. Эти доли в зависимости от финансового состояния компании (платит ли она зарплату, расплачивается ли по старым займам вовремя, получает ли прибыль и т. д.), был ли этот период пандемийным или нет, а также относится ли компания к отрасли, сильно пострадавшей от кризиса (например, туризм, общественное питание и т. д.), показали на графиках.

Рис. 3. Доля ранее одобренных кредитных линий в общем объеме займов для компаний из не подверженных пандемии отраслей, в разбивке по децилям

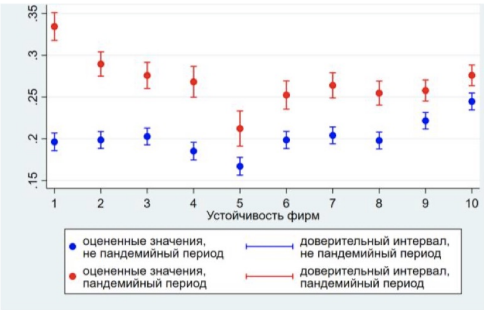
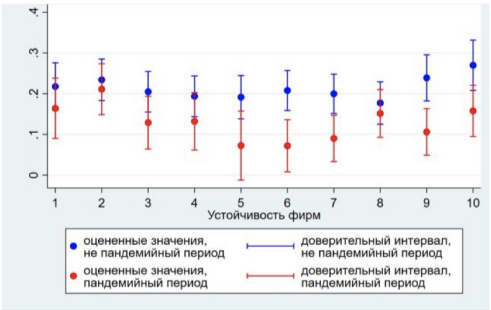


Рис. 4. Доля ранее одобренных кредитных линий в общем объеме займов для компаний из подверженных пандемии отраслей, в разбивке по децилям



Примечание. Оценки и доверительные интервалы для доли ранее одобренных кредитных линий в общем объеме заимствований компаний. Синие точки показывают оцененные значения для допандемийного периода (2017–2019 гг.), красные точки – для периода пандемии (2020 г.). Более высокие значения переменной «Устойчивость фирм» по шкале X соответствуют более высоким оценкам вероятности дефолта заемщика (то есть по более низким финансовым показателям компании).

Выберите одно или несколько верных утверждений, которые можно сделать на основании анализа указанных графиков

Обратите внимание на подпись к графикам: чем больше показатель «Устойчивость фирм», тем хуже финансовое состояние компании.

а) В допандемийный период менее устойчивые компании среди не подверженных пандемийному шоку активнее использовали имеющиеся у них кредитные линии по сравнению с более устойчивыми (+)

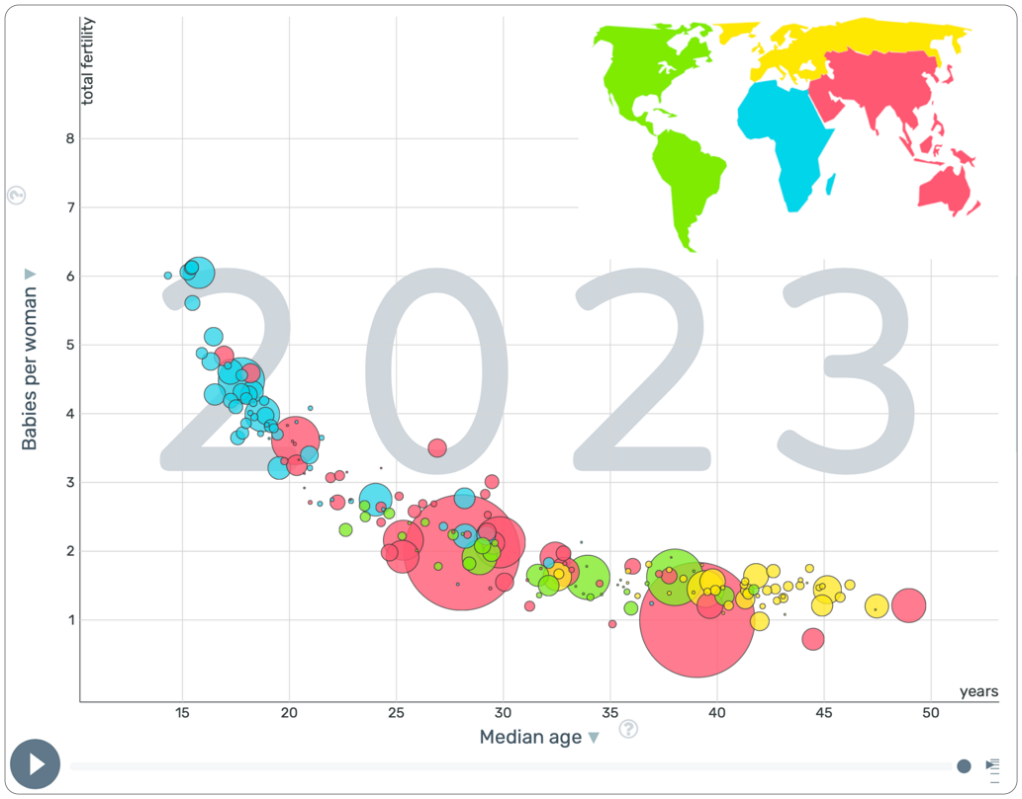
б) В пандемийный период компании из отраслей, подверженных пандемии, использовали кредитные линии с такой же интенсивностью или меньше по сравнению с допандемийным периодом (+)

в) В период до пандемии компании из отраслей, подверженных пандемии, использовали кредитные линии более интенсивно, чем компании из не подверженных шоку отраслей

г) В пандемийный период среди компаний, подверженных влиянию шока, самые финансово устойчивые (1-3 группы) и самые финансово неустойчивые (8-10 группы) компании пользовались кредитными линиями значительно активнее, чем средние фирмы (5 группа).

д) Среди других утверждений нет верных.

12. (5 баллов) На графике представлено распределение стран в зависимости от медианного возраста жителей (по горизонтальной оси), количества детей, приходящихся на одну женщину (по вертикальной оси) и размера населения (размер кругов).



Цвет кругов обозначает разные регионы мира в соответствии с картой.

Выберите одно или несколько верных утверждений, которые следуют из приведенного графика:

а) В среднем медианный возраст людей в странах Африки ниже, чем в Азии (включая Австралию, Океанию и Новую Зеландию) (+)

б) Среднее количество детей на одну женщину в Америке ниже, чем в Европе (включая Россию)

в) Чем больше численность населения в стране, тем больше медианный возраст людей в стране

г) Среднее количество детей на женщину в среднем отрицательно взаимосвязано с медианным возрастом (+)

д) Среди других утверждений нет верных.

13. (2 балла) Если бы вы хотели оценить взаимосвязь среднего количества детей на одну женщину и медианного возраста, то какое из приведенных ниже уравнений подошло бы больше всего для данных на рисунке выше? Выберите один верный вариант ответа. Все коэффициенты положительные.

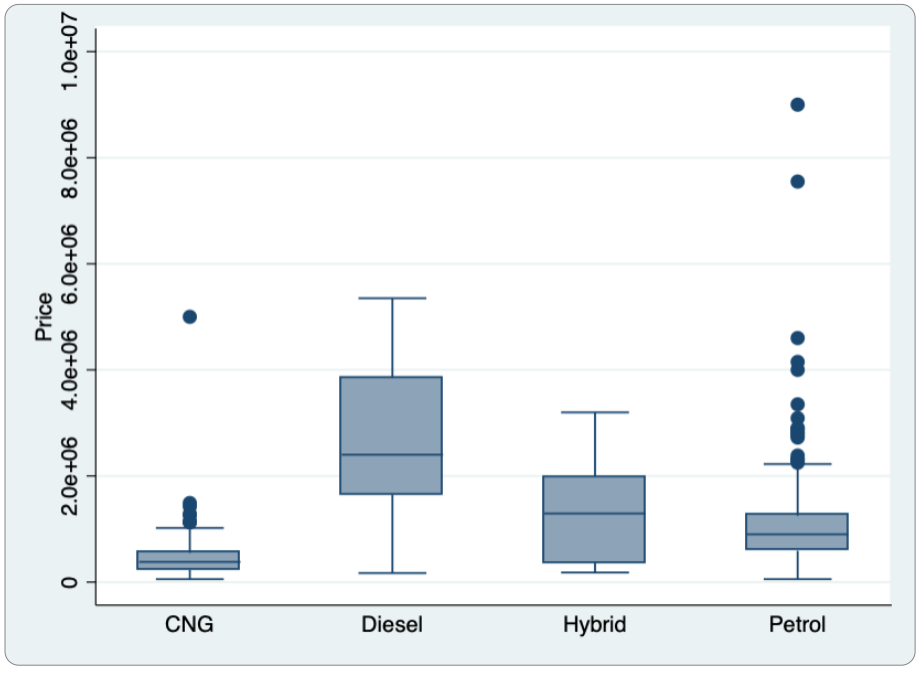
а) b0-b1*Median Age

б) b0+b1/Median Age (+)

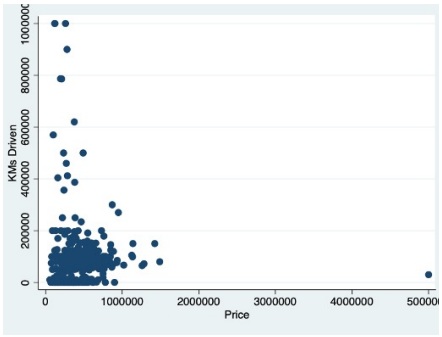
в) b0-b1*(Median Age)^2

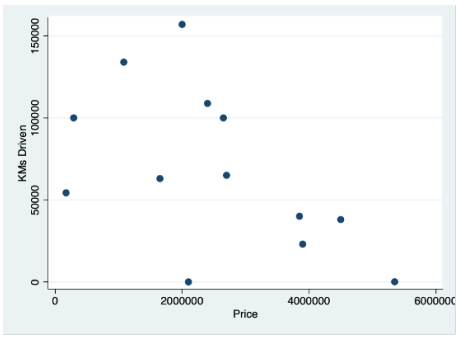
г) b0+b1*(Median Age)^0,5

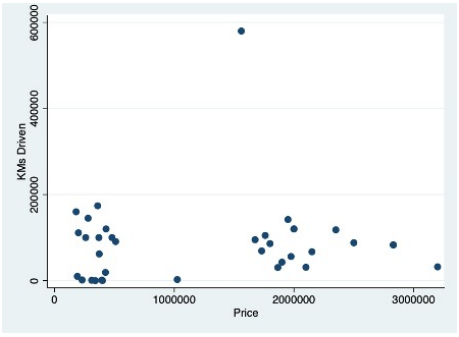
14. (8 баллов, по 2 за каждое верное соотнесение) На графике представлены «ящики с усами», отражающие распределение цены автомобиля в зависимости от типа топлива.

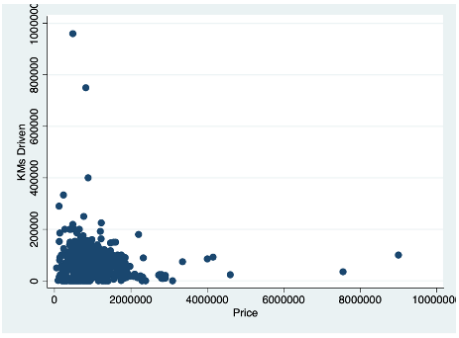


Также имеется 4 диаграммы рассеяния для изучения зависимости цены автомобиля от пробега по подгруппам в зависимости от топлива. Соотнесите диаграммы рассеивания и тип топлива автомобилей.

а) 

б) 

в) 

г) 

а) CNG

б) Diesel

в) Hybrid

г) Petrol

15. (4 балла)

С использованием данных из предыдущей задачи была оценена регрессионная модель зависимости цены автомобиля от года выпуска, пробега, типа топлива и новизны. Получилось следующее уравнение (все перечисленные коэффициенты значимы на 5% уровне значимости):

Price= -62376.67 — 0.137*KMs + 31.52*Year — 277.11*D_used + 1863.70*D_Diesel

KMs — пробег в тысячах километров, Year — год выпуска, D_used — переменная, равная 1, если автомобиль подержанный («с пробегом»), и 0, если новый. Последняя переменная — индикатор для типа топлива (то есть D_Diesel=1, если это двигатель работает на дизельном топливе, и 0, если тип топлива другой).

Возьмем два автомобиля: оба 2 000 года выпуска, подержанные, на дизельном топливе. Пробег одного из них составляет 60 тыс. километров, а второго — 120 тыс. километров. На сколько процентов дороже будет первый автомобиль по сравнению со вторым, исходя из полученных оценок модели? Укажите ответ в процентах от меньшей цены. Если ответ представлен в виде дроби, округлите его до двух знаков после запятой. Единицы измерения указывать не нужно.

Ответ: 0,37%

16. (3 балла)

Для более полного анализа факторов, влияющих на цену, было решено учесть влияние марки автомобиля, и в модель добавили индикатор на одну из наиболее часто встречающихся марок, а именно на марку Suzuki. Коэффициент для данной переменной и 95% доверительный интервал для него получились следующие:

Переменная	**Коэффициент**	**[доверительный интервал]**	
Suzuki	-443.64	-514.86	-372.42

Какой вывод о взаимосвязи марки автомобиля на цену вы можете сделать исходя из данной информации? Выберите верный вариант ответа:

а) При прочих равных автомобили марки Suzuki стоят значимо дешевле, чем средний автомобиль другой марки (+)

б) При прочих равных автомобили марки Suzuki стоят значимо дороже, чем средний автомобиль другой марки

в) При прочих равных автомобили марки Suzuki значимо не отличаются по стоимости от среднего автомобиля другой марки

г) Приведенных данных недостаточно для того, чтобы сделать вывод о значимости различия цены автомобиля Suzuki от среднего автомобиля другой марки

17. (8 баллов) (Файл 17_Распределение средств клиентов банков)

В таблице приведены данные о распределении средств различных клиентов банков (физических лиц, юридических лиц и ИП) в зависимости от размера вкладов: например, группа «<100» означает, что в этой группе собраны все вклады размером 100 тыс. рублей и меньше. Для каждого такого диапазона размера вклада и типа вкладчика указана общая сумма всех депозитов в млрд. руб. Вклады до 1,4 млн рублей являются застрахованными. Если размер вклада превышает эту сумму, то он является частично застрахованным.

Выберите одно или несколько верных утверждений, которые можно сделать на основе анализа данной таблицы.

а) На 1 июля 2024 г. в общем объеме вкладов наибольшую долю составляют депозиты размером более 20 млн. рублей (+)

б) За 1 квартал 2024 года увеличилась общая сумма вкладов физических лиц на депозиты в каждом диапазоне объемов

в) Темп прироста полностью застрахованных депозитов в июне 2024 года превышает среднемесячный темп прироста таких депозитов в 2023 году (+)

г) Все группы депозитов юридических лиц объемом свыше 700 тыс. рублей в апреле и мае 2024 года росли в среднем темпом не менее 1% в месяц (+)

д) Среди других утверждений нет верных.

18. (8 баллов) (Файлы 18_Hit.csv и 18_Hits_description)

    В файле 1 собраны данные о более чем 14 тысячах популярных песен с 1899 года. Описание характеристик можно найти в файле 2. Проанализируйте представленные данные и выберите одно или несколько верных утверждений.

    а) Более энергичные песни в среднем более громкие (+)

    б) Средняя продолжительность песни в жанре Folk составляет не более 3 минут

    в) Усредненное по песням жанра значение переменной Acoustic является наибольшим для жанра Jazz (+)

    г) В жанре Country более продолжительные композиции являются более популярными, в то время как в жанре EDM напротив более популярны менее продолжительные композиции (+)

    д) Среди других утверждений нет верных.

19. (4 балла, по 1 баллу за каждый верно заполненный пропуск)
    (Файл 19_stock_price_1.xlsx)

    Ваши коллеги из другого отдела занимаются учетом стоимости имеющихся у компании акций разных компаний. Данные за июль 2024 года представлены в файле stock_price. Там отражена цена акций четырех компаний: A, B, C и D. Вашим коллегам важно, чтобы цена у каждой бумаги была каждый день, и они прибегают к следующему способу вести свой учет. В дни, когда торги проводились (т.е. в рабочие дни), указывается цена закрытия этого дня. В другие дни (выходные или праздники) указывается последняя известная цена. Они просят вас отранжировать бумаги по их риску и выявить наиболее и наименее рискованные акции.

    В качестве меры риска предполагается использование коэффициента вариации. Вы также знаете, что при анализе рисков следует ориентироваться только на дни, когда проводятся торги. Исходя из сделанных вами расчетов, запишите в соответствующие поля название наиболее и наименее рискованной акции, а также укажите коэффициент вариации для них. В ответе необходимо указать название компании и коэффициент вариации в долях. Если ответ представлен в виде дроби, округлите его до трех знаков после запятой. Единицы измерения указывать не нужно.

    Наиболее рискованная акция компании «B», коэффициент вариации «0,059»(0,058)

    Наименее рискованная акция компании «C», коэффициент вариации «0,033»(0,032)

20. (8 баллов + 4 балла) (Файл 20_employee_v1.csv и 20_employee_description)

    Вам необходимо проанализировать ряд показателей, связанных с исполнением трудовых функций работников некоторой компании. Данные представленны в файле employee.csv, их описание — в файле employee_description.

    В частности, руководство компании интересуется, какое влияние коллеги оказывают друг на друга (например, более производительные коллеги мотивируют работать лучше, или напротив, мешают выполнению обязанностей). В данном случае коллегами будут считаться люди, выполняющие одну и ту же роль (jobrole) в одном и том же департаменте (department) в одном регионе (state) в один и тот же год проведения оценивания. Оно проводится раз в год, дата проведения указана

в переменной reviewdate.

Взаимосвязи между количественными переменными рассматриваются на основе статистической значимости соответствующей корреляции, количественной переменной с категориальной — на основе статистически значимого различия в средних на подвыборках.

Часть 1. Расчеты (8 баллов, по одному за каждое верно заполненное число)

Заполните пропуски необходимыми значениями. Если ответ представлен в виде дроби, округлите его до двух знаков после запятой. Единицы измерения указывать не нужно.

Для исследования влияния опыта работы сотрудника на оценку его деятельности менеджером будем ориентироваться на два показателя: время работы в компании и время работы на последней должности. В среднем продолжительность работы в компании в годах составляет приблизительно 5,70 (5,26), а продолжительность работы на последней должности в годах — 2,81 (2,59).

При анализе влияния коллег мы фокусируем внимание на 6015 (1154, 6013, 1153) работниках из общего количества в 6059, у которых есть хотя бы один коллега. Среднее значение оценок менеджера, полученных коллегами, составляет 3,47. В среднем у таких работников имеется 50.54 (50,56) коллег.

Коэффициент корреляции времени работы в компании с оценкой менеджера составляет 0.02. Коэффициент корреляции времени работы на последней должности с оценкой менеджера составляет 0.03. Коэффициент корреляции оценки менеджера для работника с оценкой его коллег составляет 0,00.

Часть 2. Интерпретация (4 балла, по 1 баллу за каждый верно заполненный пропуск)

Выберите наиболее подходящее заполнение пропуска из предложенных вариантов исходя из анализа, проведенного в Части 1.

Переходя к анализу влияния опыта работы, время работы в компании (связано положительно/связано отрицательно/не связано) с оценкой менеджера. Время работы на последней должности с оценкой менеджера (связано положительно/связано отрицательно/не связано).

Корреляция средней оценки менеджера, полученной коллегами, и показателя с оценкой самих работников является (положительной/отрицательной/нулевой), что говорит о (наличии положительной/наличии отрицательной/отсутствии) взаимосвязи между оценкой работника и средней оценкой его коллег.

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ

Т БАНК

1. (2 балла) Вы работаете помощником следователя в небольшом городе. Недавно вам передали ряд дел об ограблениях. Вы составили статистику по этим делам и выяснили, что в половине ограбленных домов имеется домашнее животное. Также вы знаете, что в вашем городе домашние питомцы имеются в 30% домов. Какой вывод вы можете сделать исходя из этой информации?

   а) Преступник чаще грабит дома, в которых есть домашние животные (+)

   б) Преступник реже грабит дома, в которых есть домашние животные

   в) Преступник одинаково часто грабит дома, где есть домашние животные и где их нет

   г) Предоставленной информации недостаточно, чтобы сделать любой из перечисленных выше ответов

2. (4 балла) Офлайн-магазин электроники продает телефоны и аксессуары для них. В магазине можно купить любое количество телефонов и/или аксессуаров. Известно, что за октябрь аксессуаров (в штуках) было продано меньше, чем телефонов. При этом 2% от всех товаров вернули. Выберите одно или несколько верных утверждений, которые следуют из этой информации:

   а) В октябре вернули не более 2% аксессуаров

   б) В октябре вернули не более 2% телефонов

   в) В октябре был хотя бы один покупатель, который приобрел в магазине и телефон, и аксессуар

   г) Аксессуаров без телефонов купили меньше, чем телефонов без аксессуаров

   д) Среди других утверждений нет таких, которые следуют из приведенной в условии информации (+)

3. (2 балла) Вам стало интересно узнать, сколько читают ученики старших классов в вашей школе. Вы создали небольшой опрос и планируете свои дальнейшие действия. Для этих целей вы решили в течение недели общаться со всеми старшеклассниками, которые ходят в спортивную секцию. В результате полученная вами оценка количества часов чтения:

   а) Будет завышена

   б) Будет занижена (+)

   в) Будет близка к истинному значению

   г) Может быть как завышена, так и занижена

4. (4 балла) В городе Рублёв каждый житель является клиентом по крайней мере одного из двух банков-конкурентов: банка А или банка Б. Аналитикам банка А Пете и Свете поручили посчитать, какой процент жителей города Рублёв одновременно является и клиентами банка А, и клиентами банка Б.

   Петя запустил в приложении банка А опрос, доступный клиентам-жителям Рублёва. Света опрашивала людей, выходящих из разных отделений банка Б в городе Рублёв. И Петя, и Света задавали один и тот же вопрос: «Являетесь ли вы клиентом банка-конкурента?» (т.е. банка Б для клиентов банка А — и наоборот). Оба опроса проводились одновременно и длились неделю. В Петином опросе приняли участие 8725 человек, из них 7155 являются по их словам клиентами банка Б. В опросе Светы приняли участие 1984 человека, из них 1012 являются по их словам клиентами банка А.

   В результате Петя сделал вывод, что 82% жителей является клиентами обоих банков, а Света что таких жителей 51%. Выберите одно или несколько верных утверждений, которые следуют из этой информации:

   а) Оценка Пети ближе к истинному значению, чем оценка Светы

   б) Оценка Светы ближе к истинному значению, чем оценка Пети

   в) Истинное значение меньше, чем оценки Светы и Пети

   г) Истинное значение находится между оценками Светы и Пети

   д) Недостаточно данных, чтобы сделать выводы (+)

5. (5 баллов) Некоторые пассажиры, купившие авиабилеты, не пользуются ими из-за опоздания на рейс или изменения планов. Понимая это, авиакомпании иногда специально продают больше билетов, чем есть мест в самолете, — это называется овербукинг.

   Компания «Птичка Airlines» продала 191 билет на рейс со 189 местами. За 15 минут до окончания регистрации трое из 191 пассажира не зарегистрированы на рейс — Аркадий А., Михаил П. и Валерия Е. По статистике предыдущих перелетов Аркадий А. придет на регистрацию с вероятностью 80%, Михаил П. — 50%, Валерия Е. — 30%. Какова вероятность того, что кому-то из пришедших на регистрацию пассажиров не хватит мест? Дайте ответ в процентах. Если ответ представлен в виде дроби, округлите его до целого числа. Единицы измерения указывать не нужно.

   Ответ: 55

6. (5 баллов) Компания, занимающаяся доставкой еды, решила подарить пяти своим самым активным пользователям 7 одноразовых промокодов: 6 промокодов на скидку 15% и 1 промокод — на 25%. Каждый промокод должен быть отправлен ровно одному пользователю. При этом один пользователь может как не получить ничего, так и получить несколько промокодов. Также компания приняла решение не отправлять все 6 промокодов на 15% одному пользователю. Сколько существует способов раздать все 7 промокодов? В ответе единицы измерения указывать не нужно.

   Примечание: Промокоды на 15% считайте одинаковыми: формально это разный набор букв и цифр, но важен именно эффект промокода, а не уникальное сочетание символов.

   Ответ: 1025

7. (5 баллов) Люба работает маркетологом в банке. Один из продуктов банка — платная подписка, дающая различные бонусы клиенту. Люба решила прорекламировать подписку клиентам без подписки, которые больше всего похожи на клиентов с подпиской.

   Для этого она случайным образом выбрала группу A из 1000 клиентов с подпиской и группу Б из 100 000 клиентов без подписки. Далее Люба рассчитала значения 8 параметров для каждого из клиентов в каждой из групп: возраст, доход в рублях в месяц и т.д. Все параметры — целые неотрицательные числа. Оказалось, что не существует двух клиентов из выбранных 101 000 с полностью совпадающим набором значений этих 8 параметров.

   Дальше Люба объединила выборки A и B и произвела стандартизацию значений каждого из 8 параметров для всех 101 000 клиентов по формуле:

$$x_{new} = \frac{x - m}{\sqrt{D}}$$

   Здесь x — значение параметра, m — среднее арифметическое значений параметра, D — дисперсия значений параметра, а x_{new} — стандартизированное значение параметра.

   Так Люба получила для каждого клиента X из группы A значения стандартизированных 8 параметров x_1, x_2, ..., x_8, а для каждого клиента Y из группы B — значения y_1, y_2, ..., y_8. Наконец, для каждого клиента X из группы A Люба решила найти «наиболее похожего» на него клиента Y из группы B. «Наиболее похожий» на X клиент из группы B — такой, для которого принимает наименьшее значение (среди всех клиентов в группе B с их набором y_1, y_2, ..., y_8) сумма:

   $S = |x_1 - y_1| + |x_2 - y_2| + \cdots + |x_8 - y|$

   Выберите одно или несколько верных утверждений:

   а) Может найтись клиент из группы A, для которого значение какого-то из параметров после стандартизации окажется больше 1. (+)

   б) Может найтись клиент из группы B, для которого значение всех параметров после стандартизации окажется меньше 0. (+)

   в) Каждый клиент из группы B мог оказаться «наиболее похожим» не более чем на одного клиента из группы A.

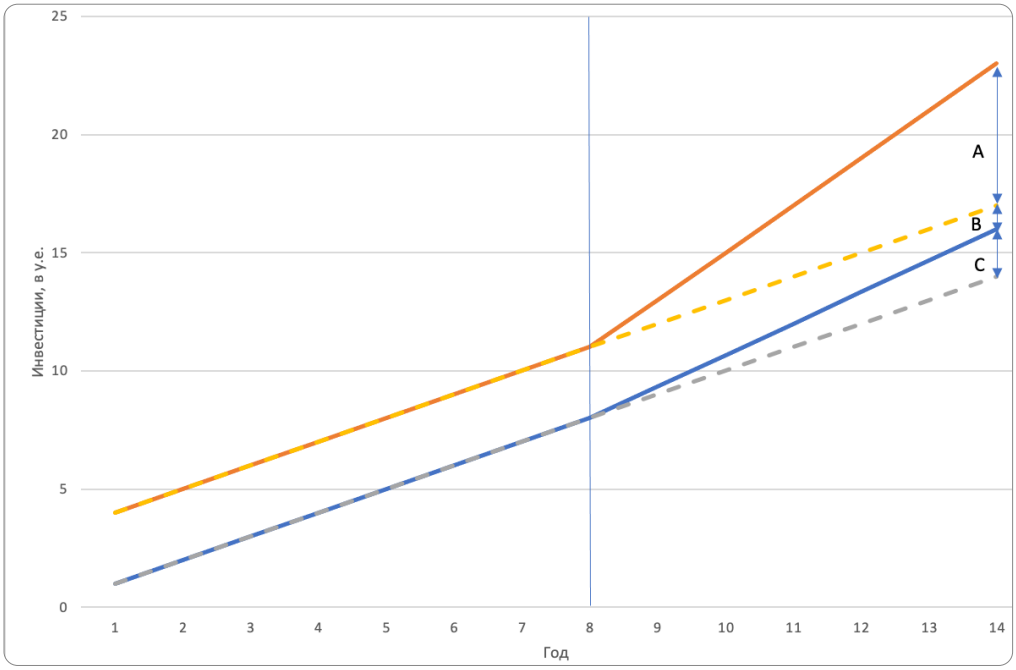
   г) Для некоторых клиентов из группы A могло найтись несколько «наиболее похожих» на них клиентов из группы B. (+)

   д) Среди других утверждений нет верных.

8. (4 балла) Вы являетесь главным экономистом в одной далекой-далекой стране, где Север и Юг отделены друг от друга, но при этом они очень похожи друг на друга. В 8-й год правительство Севера решает снизить налоги на инвестиции. Однако в это же время и Север, и Юг сталкиваются с резким ростом популярности инвестиций в страну у иностранцев, что оказывает стимулирующий эффект на оба региона.

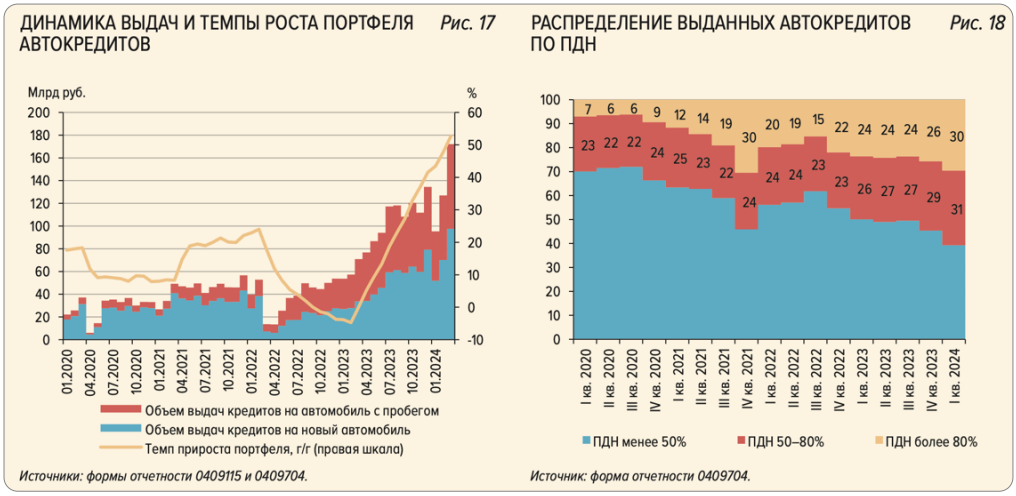
   В 14-м году вас просят оценить эффект от снижения налогов. Собранные данные показывают, что инвестиции ведут себя, как показано на рисунке ниже. Оранжевая линия — фактическая динамика инвестиций на Севере, синяя — на Юге. Желтая

и серая пунктирные линии показывают, как вели бы себя инвестиции, если бы в 8-м году ничего не менялось. Величина отрезка A составляет 6 условных единиц (у.е.), отрезка B — 1 у.е., отрезка C — 2у.е.. Чему будет равен эффект от снижения налогов в условных единицах? Запишите ответ в виде числа. Если ответ представлен в виде дроби, округлите его до целого. Единицы измерения указывать не нужно.



Ответ: 4

9. (5 баллов)



На рисунке представлены два графика из Обзора финансовой стабильности ЦБ РФ за 4-й квартал 2023 и 1-й квартал 2024 года (cbr.ru/Collection/Collection/File/49151/4_q_2023_1_q_2024.pdf).

На левом графике представлены объемы выдач кредитов на автомобили с 2020 года, а также темп прироста общего портфеля автокредитов. На правом графике представлено распределение кредитов по величине показателя долговой нагрузки

(ПДН) — это отношение между суммой ежемесячных платежей человека по всем кредитам к ежемесячному доходу. Чем выше данный показатель, тем больше шанс, что заемщик не сможет вернуть взятый кредит.

Выберите одно или несколько верных утверждений, которые можно сделать на основе данных графиков:

а) Во втором квартале 2022 года портфель автокредитов снижался

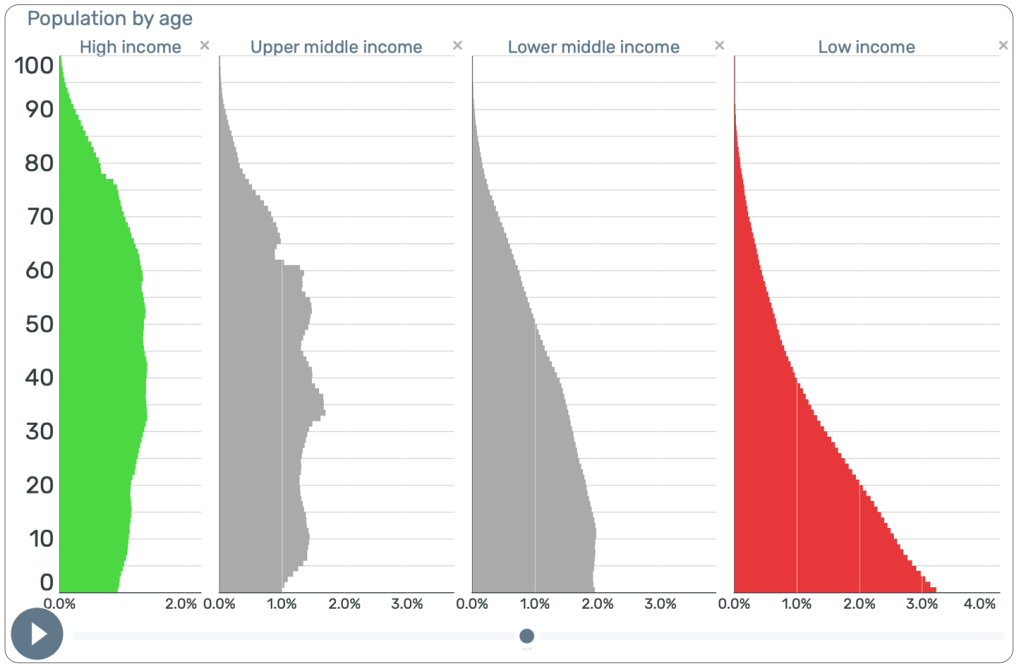
б) За 2021-2022 гг. рискованность выданных кредитов выросла (+)

в) В апреле 2022 года доля кредитов, выданных на новые автомобили, в общем объеме выдач ниже, чем доля этих кредитов в декабре 2021 (+)

г) Объем выдач кредитов на автомобили с пробегом вырос с 2022 года (+)

д) Среди других утверждений нет верных.

10. (5 баллов) На графиках представлены возрастные пирамиды (гистограммы, отражающие процент населения в каждой возрастной группе; в данном случае их 100 — одна группа соответствует каждому возможному значению возраста от 0 до 100) для четырех групп стран (на основе классификации Всемирного банка blogs.worldbank.org/en/opendata/new-world-bank-group-country-classifications-income-level-fy24), слева для самых богатых стран, справа — для самых бедных. Данные представлены на 2023 год.



Выберите одно или несколько верных утверждений на основе данных графиков:

а) В самых бедных странах происходит снижение отношения числа детей до 10 лет к численности взрослых в возрасте 30-40 лет в течение последних 10 лет

б) В странах с самым низким уровнем дохода в среднем самое старое население

в) В странах с самым низким уровнем дохода в ближайшие годы необходимо уделить большое внимание постройке новых школ для обеспечения всех детей возможностью для обучения (+)

г) В странах с доходом ниже среднего, люди в среднем старше, чем в странах с низким доходом. (+)

д) Среди других утверждений нет верных.

11. (5 баллов) Компании часто берут кредиты в виде кредитных линий. В этом случае по договору с банком они могут в любой момент получить деньги, но только в определенных пределах. Обычно эти пределы восстанавливаются, если компания вовремя возвращает деньги. Исследования показывают, что в кризисные времена компании начинают чаще пользоваться этим видом кредитования.

Группа ученых решила выяснить, как активно российские компании использовали кредитные линии во время пандемии. Для этого они собрали данные о всех кредитах, которые компании получили в период пандемии, а также за несколько лет до этого для сравнения. Также кредиты разделили на две группы: старые кредитные линии и новые кредиты. Затем рассчитали долю кредитов первой группы в общем объеме займов. Эти доли в зависимости от финансового состояния компании (платит ли она зарплату, расплачивается ли по старым займам вовремя, получает ли прибыль и т. д.), был ли этот период пандемийным или нет, а также относится ли компания к отрасли, сильно пострадавшей от кризиса (например, туризм, общественное питание и т. д.), показали на графиках.

Рис. 3. Доля ранее одобренных кредитных линий в общем объеме займов для компаний из не подверженных пандемии отраслей, в разбивке по децилям

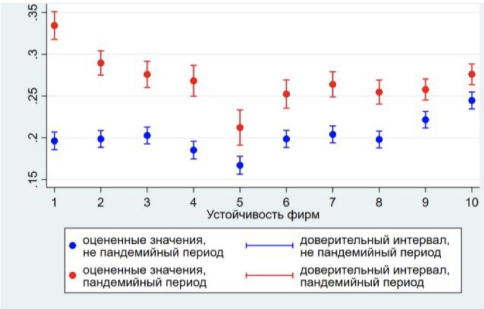
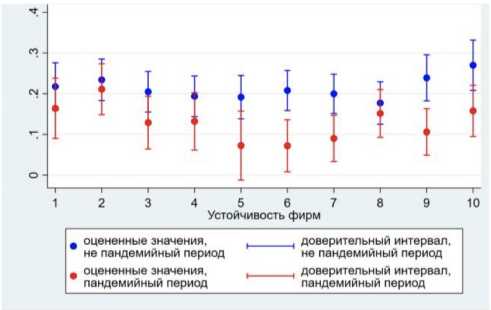


Рис. 4. Доля ранее одобренных кредитных линий в общем объеме займов для компаний из подверженных пандемии отраслей, в разбивке по децилям



Примечание. Оценки и доверительные интервалы для доли ранее одобренных кредитных линий в общем объеме заимствований компаний. Синие точки показывают оцененные значения для допандемийного периода (2017–2019 гг.), красные точки – для периода пандемии (2020 г.). Более высокие значения переменной «Устойчивость фирм» по шкале X соответствуют более высоким оценкам вероятности дефолта заемщика (то есть по более низким финансовым показателям компании).

Выберите одно или несколько верных утверждений, которые можно сделать на основании анализа указанных графиков?

Обратите внимание на подпись к графикам: чем больше показатель «Устойчивость фирм», тем хуже финансовое состояние компании.

а) В допандемийный период более устойчивые компании среди не подверженных пандемийному шоку активнее использовали имеющиеся у них кредитные линии по сравнению с менее устойчивыми

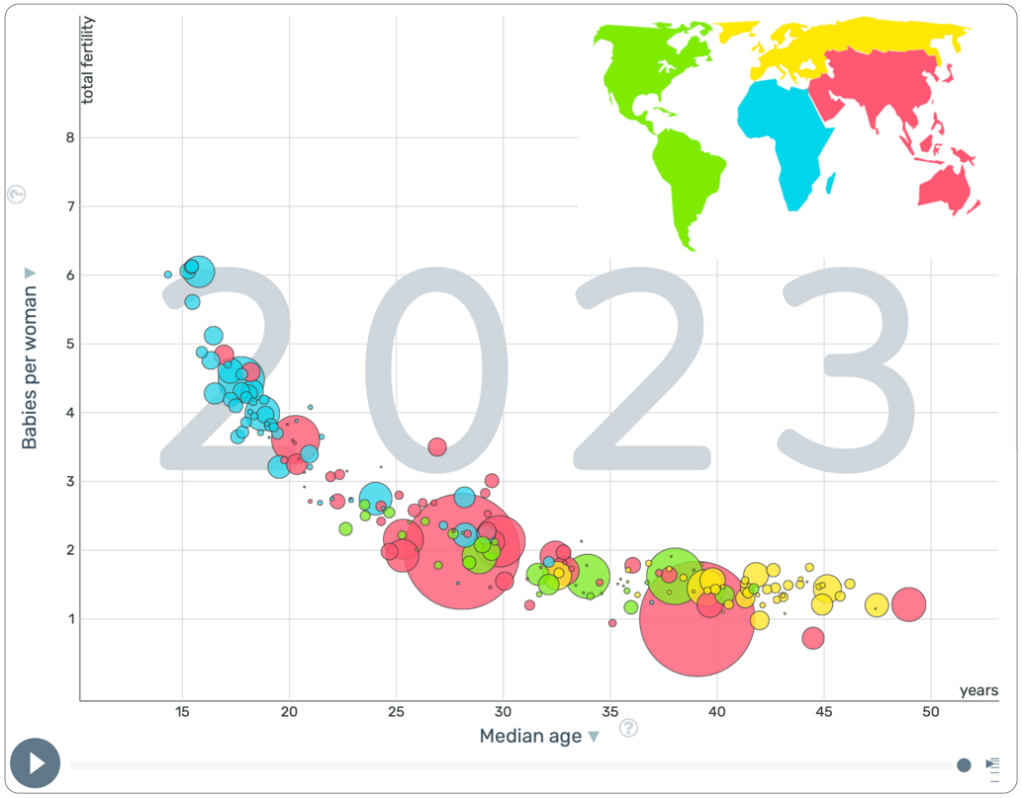
б) В пандемийный период компании из отраслей, подверженных пандемии, использовали кредитные линии с такой же интенсивностью или больше по сравнению с допандемийным периодом

в) В период пандемии компании из отраслей, подверженных пандемии, использовали кредитные линии менее интенсивно, чем компании из неподверженных шоку отраслей (+)

г) В пандемийный период среди компаний, не подверженных влиянию шока, самые финансово устойчивые (1-3 группы) и самые финансово неустойчивые (8-10 группы) компании пользовались кредитными линиями значительно активнее, чем средние фирмы (5 группа). (+)

д) Среди других утверждений нет верных.

12. (5 баллов) На графике представлено распределение стран в зависимости от медианного возраста жителей (по горизонтальной оси), количества детей, приходящихся на одну женщину (по вертикальной оси) и размера населения (размер кругов).



Цвет кругов обозначает разные регионы мира в соответствии с картой.

Выберите одно или несколько верных утверждений, следующие из приведенного графика:

а) В среднем медианный возраст людей в странах Африки ниже, чем в Америке (+)

б) Среднее количество детей на одну женщину в Африке выше, чем в Европе (включая Россию) (+)

в) Чем больше численность населения в стране, тем больше медианный возраст людей в стране

г) Среднее количество детей на женщину положительно взаимосвязано с медианным возрастом

д) Среди других утверждений нет верных.

13. (2 балла) Если бы вы хотели оценить взаимосвязь среднего количества детей на одну женщину и медианного возраста, то какое из приведенных ниже уравнений подошло бы больше всего для данных на рисунке выше? Выберите один верный вариант ответа. Все коэффициенты положительные.

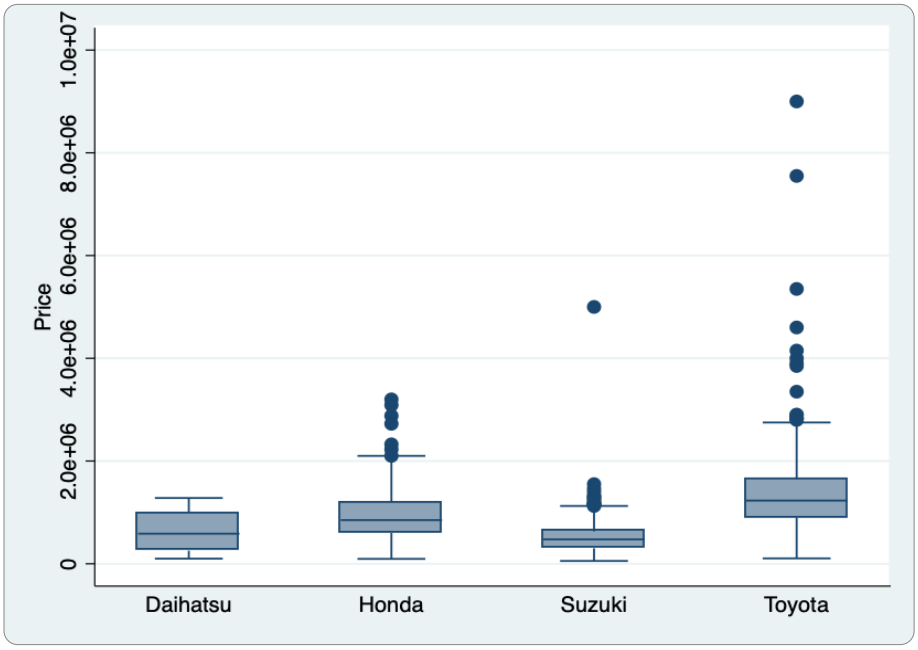
а) b0-b1*Median Age

б) b0-b1*(Median Age)^0,5 (+)

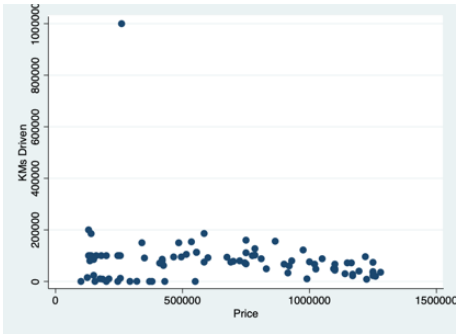
в) b0-b1*(Median Age)^2

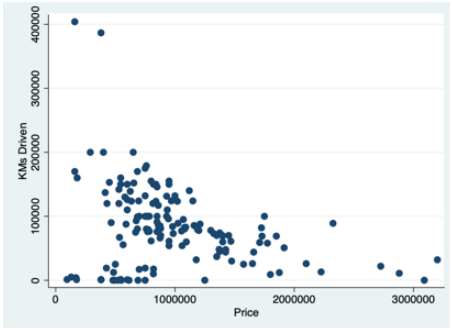
г) b0-b1/Median Age

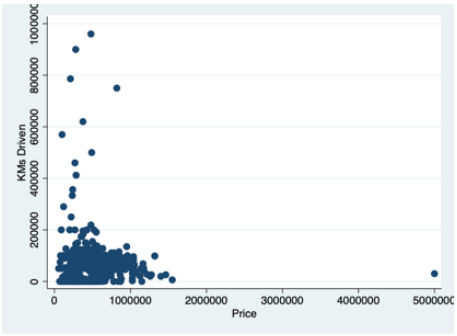
14. (8 баллов, по 2 за каждое верное соотнесение) На графике представлены ящики с усами, отражающие распределение цены автомобиля в зависимости от марки автомобиля.

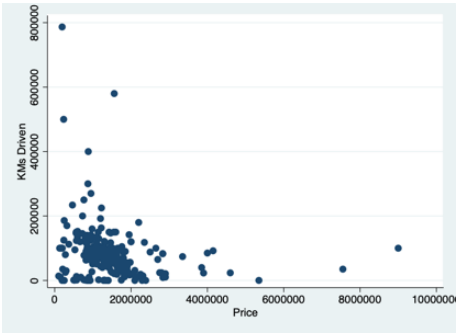


Также имеется 4 диаграммы рассеяния для изучения зависимости цены автомобиля от пробега по подгруппам в зависимости от топлива. Соотнесите диаграммы рассеивания и тип топлива автомобилей

а) 

б) 

в) 

г) 

а) Daihatsu

б) Honda

в) Suzuki

г) Toyota

15. (4 балла)

С использованием данных из предыдущей задачи была оценена регрессионная модель зависимости цены автомобиля от года выпуска, пробега, типа топлива и новизны. Получилось следующее уравнение (все перечисленные коэффициенты значимы на 5% уровне значимости):

Price= -62376.67 — 0.137*KMs + 31.52*Year — 277.11*D_used + 1863.70*D_Diesel

KMs — пробег в тысячах километров, Year — год выпуска, D_used — переменная, равная 1, если автомобиль использованный, и 0, если новый. Последняя переменная — индикатор для типа топлива (то есть D_Diesel=1, если это двигатель работает на дизельном топливе, и 0, если тип топлива другой).

Возьмем два автомобиля: оба 2000 года выпуска, подержанные, на дизельном топливе. Пробег одного из них составляет 120 тыс. километров, а второго — 180 тыс. километров. На сколько процентов дороже будет первый автомобиль по сравнению со вторым, исходя из полученных оценок модели? Укажите ответ в процентах от меньшей цены. Если ответ представлен в виде дроби, округлите его до двух знаков после запятой. Единицы измерения указывать не нужно.

(Ответ: 0,37%)

16. (3 балла) Для более полного анализа факторов, влияющих на цену, было решено учесть влияние марки автомобиля, и добавили индикатор на одну из наиболее часто встречающихся марок, а именно на марку Toyota. Коэффициент для данной переменной, и 95% доверительный интервал для него получились следующие:

Переменная	**Коэффициент**	**[доверительный интервал]**	
Toyota	533.67	455.70	611.64

Какой вывод о взаимосвязи марки автомобиля на цену вы можете сделать исходя из данной информации? Выберите верный вариант ответа:

а) При прочих равных, автомобили марки Toyota стоят значимо дешевле, чем средний автомобиль другой марки

б) При прочих равных, автомобили марки Toyota стоят значимо дороже, чем средний автомобиль другой марки (+)

в) При прочих равных, автомобили марки Toyota значимо не отличаются по стоимости от среднего автомобиля другой марки

г) При прочих равных, приведенных данных недостаточно для того, чтобы сделать вывод о значимости различия цены автомобиля Toyota от среднего автомобиля другой марки

17. (8 баллов) (Файл 17_Распределение средств клиентов банков)

В таблице приведены данные о распределении средств различных клиентов банков (физических лиц, юридических лиц и ИП) в зависимости от размера вкладов: например, группа «<100» означает, что в этой группе собраны все вклады размером 100 тыс. рублей и меньше. Для каждого такого диапазона размера вклада и типа вкладчика указана общая сумма всех депозитов в млрд. руб. Вклады до 1,4 млн рублей являются застрахованными. Если размер вклада превышает эту сумму, то он является частично застрахованным.

Выберите одно или несколько верных утверждений, которые можно сделать на основе анализа данной таблицы.

а) На 1 июля 2024 г. более половины вкладов юридических лиц приходилось на депозиты размером более 20 млн. рублей (+)

б) За 1 квартал 2024 года снизилась общая сумма вкладов ИП на депозиты в каждом диапазоне объемов

в) Темп прироста полностью застрахованных депозитов в 1 квартале 2024 года превышает среднемесячный темп прироста таких депозитов во 2 квартале 2024 года

г) Все группы депозитов физических лиц объемом свыше 1400 тыс. рублей в апреле и мае 2024 года росли в среднем темпом не менее 2% в месяц (+)

д) Среди других утверждений нет верных.

18. (8 баллов) (Файлы 18_Hit.csv и 18_Hits_description)

    В файле собраны данные о более чем 14 тысячах популярных песен с 1899 года. Описание характеристик можно найти на отдельной странице. Проанализируйте представленные данные и выберите одно или несколько верных утверждений.

    а) Более энергичные песни в среднем менее популярны

    б) Средняя продолжительность песни в жанре Reggae составляет не более 4 минут

    в) Усредненное по песням жанра значение переменной Positiveness является наибольшим для жанра SKA (+)

    г) В жанре Rock более продолжительные композиции являются менее популярными, в то время как в жанре Rap напротив более популярны менее продолжительные композиции

    д) Среди других утверждений нет верных.

19. (4 балла, по 1 баллу за каждый верно заполненный пропуск)
    (Файл 19_stock_price_2.xlsx)

    Ваши коллеги из другого отдела занимаются учетом стоимости имеющихся у компании акций разных компаний. Данные за июль 2024 года представлены в файле stock_price. Там отражена цена акций четырех компаний: A, B, C и D. Вашим коллегам важно, чтобы цена у каждой бумаги была каждый день, и они прибегают к следующему способу вести свой учет. В дни, когда торги проводились (т.е. в рабочие дни), указывается цена закрытия этого дня. В другие дни (выходные или праздники) указывается последняя известная цена. Они просят вас отранжировать бумаги по их риску и выявить наиболее и наименее рискованные акции.

    В качестве меры риска предполагается использование коэффициента вариации. Вы также знаете, что при анализе рисков следует ориентироваться только на дни, когда проводятся торги. Исходя из сделанных вами расчетов, запишите в соответствующие поля название наиболее и наименее рискованной акции, а также укажите коэффициент вариации для них.

    Наиболее рискованная акция компании «A», коэффициент вариации «0,046» (0,045)

    Наименее рискованная акция компании «D», коэффициент вариации «0,025»

20. (8 баллов + 4 балла) (Файлы 20_employee_v2.csv и 20_employee_description)

    Вам необходимо проанализировать ряд показателей, связанных с исполнением трудовых функций работников некоторой компании. В частности, руководство компании интересуется, какое влияние коллеги оказывают друг на друга (например, более производительные коллеги мотивируют работать лучше, или напротив, мешают выполнению обязанностей). В данном случае коллегами будут считаться люди, выполняющие одну и ту же роль (jobrole) в одном и том же департаменте (department) в одном регионе (state) в один и тот же год проведения оценивания. Она проводится раз в год, дата проведения указана в переменной reviewdate.

    Взаимосвязи между количественными переменными рассматриваются на основе статистической значимости соответствующей корреляции, количественной переменной с категориальной — на основе статистически значимого различия в средних на подвыборках.

Часть 1. Расчеты (8 баллов, по одному за каждое верно заполненное число)

Для исследования влияния опыта работы сотрудника на оценку его деятельности менеджером будем ориентироваться на два показателя: время работы в компании и время работы на последней должности. В среднем продолжительность работы в компании в годах составляет приблизительно 5,70 (5,26), а продолжительность работы на последней должности в годах — 2,81 (2,58).

При анализе влияния коллег мы фокусируем внимание на 5726 (1148, 5724, 1147) работниках из общего количества в 5770, у которых есть хотя бы один коллега. Среднее значение оценок менеджера, полученных коллегами, составляет 3,47. В среднем у таких работников имеется 48 (48,02)коллег.

Коэффициент корреляции времени работы в компании с оценкой менеджера составляет 0.02. Коэффициент корреляции времени работы на последней должности с оценкой менеджера составляет 0.04 (0,03). Коэффициент корреляции оценки менеджера для работника с оценкой его коллег составляет — 0.00.

Часть 2. Интерпретация (4 балла, по 1 баллу за каждый верно заполненный пропуск)

Выберите наиболее подходящее заполнение пропуска из предложенных вариантов исходя из анализа, проведенного в Части 1.

Переходя к анализу влияния опыта работы, время работы в компании (связано положительно/связано отрицательно/не связано) с оценкой менеджера. Время работы на последней должности с оценкой менеджера (связано положительно/связано отрицательно/не связано).

Корреляция средней оценки менеджера, полученной коллегами, и показателя с оценкой самих работников является (положительной/отрицательной/нулевой), что говорит о (наличии положительной/наличии отрицательной/отсутствии) взаимосвязи между оценкой работника и средней оценкой его коллег.

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ

Т БАНК

1. (2 балла) Вы работаете помощником следователя в небольшом городе. Недавно вам передали ряд дел об ограблениях. Вы составили статистику по этим делам и выяснили, что у половины пострадавших людей имеется домашнее животное. Также вы знаете, что в вашем городе домашние питомцы имеются в 50% домов. Какой вывод вы можете сделать исходя из этой информации?

   а) Преступник чаще грабит дома, в которых есть домашние животные

   б) Преступник реже грабит дома, в которых есть домашние животные

   в) Преступник одинаково часто грабит дома, где есть домашние животные и где их нет (+)

   г) Предоставленной информации недостаточно, чтобы сделать любой из перечисленных выше ответов

2. (4 балла) Офлайн-магазин электроники продает телефоны и аксессуары для них. В магазине можно купить любое количество телефонов и/или аксессуаров. Известно, что за ноябрь телефонов (в штуках) было продано меньше, чем аксессуаров. При этом 3% от всех товаров вернули. Выберите одно или несколько верных утверждений, которые следуют из этой информации:

   а) В ноябре вернули не более 3% аксессуаров

   б) В ноябре был хотя бы один покупатель, который приобрел в магазине аксессуар без телефона

   в) В ноябре был хотя бы один покупатель, который приобрел в магазине телефон без аксессуара

   г) Телефонов без аксессуаров купили меньше, чем аксессуаров без телефонов

   д) Среди других утверждений нет таких, которые следуют из приведенной в условии информации (+)

3. (2 балла) Вам стало интересно узнать, сколько читают ученики старших классов в вашей школе. Вы создали небольшой опрос и планируете свои дальнейшие действия. Для этих целей вы решили в течение недели общаться со всеми старшеклассниками, которые выходят после занятий из школы. В результате полученная вами оценка количества часов чтения:

   а) Будет завышена

   б) Будет занижена

   в) Будет близка к истинному значению (+)

   г) Может быть как завышена, так и занижена

4. (4 балла) В городе Банкнотск каждый житель является клиентом по крайней мере одного из двух банков-конкурентов: банка А или банка Б. Аналитикам банка А Пете и Свете поручили посчитать, какой процент жителей города Банкнотск одновременно является и клиентами банка А, и клиентами банка Б.

   Петя запустил в приложении банка А опрос, доступный клиентам-жителям Банкнотска. Света опрашивала людей, выходящих из разных отделений банка Б в городе Банкнотск. И Петя, и Света задавали один и тот же вопрос: «Являетесь ли вы клиентом банка-конкурента?» (т.е. банка Б для клиентов банка А — и наоборот). Оба опроса проводились одновременно и длились неделю. В Петином опросе приняли участие 1504 человека, из них 512 являются по их словам клиентами банка Б. В опросе Светы приняли участие 2235 человек, из них 1096 являются по их словам клиентами банка А.

   В результате Петя сделал вывод, что 34% жителей является клиентами обоих банков, а Света что таких жителей 49%. Выберите одно или несколько верных утверждений, которые следуют из этой информации:

   а) Оценка Пети ближе к истинному значению, чем оценка Светы

   б) Оценка Светы ближе к истинному значению, чем оценка Пети

   в) Истинное значение больше, чем оценки Светы и Пети

   г) Истинное значение меньше, чем оценки Светы и Пети

   д) Недостаточно данных, чтобы сделать выводы (+)

5. (5 баллов) Некоторые пассажиры, купившие авиабилеты, не пользуются ими из-за опоздания на рейс или изменения планов. Понимая это, авиакомпании иногда специально продают больше билетов, чем есть мест в самолете, — это называется овербукинг.

   Компания «Птичка Airlines» продала 192 билета на рейс со 190 местами. За 15 минут до окончания регистрации трое из 192 пассажиров не зарегистрированы на рейс — Аркадий А.., Ирина К. и Никита П. По статистике предыдущих перелетов Аркадий А. придет на регистрацию с вероятностью 80%, Ирина К. — 40%, Никита П. — 20%. Какова вероятность того, что кому-то из пришедших на регистрацию пассажиров не хватит мест? Дайте ответ в процентах. Если ответ представлен в виде дроби, округлите его до целого числа. Единицы измерения указывать не нужно.

   Ответ: 43

6. (5 баллов) Компания, занимающаяся доставкой продуктов, решила подарить пяти своим самым активным пользователям 6 одноразовых промокодов: 5 промокодов на скидку 15% и 1 промокод — на 25%. Каждый промокод должен быть отправлен ровно одному пользователю. При этом один пользователь может как не получить ничего, так и получить несколько промокодов. Также компания приняла решение не отправлять все 5 промокодов на 15% одному пользователю. Сколько существует способов раздать все 6 промокодов?

   Примечание: Промокоды на 15% считайте одинаковыми: формально это разный набор букв и цифр, но важен именно эффект промокода, а не уникальное сочетание символов.

   Ответ: 605

7. (5 баллов) Лиза работает маркетологом в банке. Один из продуктов банка — платная подписка, дающая различные бонусы клиенту. Лиза решила прорекламировать подписку клиентам без подписки, которые больше всего похожи на клиентов с подпиской.

   Для этого она случайным образом выбрала группу А из 1000 клиентов с подпиской и группу Б из 100 000 клиентов без подписки. Далее Лиза рассчитала значения 8 параметров для каждого из клиентов в каждой из групп: возраст, доход в рублях в месяц и т.д. Все параметры — целые неотрицательные числа. Оказалось, что не существует двух клиентов из выбранных 101 000 с полностью совпадающим набором значений этих 8 параметров.

   Дальше Лиза объединила выборки А и В и произвела стандартизацию значений каждого из 8 параметров для всех 101 000 клиентов по формуле:

$$x_{new} = \frac{x - m}{\sqrt{D}}$$

   Здесь x — значение параметра, m — среднее арифметическое значений параметра, D — дисперсия значений параметра, а x_{new} — стандартизированное значение параметра.

   Так Лиза получила для каждого клиента X из группы А значения стандартизированных 8 параметров x_1, x_2, ..., x_8, а для каждого клиента Y из группы В — значения y_1, y_2, ..., y_8. Наконец, для каждого клиента X из группы А Лиза решила найти «наиболее похожего» на него клиента Y из группы В. «Наиболее похожий» на X клиент из группы В — такой, для которого принимает наименьшее значение (среди всех клиентов в группе В с их набором y_1, y_2, ..., y_8) сумма:

   $S = |x_1 - y_1| + |x_2 - y_2| + \cdots + |x_8 - y|$

   Выберите одно или несколько верных утверждений:

   а) Один и тот же клиент из группы В мог оказаться «наиболее похожим» на нескольких клиентов из группы А. (+)

   б) Все значения всех параметров из группы А после стандартизации окажутся не больше 1.

   в) Может найтись клиент из группы В, для которого сумма значений всех параметров после стандартизации окажется равна 0. (+)

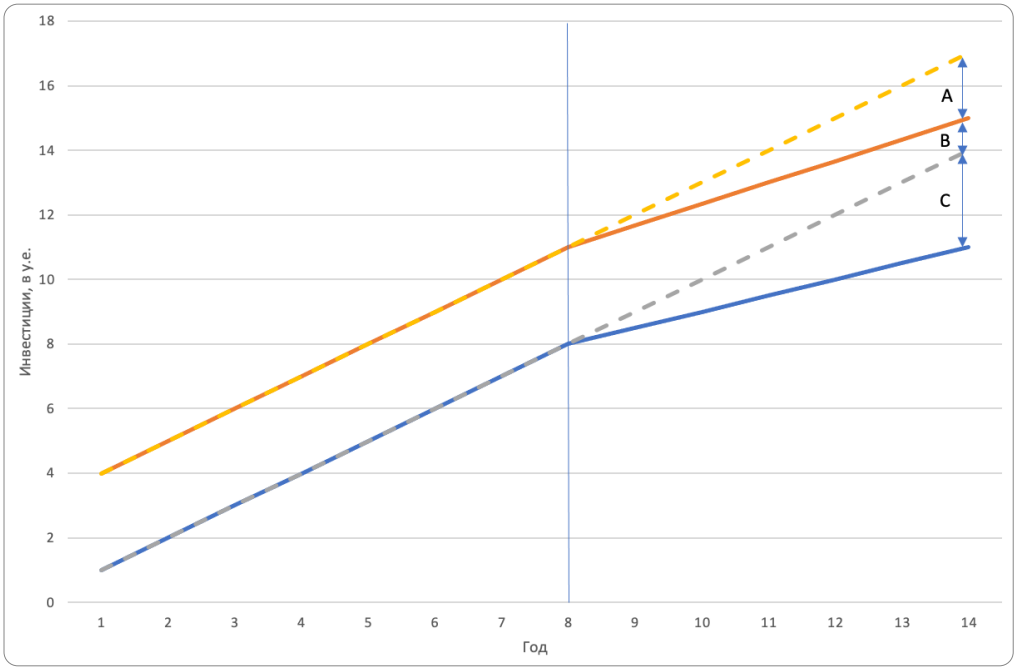
   г) Каждый клиент из группы В оказался «наиболее похожим» хотя бы на одного клиента из группы А.

   д) Среди других утверждений нет верных.

8. (4 балла) Вы являетесь главным экономистом в одной далекой-далекой стране, где Север и Юг отделены друг от друга, но при этом они очень похожи друг на друга. В 8-й год правительство Севера решает снизить налоги на инвестиции. Однако в это же время и Север, и Юг сталкиваются с резким ужесточением требований для выдачи кредитов на инвестиции, что оказывает сдерживающий эффект на оба региона.

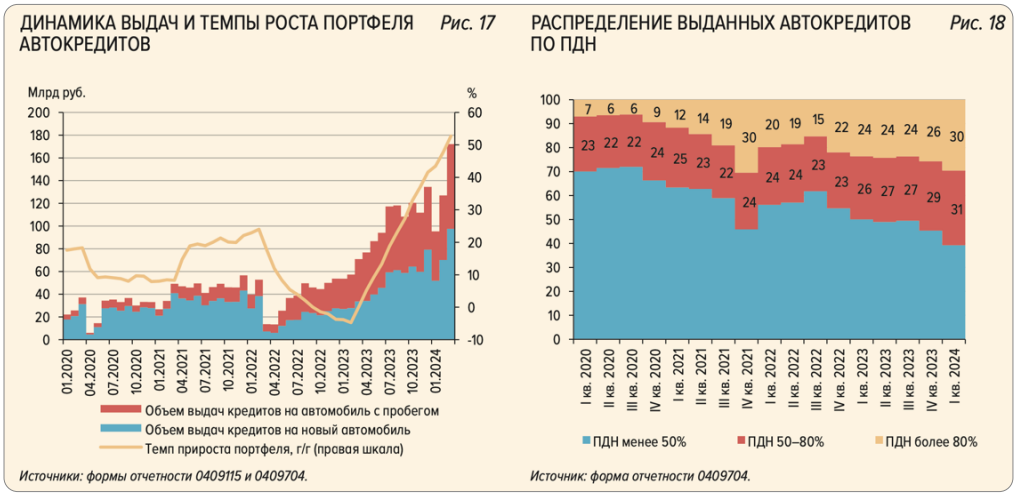
   В 14-м году вас просят оценить эффект от снижения налогов. Собранные данные показывают, что инвестиции ведут себя, как показано на рисунке ниже. Оранжевая

линия — фактическая динамика инвестиций на Севере, синяя — на Юге. Желтая и серая пунктирные линии показывают, как вели бы себя инвестиции, если бы в 8-м году ничего не менялось. Величина отрезка A составляет 2 условных единицы (у.е.), отрезка B — 1 у.е., отрезка C — 3 у.е.. Чему будет равен эффект от снижения налогов в условных единицах? Запишите ответ в виде числа. Если ответ представлен в виде дроби, округлите его до целого. Единицы измерения указывать не нужно.



Ответ: 1

9. (5 баллов)



На рисунке представлены два графика из Обзора финансовой стабильности ЦБ РФ за 4-й квартал 2023 и 1-й квартал 2024 года (cbr.ru/Collection/Collection/File/49151/4_q_2023_1_q_2024.pdf).

На левом графике представлены объемы выдач кредитов на автомобили с 2020 года, а также темп прироста общего портфеля автокредитов. На правом графике представлено распределение кредитов по величине показателя долговой нагрузки (ПДН) — это отношение между суммой ежемесячных платежей человека по всем кредитам к ежемесячному доходу. Чем выше данный показатель, тем больше шанс, что заемщик не сможет вернуть взятый кредит.

Выберите одно или несколько верных утверждений, которые можно сделать на основе данных графиков:

а) В третьем квартале 2023 года портфель автокредитов снижался

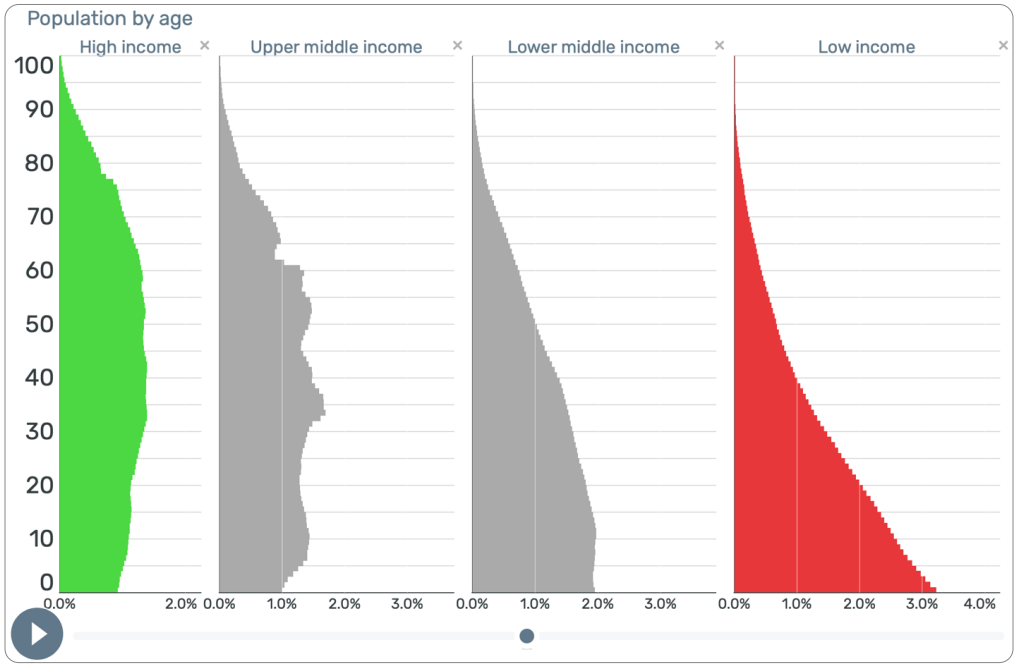
б) За 2020г. рискованность выданных автокредитов выросла (+)

в) В январе 2021 года доля кредитов, выданных на новые автомобили, в общем объеме выдач ниже, чем в январе 2024

г) Объем выдач кредитов на автомобили с пробегом в январе 2022 года вырос по сравнению с январем 2021 года. (+)

д) Среди перечисленного выше нет верных ответов

10. (5 баллов) На графиках представлены возрастные пирамиды (гистограммы, отражающие процент населения в каждой возрастной группе; в данном случае их 100 — одна группа соответствует каждому возможному значению возраста от 0 до 100) для четырех групп стран (на основе классификации Всемирного банка blogs.worldbank.org/en/opendata/new-world-bank-group-country-classifications-income-level-fy24), слева для самых богатых стран, справа — для самых бедных. Данные представлены на 2023 год.



Выберите одно или несколько верных утверждений на основе данных графиков:

а) В самых бедных странах происходит рост отношения числа детей до 10 лет к численности взрослых в возрасте 30-40 лет в течение последних 10 лет (+)

б) В странах с самым низким уровнем дохода в среднем самое молодое население (+)

в) В странах с доходом выше среднего в ближайшие годы необходимо уделить большое внимание постройке новых школ для обеспечения всех детей возможностью для обучения

г) В странах с доходом ниже среднего, люди в среднем моложе, чем в странах с доходом выше среднего. (+)

д) Среди других утверждений нет верных.

11. (5 баллов) Компании часто берут кредиты в виде кредитных линий. В этом случае по договору с банком они могут в любой момент получить деньги, но только в определенных пределах. Обычно эти пределы восстанавливаются, если компания вовремя возвращает деньги. Исследования показывают, что в кризисные времена компании начинают чаще пользоваться этим видом кредитования.

Группа ученых решила выяснить, как активно российские компании использовали кредитные линии во время пандемии. Для этого они собрали данные о всех кредитах, которые компании получили в период пандемии, а также за несколько лет до этого для сравнения. Также кредиты разделили на две группы: старые кредитные линии и новые кредиты. Затем рассчитали долю кредитов первой группы в общем объеме займов. Эти доли в зависимости от финансового состояния компании (платит ли она зарплату, расплачивается ли по старым займам вовремя, получает ли прибыль и т. д.), был ли этот период пандемийным или нет, а также относится ли компания к отрасли, сильно пострадавшей от кризиса (например, туризм, общественное питание и т. д.), показали на графиках.

Рис. 3. Доля ранее одобренных кредитных линий в общем объеме займов для компаний из не подверженных пандемии отраслей, в разбивке по децилям

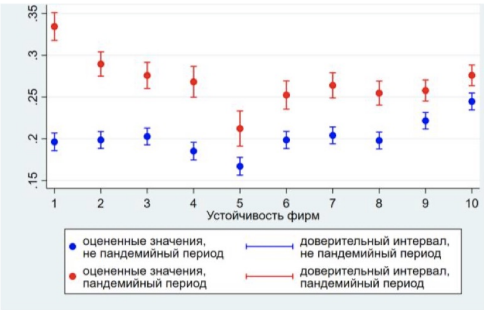
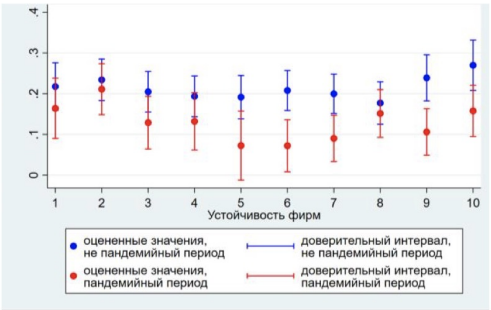


Рис. 4. Доля ранее одобренных кредитных линий в общем объеме займов для компаний из подверженных пандемии отраслей, в разбивке по децилям



Примечание. Оценки и доверительные интервалы для доли ранее одобренных кредитных линий в общем объеме заимствований компаний. Синие точки показывают оцененные значения для допандемийного периода (2017–2019 гг.), красные точки – для периода пандемии (2020 г.). Более высокие значения переменной «Устойчивость фирм» по шкале X соответствуют более высоким оценкам вероятности дефолта заемщика (то есть по более низким финансовым показателям компании).

Выберите одно или несколько верных утверждений, которые можно сделать на основании анализа указанных графиков?

Обратите внимание на подпись к графикам: чем больше показатель «Устойчивость фирм», тем хуже финансовое состояние компании

а) В пандемийный период менее устойчивые компании среди не подверженных пандемийному шоку активнее использовали имеющиеся у них кредитные линии по сравнению с более устойчивыми

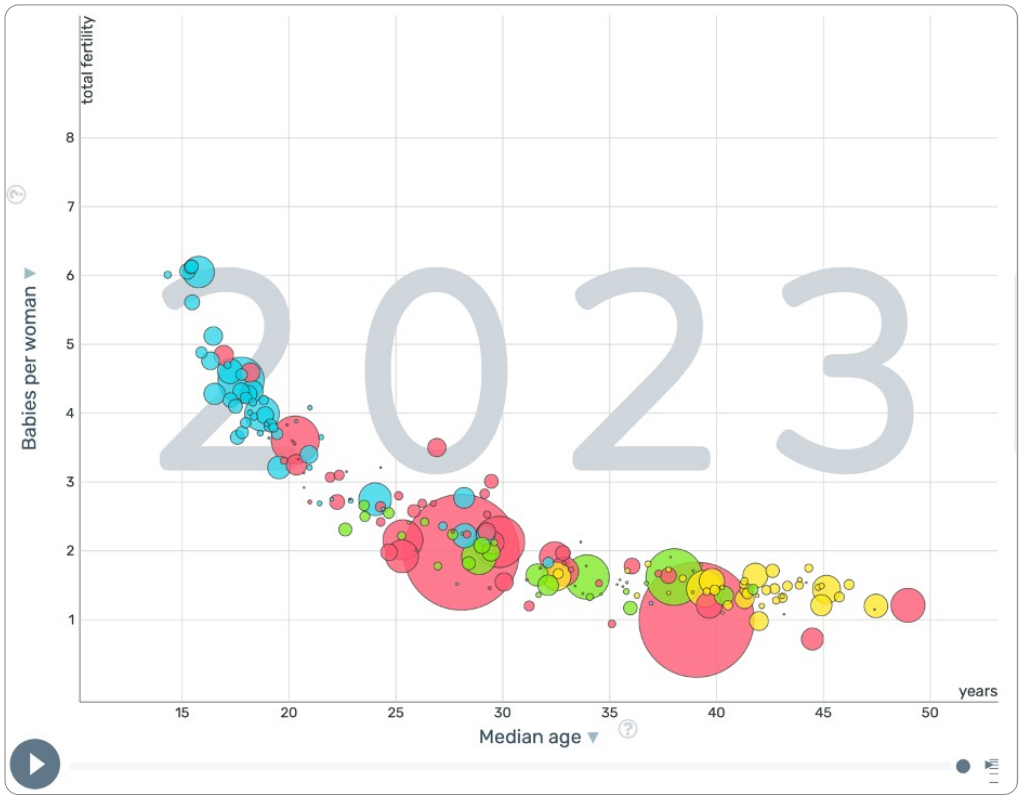
б) В пандемийный период компании из отраслей, не подверженных пандемии, использовали кредитные линии с такой же интенсивностью или больше, по сравнению с допандемийным периодом (+)

в) В период до пандемии компании из отраслей, подверженных пандемии, использовали кредитные линии менее интенсивно, чем компании из не подверженных шоку отраслей

г) В допандемийный период среди компаний, подверженных влиянию шока, самые финансово устойчивые (1-3 группы) и самые финансово неустойчивые (8-10 группы) компании пользовались кредитными линиями так же активно, как средние фирмы (5 группа). (+)

д) Среди других утверждений нет верных.

12. (5 баллов) На графике представлено распределение стран в зависимости от медианного возраста жителей (по горизонтальной оси), количества детей, приходящихся на одну женщину (по вертикальной оси) и размера населения (размер кругов). Цвет кругов обозначает разные регионы мира: голубой — Африка, красный — Азия (включая Австралию и Новую Зеландию), зеленый — Америка (Северная и Южная вместе), желтый — Европа.



Выберите одно или несколько верных утверждений, следующие из приведенного графика:

а) В среднем медиана медианный возраст в странах Азии (включая Австралию, Океанию и Новую Зеландию) ниже, чем в Европе (включая Россию) (+)

б) Среднее количество детей на одну женщину в Африке выше, чем в Америке (+)

в) Чем больше численность населения в стране, тем больше медианный возраст людей в стране

г) Рост среднего количества детей на женщину ведет к снижению медианного возраста

д) Среди других утверждений нет верных.

13. (2 балла) Если бы вы хотели оценить взаимосвязь среднего количества детей на одну женщину и медианного возраста, то какое из приведенных ниже уравнений подошло бы больше всего для данных на рисунке выше? Выберите один верный вариант ответа. Все коэффициенты положительные

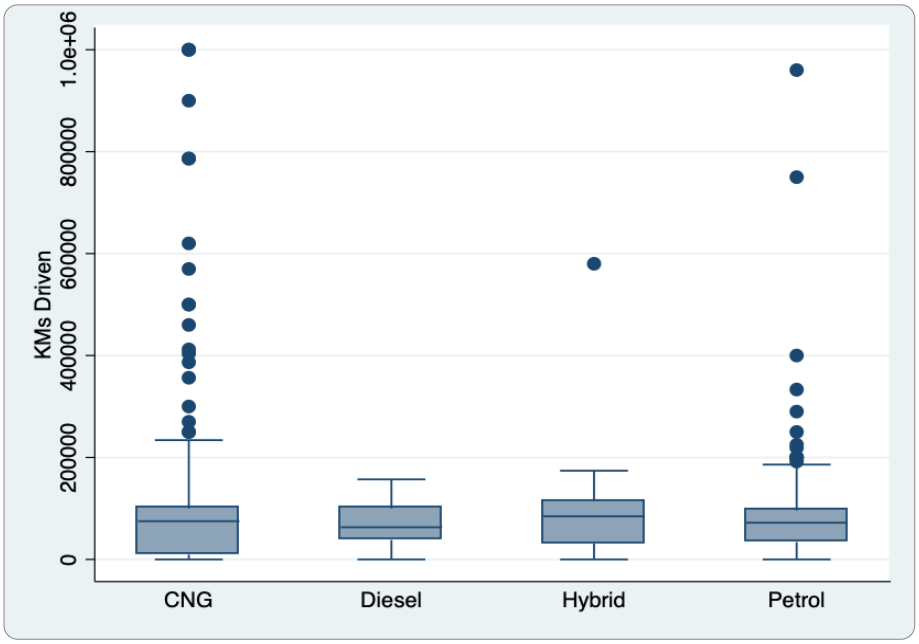
а) b0-b1*Median Age

б) b0-b1*ln(Median age) (+)

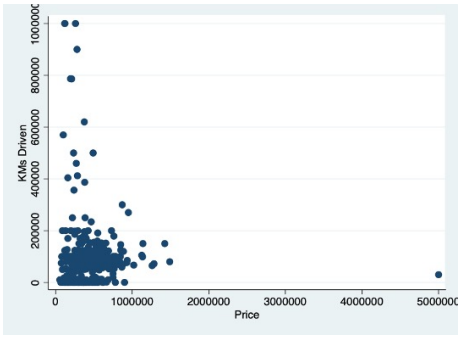
в) b0+b1*(Median Age)^2

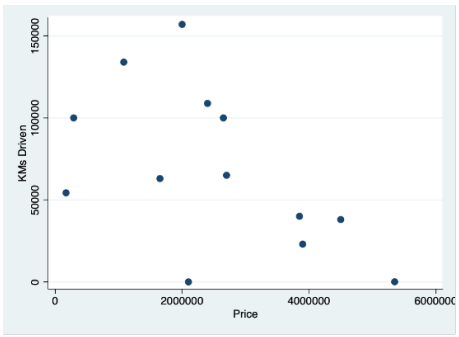
г) b0+b1*(Median Age)^0,5

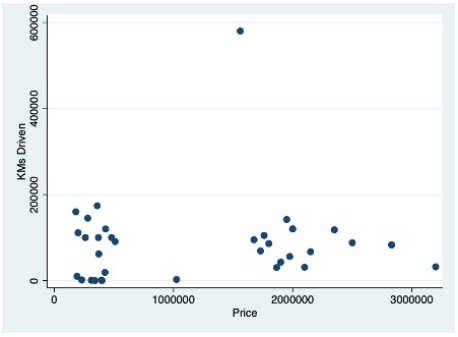
14. (8 баллов, по 2 за каждое верное соотнесение) На графике представлены ящики с усами, отражающие распределение пробега автомобиля в зависимости от типа топлива.

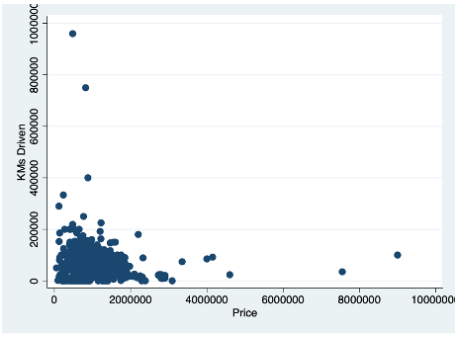


Также имеется 4 диаграммы рассеяния для изучения зависимости цены автомобиля от пробега по подгруппам в зависимости от топлива. Соотнесите диаграммы рассеивания и тип топлива автомобилей

а) 

б) 

в) 

г) 

а) CNG

б) Diesel

в) Hybrid

г) Petrol

15. (4 балла)

С использованием данных из предыдущей задачи была оценена регрессионная модель зависимости цены автомобиля от года выпуска, пробега, типа топлива и новизны. Получилось следующее уравнение (все перечисленные коэффициенты значимы на 5% уровне значимости):

Price= -62376.67 — 0.137*KMs + 31.52*Year — 277.11*D_used + 1863.70*D_Diesel

KMs — пробег в тысячах километров, Year — год выпуска, D_used — переменная, равная 1, если автомобиль использованный, и 0, если новый. Последняя переменная индикатор для типа топлива (то есть D_Diesel=1, если это двигатель работает на дизельном топливе, и 0, если тип топлива другой).

Возьмем два автомобиля: оба 2000 года выпуска, подержанные, на дизельном топливе. Пробег одного из них составляет 30 тыс. километров, а второго — 60 тыс. километров. На сколько процентов дороже будет первый автомобиль по сравнению со вторым, исходя из полученных оценок модели? Укажите ответ в процентах от меньшей цены. Если ответ представлен в виде дроби, округлите его до двух знаков после запятой. Единицы измерения указывать не нужно.

(Ответ: 0,183%)

16. (3 балла) Для более полного анализа факторов, влияющих на цену, было решено учесть влияние марки автомобиля, и добавили индикатор на одну из наиболее часто встречающихся марок, а именно на марку Honda. Коэффициент для данной переменной, и 95% доверительный интервал для него получились следующие:

Переменная	**Коэффициент**	**[доверительный интервал]**	
Honda	145.42	45.39	245.45

Какой вывод о взаимосвязи марки автомобиля на цену вы можете сделать исходя из данной информации? Выберите верный вариант ответа:

а) При прочих равных, автомобили марки Honda стоят значимо дешевле, чем средний автомобиль другой марки

б) При прочих равных, автомобили марки Honda стоят значимо дороже, чем средний автомобиль другой марки (+)

в) При прочих равных, автомобили марки Honda значимо не отличаются по стоимости от среднего автомобиля другой марки

г) При прочих равных, приведенных данных недостаточно для того, чтобы сделать вывод о значимости различия цены автомобиля Honda от среднего автомобиля другой марки

17. (8 баллов) (Файл 17_Распределение средств клиентов банков)

В таблице приведены данные о распределении средств различных клиентов банков (физических лиц, юридических лиц и ИП) в зависимости от размера вкладов: например, группа «<100» означает, что в этой группе собраны все вклады размером 100 тыс. рублей и меньше. Для каждого такого диапазона размера вклада и типа вкладчика указана общая сумма всех депозитов в млрд. руб. Вклады до 1,4 млн рублей являются застрахованными. Если размер вклада превышает эту сумму, то он является частично застрахованным.

Выберите одно или несколько верных утверждений, которые можно сделать на основе анализа данной таблицы.

а) На 1 июля 2024 г. более трети всех вкладов ИП приходилось на депозиты размером более 20 млн. рублей

б) За 1 квартал 2024 года увеличилась общая сумма вкладов юридических лиц на депозиты в каждом диапазоне объемов (+)

в) Среднемесячный темп прироста полностью застрахованных депозитов в 1 квартале 2024 года превышает среднемесячный темп прироста таких депозитов в 2023 году

г) Все группы депозитов ИП объемом свыше 1400 тыс. рублей в апреле и мае 2024 года росли в среднем темпом не менее 1% в месяц

д) Среди других утверждений нет верных.

18. (8 баллов) (Файлы 18_Hit.csv и 18_Hits_description)

В файле собраны данные о более чем 14 тысячах популярных песен с 1899 года. Описание характеристик можно найти на отдельной странице. Проанализируйте представленные данные и выберите одно или несколько верных утверждений.

а) Средняя продолжительность песни в жанре Jazz составляет не более 5 минут

б) Со временем акустические песни встречаются реже (+)

в) Усредненное по песням жанра значение переменной Liveness является наибольшим для жанра Gospel (+)

г) В жанре R&B более продолжительные композиции являются более популярными, в то время как в жанре Pop напротив более популярны менее продолжительные композиции

д) Среди других утверждений нет верных.

19. (4 балла, по 1 баллу за каждый верно заполненный пропуск)
(Файл 19_stock_price_3.xlsx)

Ваши коллеги из другого отдела занимаются учетом стоимости имеющихся у компании акций разных компаний. Данные за июль 2024 года представлены в файле stock_price. Там отражена цена акций четырех компаний: A, B, C и D. Вашим коллегам важно, чтобы цена у каждой бумаги была каждый день, и они прибегают к следующему способу вести свой учет. В дни, когда торги проводились (т.е. в рабочие дни), указывается цена закрытия этого дня. В другие дни (выходные или праздники) указывается последняя известная цена. Они просят вас отранжировать бумаги по их риску и выявить наиболее и наименее рискованные акции.

В качестве меры риска предполагается использование коэффициента вариации. Вы также знаете, что при анализе рисков следует ориентироваться только на дни, когда проводятся торги. Исходя из сделанных вами расчетов, запишите в соответствующие поля название наиболее и наименее рискованной акции, а также укажите коэффициент вариации для них.

Наиболее рискованная акция компании «A», коэффициент вариации «0,045»(0,044)

Наименее рискованная акция компании «B», коэффициент вариации «0,025»

20. (8 баллов + 4 балла) (Файлы 20_employee_v3.csv и 20_employee_description)

Вам необходимо проанализировать ряд показателей, связанных с исполнением трудовых функций работников некоторой компании. В частности, руководство компании интересуется, какое влияние коллеги оказывают друг на друга (например, более производительные коллеги мотивируют работать лучше, или напротив, мешают выполнению обязанностей). В данном случае коллегами будут считаться люди, выполняющие одну и ту же роль (jobrole) в одном и том же департаменте (department) в одном регионе (state) в один и тот же год проведения оценивания. Она проводится раз в год, дата проведения указана в переменной reviewdate.

Взаимосвязи между количественными переменными рассматриваются на основе статистической значимости соответствующей корреляции, количественной переменной с категориальной — на основе статистически значимого различия в средних на подвыборках.

Часть 1. Расчеты (8 баллов, по одному за каждое верно заполненное число)

Для исследования влияния опыта работы сотрудника на оценку его деятельности менеджером будем ориентироваться на два показателя: время работы в компании и время работы на последней должности. В среднем продолжительность работы в компании в годах составляет приблизительно 5,70 (5,27), а продолжительность работы на последней должности в годах — 2,81 (2,60).

При анализе влияния коллег мы фокусируем внимание на 5741 (1151, 5739, 1150) работниках из общего количества в 5785, у которых есть хотя бы один коллега. Среднее значение оценок менеджера, полученных коллегами, составляет 3,48. В среднем у таких работников имеется 48,13 (48,15)коллег.

Коэффициент корреляции времени работы в компании с оценкой менеджера составляет 0.02. Коэффициент корреляции времени работы на последней должности с оценкой менеджера составляет 0.03. Коэффициент корреляции оценки менеджера для работника с оценкой его коллег составляет 0.01.

Часть 2. Интерпретация. (4 балла, по 1 баллу за каждый верно заполненный пропуск)

Выберите наиболее подходящее заполнение пропуска из предложенных вариантов исходя из анализа, проведенного в Части 1.

Переходя к анализу влияния опыта работы, время работы в компании (связано положительно/связано отрицательно/не связано) с оценкой менеджера. Время работы на последней должности с оценкой менеджера (связано положительно/связано отрицательно/не связано).

Корреляция средней оценки менеджера, полученной коллегами, и показателя с оценкой самих работников является (положительной/отрицательной/нулевой), что говорит о (наличии положительной/наличии отрицательной/отсутствии) взаимосвязи между оценкой работника и средней оценкой его коллег.

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ

Т БАНК

1. (2 балла) Вы работаете помощником следователя в небольшом городе. Недавно вам передали ряд дел об ограблениях. Вы составили статистику по этим делам и выяснили, что в половине ограбленных домов имеется домашнее животное. Также вы знаете, что в вашем городе домашние питомцы имеются в 80% домов. Какой вывод вы можете сделать исходя из этой информации?

   а) преступник чаще грабит дома, в которых есть домашние животные

   б) преступник реже грабит дома, в которых есть домашние животные (+)

   в) преступник одинаково часто грабит дома, где есть домашние животные и где их нет

   г) предоставленной информации недостаточно, чтобы сделать любой из перечисленных выше ответов

   Решение. В данной формулировке условия возможно две интерпретации, соответственно и два решения засчитывались за верные. Разница состоит в том, относительно чего мы смотрим частоту.

   Подход 1. Если бы преступник одинаково часто выбирал как цели для ограбления дома с питомцами и без них, то в итоговой статистике ограбленных домов соотношение было бы таким же. Однако домов без питомцев оказалось больше. Это значит, дома, где есть домашние животные, грабили реже.

   Подход 2. По условию половина ограбленных домов была с питомцами, половина без них. В итоге получается, что преступник одинаково часто грабил и дома, где животные есть, и дома, где их нет.

2. (4 балла) Офлайн-магазин электроники продает телефоны и аксессуары для них. В магазине можно купить любое количество телефонов и/или аксессуаров. Известно, что за сентябрь аксессуаров (в штуках) было продано больше, чем телефонов. При этом 1% от всех товаров вернули. Выберите одно или несколько верных утверждений, которые следуют из этой информации:

   а) В сентябре вернули не более 1% аксессуаров

   б) В сентябре был хотя бы один покупатель, который приобрел в магазине и телефон, и аксессуар

   в) В сентябре был хотя бы один покупатель, который приобрел в магазине телефон без аксессуара

   г) Аксессуаров без телефонов купили больше, чем телефонов без аксессуаров

   д) Среди других утверждений нет таких, которые следуют из приведенной в условии информации (+)

Решение.

а) Не обязательно. Например, в сентябре могли купить 99 телефонов и 101 аксессуар, при этом вернуть из товаров 2 аксессуара.

б) Не обязательно. Каждый клиент мог купить любое количество телефонов и/или аксессуаров. А значит, все чеки в сентябре могли содержать только телефоны или только аксессуары.

в) Не обязательно. Каждый клиент мог купить любое количество телефонов и/или аксессуаров. А значит, все покупки, содержащие телефоны, могли содержать и хотя бы один аксессуар.

г) Не обязательно. Каждый клиент мог купить любое количество телефонов и/или аксессуаров. А значит, могло не быть ни одной покупки, состоящей только из аксессуаров, и одновременно с этим могла быть хотя бы одна покупка, состоящая только из телефона.

д) Так как другие утверждения не обязательно следуют из приведенной информации, то это единственно верное утверждение.

3. (2 балла) Вам стало интересно узнать, сколько читают ученики старших классов в вашей школе. Вы создали небольшой опрос и планируете свои дальнейшие действия. Для этих целей вы решили в течение недели общаться со всеми старшеклассниками, которые ходят на литературный кружок. В результате полученная вами оценка количества часов чтения, скорее всего:

а) будет завышена (+)

б) будет занижена

в) будет близка к истинному значению

г) может быть как завышена, так и занижена

Решение.

Основная идея решения состоит в том, что у людей есть ограничение по времени, и они распределяют свое свободное время исходя из предпочтений. Это распределение в среднем одинаковое у разных людей. Однако, если говорится о наличии некоторого «хобби», которым занимается человек, это уже не свободное время, в это время он занимается чем-то конкретным. Если говорится о том, что человек участвует в литературном кружке, в этот час он читает больше, чем в «обычное» время. Если говорится о любом другом кружке, не связанном с чтением (например, спортивная секция, решение задач по экономике, рукоделие и т.д.), конкретный промежуток времени чтению уделяться не может. В итоге получается, что если 23 часа в сутки люди распределяют «как все», а 1 час на соответствующий кружок, то если этот кружок связан с чтением, данные люди будут читать больше (и оценка времени чтения будет завышена), чем в среднем все остальные, если не связан с чтением — то на чтение будет уделяться чуть меньше времени (и оценка будет занижена). Отдельные люди за пределами данных кружков могут вести себя по-разному (один из посещающих литературный кружок может за его пределами не трогать книги, а один из спортсменов все оставшееся время читать), но также могут быть и их противоположности, что в среднем будет давать некоторого среднего человека.

4. (4 балла) В городе Монетск каждый житель является клиентом по крайней мере одного из двух банков-конкурентов: банка А или банка Б. Аналитикам банка А Пете и Свете поручили посчитать, какой процент жителей города Монетск одновременно является и клиентами банка А, и клиентами банка Б.

   Петя запустил в приложении банка А опрос, доступный клиентам-жителям Монетска. Света опрашивала людей, выходящих из разных отделений банка Б в городе Монетск. И Петя, и Света задавали один и тот же вопрос: «Являетесь ли вы клиентом банка-конкурента?» (т.е. банка Б для клиентов банка А — и наоборот). Оба опроса проводились одновременно и длились неделю. В Петином опросе приняли участие 12095 человек, из них 9434 являются, по их словам, клиентами банка Б. В опросе Светы приняли участие 2274 человека, из них 978 являются, по их словам, клиентами банка А.

   В результате Петя сделал вывод, что 78% жителей является клиентами обоих банков, а Света — что таких жителей 43%.

   Выберите одно или несколько верных утверждений, которые следуют из этой информации:

   а) Оценка Пети ближе к истинному значению, чем оценка Светы

   б) Оценка Светы ближе к истинному значению, чем оценка Пети

   в) Истинное значение больше, чем оценки Светы и Пети

   г) Истинное значение находится между оценками Светы и Пети

   д) Недостаточно данных, чтобы сделать выводы (+)

   Решение.

   Из приведенных данных не ясно ни сколько всего клиентов в банках А и Б, ни какая доля клиентов банка А пользуется приложением (и что это за клиенты), ни какая доля клиентов банка Б посещает отделения (и что это за клиенты). В зависимости от тех или иных значений этих фактических данных, может быть верно каждое из утверждений а)–г). Поэтому нельзя оценить репрезентативность проведенных Петей и Светой опросов — как и сделать какие-либо выводы о взаимосвязи их оценок и истинного значения процента жителей, являющихся клиентами обоих банков. Делать такие выводы, основываясь лишь на соотношении количества опрошенных ими людей и/или общих представлениях о клиентах банковских приложений и людей, выходящих из отделений банка, в данном случае некорректно.

5. (5 баллов) Некоторые пассажиры, купившие авиабилеты, не пользуются ими из-за опоздания на рейс или изменения планов. Понимая это, авиакомпании иногда специально продают больше билетов, чем есть мест в самолете, — это называется овербукинг.

   Компания «Птичка Airlines» продала 190 билетов на рейс со 188 местами. За 15 минут до окончания регистрации трое из 190 пассажиров не зарегистрированы на рейс — Елена С., Владислав П. и Ирина К. По статистике предыдущих перелетов Елена С. придет на регистрацию с вероятностью 90%, Владислав П. — 50%, Ирина К. — 40%. Какова вероятность того, что кому-то из пришедших на регистрацию пассажиров не хватит мест? Дайте ответ в процентах. Если ответ представлен в виде дроби, округлите его до целого числа. Единицы измерения указывать не нужно.

   Ответ: 65

Решение.

Зарегистрировалось 187 пассажиров, а мест всего 188, поэтому кому-то из еще не зарегистрировавшихся пассажиров не хватит мест в случае, если на регистрацию придет хотя бы 2 пассажира. Вероятность того, что на регистрацию придут Елена С. и Владислав П., равна 0,9 · 0,5; Елена С. и Ирина К. — 0,9 · 0,4; Владислав П. и Ирина К. — 0,5 · 0,4.

Каждое из этих трех событий учитывает возможность пройти регистрацию одновременно всем трем пассажирам (вероятность этого 0,9 · 0,5 · 0,4). Мы должны включить в ответ эту вероятность, но не должны ее дублировать, поэтому нужно дважды вычесть ее из ответа.

Итоговая вероятность тогда будет равна:

0,9 · 0,5 + 0,9 · 0,4 + 0,5 · 0,4 – 2 · 0,9 · 0,5 · 0, 4= 0,65 (65%)

6. (5 баллов) Компания, занимающаяся продажей и доставкой цветов, решила подарить пяти своим самым активным пользователям 8 одноразовых промокодов: 7 промокодов на скидку 15% и 1 промокод — на 25%. Каждый промокод должен быть отправлен ровно одному пользователю. При этом один пользователь может как не получить ничего, так и получить несколько промокодов. Также компания приняла решение не отправлять все 7 промокодов на 15% одному пользователю. Сколько существует способов раздать все 8 промокодов? В ответе единицы измерения указывать не нужно.

   Примечание: Промокоды на 15% считайте одинаковыми: формально это разный набор букв и цифр, но важен именно эффект промокода, а не уникальное сочетание символов.

   Ответ: 1625

   Решение.

   1) Для начала разберемся с 7 промокодами на 15%. Их нужно раздать 5 пользователям, и каждый промокод должен достаться кому-то, причем ровно одному из пользователей.

      Пронумеруем пользователей: 1,2,3,4,5 и расположим их номера в одной строке в порядке возрастания. Каждый промокод обозначим за N и также поместим в эту строку на какую-то позицию между цифрами или после цифр. Тогда можно сказать, что комбинация

      1NN2N3NNN45N

      соответствует случаю, когда 1й пользователь получил 2 промокода, 2й — 1, 3й — 3, 4й — 0, и 5й — 1. Взяв все строки такого вида, начинающиеся с 1, где цифры идут в порядке возрастания, получим все возможные способы раздать 7 промокодов.

      Чтобы получить строку такого вида, нужно из 7 + 5 – 1 = 11 позиций (строка должна начинаться с 1) выбрать 4 позиции для номеров пользователей 2, 3, 4, 5 (на всех остальных позициях будут стоять N-ки). Значит, всего таких строк $C_{7+5-1}^{5-1}=C_{11}^{4}$. При этом 5 из них соответствуют случаям, когда все 7 промокодов на 15% получает ровно один пользователь. По условию это невозможно, поэтому остается C_{11}^{4} — 5 способов.

2) Промокод на 25% получит один из 5 пользователей, поэтому способов раздать его 5.

3) Можно считать, что промокоды на 15% и промокод на 25% раздаются независимо друг от друга, поэтому способов раздать все 8 промокодов итого:

$(C_{11}^{4} - 5) \cdot 5 = 325 \cdot 5 = 1625.$

Примечание: задача поиска кол-ва способов распределения n промокодов на 15% между k пользователями тождественна задаче поиска кол-ва решений уравнения $x_1 + x_2 + \cdot + x_k = n$ в целых неотрицальных числах — и называется задачей Муавра. А искомое кол-во согласно выведенной нами формуле равно C_{n+k-1}^{k-1}.

7. (5 баллов) Лена работает маркетологом в банке. Один из продуктов банка — платная подписка, дающая различные бонусы клиенту. Лена решила прорекламировать подписку клиентам без подписки, которые больше всего похожи на клиентов с подпиской. Для этого она случайным образом выбрала группу А из 1000 клиентов с подпиской и группу Б из 100 000 клиентов без подписки.

Далее Лена рассчитала значения 8 параметров для каждого из клиентов в каждой из групп: возраст, доход в рублях в месяц и т.д. Все параметры — целые неотрицательные числа. Оказалось, что не существует двух клиентов из выбранных 101 000 с полностью совпадающим набором значений этих 8 параметров.

Дальше Лена объединила выборки А и В и произвела стандартизацию значений каждого из 8 параметров для всех 101 000 клиентов по формуле:

$$x_{new} = \frac{x - m}{\sqrt{D}}$$

Здесь x — значение параметра, m — среднее арифметическое значений параметра, D — дисперсия значений параметра, а x_{new} — стандартизированное значение параметра.

Так Лена получила для каждого клиента X из группы А значения стандартизированных 8 параметров x_1, x_2, ..., x_8, а для каждого клиента Y из группы В — значения y_1, y_2, ..., y_8. Наконец, для каждого клиента X из группы А Лена решила найти «наиболее похожего» на него клиента Y из группы В. «Наиболее похожий» на X клиент из группы В — такой, для которого принимает наименьшее значение (среди всех клиентов в группе В с их набором y_1, y2, ..., y_8) сумма:

$$S = |x_1 - y_1| + |x_2 - y_2| + ... + |x_8 - y_8|$$

Выберите одно или несколько верных утверждений:

а) Один и тот же клиент из группы В мог оказаться «наиболее похожим» на нескольких клиентов из группы А. (+)

б) Все значения всех параметров из групп А и В после стандартизации будут лежать в интервале [– 1; 1].

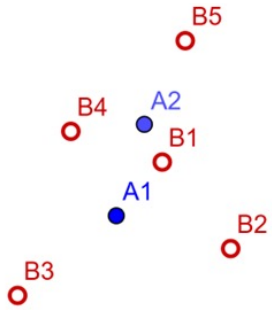
в) Может найтись клиент из группы А, для которого сумма значений всех параметров после стандартизации окажется равна 0. (+)

г) Некоторые клиенты из группы В могли не оказаться «наиболее похожими» ни на кого из клиентов из группы А. (+)

д) Среди других утверждений нет верных.

Решение.

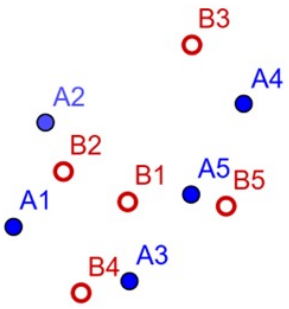
а) Верно. Ничто не запрещает клиенту B1 из группы B оказаться «наиболее похожим» одновременно на клиентов A1 и A2 из группы A. Ниже приведен пример такого случая для упрощенного двумерного варианта (когда параметров 2, а не 8). Здесь каждый клиент отображен точкой на координатной плоскости, а расстояние между каждыми двумя точками равно значению S — степени «похожести» клиентов.



б) Неверно. Стандартизация значений не гарантирует попадание новых значений в интервал [–1; 1]. Хотя и большинство значений действительно будет лежать в этом интервале.

в) Верно. Несмотря на то, что в данном случае сумма значений всех параметров после стандартизации сама по себе ничего не значит, она может оказаться равна 0. Например, после стандартизации в группе A может оказаться клиент со значениями параметров , и как следствие сумма значений параметров для него тоже окажется равной 0.

г) Верно. Клиент B1 из группы B может не оказаться «наиболее похожим» ни на одного клиента из A. Ниже приведен пример такого случая для упрощенного двумерного варианта (когда параметров 2, а не 8). Здесь каждый клиент отображен точкой на координатной плоскости, а расстояние между каждыми двумя точками равно значению S — степени «похожести» клиентов.



д) Так как среди других утверждений есть верные, то это утверждение неверно.

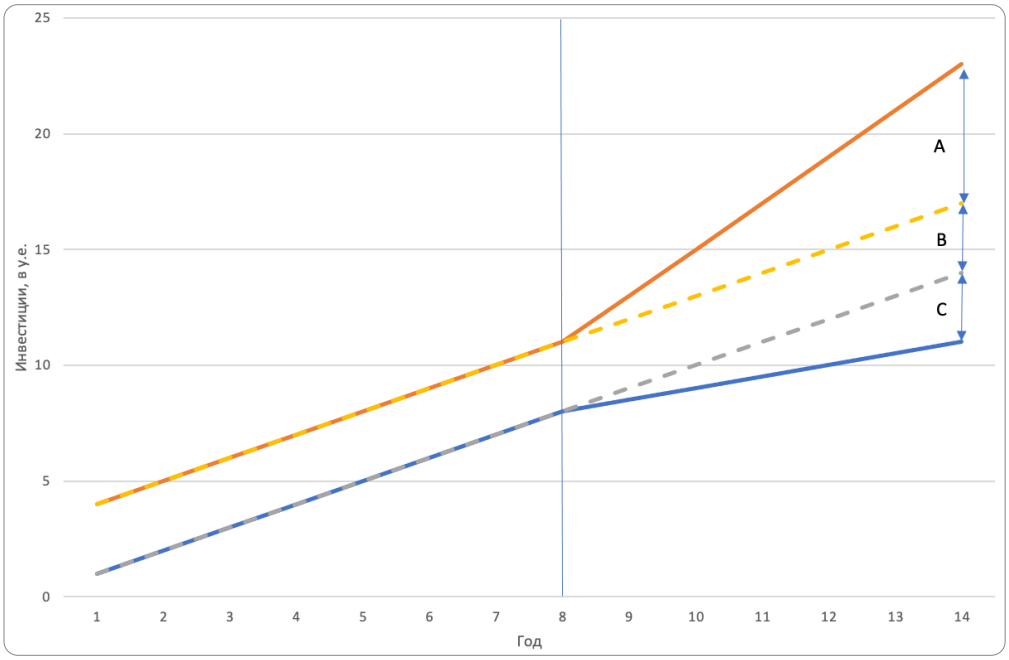
8. (4 балла) Вы являетесь главным экономистом в одной далекой-далекой стране, где есть два очень похожих друг на друга региона — Север и Юг. В 8-й год правительство Севера решает снизить налоги на инвестиции, на Юге этого не происходит. В это же время и Север, и Юг сталкиваются с резким ужесточением

требований для выдачи кредитов на инвестиции, что оказывает сдерживающий эффект на оба региона.

В 14-м году вас просят оценить эффект от снижения налогов. Собранные данные показывают, что инвестиции ведут себя, как показано на рисунке ниже. Оранжевая линия — фактическая динамика инвестиций на Севере, синяя — на Юге. Желтая и серая пунктирные линии показывают, как вели бы себя инвестиции, если бы в 8-м году ничего не менялось.

Величина отрезка A составляет 6 условных единиц (у.е.), отрезка B — 3 у.е., отрезка C — 3 у.е. Чему будет равен эффект от снижения налогов в условных единицах?

Запишите ответ в виде числа. Если ответ представлен в виде дроби, округлите его до целого. Единицы измерения указывать не нужно.

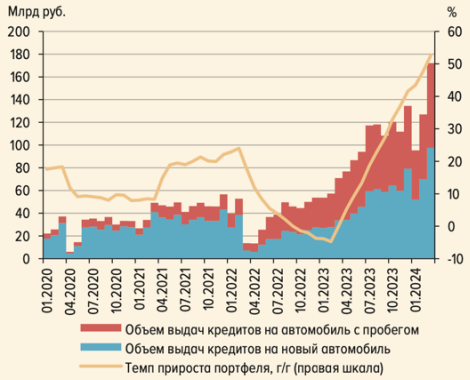


Ответ: 9

Решение: В условии сказано о том, что на Севере происходит снижение налогов, а также на Севере и на Юге ужесточаются требования к инвестиционным кредитам. Таким образом, если бы не изменение налогов, то линии продолжили бы идти параллельно (и оранжевая линия шла бы параллельно синей), и эффект от ужесточения требований составляет 3 у.е. (отрезок C). Однако на Севере не происходит снижения на 3 у.е., а происходит рост на 6 у.е. (отрезок A). Таким образом, эффект от снижения налогов на Севере составляет 9 у.е.: 6 у.е. (на которые инвестиции выросли относительно состояния без каких-либо изменений в налогах и требованиях к кредитам) плюс 3 у.е. (на которые инвестиции должны снизиться из-за эффекта увеличения требования по кредитам).

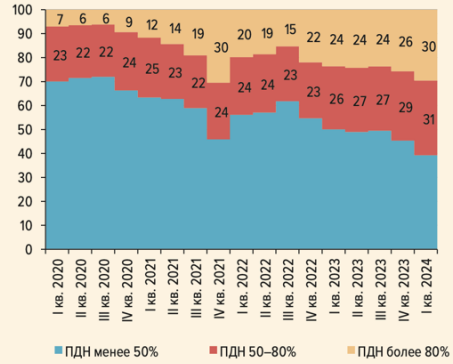
9. (5 баллов)

ДИНАМИКА ВЫДАЧ И ТЕМПЫ РОСТА ПОРТФЕЛЯ АВТОКРЕДИТОВ *Рис. 17*



Источники: формы отчетности 0409115 и 0409704.

РАСПРЕДЕЛЕНИЕ ВЫДАННЫХ АВТОКРЕДИТОВ ПО ПДН *Рис. 18*



Источник: форма отчетности 0409704.

На рисунке представлены два графика из Обзора финансовой стабильности ЦБ РФ за 4-й квартал 2023 и 1-й квартал 2024 года (cbr.ru/Collection/Collection/File/49151/4_q_2023_1_q_2024.pdf).

На левом графике представлены объемы выдач кредитов на автомобили с 2020 года, а также темп прироста общего портфеля автокредитов. На правом графике представлено распределение кредитов по величине показателя долговой нагрузки (ПДН) — это отношение между суммой ежемесячных платежей человека по всем кредитам к ежемесячному доходу. Чем выше данный показатель, тем больше шанс, что заемщик не сможет вернуть взятый кредит.

Выберите одно или несколько верных утверждений, которые можно сделать на основе данных графиков

а) В первом квартале 2023 года портфель автокредитов снижался (+)

б) За 2022-2023 гг. рискованность выданных автокредитов выросла (+)

в) В январе 2021 года доля кредитов, выданных на автомобили с пробегом, в общем объеме выдач была выше, чем доля этих кредитов в январе 2023-го

г) Объем выдач кредитов на новые автомобили вырос с 2022 года (+)

д) Среди других утверждений нет верных.

Решение. Портфель автокредитов характеризуется желтой линией на левом графике (Рис. 17). Важно понимать, что там отражаются темпы прироста, а значит портфель растет, если эта линия находится выше нуля, и падает, если линия находится ниже. Первый квартал 2023 года находится между значениями 01.2023 и 04.2023, и весь этот период на графике значения темпов прироста не превышают нуля.

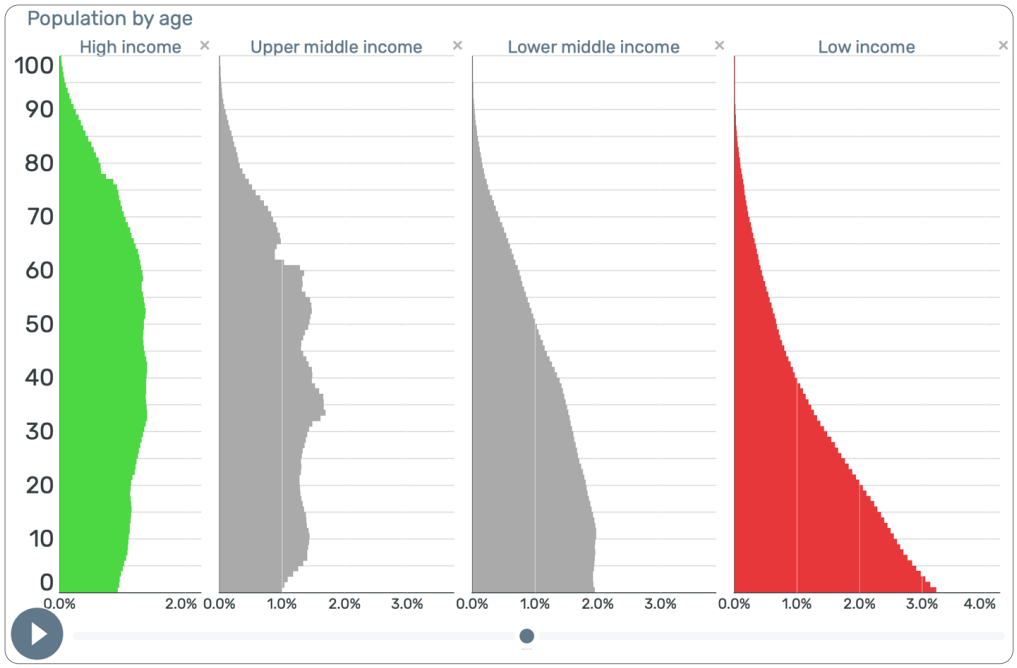
Рискованность портфеля оценивается по доле кредитов с высоким ПДН. За 2022 и 2023 год выросла и доля кредитов с ПДН более 50%.

Доли выданных кредитов на автомобили с пробегом и на новые оцениваются по соотношению частей столбцов на левом графике. В данном случае в январе 2021 года доля кредитов на автомобили с пробегом (доля красного в общей высоте

соответствующего столбца не больше 25%) сильно меньше, чем в январе 2023 года (красного около половины).

Объем выдач кредитов с 2022 года вырос: около 40 млрд рублей в январе 2022 по сравнению со 170 млрд рублей в марте 2024 (последние доступные данные). Кредиты действительно падали в марте и апреле 2022, однако здесь вопрос о том, выросли ли они в целом с 2022 года по последний доступный нам момент времени.

10. (5 баллов) На графиках представлены возрастные пирамиды (гистограммы, отражающие процент населения в каждой возрастной группе; в данном случае их 100 — одна группа соответствует каждому возможному значению возраста от 0 до 100) для четырех групп стран (на основе классификации Всемирного банка blogs.worldbank.org/en/opendata/new-world-bank-group-country-classifications-income-level-fy24), слева для самых богатых стран, справа — для самых бедных. Данные представлены на 2023 год.



Выберите одно или несколько верных утверждений на основе данных графиков:

а) В самых богатых странах происходит снижение отношения числа детей до 10 лет к численности взрослых в возрасте 30-40 лет в течение последних 10 лет (+/-)

б) В странах с самым высоким уровнем дохода в среднем самое молодое население

в) В странах с высоким доходом в ближайшие годы необходимо уделить большое внимание постройке новых школ для обеспечения всех детей возможностью для обучения

г) В странах с доходом ниже среднего люди в среднем моложе, чем в странах с низким доходом.

д) Среди других утверждений нет верных.

Решение. Пункт а) в оценивании не учитывался, поскольку действительно корректно оценить изменение соотношение за 10 лет по статическому графику без дополнительных предположений нельзя.

Соотношение средних возрастов можно оценить по долям людей каждого возраста и их соотношению. Так, в богатых странах людей в возрасте до 20 лет точно меньше 2%, в то время как в бедных странах (самый правый график) их точно больше. При этом обратная картина наблюдается для более старших возрастов (старше 40 лет). Из этой логики в среднем самое молодое население в самых бедных странах, а значит оно моложе, чем в странах с доходом ниже среднего.

В странах с высоким доходом очевидный тренд на снижение количества детей (по сути на снижение рождаемости). Поэтому старых школ достаточно для обеспечения меньшего количества детей местами и вопрос создания дополнительных мест не стоит. В самых же бедных странах этот вопрос стоит острее. Даже несмотря на более высокий уровень детской смертности (да и в целом смертности из-за проблем с доступом к медицине), непопулярность образования среди бедных семей (дети рано начинают работать и помогать с хозяйством родителям), если сравнить число детей, которые в текущем году выпускаются из школы (группа около 18 лет) и которые придут в школу (около 6 лет), численность различается в 1,5 раза. Сложно представить себе ситуацию, в которой такое увеличение числа учеников исправляется естественным образом. Таким образом, если не уделять внимание этому вопросу, возникающий дефицит учебных мест будет вести к снижению уровня образованности населения, а значит и к снижению качества жизни. При этом важно понимать, что «уделить внимание» не равно «строить обязательно». Возможно в стране и так уделяется внимание данному вопросу, и поэтому где-то дефицита и не возникает. Больше необходимого строить также никто не будет, потому что это экономически неэффективно, и подобный контраргумент не валиден.

11. (5 баллов) Компании часто берут кредиты в виде кредитных линий. В этом случае по договору с банком они могут в любой момент получить деньги, но только в определенных пределах. Обычно эти пределы восстанавливаются, если компания вовремя возвращает деньги. Исследования показывают, что в кризисные времена компании начинают чаще пользоваться этим видом кредитования.

    Группа ученых решила выяснить, как активно российские компании использовали кредитные линии во время пандемии. Для этого они собрали данные о всех кредитах, которые компании получили в период пандемии, а также за несколько лет до этого для сравнения. Также кредиты разделили на две группы: старые кредитные линии и новые кредиты. Затем рассчитали долю кредитов первой группы в общем объеме займов. Эти доли в зависимости от финансового состояния компании (платит ли она зарплату, расплачивается ли по старым займам вовремя, получает ли прибыль и т. д.), был ли этот период пандемийным или нет, а также относится ли компания к отрасли, сильно пострадавшей от кризиса (например, туризм, общественное питание и т. д.), показали на графиках.

Рис. 3. Доля ранее одобренных кредитных линий в общем объеме займов для компаний из не подверженных пандемии отраслей, в разбивке по децилям

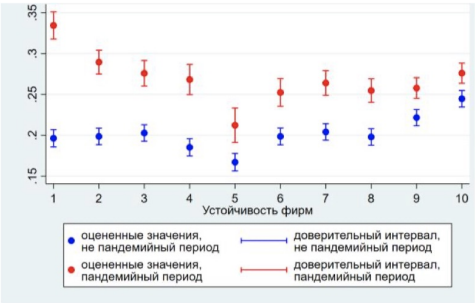
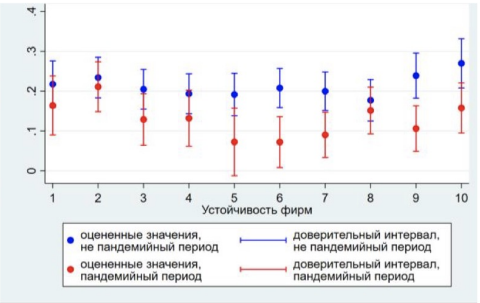


Рис. 4. Доля ранее одобренных кредитных линий в общем объеме займов для компаний из подверженных пандемии отраслей, в разбивке по децилям



Примечание. Оценки и доверительные интервалы для доли ранее одобренных кредитных линий в общем объеме заимствований компаний. Синие точки показывают оцененные значения для допандемийного периода (2017–2019 гг.), красные точки – для периода пандемии (2020 г.). Более высокие значения переменной «Устойчивость фирм» по шкале X соответствуют более высоким оценкам вероятности дефолта заемщика (то есть по более низким финансовым показателям компании).

Выберите одно или несколько верных утверждений, которые можно сделать на основании анализа указанных графиков

Обратите внимание на подпись к графикам: чем больше показатель «Устойчивость фирм», тем хуже финансовое состояние компании.

а) В допандемийный период менее устойчивые компании среди не подверженных пандемийному шоку активнее использовали имеющиеся у них кредитные линии по сравнению с более устойчивыми (+)

б) В пандемийный период компании из отраслей, подверженных пандемии, использовали кредитные линии с такой же интенсивностью или меньше по сравнению с допандемийным периодом (+)

в) В период до пандемии компании из отраслей, подверженных пандемии, использовали кредитные линии более интенсивно, чем компании из не подверженных шоку отраслей

г) В пандемийный период среди компаний, подверженных влиянию шока, самые финансово устойчивые (1-3 группы) и самые финансово неустойчивые (8-10 группы) компании пользовались кредитными линиями значительно активнее, чем средние фирмы (5 группа).

д) Среди других утверждений нет верных.

Решение. В п. а) необходимо посмотреть на положение синих точек (допандемийный период) на левом графике (неподверженные компании). Мы видим повышающийся тренд, при этом правый хвост находится статистически значимо выше левого. Отсюда можем сделать вывод, что менее устойчивые компании (которые находятся правее) использовали кредитные линии больше, чем более финансово устойчивые.

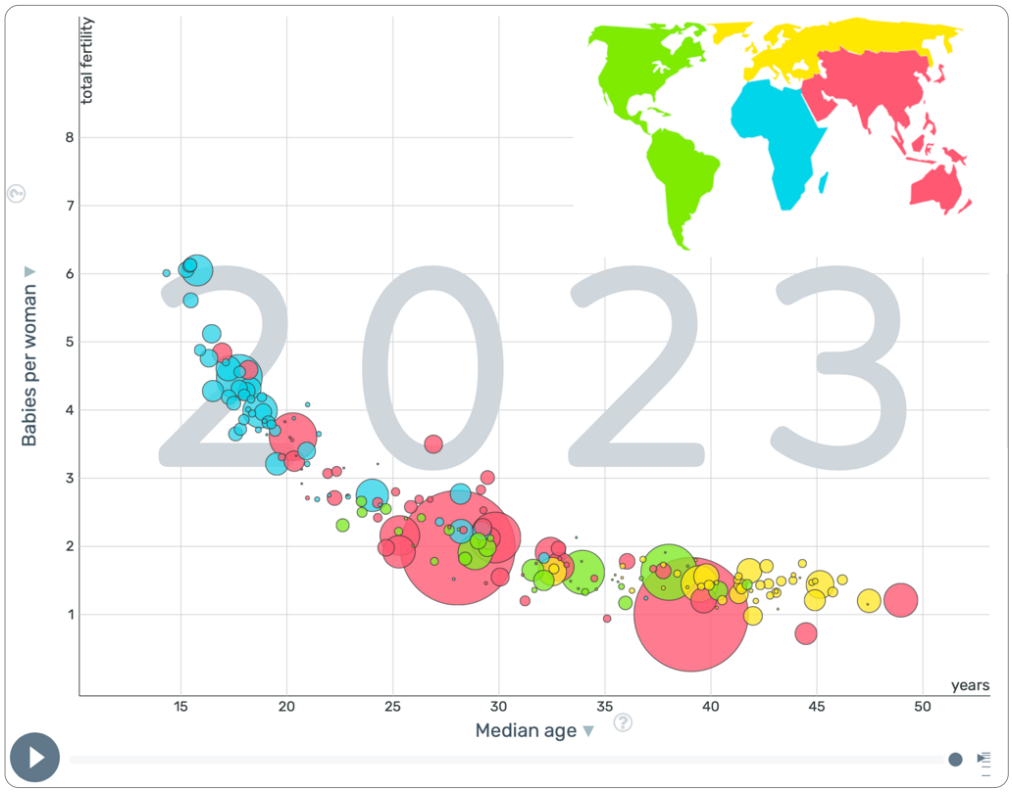
В п. б) необходимо сравнить синие (допандемийный период) и красные (пандемийный период) точки на правом графике (подверженные компании). Мы

видим, что красные точки с учетом доверительных интервалов в большинстве не отличаются от синих, а для некоторых групп фирм (например, 6 и 9 по шкале «Устойчивость фирм») лежат ниже.

В п. в) необходимо сравнить синие точки (допандемийный период) на левом графике (неподверженные компании) и на правом графике (подверженные компании). На первый взгляд может показаться, что справа точки выше, однако важно ориентироваться на шкалу и довольно широкие доверительные интервалы на правом графике, можно увидеть, что в обоих случаях значения находятся около 0,2 с подъемом до 0,25 в самом конце.

В п. г) смотрим на правый график (подверженные компании), красные точки (пандемийный период), и сравниваем три самые левые группы, три самые правые, и пятую в середине. С учетом доверительных интервалов, даже если найдется различие для одной группы из трех, нельзя сказать что все три наиболее устойчивые и три наименее устойчивые группы пользовались кредитными линиями активнее.

12. (5 баллов) На графике представлено распределение стран в зависимости от медианного возраста жителей (по горизонтальной оси), количества детей, приходящихся на одну женщину (по вертикальной оси) и размера населения (размер кругов).



Цвет кругов обозначает разные регионы мира в соответствии с картой.

Выберите одно или несколько верных утверждений, которые следуют из приведенного графика:

а) В среднем медианный возраст людей в странах Африки ниже, чем в Азии (включая Австралию, Океанию и Новую Зеландию) (+)

б) Среднее количество детей на одну женщину в Америке ниже, чем в Европе (включая Россию)

в) Чем больше численность населения в стране, тем больше медианный возраст людей в стране

г) Среднее количество детей на женщину в среднем отрицательно взаимосвязано с медианным возрастом (+)

д) Среди других утверждений нет верных.

Решение.

а) Африка отражается на графике синим цветом, Азия — красным. Большая часть стран Африки располагается в медианном возрасте 15-30 лет (большинство сконцентрировано в районе 15-20 лет), в то время как в странах Азии медианный возраст доходит до 50 лет (большая концентрация наблюдений в районе 25-30 лет). Поэтому в среднем в Африканских странах медианный возраст ниже, чем в Азии.

б) Америка отражена на карте зеленым цветом, Европа — желтым. Большая часть наблюдений в этих странах лежит между 1 и 2 детьми, однако в случае Америки есть ряд стран с количеством детей 2-3 на одну женщину. Соответственно, в Америке не может быть в среднем меньше детей, чем в Европе.

в) Два больших круга на графике — это Китай и Индия. Они находятся довольно близко к середине по медианному возрасту. Остальные круги так не выделяются и расположены более-менее равномерно по всем медианным возрастам, так что нельзя говорит о наличии положительной взаимосвязи между медианным возрастом и численностью населения.

г) На графике очевидна отрицательная взаимосвязь этих двух показателей. При этом важно отметить, что мы говорим именно о взаимосвязи, выводах о причинности в данном случае мы бы не смогли сделать.

13. (2 балла) Если бы вы хотели оценить взаимосвязь среднего количества детей на одну женщину и медианного возраста, то какое из приведенных ниже уравнений подошло бы больше всего для данных на рисунке выше? Выберите один верный вариант ответа. Все коэффициенты положительные.

а) b0-b1*Median Age

б) b0+b1/Median Age (+)

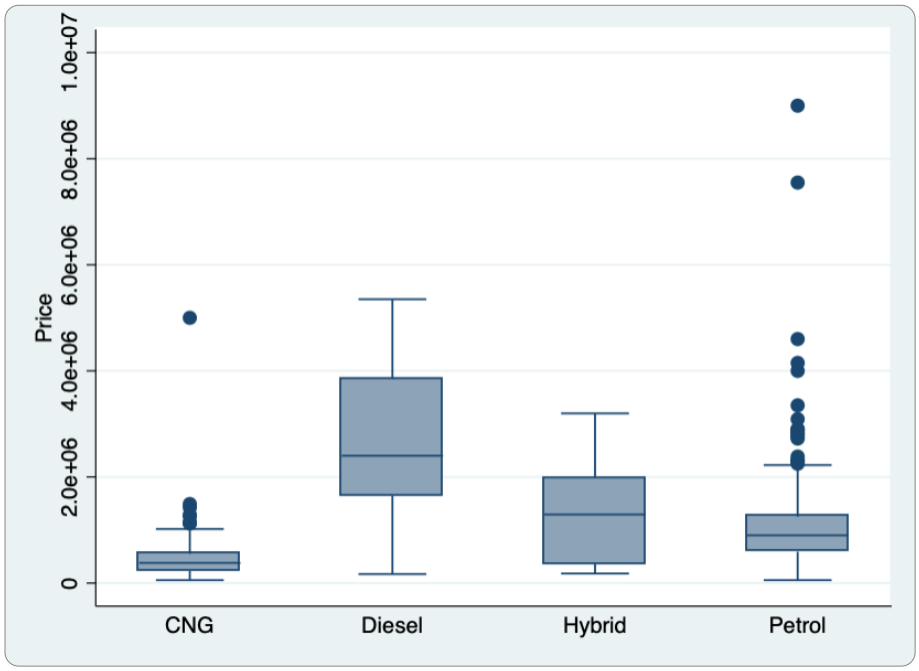
в) b0-b1*(Median Age)^2

г) b0+b1*(Median Age)^0,5

Решение. По графику мы видим убывающую взаимосвязь, больше всего похожую на гиперболу. Соответственно, из перечисленных наиболее подходящее уравнение регрессии имело бы вид

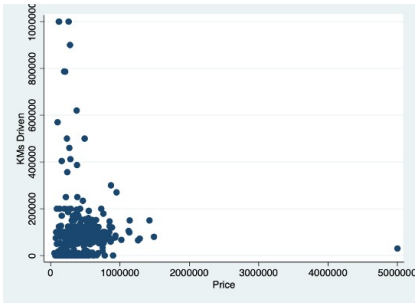
Babies per woman=b0+b1/Median age. Однако похожую форму может иметь график корня, если взять его с минусом и сдвинуть выше (то есть b0-b1*(Median Age)^0,5), либо функция логарифма, взятая с минусом и также сдвинутая выше (b0-b1*ln (Median age)). Важно, что функция должна отражать отрицательную взаимосвязь и иметь определенную форму (сначала сокращаться довольно быстро, а затем все медленнее, стремясь к горизонтали).

14. (8 баллов, по 2 за каждое верное соотнесение) На графике представлены «ящики с усами», отражающие распределение цены автомобиля в зависимости от типа топлива.

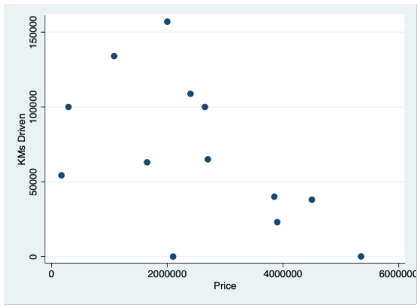


Также имеется 4 диаграммы рассеяния для изучения зависимости цены автомобиля от пробега по подгруппам в зависимости от топлива. Соотнесите диаграммы рассеивания и тип топлива автомобилей.

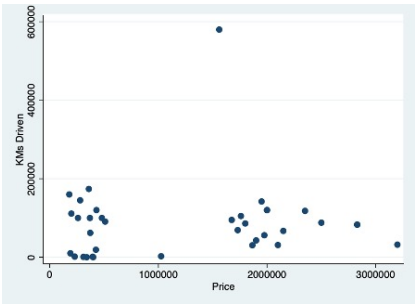
а)



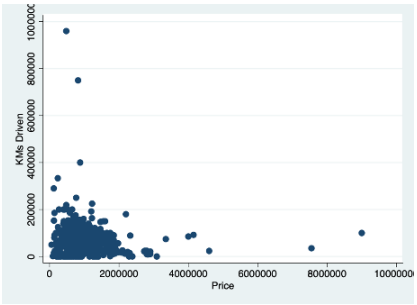
б)



в)



г)



Решение:

а) CNG (выявляется по явному одиночному выбросу Price=5 000 000)

б) Diesel (равномерно распределены наблюдения, почти от 0 до 6 000 000)

в) Hybrid (две ценовые группы на «ящике с усами» выделяться существенно не будут, однако здесь максимальная цена ниже, чем у предыдущего типа топлива)

г) Petrol (в основном отличается сильной концентрацией наблюдений от 0 до примерно 2 00 0000, и далее два сильно выделяющихся наблюдения справа: близкое к 8 000 000 и около 9 000 000)

15. (4 балла)

С использованием данных из предыдущей задачи была оценена регрессионная модель зависимости цены автомобиля от года выпуска, пробега, типа топлива и новизны. Получилось следующее уравнение (все перечисленные коэффициенты значимы на 5% уровне значимости):

Price= -62376.67 — 0.137*KMs + 31.52*Year — 277.11*D_used + 1863.70*D_Diesel

KMs — пробег в тысячах километров, Year — год выпуска, D_used — переменная, равная 1, если автомобиль подержанный («с пробегом»), и 0, если новый. Последняя переменная — индикатор для типа топлива (то есть D_Diesel=1, если это двигатель работает на дизельном топливе, и 0, если тип топлива другой).

Возьмем два автомобиля: оба 2000 года выпуска, подержанные, на дизельном топливе. Пробег одного из них составляет 60 тыс. километров, а второго — 120 тыс. километров. На сколько процентов дороже будет первый автомобиль по сравнению со вторым, исходя из полученных оценок модели? Укажите ответ в процентах от меньшей цены. Если ответ представлен в виде дроби, округлите его до двух знаков после запятой. Единицы измерения указывать не нужно.

Ответ: 0,37%

Решение: Из условия в уравнение необходимо подставить значение для соответствующих переменных (год выпуска 2000; индикатор автомобиля с пробегом равен 1, поскольку обе машины в примере с пробегом; аналогично индикатор автомобиля на дизельном топливе будет в обоих случаях равен 1; пробег у двух автомобилей одинаковый, в уравнение вносится без дополнительных нулей, поскольку было сказано, что KMs уже в тысячах). Разница в процентах указана в таблице ниже.

	коэффициенты	**Авто 1**	**Авто 2**
const	–62 376,67		
KMs	–0,14	60	120
Year	31,52	2000	2 000
D_used	–277,11	1	1
D_Diesel	1863,7	1	1
Оценка цены		2241,7	2 233,48
			0,3680%

16. (3 балла)

Для более полного анализа факторов, влияющих на цену, было решено учесть влияние марки автомобиля, и в модель добавили индикатор на одну из наиболее часто встречающихся марок, а именно на марку Suzuki. Коэффициент для данной переменной и 95% доверительный интервал для него получились следующие:

Переменная	**Коэффициент**	**[доверительный интервал]**	
Suzuki	–443.64	–514.86	–372.42

Какой вывод о взаимосвязи марки автомобиля на цену вы можете сделать исходя из данной информации? Выберите верный вариант ответа:

а) При прочих равных автомобили марки Suzuki стоят значимо дешевле, чем средний автомобиль другой марки (+)

б) При прочих равных автомобили марки Suzuki стоят значимо дороже, чем средний автомобиль другой марки

в) При прочих равных автомобили марки Suzuki значимо не отличаются по стоимости от среднего автомобиля другой марки

г) Приведенных данных недостаточно для того, чтобы сделать вывод о значимости различия цены автомобиля Suzuki от среднего автомобиля другой марки

Решение: Проверка гипотезы о значимости отличия коэффициента от 0 с помощью доверительного интервала проводится следующим образом: если 0 принадлежит доверительному интервалу, то мы не может сказать, что коэффициент значимо от него отличается, если 0 не принадлежит доверительному интервалу, то может сказать, что коэффициент значимо отличен от нуля. В последнем случае можем интерпретировать знак коэффициента. В данном случае индикатор ставился только на автомобили марки Suzuki, чтобы сравнить их цену со средней ценой машин остальных марок. В данном случае видим, что коэффициент отрицательный, а ноль не принадлежит доверительному интервалу. Значит машины марки Suzuki стоят значимо дешевле автомобиля другой марки.

17. (8 баллов) (см. файл 17_Распределение средств клиентов банков)

В таблице приведены данные о распределении средств различных клиентов банков (физических лиц, юридических лиц и ИП) в зависимости от размера вкладов: например, группа «<100» означает, что в этой группе собраны все вклады размером 100 тыс. рублей и меньше. Для каждого такого диапазона размера вклада и типа вкладчика указана общая сумма всех депозитов в млрд. руб. Вклады до 1,4 млн рублей являются застрахованными. Если размер вклада превышает эту сумму, то он является частично застрахованным.

Выберите одно или несколько верных утверждений, которые можно сделать на основе анализа данной таблицы.

а) На 1 июля 2024 г. в общем объеме вкладов наибольшую долю составляют депозиты размером более 20 млн. рублей (+)

б) За 1 квартал 2024 года увеличилась общая сумма вкладов физических лиц на депозиты в каждом диапазоне объемов

в) Темп прироста полностью застрахованных депозитов в июне 2024 года превышает среднемесячный темп прироста таких депозитов в 2023 году (+)

г) Все группы депозитов юридических лиц объемом свыше 700 тыс. рублей в апреле и мае 2024 года росли в среднем темпом не менее 1% в месяц (+)

д) Среди других утверждений нет верных.

Решение:

а) Для расчетов используем столбец R. Сумма вкладов на депозитах размеров более 20 млн. рублей составляет около 32% от всех. Эта доля наибольшая из всех групп (следующая по объему группа депозитов размером от 1,4 млн до 3 млн рублей.

б) В данном случае используем столбец K, и считаем темп прироста относительно 1 января 2024 года (т.е. столбца G). Можем заметить, что для самой первой группы происходит снижение объемов депозитов в объемах до 100 тыс. рублей. Соответственно приведенное в этом пункте утверждение неверное.

в) Темп прироста в июне считается исходя из отношения данных в столбце R к данным в столбце N. Темп прироста в 2023 году считается из отношения столбца F к столбцу B. Получаем 1,40%. Для получения среднемесячного темпа необходимо воспользоваться формулой сложных процентов, то есть из темпа роста (единица плюс темп прироста) взять корень 12 степени и вычесть 1. Получаем 0,93%.

г) Изменение депозитов юридических лиц за апрель и май оценивается по сравнению столбцов Q и M. Начиная с группы в 700 тыс. рублей и по возрастанию размера депозита, среднемесячные темпы прироста составили 1,57%, 2,39%, 2,45%, 2,99%, 2,59%, 2,62% и 4,32%. Все они больше 1%.

18. (8 баллов) 18_Hit.csv и 18_Hits_description

В файле 1 собраны данные о более чем 14 тысячах популярных песен с 1899 года. Описание характеристик можно найти в файле 2. Проанализируйте представленные данные и выберите одно или несколько верных утверждений.

а) Более энергичные песни в среднем более громкие (+)

б) Средняя продолжительность песни в жанре Folk составляет не более 3 минут

в) усредненное по песням жанра значение переменной Acoustic является наибольшим для жанра Jazz (+)

г) В жанре Country более продолжительные композиции являются более популярными, в то время как в жанре EDM напротив более популярны менее продолжительные композиции (+)

д) Среди других утверждений нет верных.

Решение.

а) Корреляция loudness и energy составляет примерно 0,75, она статистически значима. Значит более энергичные песни в среднем более громкие.

б) Находим среднее значение только среди песен, где значение genge=»-Folk». Можно предварительно перевести продолжительность каждой песни

из миллисекунд в минуты, можно сделать уже после расчета среднего. Получаем примерно 3,75 минуты, что больше 3 минут.

в) Находим среднее значение переменной Acousticness по каждому жанру. Далее выбираем из них максимальное. Оно действительно относится к жанру Jazz и составляет примерно 0,73.

г) Здесь необходимо сравнить корреляции двух переменных, которые мы находим для песен двух жанров: Country и EDM. В первом случае она составляет 0.29 и статистически значимая. Во втором случае она составляет -0,20 и она тоже статистически значимая. Таким образом, в жанре Country более популярны более продолжительные композиции, а в жанре EDM более популярны менее продолжительные композиции.

19. (4 балла, по 1 баллу за каждый верно заполненный пропуск) 19_stock_price_1.xlsx

Ваши коллеги из другого отдела занимаются учетом стоимости имеющихся у компании акций разных компаний. Данные за июль 2024 года представлены в файле stock_price. Там отражена цена акций четырех компаний: A, B, C и D. Вашим коллегам важно, чтобы цена у каждой бумаги была каждый день, и они прибегают к следующему способу вести свой учет. В дни, когда торги проводились (т.е. в рабочие дни), указывается цена закрытия этого дня. В другие дни (выходные или праздники) указывается последняя известная цена. Они просят вас отранжировать бумаги по их риску и выявить наиболее и наименее рискованные акции.

В качестве меры риска предполагается использование коэффициента вариации. Вы также знаете, что при анализе рисков следует ориентироваться только на дни, когда проводятся торги. Исходя из сделанных вами расчетов, запишите в соответствующие поля название наиболее и наименее рискованной акции, а также укажите коэффициент вариации для них. В ответе необходимо указать название компании и коэффициент вариации в долях. Если ответ представлен в виде дроби, округлите его до трех знаков после запятой. Единицы измерения указывать не нужно.

Наиболее рискованная акция компании « », коэффициент вариации « »

Наименее рискованная акция компании « », коэффициент вариации « »

Решение:

Для расчетов необходимо было удалить наблюдения за выходные дни (остается 23 наблюдения). Далее рассчитывается коэффициент вариации как отношение стандартного отклонения к среднему. Акции компания, где коэффициент вариации максимальный из четырех, являются наиболее рискованными, а где коэффициент минимальный — наименее рискованными. Поскольку не было сказано, выборка представлена или генеральная совокупность, засчитывались оба варианта подсчета стандартного отклонения.

Наиболее рискованная акция компании «B», коэффициент вариации «0,059»(0,058)

Наименее рискованная акция компании «C», коэффициент вариации «0,033»(0,032)

20. (8 баллов + 4 балла) 20_employee_v1.csv и 20_employee_description

Вам необходимо проанализировать ряд показателей, связанных с исполнением трудовых функций работников некоторой компании. Данные представленны в файле employee.csv, их описание — в файле employee_description.

В частности, руководство компании интересуется, какое влияние коллеги оказывают друг на друга (например, более производительные коллеги мотивируют работать лучше, или напротив, мешают выполнению обязанностей). В данном случае коллегами будут считаться люди, выполняющие одну и ту же роль (jobrole) в одном и том же департаменте (department) в одном регионе (state) в один и тот же год проведения оценивания. Оно проводится раз в год, дата проведения указана в переменной reviewdate.

Взаимосвязи между количественными переменными рассматриваются на основе статистической значимости соответствующей корреляции, количественной переменной с категориальной — на основе статистически значимого различия в средних на подвыборках.

Часть 1. Расчеты (8 баллов, по одному за каждое верно заполненное число)

Заполните пропуски необходимыми значениями. Если ответ представлен в виде дроби, округлите его до двух знаков после запятой. Единицы измерения указывать не нужно.

Для исследования влияния опыта работы сотрудника на оценку его деятельности менеджером будем ориентироваться на два показателя: время работы в компании и время работы на последней должности. В среднем продолжительность работы в компании в годах составляет приблизительно 5,70 (5,26), а продолжительность работы на последней должности в годах — 2,81 (2,59).

При анализе влияния коллег мы фокусируем внимание на 6015 (1154, 6013, 1153) работниках из общего количества в 6059, у которых есть хотя бы один коллега. Среднее значение оценок менеджера, полученных коллегами, составляет 3,47. В среднем у таких работников имеется 50.54 (50,56) коллег.

Коэффициент корреляции времени работы в компании с оценкой менеджера составляет 0.02. Коэффициент корреляции времени работы на последней должности с оценкой менеджера составляет 0.03. Коэффициент корреляции оценки менеджера для работника с оценкой его коллег составляет 0,00.

Комментарии по решению:

Количество коллег и среднее по оценкам, которые им выставил менеджер, не дано. Исходя из описания, коллеги определялись по нескольким факторам: роль, департамент, регион и год. После группировки по указанным характеристикам необходимо было посчитать количество людей в группе, за исключением самого человека, для которого считаем число, и среднюю оценку людей в группе, опять же за исключением самого себя. Эта средняя оценка коллег и есть та переменная, с которой необходимо было посчитать последнюю корреляцию.

Первые два числа (продолжительность работы в компании и на последней должности) можно рассчитывать из двух соображений. Во-первых, мы характеризуем целиком наши данные, которые являются несбалансированными панельными данными (когда много людей наблюдаются в течение нескольких периодов времени и имеют много характеристик, при этом некоторые люди уходят

из выборки, а некоторые появляются). Тогда мы можем просто посчитать среднее значение длительности работы в компании по всем наблюдениям. У этого подхода есть ограничение в виде того, что люди, работающие несколько лет, будут создавать искажение. Поэтому можно использовать второй подход — взять срез на последний год. В данной выборке последний год 2022, поэтому можно было посчитать среднее значение показателей только по этому году. Во всех остальных подходах (когда оставляют одно какое-то наблюдение или только последнее), результат не может быть никак проинтерпретирован. Других оснований для исключения наблюдений из подсчета среднего нет (в том числе, не подходит индикатор увольнения сотрудника, если по нему есть данные на 2022 год, потому что человек уволился после проведения опроса).

Переходим к подсчету количества работников. Да, действительно, если считать по уникальным идентификаторам работников, людей будет сильно меньше, чем 6059 даже в общем наборе. Однако в одном из подходов к работе с панельными данными наблюдения за одним человеком в разные периоды времени может приниматься за два разных наблюдения за разными людьми (так называемая сквозная регрессия). В силу того, что формулировку можно интерпретировать по-разному, засчитывалось как подсчитанное количество строк, которое остается без учета людей без коллег, так и количество уникальных идентификаторов. Более того, в выборке имеются люди, которые дважды проходили опрос в течение одного года (1 января и 31 декабря). Один из них из-за этого становился коллегой сам себе, и отсюда могло браться еще одно расхождение, однако если эта проблема с базой не была замечена, ошибкой это не считалось. На дальнейшие расчеты этот нюанс не оказывал влияния (кроме количества коллег, что также отражено в наличии второго возможного ответа).

Корреляции времени работы в компании и на должности необходимо было считать по всем людям, а не только по тем, у кого есть коллеги: в тексте задания, когда надо вписывать, уточняется, что при анализе влияния коллег мы ограничиваем выборку, но не при анализе влияния своего стажа. Статистическая значимость корреляции проверяется отдельным тестом (как проверяется значимость коэффициентов в уравнении регрессии, или значимость различия средних). Граничные значения, которые приводятся в некоторых учебниках (0,2; 0,3; 0,5 и пр.) — не определяются статистической значимостью. Они могут говорить о силе взаимосвязи, о близости точек к некоторой прямой, о некоторой «экономической значимости», но они не говорят о статистической значимости. В данном случае из трех регрессий статистически значимой на 5% уровне значимости оказывается лишь одна — корреляция времени работы на последней должности с оценкой менеджера. Можно ли при таком уровне говорить о том, что на scatter plot точки будут лежать близко к одной линии или вообще будут похожи на вытянутое в нужном направлении облако? Нет, не будут. Грубо говоря, из всего разброса одной переменной мы с помощью другой можем объяснить лишь 3%. Но этого достаточно, чтобы корреляция была статистически значимой.

Часть 2. Интерпретация. (4 балла, по 1 баллу за каждый верно заполненный пропуск)

Выберите наиболее подходящее заполнение пропуска из предложенных вариантов исходя из анализа, проведенного в Части 1.

Переходя к анализу влияния опыта работы, время работы в компании (связано положительно/связано отрицательно/не связано) с оценкой менеджера. Время работы на последней должности с оценкой менеджера (связано положительно/связано отрицательно/не связано).

Корреляция средней оценки менеджера, полученной коллегами, и показателя с оценкой самих работников является (положительной/отрицательной/нулевой), что говорит о (наличии положительной/наличии отрицательной/отсутствии) взаимосвязи между оценкой работника и средней оценкой его коллег.

Комментарии к решению: из трех корреляций статистически значимой и положительной оказалась лишь одна — корреляция оценки менеджера с временем работы на последней должности. Поэтому второй пропуск заполняется как «связано положительно». Более развернутый комментарий по поводу статистической значимости приведет выше. Две остальные корреляции статистически не отличимы от нуля, а значит взаимосвязи там нет, а про корреляцию мы можем сказать, что она нулевая, вне зависимости от полученного знака.

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ

Т БАНК

Документ приведен в редакции, согласованной на итоговом заседании жюри и оргкомитета Национальной олимпиады по анализу данных DANO от 17 декабря 2024 г.

Блок I — постановка задачи (MAX 9 Б)

Критерий	0 баллов	1 балл	2 балла	3 балла	Вес
Предварительный анализ и анализ структуры данных	Предварительного анализа нет или он некорректный	Представлен анализ структуры данных И Без ошибок сделано два из трех: ▸ Исследованы основные показатели, их статистики ▸ Исследованы распределения основных показателей ▸ Обработаны выбросы	То же, что на 1 балл, И сделано одно из двух: ▸ исследованы взаимосвязи/ корреляция переменных ▸ сделаны выводы из предварительного анализа, показано как выявленные нюансы базы данных влияют на дальнейшее исследование	То же, что на 1 балл, И сделано два из двух: ▸ исследованы взаимосвязи/ корреляция переменных ▸ сделаны выводы из предварительного анализа, показано как выявленные нюансы базы данных влияют на дальнейшее исследование	1
Гипотеза и исследовательский вопрос	Нет гипотезы, нет исследовательского вопроса, или гипотеза не соответствует вопросу	Есть четко сформулированные гипотеза и исследовательский вопрос, гипотеза соответствует исследовательскому вопросу	Есть четко сформулированные гипотеза и исследовательский вопрос; гипотеза соответствует исследовательскому вопросу, соотносится с предварительным анализом и не противоречит ему	Не ставится	2
Механизм	Механизма нет, рассуждения, почему гипотеза может быть верна, не представлены	Механизм есть, представляет собой логическую цепочку, объясняющую, почему гипотеза может быть верна, но с недостатками в логике или не соотносится с гипотезой	Механизм есть, представляет собой логическую цепочку, объясняющую, почему гипотеза может быть верна, механизм соотносится с гипотезой	Не ставится	1

Блок II — Анализ (MAX 13 Б)

Критерий	0 баллов	1 балл	2 балла	3 балла	Вес
Математические методы проверки гипотезы	Нет мат. методов, или любой из методов применен с критичными ошибками или необоснованно	Использованы матмодель/ матметоды, без критичных ошибок, учтен размер выборки и другие выводы из преданализа. Матметоды проверяют гипотезу (или пункты механизма) и ни что другое, применение каждого метода обосновано	То же, что на 1 балл, плюс учтена вариативность и структура данных, проверена устойчивость моделей, показана применимость выбранного метода для проверки выбранной гипотезы на данном датасете	То же, что на 2 балла, плюс математический анализ полный: все пункты механизма, которые можно проверить на предоставленных данных, исследованы	2
Визуализация результата	В работе нет визуализации, или визуализация не отражает обсуждаемые в исследовании зависимости	Визуализация есть (хотя бы один график/схема/ таблица), но ее невозможно проинтерпретировать без пояснений	В работе есть визуализация (несколько иллюстраций разного типа), она считывается без пояснений, из нее можно сделать выводы	То же, что на 2 балла, плюс анализ полный: проиллюстрированы все обсуждаемые в исследовании закономерности, включая матмодель	1
Интерпретация	Интерпретация не представлена	Интерпретация результатов представлена, опирается именно на результат работы модели/матметодов, но в ней есть существенные недочеты	Интерпретация результатов представлена, опирается именно на результат работы модели/матметодов и в ней нет существенных недочётов	Не ставится	2

Блок III — Выводы (MAX 10 Б)

Критерий	0 баллов	1 балл	2 балла	3 балла	Вес
Выводы и рекомендации	В работе НЕ описаны перспективы/ограничения И практическая польза исследования	Выполнено одно из трех: - Описана реально применимая практическая польза и/или policy implication - Обсуждаются альтернативные механизмы или направления влияния, которые могли привести к тем же выводам из модели - Описаны другие ограничения применения модели к используемым данным	Выплнено два из трех: - Описана реально применимая практическая польза и/или policy implication - Обсуждаются альтернативные механизмы или направления влияния, которые могли привести к тем же выводам из модели - Описаны другие ограничения применения модели к используемым данным	Выплнено три из трех: - Описана реально применимая практическая польза и/или policy implication - Обсуждаются альтернативные механизмы или направления влияния, которые могли привести к тем же выводам из модели - Описаны другие ограничения применения модели к используемым данным	2
Командная работа	Командная работа не видна (не все участвовали в работе, или каждый участник знает только свою часть решения)	Командная работа видна, но не все участники знают общую картину и полностью разбираются в решении команды	Командная работа видна, все участники хорошо разбираются в решении команды	Не ставится	1
Общее впечатление от исследования	В работе использованы стандартные методы или полученные выводы тривиальны	В целом исследуемый вопрос и полученные выводы нетривиальны, использованы нестандартные модели/ визуализации/механизмы, в работе логично выстроено повествование и считывается история	Не ставится	Не ставится	2

Ограничений на баллы в зависимости от баллов за другие криерии не предусмотрено

Процедура подсчета итогового балла за Проектный тур:

1. Каждый эксперт из комиссии выставляет команде баллы по каждому из критериев.
2. По каждому критерию, кроме Общего впечатления, рассчитывается медианный балл среди баллов выставленных членами комиссии
3. По критерию Общее впечатление рассчитывается средний балл.
4. Полученные медианные и средние баллы по критериям подставляются в формулу:
   Оценка = сумма ([медианной или средней оценке за критерий] * вес криетрия) по всем критериям во всех блоках.
5. Итоговая оценка за проектный тур = Оценка/32 * 100, без округлений.

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ | ТИНЬКОФФ

ВТОРОЙ ОТБОРОЧНЫЙ ЭТАП, 1 ВАРИАНТ 2023/2024

1. (2 балла) Один интернет-магазин решил добавить для пользователей мобильных устройств кнопку чата в углу экрана. Но перед этим он выбрал большую репрезентативную группу своих постоянных клиентов, чтобы посмотреть, насколько востребованной будет эта функция. Оказалось, что в этой группе половина — пользователи Android, треть — пользователи браузерной версии, а остальные — пользователи iOS. При этом после теста выяснилось, что из пользователей Android кнопкой чата воспользовались лишь 40%, среди пользователей браузерной версии — 65%, а среди пользователей iOS — 95%. (Известно, что каждый клиент в группе пользуется только одной из платформ.)

   Исходя из этих данных, если постоянный клиент воспользовался кнопкой чата, то пользователем какой платформы из этих трех он вероятнее всего является?

   a. Android

   b. Браузерная версия (+)

   c. iOS

   d. Из этих условий невозможно однозначно определить ответ

2. (2 балла) Юный исследователь захотел оценить количество посетителей ближайшего торгового центра. Заняться проведением наблюдений было решено в выходные. Он тщательно пересчитал всех посетителей ТЦ в субботу и воскресенье. За время наблюдений получилось, что в среднем ТЦ посещает 1548 человек в день, или 46 440 человек за месяц. Как вы можете прокомментировать полученную оценку числа посетителей?

   a. Эта оценка близка к реальному количеству посетителей

   b. Эта оценка будет занижать количество посетителей

c. Эта оценка будет завышать количество посетителей (+)

d. Недостаточно данных, чтобы ответить на вопрос

3. (2 балла) Один интернет-магазин в конце 2023 года решил объявить список из 7 своих самых продаваемых товаров за год. Каждый из аналитиков магазина, включая главу аналитики и стажера, попробовал угадать этот список — и записал заранее 7 товаров, которые, как он предположил, туда попадут. После оглашения списка оказалось, что половина аналитиков угадали от 3 до 6 товаров, глава аналитики угадал все товары, стажер угадал лишь 1 товар. А остальные угадали ровно по 2 товара, причем среди них нет тех, кто угадал один и тот же набор из 2 товаров, а также нет тех, кто угадал товар, угаданный стажером.

   Какое максимальное число аналитиков может работать в этом магазине?

   a. 34 (+)

   b. 36

   c. 44

   d. 46

4. (5 баллов) Выборка состоит из 3051 различного числа, причем все числа положительные и представимы в виде конечной десятичной дроби. Все числа из выборки упорядочили по возрастанию и разделили на 9 равных по величине групп, которые пронумеровали от 1 до 9. То есть первые 339 чисел упорядоченной выборки оказались в группе 1, следующие 339 чисел — в группе 2 и так далее. Выберите все верные утверждения:

   a. Среднее арифметическое чисел в группе 3 больше среднего арифметического чисел в группе 2 (+)

   b. Если одно число больше другого в 9 раз, то они обязательно окажутся в разных группах

   c. Медиана выборки обязательно окажется в группе 5 (+)

   d. Сумма двух чисел из группы 1 не может оказаться больше числа из группы 9

   e. Среди перечисленного выше нет верных ответов

5. (5 баллов) В таблице ниже представлено распределение ответов школьников на вопрос «Как изменилась ваша успеваемость в этом учебном году

по сравнению с предыдущим?». Все ученики отвечали на вопрос правдиво, таким образом, представленные числа отражают реальное изменение успеваемости.

Ответ	Частота
Значительно улучшилась	16
Немного улучшилась	8
Не изменилась	12
Немного ухудшилась	4
Сильно ухудшилась	3

Выберите все верные варианты ответа:

a. Успеваемость улучшилась более чем у половины школьников (+)

b. Успеваемость не улучшилась более чем у половины школьников

c. У медианного школьника успеваемость не изменилась

d. У медианного школьника успеваемость немного улучшилась (+)

e. Среди перечисленного выше нет верных ответов

6. (5 баллов) Кристина устала от подсчета обычного среднего арифметического — и решила придумать свое среднее, которое назвала «среднее Кристинино». Оно считается так: если имеется выборка из N различных чисел, то она сначала упорядочивается либо по возрастанию, либо по убыванию, а затем считается среднее арифметическое первых 2 чисел, потом — среднее арифметическое получившегося среднего и следующего числа из выборки, затем — получившегося теперь числа и следующего числа из выборки и так далее.

Например, если выборка состоит из 5 упорядоченных по возрастанию/убыванию чисел a_1, a_2, a_3, a_4, a_5, то:

$$m_{Kp} = \frac{\frac{\frac{\frac{a_1+a_2}{2}+a_3}{2}+a_4}{2}+a_5}{2}$$

Кристина решила протестировать работу придуманного ею среднего и взяла какую-то выборку из 16 различных натуральных чисел $a_1, a_2, \ldots, a_{16}$, каждое от 1 до 100. Она упорядочила выборку либо по возрастанию, либо по убыванию, затем посчитала среднее Кристинино и среднее арифметическое — и сравнила их.

Какие результаты могли получиться у Кристины?

a. Если Кристина упорядочила выборку по возрастанию, то среднее Кристинино могло оказаться больше среднего арифметического (+)

b. Если Кристина упорядочила выборку по возрастанию, то среднее Кристинино могло оказаться меньше среднего арифметического

c. Если Кристина упорядочила выборку по убыванию, то среднее Кристинино могло оказаться больше среднего арифметического

d. Если Кристина упорядочила выборку по убыванию, то среднее Кристинино могло оказаться меньше среднего арифметического (+)

e. Среди перечисленного выше нет верных ответов

7. (8 баллов, по 2 на каждый вопрос) Предположим, в стране проживает 9 человек, доходы которых представлены в таблице ниже. Государству не нравится, что средний доход отличается от медианного, и оно хочет это исправить. Для этого предлагается ввести в стране налоги на богатых и раздать эти деньги другим гражданам. При этом государство также хочет собирать как можно меньше налогов с богатых.

Вам необходимо посчитать, сколько налогов и субсидий необходимо собрать и раздать, чтобы медиана и среднее оказались равны. Если подходящих способов несколько, используйте любой из них для ответа на все вопросы ниже

Житель	A	B	C	D	E	F	G	H	I
Доход (у. е.)	8	10	10	20	30	60	100	170	600

Вопрос 1. Кто из жителей будет получать субсидию? Перечислите их в алфавитном порядке через запятую.

Ответ: E, F, G

Вопрос 2. Какую субсидию будет получать каждый из тех жителей, которых вы перечислили выше? Перечислите их через запятую в порядке, соответствующем порядку жителей. Если ответ представлен в виде дроби, округлите его до целого. Единицы измерения указывать не нужно.

Ответ: 82, 52, 12

Вопрос 3. Кто из жителей будет платить налог? Перечислите их в алфавитном порядке через запятую.

Ответ: либо I; либо H, I

Вопрос 4. Какой объем налогов суммарно заплатят все, кого вы перечислили выше? Если ответ представлен в виде дроби, округлите его до целого. Единицы измерения указывать не нужно.

Ответ: 146

8. (5 баллов) В таблице ниже приведены данные об общей кредитной задолженности компаний и индивидуальных предпринимателей по видам экономической деятельности и направлениям использования средств (в млн рублей).

Виды экономической деятельности и отдельные направления использования средств	01.02.2019	01.03.2019	01.04.2019
ВСЕГО	25 728 662	25 885 238	26 209 480
добыча полезных ископаемых	959 863	973 512	986 700
обрабатывающие производства	6 082 270	6 137 454	6 138 053
производство и распределение электроэнергии, газа и воды	1 218 916	1 207 717	1 180 787
сельское хозяйство, охота и лесное хозяйство	1 725 294	1 746 871	1 800 908
строительство	1 063 041	1 087 213	1 108 528
транспорт и связь	1 771 028	1 805 037	1 841 668
оптовая и розничная торговля	3 681 859	3 678 621	3 747 668
операции с недвижимым имуществом, аренда и предоставление услуг	3 874 280	3 915 409	3 936 643
прочие виды деятельности	5 078 084	5 040 035	5 163 325
на завершение расчетов	274 027	293 369	305 200

Выберите все верные утверждения из представленных ниже:

a. За март 2019 г. общий объем кредитов вырос примерно на 0,6%

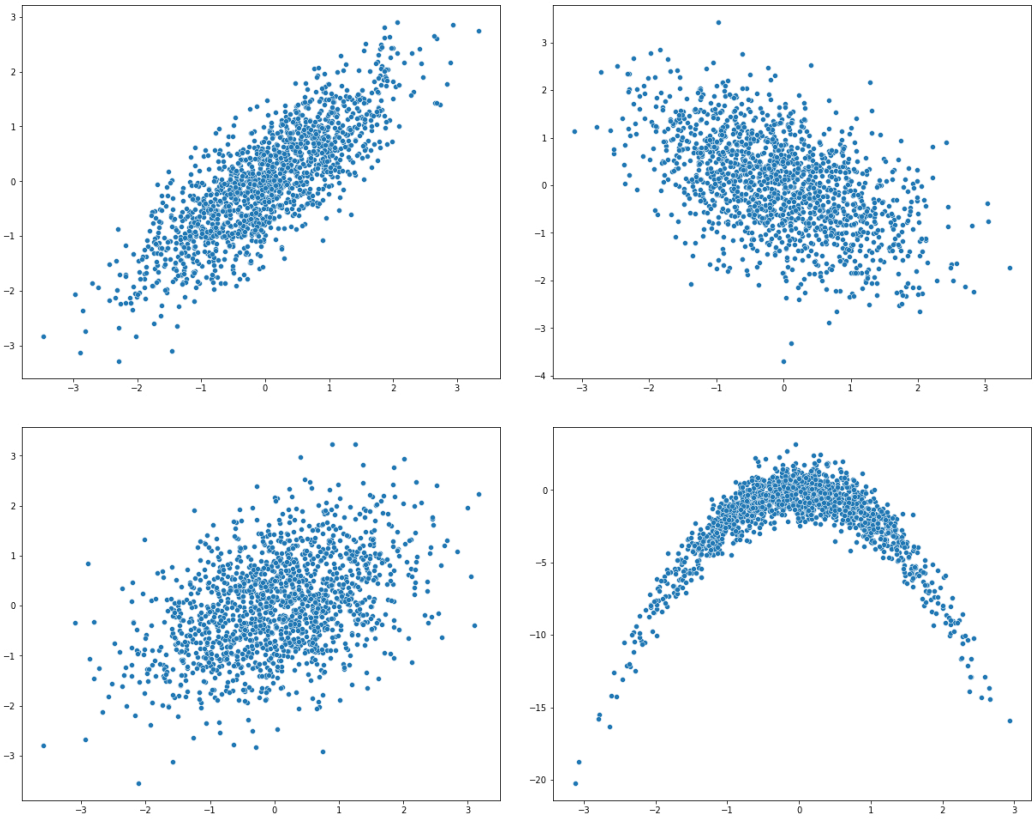
b. Кредиты в секторе оптовой и розничной торговли в среднем растут в феврале — марте 2019 г.

c. На три вида экономической деятельности с самым большим объемом задолженности в указанный период приходилось более половины всей задолженности в экономике (+)

d. Доля задолженности обрабатывающих производств в общем объеме снизилась за рассматриваемый промежуток времени (+)

e. Среди перечисленного выше нет верных ответов

9. (4 балла, по 1 за каждый график) Установите взаимосвязь между данными на графике и значениями коэффициента корреляции.



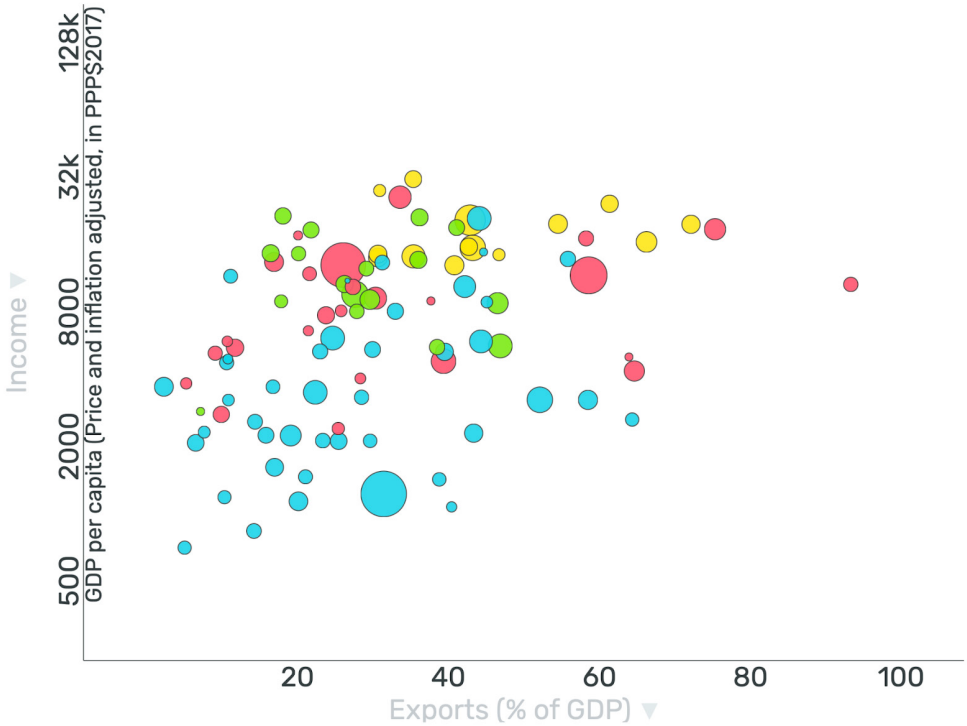
a. 0,8

b. −0,5

c. 0,4

d. −0,04

10. (5 баллов) На рисунке изображена диаграмма рассеяния, показывающая взаимосвязь между доходами населения и долей экспорта в ВВП по состоянию на 2021 год. На графике представлены в основном развивающиеся страны.



По вертикальной оси отражен реальный ВВП на душу населения в долларах (показатель скорректирован на инфляцию и пересчитан по паритету покупательной способности для сопоставимости между странами). Для наглядности графика значения ВВП преобразованы, при этом способ качественно не влияет на выводы.

По горизонтальной оси отражено отношение экспорта страны к ее ВВП.

Размер кругов отображает третий показатель — отношение совокупного внешнего долга страны к валовому национальному доходу — и отражает задолженность страны (государства и частных лиц) перед нерезидентами (иностранными государствами, фирмами и людьми). Чем больше размер круга, тем больше задолженность страны.

Цвет кругов обозначает разные регионы мира: голубой — Африка, красный — Азия (включая Австралию и Новую Зеландию), зеленый — Америка (Северная и Южная вместе), желтый — Европа.

Выберите все верные утверждения, которые можно сделать на основании этого графика про страны, которые на нем изображены:

a. В среднем доход на душу населения в странах Европы выше, чем в странах Африки (+)

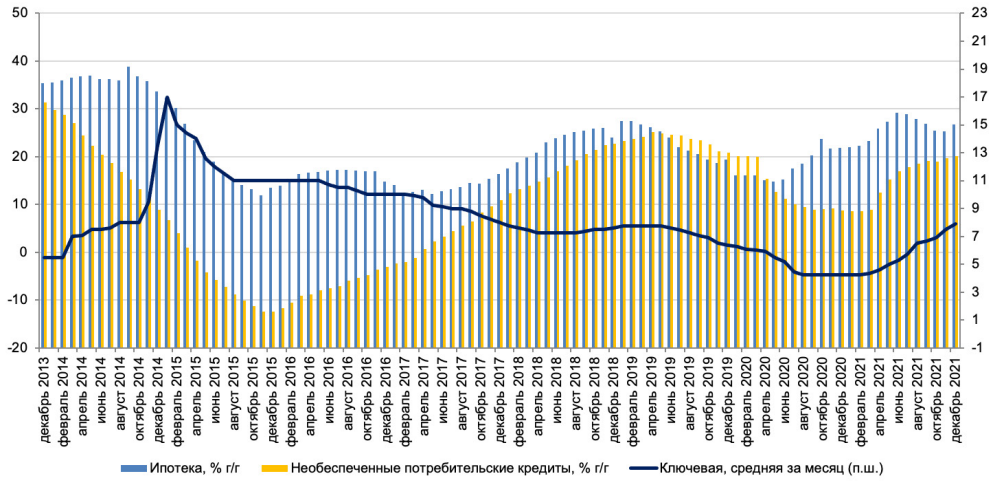
b. В среднем отношение экспорта к ВВП в странах Европы ниже, чем в странах Северной и Южной Америки

c. Разброс доходов на душу населения в странах Европы выше, чем в странах Африки

d. Три страны с наибольшим отношением задолженности иностранному сектору к доходу — страны Африки и Азии (+)

e. Среди перечисленного выше нет верных ответов

11. (5 баллов) На графике (взят из Обзора российского финансового сектора и финансовых инструментов Банка России за 2021 г од) показана динамика ипотечного и необеспеченного потребительского кредитования в России за 2014–2021 годы, а также ключевая ставка за тот же промежуток времени. Темпы прироста кредитования отложены по левой шкале, ключевая ставка — по правой.



Выберите все утверждения, которые можно сделать на основе приведенного выше графика:

a. Темпы роста ипотечного кредитования в среднем более стабильны, чем темпы роста необеспеченного кредитования (+)

b. С октября 2014 по октябрь 2015 объем ипотечного кредитования снижался

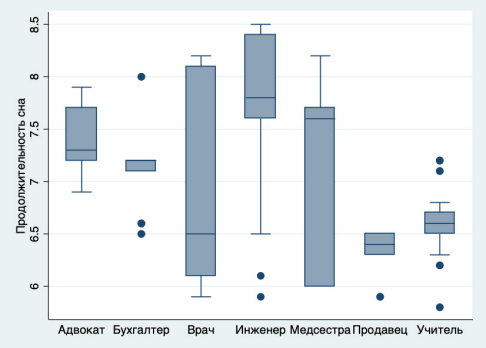
c. В течение 2017 года темп роста необеспеченного потребительского кредитования увеличивался (+)

d. В первой половине 2015 года наблюдается отрицательная взаимосвязь между темпами роста ипотечного кредитования и ключевой ставкой

e. Среди перечисленного выше нет верных ответов

12. (10 баллов) (Файл sleep.xlsx) В представленном файле вы можете найти информацию о роде деятельности человека, различных индикаторах качества его сна (субъективная оценка качества, продолжительность, наличие проблем со сном) и состоянии его здоровья. Какие из приведенных ниже графиков могли бы быть получены при проведении анализа взаимосвязи различных показателей качества сна с различными персональными характеристиками человека?

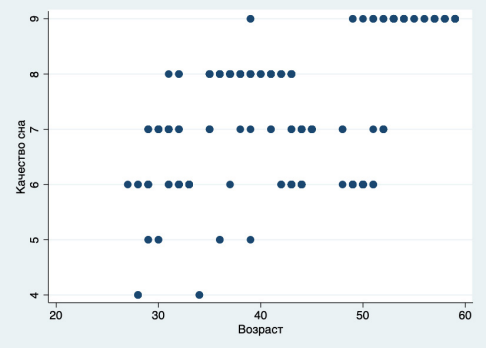
a)



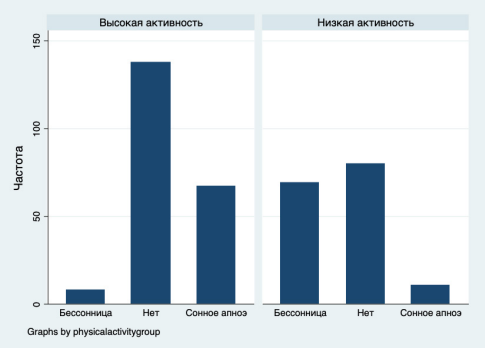
b)



c) +



d) +



e) Среди перечисленного выше нет верных ответов

13. (6 баллов) Вы провели исследование зарплат на рынке труда Соединенных Штатов Америки и получили следующее уравнение регрессии:

$$wage_i = 0.44\ edu_i + 0.2\ male_i + 0.5\ age_i - 0.03\ age_i^2 + 0.05\ male_i \times edu_i + 12384.72$$

где wage — зарплата индивида в тысячах долларов в год;

edu — количество лет, потраченных на получение образования;

male — переменная пола: 1 — если пол мужской, 0 — если пол женский;

age — возраст индивида.

Вас интересует разница в ожидаемой зарплате между двумя группами людей: выпускниками (1-я группа) и выпускницами школ (2-я группа). Также вы знаете, что в школах США все учатся 12 лет и можно считать всех окончивших школу ровесниками.

В ответе укажите разницу в среднем годовом доходе между первой и второй группами — в долларах. Если ответ представлен в виде десятичной дроби, запишите его через точку или запятую с округлением до двух знаков после запятой. Единицы измерения указывать не нужно.

Например, если доход первой группы — 15 долларов, а второй — 20 долларов, в ответе необходимо указать -5.

Ответ: 800

14. (5 баллов) Вы хотите исследовать взаимосвязь между возникновением онкологических заболеваний и загрязнением атмосферы в провинциях Китая. Какие показатели могли бы использоваться для проведения исследования? Выберите все подходящие комбинации.

    a. Количество пациентов с онкологическими заболеваниями в провинции И количество выбросов в атмосферу за год в провинции

    b. Количество пациентов с онкологическими заболеваниями на 1000 человек в провинции И средняя концентрация примесей в воздухе в провинции (+)

    c. Количество смертей от онкологических заболеваний в год в провинции И максимальная концентрация примесей в воздухе в провинции

    d. Смертность от онкологических заболеваний в провинции И среднеквадратическое отклонение от нормы примесей в воздухе в провинции

    e. Среди перечисленного выше нет верных ответов

15. (8 баллов) (Файл «Результаты 2022.xls») В файле с данными представлены результаты финала олимпиады DANO в 2022 году. Этот этап разделен на два тура. Задачный тур является индивидуальным (то есть каждому участнику засчитываются набранные им баллы). Он был написан в онлайн-формате. Проектный тур является командным (то есть все участники одной команды, защищавшие проект, получают одинаковое количество баллов). Он проводился очно. Туры проводились в разное время.

    Если участник пропустил один из туров, он мог принять участие в другом. Все школьники, принимавшие участие в одном из туров, получили за него ненулевой балл (то есть итоговая оценка 0 за тот или иной тур означает, что школьник отказался от участия в этом туре или был отстранен). В проектном туре от участия могла отказаться как вся команда, так и отдельные ее участники.

    Выберите все верные варианты ответа исходя из анализа представленных в файле данных:

    a. Средний балл за проектный тур у школьников из Санкт-Петербурга выше, чем у школьников из Москвы (+)

    b. Коэффициент корреляции между оценками команд за аналитический блок и за презентацию — приблизительно 0,806 (+)

    c. Средний балл за проектный тур у девятиклассников не ниже, чем у десятиклассников

    d. Среди перечисленного выше нет верных ответов

16. (14 баллов, по 2 за каждое число) (файл defaults_v2.xlsx) По этому файлу делаются задания 16 и 17.

    Вам представлен набор данных о наличии у клиента банка проблем с возвратом кредита, а также другая дополнительная информация о клиенте и взятом кредите. Банки часто используют такую информацию для того, чтобы строить модели для прогнозирования кредитоспособности людей, обращающихся за займом. В следующих двух заданиях вам предлагается рассмотреть несколько факторов на предмет их взаимосвязи с вероятностью допущения неплатежей по кредиту (вероятностью дефолта).

    Рассчитайте некоторые значения показателей, необходимые вам для выполнения следующего задания. Если ответ представлен в виде десятичной дроби, запишите его через точку или запятую с округлением до двух знаков после запятой. Единицы измерения указывать не нужно.

Медианное значение LTI = 3,25 (Ответ: 324,88)

Доля дефолтов в группе с LTI ниже медианы = 8,04 (Ответ: 0,08)

Доля дефолтов в группе с LTI выше медианы = 8,23 (Ответ: 0,08)

Доля дефолтов в группе с автомобилями = 7,3 (Ответ: 0,07)

Доля дефолтов в группе без автомобилей = 8,56 (Ответ: 0,09)

Доля дефолтов в группе с недвижимостью = 8,02 (Ответ: 0,08)

Доля дефолтов в группе без недвижимости = 8,39 (Ответ: 0,08)

17. (9 баллов, по 1 за каждый выбор из вариантов) Продолжение задания 16.

Далее для выполнения задания считайте, что если доли дефолтов в двух интересующих вас группах различаются на 1 процентный пункт и более, то отличие считается значимым. Если разница меньше, то считается, что доли равны.

Вам необходимо выбрать подходящий вариант заполнения пропуска, чтобы получилось верное описание гипотез и выводов из расчетов, сделанных ранее.

В этом исследовании мы хотим проверить, связаны ли проблемы с выплатой по кредитам с личными характеристиками заемщика.

Первая гипотеза состоит в том, что отношение объема взятого кредита к доходу (Loan to Income, LTI) (положительно / отрицательно / никак не) взаимосвязан с шансом допустить по нему дефолт. Поделив выборку по этому показателю на две равные части, мы можем посчитать долю дефолтов в группе с высоким LTI и с низким. В результате оказывается, что доля дефолтов в группе с высоким LTI (не отличается от / больше / меньше) доли дефолтов в группе с высоким LTI, то есть гипотеза (отвергается/не отвергается).

Вторая гипотеза состоит в том, что владение автомобилем, на который сейчас не оформлен кредит, (снижает / увеличивает / не влияет на) вероятность того, что человек будет иметь проблемы с возвратом кредитов. Доля дефолтов в группе обладателей автомобилей (не отличается от / больше / меньше) доли дефолтов в группе людей без машины. Таким образом, гипотеза (отвергается / не отвергается).

Третья гипотеза состоит в том, что владение недвижимостью, на которую сейчас не оформлен кредит, (снижает /увеличивает/не влияет на) вероятность того,

что человек будет иметь проблемы с возвратом кредитов. Доля дефолтов в группе собственников недвижимости (не отличается от / больше / меньше) доли дефолтов в группе людей, которые не владеют квартирами. Таким образом, гипотеза (отвергается / не отвергается).

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ | ТИНЬКОФФ

ВТОРОЙ ОТБОРОЧНЫЙ ЭТАП, 2 ВАРИАНТ 2023/2024

1. (2 балла) Один интернет-магазин решил добавить для пользователей мобильных устройств кнопку чата в углу экрана. Но перед этим он выбрал большую репрезентативную группу своих постоянных клиентов, чтобы посмотреть, насколько востребованной будет эта функция. Оказалось, что в этой группе треть — пользователи Android, четверть — пользователи браузерной версии, а остальные — пользователи iOS. При этом после теста выяснилось, что из пользователей Android кнопкой чата воспользовались 70%, среди пользователей браузерной версии — 90%, а среди пользователей iOS — всего 55%. (Известно, что каждый клиент в группе пользуется только одной из платформ.)

   Исходя из этих данных, если постоянный клиент воспользовался кнопкой чата, то пользователем какой платформы из этих трех он вероятнее всего является?

   a. Android (+)

   b. Браузерная версия

   c. iOS

   d. Из этих условий невозможно однозначно определить ответ

2. (2 балла) Юный исследователь захотел оценить количество посетителей ближайшего кинотеатра. Заняться проведением наблюдений было решено утром в будни. Он тщательно пересчитал всех посетителей кинотеатра в понедельник и среду. За время наблюдений получилось, что в среднем его посещает 1548 человек в день, или 46 440 человек за месяц. Как вы можете прокомментировать полученную оценку числа посетителей?

   a. Эта оценка близка к реальному количеству посетителей

   b. Эта оценка будет занижать количество посетителей (+)

c. Эта оценка будет завышать количество посетителей

d. Недостаточно данных, чтобы ответить на вопрос

3. (2 балла) Один маркетплейс в конце 2023 года решил объявить список из 8 своих самых продаваемых товаров за год. Каждый из аналитиков маркетплейса, включая главу аналитики и стажера, попробовал угадать этот список — и записал заранее 8 товаров, которые, как он предположил, туда попадут. После оглашения списка оказалось, что половина аналитиков угадали от 3 до 7 товаров, глава аналитики угадал все товары, стажер угадал лишь 1 товар. А остальные угадали ровно по 2 товара, и среди них не оказалось тех, кто угадал один и тот же набор из 2 товаров, а также тех, кто угадал бы товар, угаданный стажером.

   Какое максимальное число аналитиков может работать в этом маркетплейсе?

   a. 46 (+)

   b. 48

   c. 60

   d. 62

4. (5 баллов) Выборка состоит из 3047 различных чисел, причем все числа положительные и представимы в виде конечной десятичной дроби. Все числа из выборки упорядочили по возрастанию и разделили на 11 равных по величине групп, которые пронумеровали от 1 до 11. То есть первые 277 чисел упорядоченной выборки оказались в группе 1, следующие 277 чисел — в группе 2 и так далее. Выберите все верные утверждения:

   a. Среднее арифметическое чисел в группе 9 меньше среднего арифметического чисел в группе 10 (+)

   b. Медиана выборки может оказаться не в группе 6

   c. Сумма двух чисел из группы 1 не может оказаться больше числа из группы 11

   d. Если одно число меньше другого в 11 раз, то они могут оказаться в одной группе (+)

   e. Среди перечисленного выше нет верных ответов

5. (5 баллов) В таблице ниже представлено распределение ответов школьников на вопрос «Как изменилась ваша успеваемость в этом учебном году по

сравнению с предыдущим?». Все ученики отвечали на вопрос правдиво, таким образом представленные числа отражают реальное изменение успеваемости.

Ответ	Частота
Значительно улучшилась	12
Немного улучшилась	8
Не изменилась	16
Немного ухудшилась	4
Сильно ухудшилась	3

Выберите все верные варианты ответа:

a. Успеваемость улучшилась более чем у половины школьников

b. Успеваемость не улучшилась более чем у половины школьников (+)

c. У медианного школьника успеваемость не изменилась (+)

d. У медианного школьника успеваемость немного улучшилась

e. Среди перечисленного выше нет верных ответов

6. (5 баллов) Даня устал от подсчета среднего арифметического и медианы — и решил придумать свое среднее, которое назвал «среднее Данино». Оно считается так: если имеется выборка из N различных чисел, то она сначала упорядочивается либо по возрастанию, либо по убыванию, а затем считается среднее арифметическое первых 2 чисел, потом — среднее арифметическое получившегося среднего и следующего числа из выборки, затем — получившегося теперь числа и следующего числа из выборки и так далее.

Например, если выборка состоит из 5 упорядоченных по возрастанию/убыванию чисел a_1, a_2, a_3, a_4, a_5, то:

$$m_Д = \frac{\frac{\frac{\frac{a_1+a_2}{2}+a_3}{2}+a_4}{2}+a_5}{2}$$

Даня решил протестировать работу придуманного им среднего и взял какую-то выборку из 16 различных натуральных чисел $a_1, a_2, \ldots, a_{16}$, каждое от 1 до 100. Он упорядочил выборку либо по возрастанию, либо по убыванию, затем посчитал среднее Данино и медиану выборки — и сравнил их. Медиана в случае четного количества чисел равна полусумме чисел в середине

упорядоченной выборки.

Какие результаты могли получиться у Дани?

a. Если Даня упорядочил выборку по возрастанию, то медиана могла оказаться больше среднего Даниного

b. Если Даня упорядочил выборку по возрастанию, то медиана могла оказаться меньше среднего Даниного (+)

c. Если Даня упорядочил выборку по убыванию, то медиана могла оказаться больше среднего Даниного (+)

d. Если Даня упорядочил выборку по убыванию, то медиана могла оказаться меньше среднего Даниного

e. Среди перечисленного выше нет верных ответов

7. (8 баллов, по 2 на каждый вопрос) Предположим, в стране проживает 9 человек, доходы которых представлены в таблице ниже. Государству не нравится, что средний доход отличается от медианного, и оно хочет это исправить. Для этого предлагается ввести в стране налоги на богатых и раздать эти деньги другим гражданам. При этом государство также хочет собирать как можно меньше налогов с богатых.

Вам необходимо посчитать, сколько налогов и субсидий необходимо собрать и раздать, чтобы медиана и среднее оказались равны. Если подходящих способов несколько, используйте любой из них для ответа на все вопросы ниже.

Житель	A	B	C	D	E	F	G	H	I
Доход (у. е.)	8	10	10	20	30	60	100	170	600

Вопрос 1. Кто из жителей будет получать субсидию? Перечислите их в алфавитном порядке через запятую.

Ответ: E, F, G

Вопрос 2. Какую субсидию будет получать каждый из тех жителей, которых вы перечислили выше? Перечислите размеры субсидий через запятую в порядке, соответствующем порядку жителей, которые их получат. Если ответ представлен в виде дроби, округлите его до целого. Единицы измерения указывать не нужно.

Ответ: 90, 60, 20

Вопрос 3. Кто из жителей будет платить налог? Перечислите их в алфавитном порядке через запятую.

Ответ: либо I; либо H, I

Вопрос 4. Какой объем налогов суммарно заплатят все, кого вы перечислили выше? Если ответ представлен в виде дроби, округлите его до целого. Единицы измерения указывать не нужно.

Ответ: 170

8. (5 баллов) В таблице ниже приведены данные об общей кредитной задолженности компаний и индивидуальных предпринимателей по видам экономической деятельности и направлениям использования средств (в млн рублей).

Виды экономической деятельности и отдельные направления использования средств	01.02.2019	01.03.2019	01.04.2019
ВСЕГО	25 728 662	25 885 238	26 209 480
добыча полезных ископаемых	959 863	973 512	986 700
обрабатывающие производства	6 082 270	6 137 454	6 138 053
производство и распределение электроэнергии, газа и воды	1 218 916	1 207 717	1 180 787
сельское хозяйство, охота и лесное хозяйство	1 725 294	1 746 871	1 800 908
строительство	1 063 041	1 087 213	1 108 528
транспорт и связь	1 771 028	1 805 037	1 841 668
оптовая и розничная торговля	3 681 859	3 678 621	3 747 668
операции с недвижимым имуществом, аренда и предоставление услуг	3 874 280	3 915 409	3 936 643
прочие виды деятельности	5 078 084	5 040 035	5 163 325
на завершение расчетов	274 027	293 369	305 200

Выберите все верные утверждения из представленных ниже:

а. За апрель 2019 общий объем кредитов вырос примерно на 1,25%

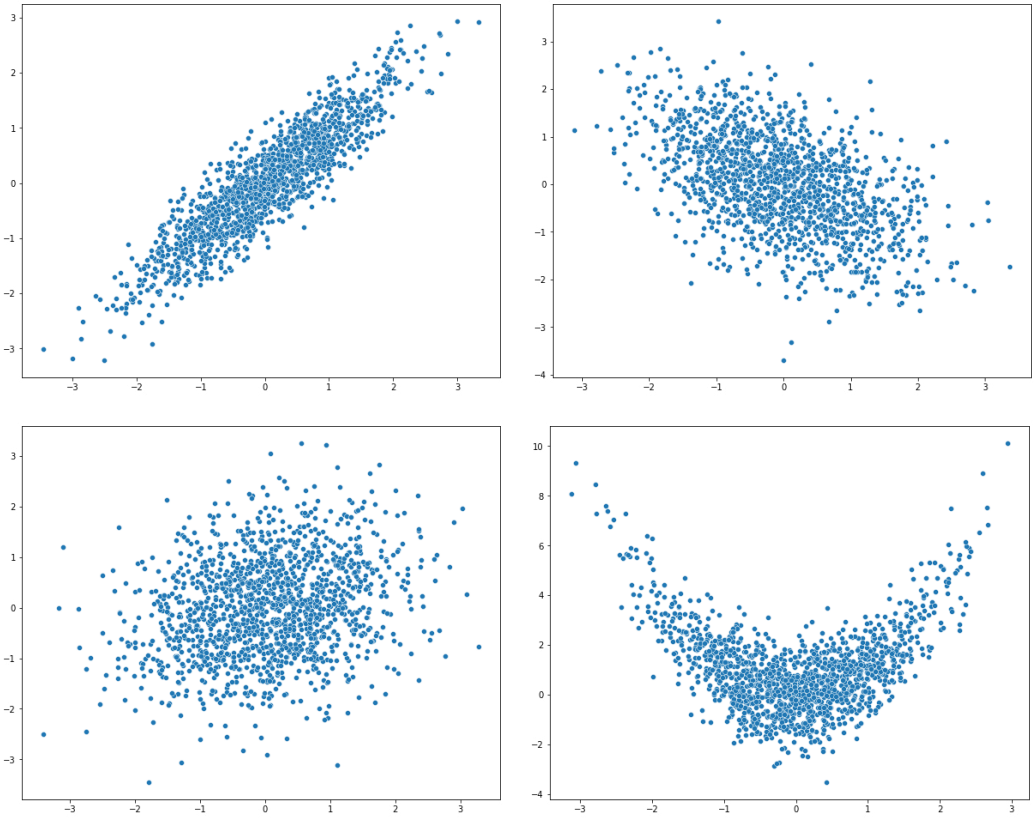
b. Кредиты в прочих видах деятельности в среднем растут в феврале — марте 2019 (+)

c. На два вида экономической деятельности с самым большим объемом задолженности в указанный период приходилось более 40% всей задолженности в экономике (+)

d. Доля задолженности компаний транспорта и связи в общем объеме снизилась за рассматриваемый промежуток времени

e. Среди перечисленного выше нет верных ответов

9. (4 балла, по 1 за каждый график) Установите взаимосвязь между данными на графике и значениями коэффициента корреляции.



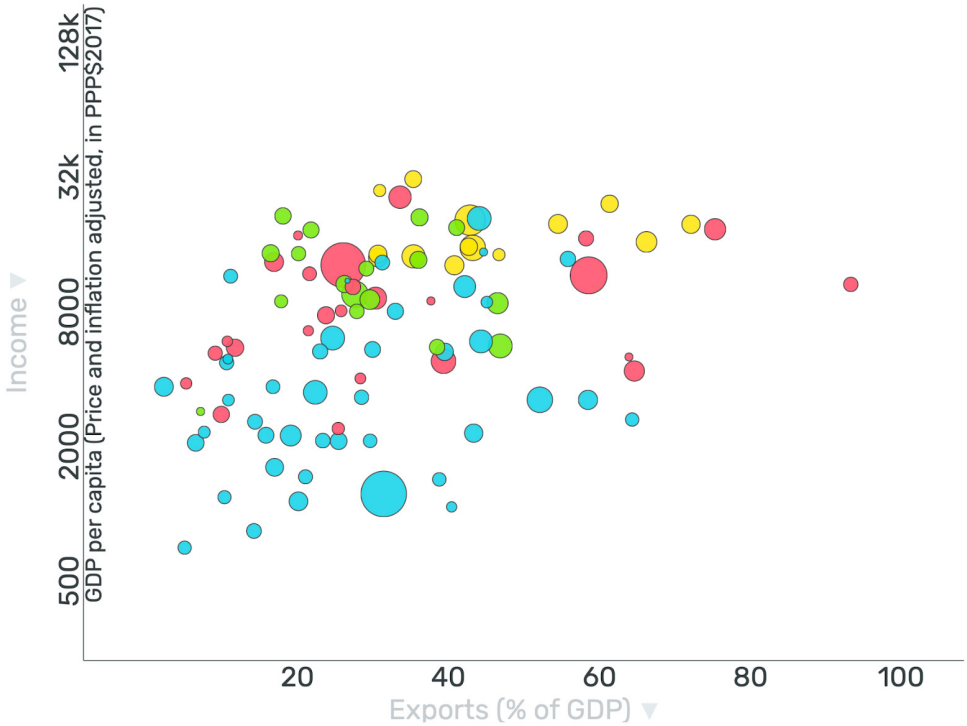
a. 0,9

b. −0,5

c. 0,2

d. 0

10. (5 баллов) На рисунке изображена диаграмма рассеяния, показывающая взаимосвязь между доходами населения и долей экспорта в ВВП по состоянию на 2021 год. На графике представлены в основном развивающиеся страны.



По вертикальной оси отражен реальный ВВП на душу населения в долларах (показатель скорректирован на инфляцию и пересчитан по паритету покупательной способности для сопоставимости между странами). Для наглядности графика значения ВВП преобразованы, при этом способ качественно не влияет на выводы.

По горизонтальной оси отражено отношение экспорта страны к ее ВВП.

Размер кругов отображает третий показатель — отношение совокупного внешнего долга страны к валовому национальному доходу — и отражает задолженность страны (государства и частных лиц) перед нерезидентами (иностранными государствами, фирмами и людьми). Чем больше размер круга, тем больше задолженность страны.

Цвет кругов обозначает разные регионы мира: голубой — Африка, красный — Азия (включая Австралию и Новую Зеландию), зеленый — Америка (Северная и Южная вместе), желтый — Европа.

Выберите все верные утверждения, которые можно сделать на основании этого графика про страны, которые на нем изображены:

a. В среднем доход на душу населения в странах Европы ниже, чем в странах Африки

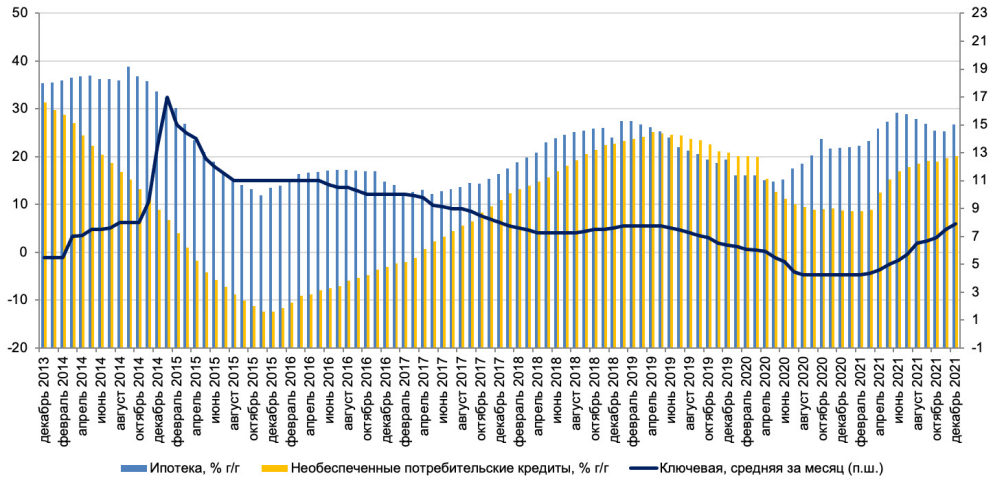
b. В среднем отношение экспорта к ВВП в странах Европы выше, чем в странах Африки (+)

c. Разброс доходов на душу населения в странах Европы ниже, чем в странах Азии (+)

d. Три страны с наибольшим отношением задолженности иностранному сектору к доходу — страны Европы и Азии

e. Среди перечисленного выше нет верных ответов

11. (5 баллов) На графике (взят из Обзора российского финансового сектора и финансовых инструментов Банка России за 2021 год) показана динамика ипотечного и необеспеченного потребительского кредитования в России за 2014–2021 годы, а также ключевая ставка за тот же промежуток времени. Темпы прироста кредитования отложены по левой шкале, ключевая ставка — по правой.



Выберите все утверждения, которые можно сделать на основе приведенного выше графика:

a. Темпы роста ипотечного кредитования в среднем более стабильны, чем темпы роста необеспеченного кредитования (+)

b. С октября 2014 по октябрь 2015 объем ипотечного кредитования снижался

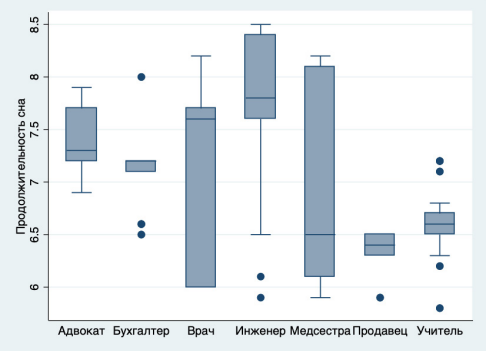
c. В течение 2017 года темп роста необеспеченного потребительского кредитования увеличивался (+)

d. В первой половине 2015 года наблюдается отрицательная взаимосвязь между темпами роста ипотечного кредитования и ключевой ставкой

e. Среди перечисленного выше нет верных ответов

12. (10 баллов) (Файл sleep.xlsx) В представленном файле вы можете найти информацию о роде деятельности человека, различных индикаторах качества его сна (субъективная оценка качества, продолжительность, наличие проблем со сном) и состоянии его здоровья. Какие из приведенных ниже графиков могли бы быть получены при проведении анализа взаимосвязи различных показателей качества сна с различными персональными характеристиками человека?

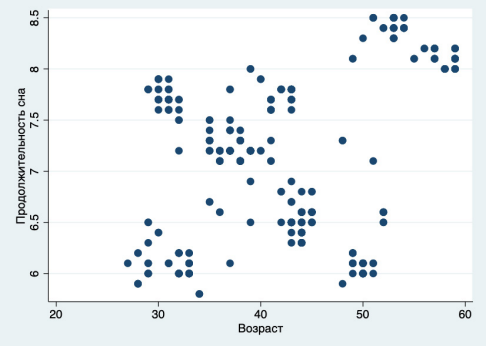
a) +



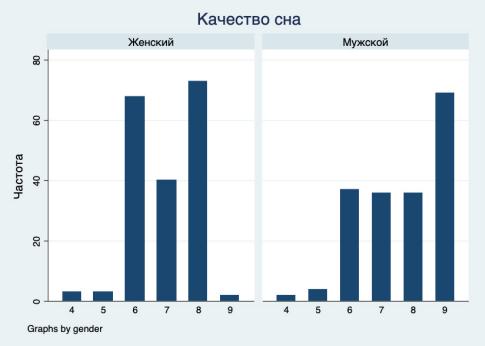
b)



c) +



d)



e) Среди перечисленного выше нет верных ответов

13. (6 баллов) Вы провели исследование успеваемости старшекурсников в вузах Франции и получили следующее уравнение регрессии:

$$gpa_i = 0.075\ study_i + 0.3\ female_i - 0.5\ work_i + 0.05\ female_i \times study_i - 0.03\ work_i \times female_i + 4.7$$

где gpa — средневзвешенный балл;

study — среднее количество часов, посвященных учебе, в день;

work — 1, если студент работает, иначе 0;

female — 1, если студент женского пола, иначе 0.

Вас интересует разница в средних баллах у работающих студентов (группа 1) и неработающих студенток (группа 2). Из данных вы знаете, что и те и другие уделяют учебе в среднем 8 часов в день.

В ответе укажите разницу в среднем балле между первой и второй группами (в баллах). Если ответ представлен в виде десятичной дроби, запишите его через точку или запятую с округлением до двух знаков после запятой. Например, если средний балл первой группы — 15, а второй — 20, в ответе необходимо указать -5.

Ответ: -1,2

14. (5 баллов) Вы хотите исследовать взаимосвязь между количеством аварий на дорогах в регионах Франции и уровнем коррупции. Какие показатели могли бы использоваться для проведения исследования? Выберите все подходящие комбинации.

(Индекс восприятия коррупции - показатель, отражающий оценку уровня восприятий коррупции экспертами и предпринимателями по шкале от 0 (максимальный уровень коррупции) до 100 (минимальный уровень коррупции).)

a. Количество ДТП в регионе И количество уголовных дел в регионе, возбужденных по статьям, связанным с коррупцией

b. Количество уголовных дел в регионе, открытых вследствие ДТП, И средний размер взятки в регионе

c. Количество ДТП на 1000 автомобилей в регионе И индекс восприятия коррупции в регионе (+)

d. Количество погибших на 1000 ДТП в регионе И количество обвинительных приговоров в делах о коррупции в регионе

e. Среди перечисленного выше нет верных ответов

15. (8 баллов) (Файл «Результаты 2022.xls») В файле с данными представлены результаты финала олимпиады DANO в 2022 году. Этот этап разделен на два тура. Задачный тур является индивидуальным (то есть каждому участнику засчитываются набранные им баллы). Он был написан в онлайн-формате. Проектный тур является командным (то есть все участники одной команды, защищавшие проект, получают одинаковое количество баллов). Он проводился очно. Туры проводились в разное время.

    Если участник пропустил один из туров, он мог принять участие в другом. Все школьники, принимавшие участие в одном из туров, получили за него ненулевой балл (то есть итоговая оценка 0 за тот или иной тур означает, что школьник отказался от участия в этом туре или был отстранен). В проектном туре от участия могла отказаться как вся команда, так и отдельные ее участники.

    Выберите все верные варианты ответа исходя из анализа представленных в файле данных:

    a. А) Средний балл за задачный тур у школьников из Москвы выше, чем средний балл у школьников из других регионов (+)

    b. Б) Коэффициент корреляции между оценками команд за постановку задачи и за аналитический блок — приблизительно 0,831 (+)

    c. В) Средний балл за задачный тур у десятиклассников не ниже, чем у одиннадцатиклассников

    d. Г) Среди перечисленного выше нет верных ответов

16. (14 баллов, по 2 за каждое число) (файл defaults_v2.xlsx) По этому файлу делаются задания 16 и 17.

    Вам представлен набор данных о наличии у клиента банка проблем с возвратом кредита, а также другая дополнительная информация о клиенте и взятом кредите. Банки часто используют такую информацию для того, чтобы строить модели для прогнозирования кредитоспособности людей, обращающихся за займом. В следующих двух заданиях вам предлагается рассмотреть несколько факторов на предмет их взаимосвязи с вероятностью допущения неплатежей по кредиту (вероятностью дефолта).

    Рассчитайте некоторые значения показателей, необходимые вам для выполнения следующего задания. Если ответ представлен в виде десятичной дроби, запишите его через точку или запятую с округлением до двух знаков после запятой. Единицы измерения указывать не нужно.

Медианное значение LTI = 3,26 (Ответ: 326,09)

Доля дефолтов в группе с LTI ниже медианы = 8,16 (Ответ: 0,08)

Доля дефолтов в группе с LTI выше медианы = 8,13 (Ответ: 0,08)

Доля дефолтов в группе с автомобилями = 7,36 (Ответ: 0,07)

Доля дефолтов в группе без автомобилей = 8,55 (Ответ: 0,09)

Доля дефолтов в группе с недвижимостью = 7,97 (Ответ: 0,08)

Доля дефолтов в группе без недвижимости = 8,55 (Ответ: 0,09)

17. (9 баллов, по 1 за каждый выбор из вариантов) Продолжение задания 16.

Далее для выполнения задания считайте, что если доли дефолтов в двух интересующих вас группах различаются на 1 процентный пункт и более, то отличие считается значимым. Если разница меньше, то считается, что доли равны.

Вам необходимо выбрать подходящий вариант заполнения пропуска, чтобы получилось верное описание гипотез и выводов из расчетов, сделанных ранее.

Первая гипотеза состоит в том, что отношение объема взятого кредита к доходу (Loan to Income, LTI) (положительно / отрицательно / никак не) взаимосвязан с шансом допустить по нему дефолт. Поделив выборку по этому показателю на две равные части, мы можем посчитать долю дефолтов в группе с высоким LTI и с низким. В результате оказывается, что доля дефолтов в группе с высоким LTI (не отличается от / больше / меньше) доли дефолтов в группе с высоким LTI, то есть гипотеза (отвергается/не отвергается).

Вторая гипотеза состоит в том, что владение автомобилем, на который сейчас не оформлен кредит, (снижает /увеличивает/не влияет на) вероятность того, что человек будет иметь проблемы с возвратом кредитов. Доля дефолтов в группе обладателей автомобилей (не отличается от / больше / меньше) доли дефолтов в группе людей без машины. Таким образом, гипотеза (отвергается / не отвергается).

Третья гипотеза состоит в том, что владение недвижимостью, на которую сейчас не оформлен кредит, (снижает /увеличивает/не влияет на) вероятность того, что человек будет иметь проблемы с возвратом кредитов. Доля дефолтов в группе собственников недвижимости (не отличается от / больше / меньше) доли дефолтов в группе людей, которые не владеют квартирами. Таким образом, гипотеза (отвергается / не отвергается).

DANO
ВЫСШАЯ ШКОЛА ЭКОНОМИКИ
ТИНЬКОФФ

ВТОРОЙ ОТБОРОЧНЫЙ ЭТАП, 3 ВАРИАНТ 2023/2024

1. (2 балла) Один интернет-магазин решил добавить для пользователей мобильных устройств кнопку чата в углу экрана. Но перед этим он выбрал большую репрезентативную группу своих постоянных клиентов, чтобы посмотреть, насколько востребованной будет эта функция. Оказалось, что в этой группе половина — пользователи Android, пятая часть — пользователи браузерной версии, а остальные — пользователи iOS. При этом после теста выяснилось, что из пользователей Android кнопкой чата воспользовались 35%, среди пользователей браузерной версии — 85%, а среди пользователей iOS — 60%. (Известно, что каждый клиент в группе пользуется только одной из платформ.)

   Исходя из этих данных, если постоянный клиент воспользовался кнопкой чата, то пользователем какой платформы из этих трех он вероятнее всего является?

   a. Android

   b. Браузерная версия

   c. iOS (+)

   d. Из этих условий невозможно однозначно определить ответ

2. (2 балла) Юный исследователь захотел оценить количество посетителей ближайшего торгового центра. Он тщательно пересчитал всех посетителей на протяжении недели. За время наблюдений получилось, что в среднем ТЦ посещает 1548 человек в день, или 46 440 человек за месяц. Как вы можете прокомментировать полученную оценку числа посетителей?

   a. Эта оценка близка к реальному количеству посетителей (+)

   b. Эта оценка будет занижать количество посетителей

c. Эта оценка будет завышать количество посетителей

d. Недостаточно данных, чтобы ответить на вопрос

3. (2 балла) Одна компания в конце 2023 года решила объявить список из 8 своих самых продаваемых товаров за год. Каждый из аналитиков компании, включая главу аналитики и стажера, попробовал угадать этот список — и записал заранее 8 товаров, которые, как он предположил, туда попадут. После оглашения списка оказалось, что половина аналитиков угадали от 4 до 7 товаров, глава аналитики угадал все товары, стажер угадал лишь 2 товара. А остальные угадали ровно по 3 товара, и среди них не оказалось тех, кто угадал один и тот же набор из 3 товаров, а также тех, кто угадал хотя бы один из товаров, угаданных стажером.

   Какое максимальное число аналитиков может работать в этом магазине?

   a. 34

   b. 44 (+)

   c. 54

   d. 74

4. (5 баллов) Выборка состоит из 3510 различных чисел, причем все числа положительные и представимы в виде конечной десятичной дроби. Все числа из выборки упорядочили по возрастанию и разделили на 13 равных по величине групп, которые пронумеровали от 1 до 13. То есть первые 270 чисел упорядоченной выборки оказались в группе 1, следующие 270 чисел — в группе 2 и так далее. Выберите все верные утверждения:

   a. Среднее арифметическое чисел в группе 3 может оказаться больше среднего арифметического чисел в группе 4

   b. Сумма двух чисел из группы 1 не может оказаться больше числа из группы 13

   c. Если одно число меньше другого в 13 раз, то они могут оказаться в одной группе (+)

   d. Медиана выборки обязательно окажется в группе 7 (+)

   e. Среди перечисленного выше нет верных ответов

5. (5 баллов) В таблице ниже представлено распределение ответов школьников на вопрос «Как изменилась ваша успеваемость в этом учебном году

по сравнению с предыдущим?». Все ученики отвечали на вопрос правдиво, таким образом представленные числа отражают реальное изменение успеваемости.

Ответ	Частота
Значительно улучшилась	16
Немного улучшилась	8
Не изменилась	12
Немного ухудшилась	4
Сильно ухудшилась	3

Выберите все верные варианты ответа:

a. Успеваемость улучшилась более чем у половины школьников (+)

b. Успеваемость не улучшилась более чем у половины школьников

c. У медианного школьника успеваемость не изменилась

d. У медианного школьника успеваемость немного улучшилась (+)

e. Среди перечисленного выше нет верных ответов

6. (5 баллов) Диана устала от подсчета среднего арифметического и медианы — и решила придумать свое среднее, которое назвала «среднее Дианино». Оно считается так: если имеется выборка из N различных чисел, то она сначала упорядочивается по убыванию, а затем считается среднее арифметическое первых 2 чисел, потом — среднее арифметическое получившегося среднего и следующего числа из выборки, затем — получившегося теперь числа и следующего числа из выборки и так далее.

Например, если выборка состоит из 5 упорядоченных по возрастанию/убыванию чисел a_1,a_2,a_3,a_4,a_5, то:

$$m_Д = \frac{\frac{\frac{\frac{a_1+a_2}{2}+a_3}{2}+a_4}{2}+a_5}{2}$$

Диана решила протестировать работу придуманного ею среднего и взяла какую-то выборку из 16 различных натуральных чисел $a_1,a_2,\ldots,a_{16}$, каждое от 1 до 100. Она упорядочила выборку по убыванию, затем посчитала среднее Дианино, среднее арифметическое и медиану выборки — и сравнила их.

Медиана в случае четного количества чисел равна полусумме чисел в середине упорядоченной выборки.

Какие результаты могли получиться у Дианы?

a. Среднее Дианино могло оказаться больше среднего арифметического

b. Среднее Дианино могло оказаться больше медианы

c. Среднее Дианино могло оказаться меньше среднего арифметического (+)

d. Среднее Дианино могло оказаться меньше медианы (+)

e. Среди перечисленного выше нет верных ответов

7. (8 баллов, по 2 на каждый вопрос) Предположим, в стране проживает 9 человек, доходы которых представлены в таблице ниже. Государству не нравится, что средний доход отличается от медианного, и оно хочет это исправить. Для этого предлагается ввести в стране налоги на богатых и раздать эти деньги другим гражданам. При этом государство также хочет собирать как можно меньше налогов с богатых.

Вам необходимо посчитать, сколько налогов и субсидий необходимо собрать и раздать, чтобы медиана и среднее оказались равны. Если подходящих способов несколько, используйте любой из них для ответа на все вопросы ниже

Житель	A	B	C	D	E	F	G	H	I
Доход (у. е.)	10	15	20	30	50	80	110	220	500

Вопрос 1. Кто из жителей будет получать субсидию? Перечислите их в алфавитном порядке через запятую.

Ответ: E, F, G

Вопрос 2. Какую субсидию будет получать каждый из тех жителей, которых вы перечислили выше? Перечислите их через запятую в порядке, соответствующем порядку жителей. Если ответ представлен в виде дроби, округлите его до целого. Единицы измерения указывать не нужно.

Ответ: *65, 35, 5*

Вопрос 3. Кто из жителей будет платить налог? Перечислите их в алфавитном

порядке через запятую.

Ответ: либо I; либо H, I

Вопрос 4. Какой объем налогов суммарно заплатят все, кого вы перечислили выше? Если ответ представлен в виде дроби, округлите его до целого. Единицы измерения указывать не нужно.

Ответ: 105

8. (5 баллов) В таблице ниже приведены данные об общей кредитной задолженности компаний и индивидуальных предпринимателей по видам экономической деятельности и направлениям использования средств (в млн рублей).

Виды экономической деятельности и отдельные направления использования средств	01.02.2019	01.03.2019	01.04.2019
ВСЕГО	25 728 662	25 885 238	26 209 480
добыча полезных ископаемых	959 863	973 512	986 700
обрабатывающие производства	6 082 270	6 137 454	6 138 053
производство и распределение электроэнергии, газа и воды	1 218 916	1 207 717	1 180 787
сельское хозяйство, охота и лесное хозяйство	1 725 294	1 746 871	1 800 908
строительство	1 063 041	1 087 213	1 108 528
транспорт и связь	1 771 028	1 805 037	1 841 668
оптовая и розничная торговля	3 681 859	3 678 621	3 747 668
операции с недвижимым имуществом, аренда и предоставление услуг	3 874 280	3 915 409	3 936 643
прочие виды деятельности	5 078 084	5 040 035	5 163 325
на завершение расчетов	274 027	293 369	305 200

Выберите все верные утверждения из представленных ниже:

a. За март 2019 общий объем кредитов вырос на 1,25% (+)

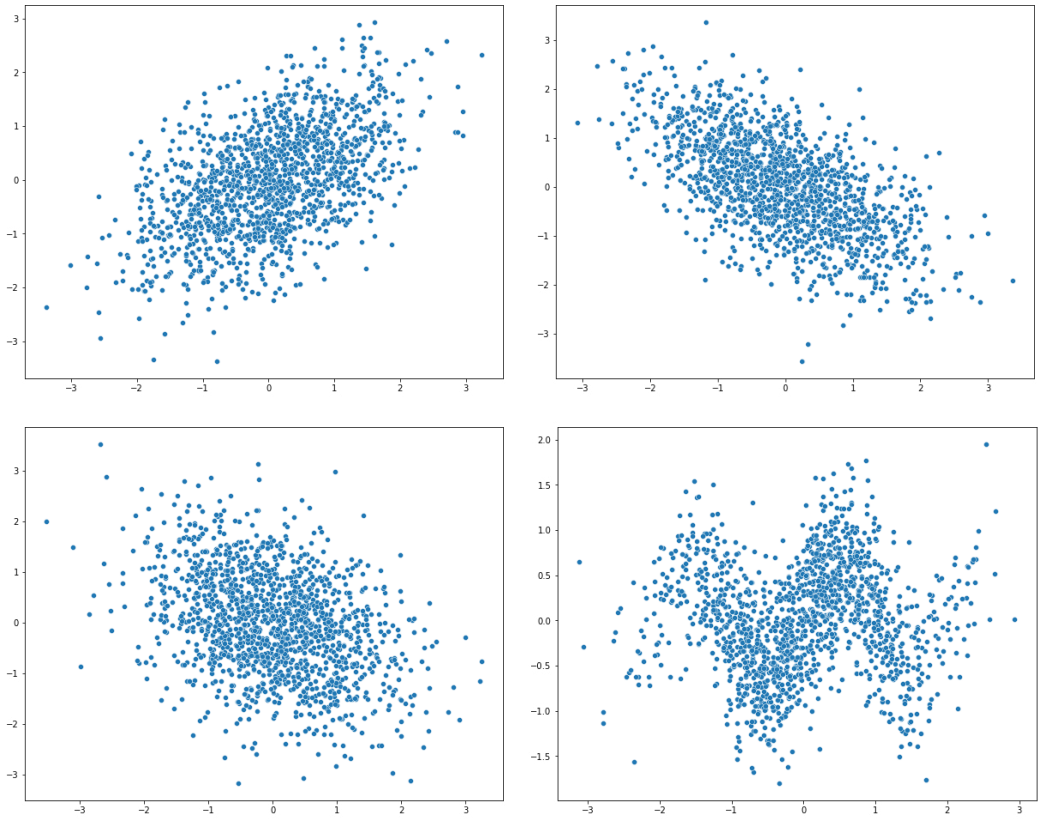
b. Кредиты в секторе производства и распределения электроэнергии, газа и воды в среднем растут в феврале — марте 2019

c. На четыре вида экономической деятельности с самым большим объемом задолженности в указанный период приходилось более 75% всей задолженности в экономике

d. Доля задолженности строительных компаний выросла за рассматриваемый промежуток времени (+)

e. Среди перечисленного выше нет верных ответов

9. (4 балла, по 1 за каждый график) Установите взаимосвязь между данными на графике и значениями коэффициента корреляции.



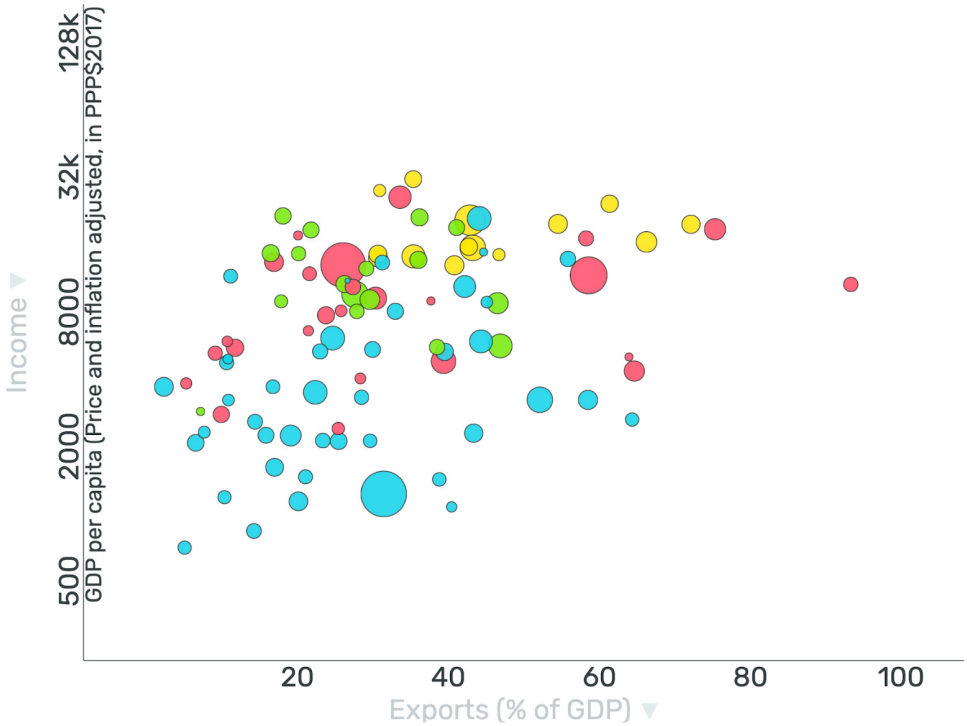
a. 0,5

b. 0,6

c. 0,33

d. 0,02

10. (5 баллов) На рисунке изображена диаграмма рассеяния, показывающая взаимосвязь между доходами населения и размером экспорта по состоянию на 2021 год. На графике представлены в основном развивающиеся страны.



По вертикальной оси отражен реальный ВВП на душу населения в долларах (показатель скорректирован на инфляцию и пересчитан по паритету покупательной способности для сопоставимости между странами).
Для наглядности графика значения ВВП преобразованы, при этом способ качественно не влияет на выводы.

По горизонтальной оси отражено отношение экспорта страны к ее ВВП.

Размер кругов отображает третий показатель — отношение совокупного внешнего долга страны к валовому национальному доходу — и отражает задолженность страны (государства и частных лиц) перед нерезидентами (иностранными государствами, фирмами и людьми). Чем больше размер круга, тем больше задолженность страны.

Цвет кругов обозначает разные регионы мира: голубой — Африка, красный — Азия (включая Австралию и Новую Зеландию), зеленый — Америка (Северная и Южная вместе), желтый — Европа.

Выберите все верные утверждения, которые можно сделать на основании этого графика:

a. В среднем доход на душу населения в странах Северной и Южной Америки выше, чем в странах Африки (+)

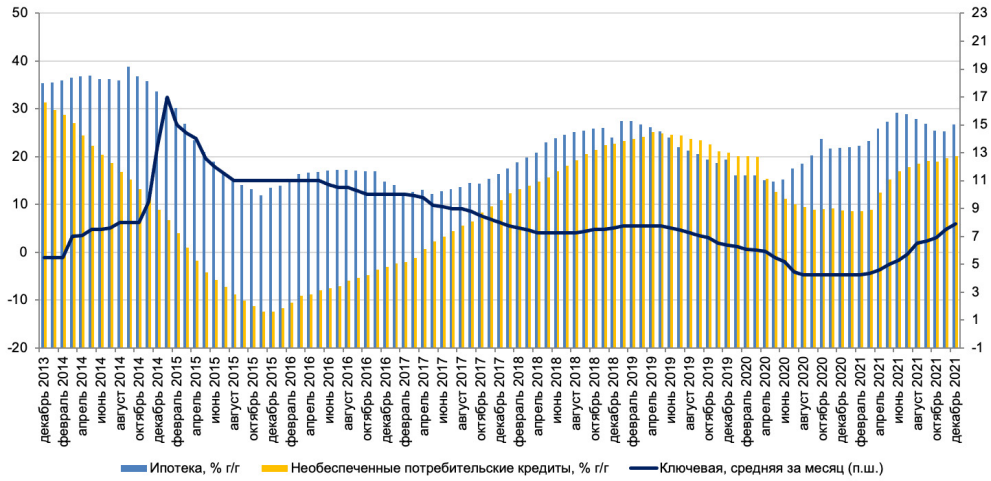
b. В среднем отношение экспорта к ВВП в странах Европы ниже, чем в странах Африки

c. Разброс доходов на душу населения в странах Европы ниже, чем в странах Африки (+)

d. Три страны с наибольшим отношением задолженности иностранному сектору к доходу — страны Африки и Европы

e. Среди перечисленного выше нет верных ответов

11. (5 баллов) На графике (взят из Обзора российского финансового сектора и финансовых инструментов Банка России за 2021 год) показана динамика ипотечного и необеспеченного потребительского кредитования в России за 2014–2021 годы, а также ключевая ставка за тот же промежуток времени. Темпы прироста кредитования отложены по левой шкале, ключевая ставка — по правой.



Выберите все утверждения, которые можно сделать на основе приведенного выше графика:

a. Объемы ипотечного кредитования в среднем растут меньше, чем объемы необеспеченного кредитования

b. С апреля 2017 по апрель 2018 объем ипотечного кредитования снижался

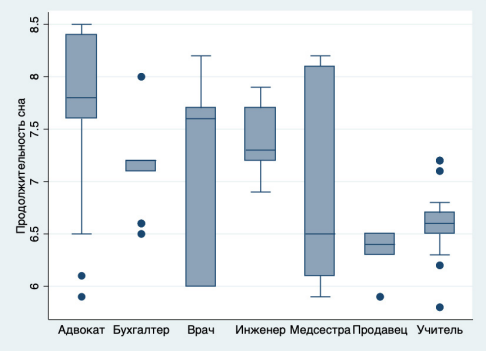
c. В течение 2017 года темп роста обоих видов кредитования в среднем увеличивался (+)

d. На протяжении 2016—2018 годов наблюдается отрицательная взаимосвязь между темпом роста ипотечного кредитования и ключевой ставкой (+)

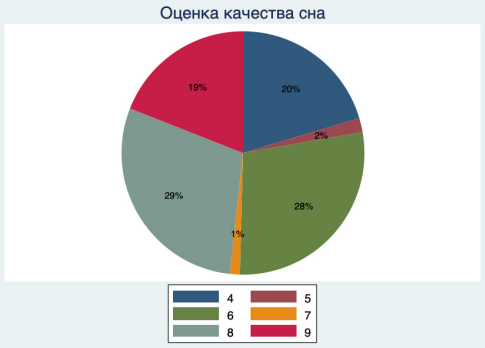
e. Среди перечисленного выше нет верных ответов

12. (10 баллов) (Файл sleep.xlsx) В представленном файле вы можете найти информацию о роде деятельности человека, различных индикаторах качества его сна (субъективная оценка качества, продолжительность, наличие проблем со сном) и состоянии его здоровья. Какие из приведенных ниже графиков могли бы быть получены при проведении анализа взаимосвязи различных показателей качества сна с различными персональными характеристиками человека?

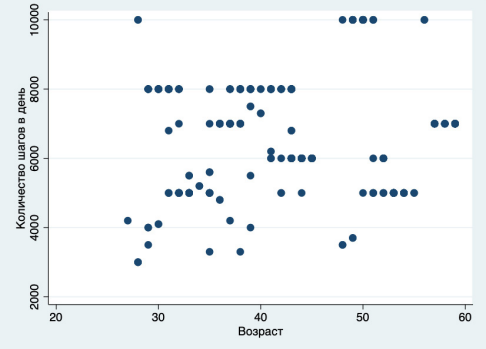
a)



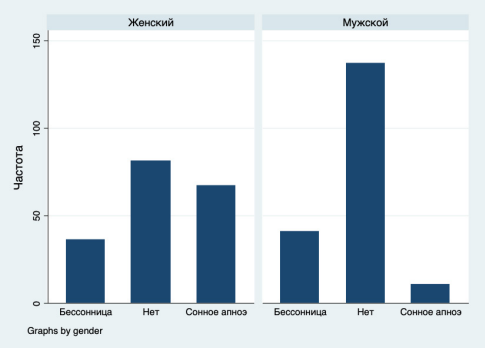
b)



c)



d) +



e) Среди перечисленного выше нет верных ответов

13. (6 баллов) Вы провели исследование потребления сладких газированных напитков в Англии и получили следующее уравнение регрессии:

$$soda_i = 2.5\ stress_i + 0.5\ age_i - 0.01\ age_i^2 + 0.3\ divorce_i - 0.05 \times child_i + 0.3\ divorce_i \times child_i + 8.3$$

где soda — потребление сладких газированных напитков в литрах в год;

stress — уровень стресса индивида от 0 до 10;

age — возраст индивида;

divorce — 1, если индивид в разводе, иначе 0;

child — 1, если у индивида есть дети, иначе 0.

Вас интересует разница в потреблении сладких газированных напитков у двух групп людей одного возраста, находящихся в разводе, однако у людей в группе 1 есть дети и уровень стресса выше на 2 балла по сравнению с людьми из группы 2. У людей в группе 2 детей нет.

В ответе укажите разницу в среднем объеме потребляемых за год напитков между первой и второй группами (в литрах). Если ответ представлен в виде десятичной дроби, запишите его через точку или запятую с округлением до двух знаков после запятой. Например, если средний объем потребления напитков в первой группе — 15, а во второй — 20, в ответе необходимо указать -5.

Ответ: 5,25

14. (5 баллов) Вы хотите исследовать взаимосвязь между неравенством доходов и количеством краж в населенных пунктах Ленинградской области в 2021 году. Предположим, что вы можете получить любые из перечисленных показателей моментально и в полном объеме. Какие наборы показателей могли бы использоваться? Выберите все подходящие комбинации.

(Индекс Робин Гуда (Robin Hood index), также известный как индекс Гувера (Hoover index), — это показатель неравенства по доходам, равен доле дохода общества, которую необходимо перераспределить для достижения равенства.

Коэффициент Джини (индекс Джини, или «индекс справедливости») — показатель, отражающий степень неравенства в распределении доходов внутри различных групп населения. Рассчитывается на основе информации о том, какую долю от совокупного дохода получает каждая группа населения — от самых бедных до самых богатых. Чем ближе к 1, тем выше уровень неравенства.)

a. Размах в официальных (белых) зарплатах по населенным пунктам И количество краж на 100 человек за 2021 год по населенным пунктам

b. Индекс Робин Гуда по населенным пунктам И количество краж за 2021 год по населенным пунктам

c. Индекс Джини по населенным пунктам И количество краж на 1000 человек по населенным пунктам (+)

d. Разность между совокупными доходами 10% самых богатых и 10% самых бедных граждан по населенным пунктам И процент нераскрытых краж по населенным пунктам

e. Среди перечисленного выше нет верных ответов

15. (8 баллов) (Файл «Результаты 2022.xls») В этом файле представлены результаты финала олимпиады DANO в 2022 году. Этот этап разделен на два тура. Задачный тур является индивидуальным (то есть каждому участнику засчитываются набранные им баллы). Он был написан в онлайн-формате. Проектный тур является командным (то есть все участники одной команды, защищавшие проект, получают одинаковое количество баллов). Он проводился очно. Туры проводились в разное время.

    Если участник пропустил один из туров, он мог принять участие в другом. Все школьники, принимавшие участие в одном из туров, получили за них ненулевой балл (то есть итоговая оценка 0 за тот или иной тур означает, что школьник отказался от участия в этом туре или был отстранен). В проектном туре от участия могла отказаться как вся команда, так и отдельные ее участники.

    Выберите все верные варианты ответа исходя из анализа представленных в файле данных:

    a. Средний балл за задачный тур у школьников из Санкт-Петербурга выше, чем у школьников не из Санкт-Петербурга

    b. Коэффициент корреляции между оценками команд за постановку задачи и за презентацию — приблизительно 0,726 (+)

    c. Средний балл за задачный тур у девятиклассников ниже, чем у одиннадцатиклассников (+)

    d. Среди перечисленного выше нет верных ответов

16. (14 баллов, по 2 за каждое число) (файл defaults_v2.xlsx) По этому файлу делаются задания 16 и 17.

Вам представлен набор данных о наличии у клиента банка проблем с возвратом кредита, а также другая дополнительная информация о клиенте и взятом кредите. Банки часто используют такую информацию для того, чтобы строить модели для прогнозирования кредитоспособности людей, обращающихся за займом. В следующих двух заданиях вам предлагается рассмотреть несколько факторов на предмет их взаимосвязи с вероятностью допущения неплатежей по кредиту (вероятностью дефолта).

Рассчитайте некоторые значения показателей, необходимые вам для выполнения следующего задания. Если ответ представлен в виде десятичной дроби, запишите его через точку или запятую с округлением до двух знаков после запятой. Единицы измерения указывать не нужно.

Медианное значение LTI = 3,29 (Ответ: 328,93)

Доля дефолтов в группе с LTI ниже медианы = 8,05 (Ответ: 0,08)

Доля дефолтов в группе с LTI выше медианы = 7,82 (Ответ: 0,08)

Доля дефолтов в группе с автомобилями = 7,07 (Ответ: 0,07)

Доля дефолтов в группе без автомобилей = 8,38 (Ответ: 0,08)

Доля дефолтов в группе с недвижимостью = 7,89 (Ответ: 0,08)

Доля дефолтов в группе без недвижимости = 8,03 (Ответ: 0,08)

17. (9 баллов, по 1 за каждый выбор из вариантов) Продолжение задания 16.

Далее для выполнения задания считайте, что если доли дефолтов в двух интересующих вас группах различаются на 1 процентный пункт и более, то отличие считается значимым. Если разница меньше, то считается, что доли равны.

Вам необходимо выбрать подходящий вариант заполнения пропуска, чтобы получилось верное описание гипотез и выводов из расчетов, сделанных ранее.

Первая гипотеза состоит в том, что отношение объема взятого кредита к доходу (Loan to Income, LTI) (положительно / отрицательно / никак не) взаимосвязан с шансом допустить по нему дефолт. Поделив выборку по этому показателю на две равные части, мы можем посчитать долю дефолтов в группе с высоким LTI и с низким. В результате оказывается, что доля дефолтов в группе с высоким LTI (не отличается от / больше / меньше) доли дефолтов в группе с высоким LTI, то есть гипотеза (отвергается/не отвергается).

Вторая гипотеза состоит в том, что владение автомобилем, на который сейчас не оформлен кредит, (снижает / увеличивает / не влияет на) вероятность того, что человек будет иметь проблемы с возвратом кредитов. Доля дефолтов в группе обладателей автомобилей (не отличается от / больше / меньше) доли дефолтов в группе людей без машины. Таким образом, гипотеза (отвергается / не отвергается).

Третья гипотеза состоит в том, что владение недвижимостью, на которую сейчас не оформлен кредит, (снижает /увеличивает / не влияет на) вероятность того, что человек будет иметь проблемы с возвратом кредитов. Доля дефолтов в группе собственников недвижимости (не отличается от / больше / меньше) доли дефолтов в группе людей, которые не владеют квартирами. Таким образом, гипотеза (отвергается / не отвергается).

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ | ТИНЬКОФФ

КРИТЕРИИ ЗАДАЧНОГО ТУРА ЗАКЛЮЧИТЕЛЬНОГО ЭТАПА 2023/2024

Задача 1 (Странные числа) Всего баллов - 40

Ответы:

1. 10%, 5%
2. 7.5%
3. Да. При перебалансировке размера групп в сторону более слабой, для нас женщин.
4. От 7 до 12 при увеличении до бесконечности заявителей одного пола

Критерии оценивания:

Критерий 1. (6 баллов):

Есть формула для конверсии для женщин 2 балла 5/100 =5%

Есть ответ для женщин 2 балла.

Есть ответ для мужчин 2 балла)

Критерий 2. (6 баллов):

Есть формула для общей конверсии 5+10/100+100 (4 балла)

Ответ 7.5% (2 балла)

Критерий 3. (12 баллов):

Ответ «Да» без обоснования 4 балла.

Корректное обоснование — 8 баллов.

Критерий 4. (16 баллов):

Получен интервал $(7; 12)$ - 6 баллов. Если границы включены, то 4 балла.

Есть корректное обоснование 10 баллов.

Итого 40 баллов.

Задача 2 (Вкусные булочки) Всего баллов - 28

Ответы:

1. 3 наблюдения, выборка: 0, 1, 1, среднее= 2/3, дисперсия=2/9, доля 2/3
2. Первая вероятность = $p(1-p)$, вторая вероятность = $2p(1-p)$
3. Можно вывести, перебирая день, когда нет булочек: $(1-p)pp + p(1-p)p + pp(1-p) = 3p^2(1-p)$. Либо сразу по формуле, если ее знают.
4. Нужно найти наибольшее значение функции из предыдущего пункта на отрезке от 0 до 1. Если взять производную, доказать, что ищем экстремум, найти точку экстремума, то получим 2/3. Значение оценки интерпретируется как доля дней, когда булочки были в наличии. Полученная нами оценка $p = 2/3$ совпадает со средним значением X, которое наблюдает Дима. Любой разумный ответ в эту сторону можно засчитать.
5. Нет, неверный. Причины: вероятность получена на выборке, нет оснований полагать, что на самом деле вероятность именно такая. Мало наблюдений для оценки вероятности. Возможно, выборка собрана неправильно (пекарня ошиблась, Дима не так расслышал и тд). Любая причина засчитывается.
6. Например, гипотеза: в новой пекарне чаще в наличии булочки с повидлом. Механизм: новая пекарня находится ближе к рынку, где продаются более дешевые абрикосы для повидла -> новой пекарне выгодно делать булочки с повидлом -> они делают больше булочек с повидлом -> они чаще в наличии. Если сравнивать средние, то можно сравнить 70 и 60 или 0.7 и

0.6 и сказать, что в новой чаще. Если проверять статзначимость, то считаем z-тест для долей, рассчитываем статистику (0.7-0.6) / sqrt((1-0.7)*0.7/100 + (1-0.6)*0.6/100) = 1.49 < 1.65 < 1.96 — при разных разумных уровнях значимости результат незначимый, то есть в пекарнях одинаково часто встречаются булочки с повидлом

Критерии оценивания:

Критерий 1. (5 баллов) 1 балл за каждый вопрос пункта:

- Правильно посчитано число наблюдений - 1 балл

- Правильно выписаны значения выборки - 1 балл

- Правильно посчитано среднее X - 1 балл

- Правильно посчитана дисперсия X - 1 балл

- Правильно посчитано, в какой доле случаев булочки были в наличии - 1 балл

Если ответ на любой вопрос пункта неправильный (неважно, по какой причине - арифметика, понимание и тд), то за вопрос выставляется 0

Критерий 2. (4 балла):

2 балла за расчет каждой вероятности.

0 баллов Если неправильно рассчитана вероятность (неважно по какой причине - арифметика, понимание и тд)

Критерий 3. (3 балла) за верный ответ.

-1 балл за арифметику

0 баллов за пункт если ответ $p^2(1-p)$, то есть если не учли, что день без булочек может быть любым из трех

Критерий 4. (6 баллов):

4 балла за найденное значение p: -1 балл за арифметику, -1 балл если не пояснили максимум (производная + нужный экстремум выбран и пояснен), -1 балл, если не проверили/не пояснили краевые случаи (тк ищем наибольшее значение, а не экстремумы).

2 балла за ответ на вопрос про связь значения и наблюдений

Критерий 5. (4 балла): 1 балл за ответ + 3 балла за аргументацию

Критерий 6. (6 баллов):

1 балл за гипотезу + 2 балл за механизм + 3 балла за проверку (1 балл за сравнение средних, 2 балла за определение стат значимости).

0 баллов за гипотезу, если сформулировали гипотезу, не отражающую в себе сравнение 2 пекарен.

0 за механизм, если он нелогичен или есть пробелы в логике, например, в новой пекарне чаще в наличии булочки с повидлом, так как она новая — не хватает пояснения, что например, пекарня новая - в ней больше места и полок - они делают больше булочек, в том числе булочек с повидлом - булочки с повидлом встречаются чаще.

Даже если гипотеза по нулям, за механизм можно получит баллы, если он логичен.

-1 балл если ошибка в арифметике

-1 балл за неверную интерпретацию проверки

0 за проверку если выбрали некорректный способ.

Задача 3 (Веселые горки) Всего баллов — 16

Ответы:

1. Значения функции: [80000, 62000, 48000, 38000, 32000, 30000, 32000, 38000, 48000, 62000, 80000]. Среднее значение x = 50, Среднее значение y = 50000

2. Коэффициент равен 0, неважно как посчитали, ручками, программой или интуитивно (но пояснили почему). Интерпретация: между переменными нет линейной зависимости.

3. Коэффициент равен -0.98. Интерпретация: между переменными присутствует отрицательная около линейная зависимость. Это соответствуют убыванию параболы на рассматриваемом промежутке.

4. Например, 1) кол-во свободного времени в секундах в зависимости от возраста или 2) самочувствие пациента в зависимости от кол-ва лекарств.

5. Коэффициент все еще равен 0, так как просто изменился масштаб переменной y, от умножения/деления на константу коэффициент корреляции не поменяется. Если посчитать, это подтвердится.

Критерии оценивания:

Критерий 1. (3 балла):

1 балл за найденные значения функции

1 балл за среднее значение x

1 балл за среднее значение y.

Соответственно, 0 за неверный ответ на каждый вопрос, неважно по какой причине (арифметика и тд)

Критерий 2. (3 балла):

1 балл за коэффициент + 2 балла за корректную интерпретацию.

-1 балл за арифметику.

Если коэффициент найден неверно, за интерпретацию все еще можно получить 2 балла. 0 за интерпретацию, если упускают слово линейная, тк зависимость по условию есть.

Критерий 3. (3 балла):

1 балл за коэффициент корреляции + 1 балл за корректную интерпретацию коэффициента корреляции + 1 балл за соотнесение коэффициента корреляции с убывающим участком параболы

-1 балл за арифметику.

Если коэффициент найден неверно, за интерпретацию все еще можно получить 1 балл и связь с параболой (если повезет, что она будет корректной)

Критерий 4. (4 балла): По 4 балла за пример

Критерий 5. (3 балла):

2 балла за корректное объяснение

1 балл за правильный расчет коэффициента.

-1 балл за арифметику.

-1 балл, если написано что коэффициент не изменится, но объяснение некорректное.

Задача 4 (Умный аналитик) Всего баллов — 38

Ответы:

revenue_per_user — есть статзначимая разница в худшую сторону (в группе A ср.значение = 1003, в группе B = 996)

orders_cnt_per_user — в столбце есть 14 точек, которые являются выбросами. Выбросы обнаруживаются как с помощью z — значения или интерквартильного размаха, так и визуально.

С выбросами есть статистическая разница, а без них — нет

converted_from_main_screen_to_item_card_screen — бинарный столбец, есть статзначимая разница

Итого:

revenue_per_user стат.значимо упала

orders_cnt_per_user стат.значимо не изменилась

converted_from_main_screen_to_item_card_screen стат.значимо выросла

Вывод: внедрение нового магазина несет убытки, необходимо вернуться на старую версию магазина

Критерии оценивания:

Критерий 1. Способ проверки гипотезы: (18 баллов)

a. С помощью статистического критерий 18 баллов (по 6 за каждую метрику)

b. С помощью доверительного интервала, построенного по z значению (если используется дисперсия для одной группы) 12 баллов (по 4 за каждую метрику)

c. По графику или по средним значениям 6 баллов (по 2 за каждую метрику) ИЛИ сделали сравнение период к периоду

Критерий 2. Проведена очистка от выбросов: (8 баллов) в столбце ‘orders_cnt_per_user’ до того, как проверялась гипотеза

a. Выбросы удалены, границы выбросов определялись с помощью z-значения или интерквартильного размаха (найдены все 14 точек) 8 балла

b. Выбросы удалены, границы выбросов определялись по визуальной оценки 4 балла

c. Выбросы не удалялись 0 баллов

Критерий 3. Описаны корректные выводы о сравнении каждой метрики: (6 баллов)

a. Да 6 баллов (по 2 за каждую метрику)

b. Нет 0 баллов

Критерий 4. Правильно написан вывод о внедрении изменений: (6 баллов)

a. Обоснованно получен результат об убыточности внедрения 6 баллов

b. Необоснованный вывод или вывода нет 0 баллов

Задача 5 (Оптимальный колл-центр) Всего баллов — 25

Ответ:

1. 106 операторов = 53 * 2 для симметричного и 105 = 54 + 51 для несимметричного, где 54 на машины и 51 на мотоциклы

2. примерно 1 100 000р (1 097 593.9р)

Критерии оценивания

Критерий 1. (2 балла) Получена формула rev = min(op1, ap_1)*cost_m + min(op2, ap_2)*cost_c - (op1*cost_op_1 + op2*cost_op_2)

Критерий 2 (5 балла) Сказано, что поток заявок распределен нормально(3 балла). И обосновано. (2 балла)

Критерий 3. (4 балла) 1 за среднее 3 за найденные параметры нормального

распределения - (50,25) или 50-медиана/среднее и 5-сигма

Поиск числа операторов:

Критерий 4.

Симметричный случай

8 баллов Рассмотрен интервал 50 – 55 операторов (или более широкий) и найден оптимум на 53 операторах.

2 балла Всего нужно 106 операторов (53*2)

Несимметричный случай

10 баллов Рассмотрен интервал 50 - 55 операторов (или более широкий) и найден оптимум на 54 для машин и 51 для мотоциклов операторах

2 балла Всего нужно 105 оператора (54 + 51)

Критерий 5. (2 балла) Получено, что максимальных доход 1097593 (засчитываем ответы 1097к-1098к или при округлении 1100к)

Итоговая формула по задачам

Балл_за_тур = X1/4 + X2/28 *20 + X3/16 *20 + X4/38 *25 + X5, где

X1 - балл за 1-ую задачу (из 40)

X2 - балл за 2-ую задачу (из 28)

X3 - балл за 3-ю задачу (из 16)

X4 - балл за 4-ую задачу (из 38)

X5 - балл за 5-ую задачу (из 25)

Содержание

Вариант 1 (с ответами)..... 2
Вариант 1 (без ответов)..... 10

Вариант 1 (с ответами)

1. Средняя оценка пользователей (2 балл)

На одном из сайтов с оценкой недвижимости рейтинги жилых комплексов формируются как средняя оценка пользователей по пятибалльной шкале без округления. Жилой комплекс «Сердце столицы» компании «Донстрой» имеет рейтинг 4,7 по оценкам 820 пользователей. Какое наименьшее количество пользователей должно еще выставить свои оценки, чтобы рейтинг этого жилого комплекса увеличился хотя бы на 0,1 без округления?

а) 420

б) 220

в) 410 (+)

г) 210

д) Среди остальных ответов нет ни одного верного

2. Зоопарк (3 балла)

Владельцы одного зоопарка заметили, что с наступлением холодов 80% млекопитающих перестают покидать свои места ночлега, в то время как из северных животных таких всего 20%. Еще владельцы зоопарка выяснили, что животные, покидающие свои места ночлега с наступлением холодов, — это в точности все северные млекопитающие и только они. Известно, что число животных, не относящихся ни к северным, ни к млекопитающим, составляет 80% от общего числа животных в зоопарке.

Сколько процентов от общего числа животных в зоопарке составляют северные млекопитающие? Округлите ответ до двух знаков после запятой.

(3,81)

3. Задача про торговую сеть (5 балла)

Менеджеры одной сети розничных магазинов электроники решили изучить объемы продаж товаров в одном из магазинов сети за февраль 2022 года. Они выделили две категории покупателей:

- покупатели типа А — те, кто приобрели ровно одну единицу любого товара за месяц;
- покупатели типа Б — все остальные.

Менеджеры выяснили, что за февраль на каждых четырех покупателей типа А приходится ровно один покупатель типа Б. Известно, что за месяц данным магазином было продано не более 1020 единиц любых товаров. Какие выводы могут сделать менеджеры на основе имеющейся информации? Выберите все верные ответы.

а) Количество покупателей типа Б составляет 25% от количества всех покупателей магазина в этом месяце

б) За каждый день магазином было продано в среднем 34 единицы товаров

в) В этом месяце количество единиц товаров, проданных покупателям типа Б, не превышает количество единиц товаров, проданных покупателям типа А

г) В этом месяце покупателей типа Б было не более 170 (+)

д) Среди остальных ответов нет ни одного верного

4. Задача про настольные игры (5 балла)

Компания, занимающаяся производством и продажей настольных игр, решила изучить, как COVID-19 повлиял на ее выручку. Все свои игры эта компания делит на несколько сегментов, в каждом из которых игры стоят одинаково. Для этого аналитики компании строят одни и те же графики за период с сентября по ноябрь 2019 года, когда пандемия еще не наступила, и за период с сентября по ноябрь 2020 года, после начала пандемии, и сравнивают их. Какие из перечисленных графиков помогут компании проанализировать влияние COVID-19 на выручку компании? Выберите все подходящие варианты ответа.

а) столбчатая диаграмма, показывающая среднее количество покупателей магазина за каждый день недели

б) столбчатая диаграмма, показывающая количество проданных игр по каждому ценовому сегменту (+)

в) гистограмма распределения расстояния от места жительства покупателей до магазина

г) круговая диаграмма с процентным соотношением суммарной стоимости проданных игр по дням недели

д) Среди остальных ответов нет ни одного верного

5. Selection bias (5 балла)

Вы консультант министерства здравоохранения и хотите выяснить, насколько хорошо работают больницы, а именно улучшают ли они состояние здоровья людей. Вам доступны результаты опрос населения, в ходе которого у людей узнавали, был ли человек хотя бы раз госпитализирован за последний год (то есть оставался ли он в больнице более чем на сутки), а также попросили оценить общее состояние своего здоровья по шкале от 1 до 5 (где 1 — очень плохо, а 5 — прекрасно). Эти результаты представлены в таблице ниже. Разница между двумя средними показателями значимая.

Группа	Размер выборки	Среднее состояние здоровья	Стандартная ошибка
Был госпитализирован	7 774	3,21	0,014
Не был госпитализирован	90 049	3,93	0,003

Вам необходимо проинтерпретировать полученные в ходе опроса результаты. Какие из приведенных ниже утверждений являются верными ?

а) Так как средняя оценка здоровья госпитализированных ниже, мы можем сделать вывод, что больницы ухудшают состояние здоровья пациентов

б) Люди с плохим состоянием здоровья скорее окажутся госпитализированными, поэтому среднее состояние в группе госпитализированных могло оказаться ниже. (+)
в) Люди врут в опросах, и если бы состояние их здоровья было оценено объективно, то соотношение было бы другим
г) Среди остальных ответов нет ни одного верного

6. Gapminder (5 балла)

На рисунке изображена диаграмма рассеяния, показывающая взаимосвязь между экономическим развитием и продолжительностью жизни в 2018 году.

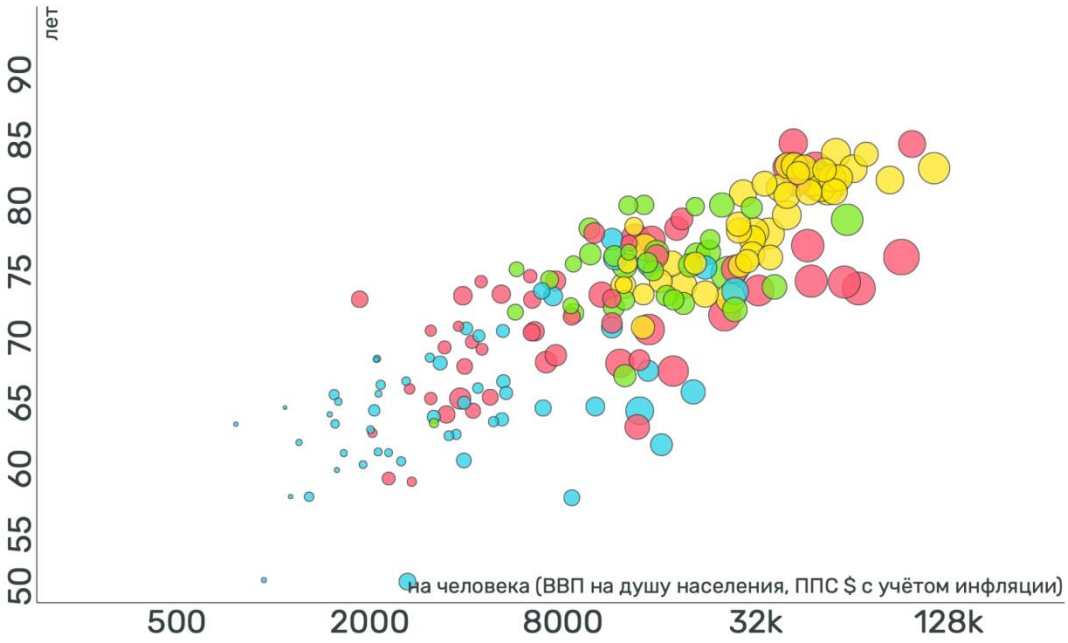
По вертикальной оси показана средняя продолжительность жизни в годах.

По горизонтальной оси отражен реальный ВВП на душу населения в долларах (показатель скорректирован на инфляцию и пересчитан по паритету покупательной способности для сопоставимости между странами). Для наглядности графика значения ВВП преобразованы специальным образом, который при этом качественно не влияет на выводы.

Размер кругов отражает третий показатель — выбросы CO_2 в атмосферу — и измеряется в метрических тоннах выбросов на человека. Чем больше размер круга, тем больше выбросы.

Цвет кругов обозначает разные регионы мира: голубой — Африка, красный — Азия (включая Австралию и Новую зеландию), зеленый — Америка (Северная и Южная вместе), желтый — Европа.

Источник: Gapminder, URL: https://www.gapminder.org



Выберите все верные утверждения, следующие из графика.

а) Существует положительная корреляция между экономическим развитием и средней продолжительностью жизни населения (+)

б) Выбросы CO_2 влияют на продолжительность жизни населения

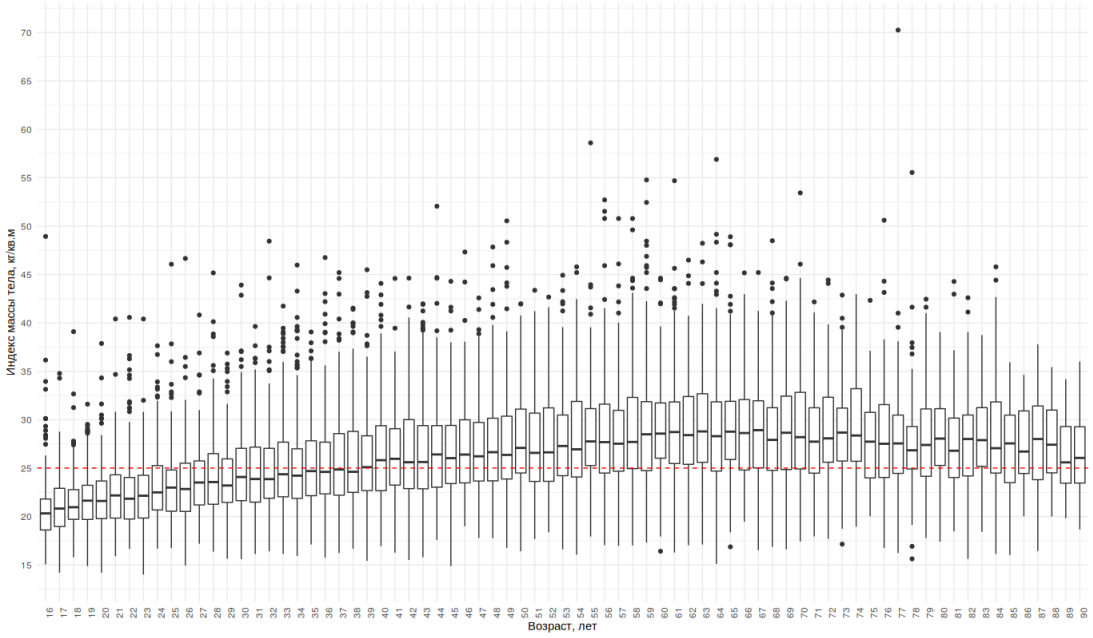
в) Средняя продолжительность жизни в странах Африки в среднем выше, чем в странах Европы

г) Среди остальных ответов нет ни одного верного

7. Индекс массы тела (5 балла)

Один из основных показателей здоровья — *индекс массы тела (ИМТ)*. Показатель рассчитывается путем деления веса в килограммах на квадрат роста в метрах. В своих исследованиях ученые используют различные уровни (или интервалы) ИМТ в качестве некоторой базы для сравнения. Здесь в качестве такого значения будет использован ИМТ, равный 25 (отмечен на графике красным пунктиром).

На рисунке представлен график распределения ИМТ среди россиян разного возраста, а именно: для каждого возраста от 16 до 90 лет построен отдельный «ящик с усами» (boxplot).



Источник: РМЭЗ, 28-я волна, данные за 2019 год

Выберите все утверждения, следующие из графика.

а) Разброс ИМТ у людей в возрасте 50 лет выше, чем у людей в возрасте 90 лет (+)

б) Медианный уровень ИМТ превышает 25 для людей в возрасте от 39 до 90 лет (+)

в) Первый квартиль (25-й перцентиль) ИМТ ниже 25 в любом возрасте

г) Среди остальных ответов нет ни одного верного

8. Задача про нормирование (6 баллов, по 3 на каждый способ, можно частичные баллы (если к одному способу ответ верный, а к другому нет))

Андрей слышал, что для решения задач по анализу данных бывает полезным нормировать данные. У него был набор данных, состоящий из 100 значений, — целых чисел от −1000 до 1000 (известно, что не все числа одинаковые). Он решил нормировать каждое значение из набора двумя способами, о которых недавно узнал.

Способ 1

$$x_{new} = (x - x_{min})/(x_{max} - x_{min})$$

Из каждого значения вычитается минимальное значение из набора данных x_{min} и делится на разность максимального и минимального значений из набора данных $x_{max} - x_{min}$.

Способ 2

$$x_{new} = (x - \bar{x})/\sqrt{D}$$

Из каждого значения вычитается среднее арифметическое всех значений набора данных $\bar{x}$ и делится на корень из дисперсии набора данных $\sqrt{D}$ (дисперсия равна D).

Укажите по очереди для каждого способа в алфавитном порядке все пункты, которые выполняются для этого способа (например, 1бг2аг).

Обратите внимание: не обязательно должны быть использованы все пункты, при этом некоторые свойства могут соответствовать и первому, и второму способу:

а) новое значение может оказаться меньше нуля;
б) новое значение может оказаться больше 1;
в) новое значение может оказаться больше старого значения;
г) одно из новых значений обязательно окажется равным 0.

Ответ: 1вг; 2абв

9. Задача на графики (8 баллов, по 2 за каждое верное соотнесение, можно частичные баллы)

Аналитики международной компании, занимающейся продажей спортивного инвентаря, решили проанализировать продажи основных товаров, распространяемых компанией, — велосипедов и лыж — за каждый квартал 2021 года. Они построили графики и диаграммы продаж в четырех магазинах компании, находящихся в разных городах мира. Каждому магазину соответствует один график и одна диаграмма. Каждый график показывает продажи велосипедов и лыж по отдельности, за каждый квартал по очереди. Каждая диаграмма отображает общую долю продаж (и велосипедов, и лыж) за каждый квартал относительно суммы всех продаж (и велосипедов, и лыж) в этом магазине за год. Для каждого графика укажите диаграмму, построенную для того же магазина, что и этот график.

Примечание: секторы одного и того же цвета на разных диаграммах могут соответствовать разным кварталам.

(Условие общее для всех 3 вариантов, картинки лежат в отдельных папках, у парных совпадают номер)

10. Платежеспособность заемщика (8 баллов)

Банк заинтересован в анализе платежеспособности своих заемщиков. В идеале он хотел бы точно знать, кто вернет кредит, а кто нет, и давать кредит только первым. На практике банки пытаются оценить вероятность невозврата кредита и используют для этого различные способы. Используя эти оценки вероятности, банк принимает решение о выдаче кредита. При этом важным оказывается выбор порогового значения вероятности. Тогда, если предсказанная вероятность больше порогового значения, будет предсказана невыплата (и банк откажет такому клиенту в выдаче средств), а если меньше — будет предсказано, что заемщик вернет кредит полностью (и такому клиенту банк выдаст кредит). Если поставить пороговое значение слишком низко (скажем, выдавать кредиты только людям, у которых вероятность невыплат составляет 0,01), то таких людей может быть слишком мало и банк не сможет получить прибыль, а если слишком высоко, то число неплатежей будет большим и банк будет терпеть убытки.

В файле ‘default.csv’ содержатся данные о 100 фактических заемщиках банка. Переменная DEFAULT принимает значение 1, если заемщик по факту не вернул кредит полностью или частично (и такого заемщика мы будем называть недобросовестным), и принимает значение 0, если заемщик полностью вернул кредит (такого заемщика мы будем называть добросовестным). Переменная PD принимает значения от 0 до 1 и показывает вероятность невозврата кредита для этих заемщиков, оцененную банком.

Сделав необходимые расчеты, выберите все верные утверждения.

а) При пороговом значении 0,45 модель верно предсказывает добросовестного заемщика в 67 случаях (+)

б) При пороговом значении в 0,25 модель не может предсказать дефолт у 5 заемщиков (+)

в) Чем ниже выбирается пороговое значение, тем в большем числе случаев правильно предсказываются добросовестные заемщики

г) Среди остальных ответов нет ни одного верного

11. Характеристики людей (8 баллов)

В файле gender.xlsx представлены данные, касающиеся различных физиологических параметров лица человека. Описание всех переменных приведено в файле на листе «Описание». На основании предложенных данных и ваших расчетов выберите все верные варианты ответа.

а) Стандартное отклонение в ширине лба среди мужчин больше, чем среди женщин (+)

б) У женщин лоб в среднем выше, чем у мужчин

в) У большинства мужчин длинные волосы (+)

г) Среди остальных ответов нет ни одного верного

12. Фильмы (8 баллов)

Вам представлены два файла. Один из них (movies_ratings.csv) содержит информацию о названиях фильмов, их популярности, бюджете, кассовых сборах, а также оценках,

выставленных отдельными пользователями каждому из фильмов. Описание всех переменных находится на листе «Описание» в файле movies.xlsx. Посчитайте корреляции необходимых переменных и выберите верные утверждения из приведенных ниже.
а) чем новее фильм, тем более высокую оценку пользователей в среднем он имеет
б) более продолжительные фильмы приносят больше кассовых сборов (+)
в) Фильм, получивший наибольшую среднюю оценку пользователей, был выпущен в 21-м веке
г) Среди остальных ответов нет ни одного верного

13. Рейтинг команд (15 баллов, по 5 за каждый верный ряд, частичные баллы (если 1 ряд верный, а 2 и 3 нет, получают 5 из 15))

В файле «Оценки.xlsx» вам представлены результаты команд, которые принимали участие в некотором соревновании.

Итоговый балл (ОБЩИЙ ИТОГ) рассчитывался как сумма трех итоговых оценок по теоретическому блоку, практическому блоку и за презентацию. Каждая из итоговых оценок складывалась из взвешенной суммы оценок по отдельным критериям по формулам, приведенным ниже. Каждый критерий оценивался по шкале от 0 до 3.

Итог за теоретический блок = 2*«Гипотеза и механизм» + 1*«Корректность и оригинальность»
Итог за практический блок = 2*«Интерпретация статанализа» + 1*«Перспективы и применимость» + 2*«Дан ответ на поставленный вопрос» + 1*«Визуализация результата»
Итого за презентацию = 1*«Командная работа» + 1*«Логика, связность и читаемость слайдов»

У жюри есть несколько вариантов подведения итогов и сложения всех оценок:

- по указанной формуле посчитать итоговую оценку каждого члена жюри, далее найти средний балл по всем членам жюри и выбрать победителем команду с наибольшим баллом;
- по указанной формуле посчитать итоговую оценку для каждого члена жюри, далее найти медианный балл и выбрать победителем команду с наибольшим баллом;
- найти медианный балл по отдельным критериям, а затем получить из них итоговую оценку по приведенным формулам.

Каждый из этих подходов имеет свои плюсы и минусы. В данном задании вам необходимо построить рейтинг команд по каждому из указанных принципов. При вводе ответа укажите номера команд через запятую, начиная с команды, набравшей наибольшее количество баллов, и далее по убыванию баллов (то есть команда, занявшая первое место, будет идти в списке первой, второе место — второй и так далее). Если у команд получается одинаковый итоговый балл, ранжируйте их по возрастанию номеров (например, если команда 1 и команда 2 набрали по 29 баллов, то в ответе необходимо указать “1, 2”).

При выборе победителя по принципу нахождения среднего итогового балла из оценок всех членов жюри порядок команд будет следующим: (9, 17, 12, 1, 14)
При выборе победителя по принципу нахождения медианного итогового балла порядок команд будет следующим: (9, 17, 1, 12, 14)
При выборе победителя по принципу подсчета итогового балла из медианных баллов жюри по отдельным критериям порядок команд будет следующим: (9, 17, 1, 12, 14)

14. Задача про машины-1 (14 баллов, по 2 за каждый пропуск)

В файле Auto.xlsx вам показаны данные по некоторым характеристикам подержанных автомобилей, представленных на рынке некой страны. Подробное описание переменных дано в файле на листе «Описание». Сами данные находятся на листе «Данные». Проведите небольшой анализ представленных там показателей и заполните пропуски в тексте ниже.
Если ваш ответ представлен дробным числом, запишите его через запятую с округлением до 2 знаков после запятой (например, «0,33»).
Обратите внимание: запомните полученные вами результаты — они будут нужны в следующем задании.

При анализе факторов, влияющих на ценообразование подержанных автомобилей, необходимо рассчитать корреляцию с основными факторами. Так, корреляция цены с возрастом автомобиля (по состоянию на 2022 год) составляет XXXX (−0,58), цены с пробегом автомобиля — XXXX (−0,57), а цены с объемом двигателя — XXXX (0,33).

Отметим также, что наибольший средний возраст автомобилей наблюдается в группе с двигателями типа XXXX (LPG) и составляет XXXX (12,82) лет, наибольший средний пробег — в группе с двигателями XXXX (LPG) и составляет XXXX (198027,12).

15. Задача про машины-2 (3 балла, за все верные, иначе 0)

(продолжение задачи 14)
В любом анализе важно указать возможный механизм влияния одного фактора на другой. Ниже предлагаем вам заполнить пропуски в описании взаимосвязи цены с возрастом и пробегом автомобиля, которую вы получили в предыдущем задании, чтобы получилась верная логическая цепочка.

Наличие такой взаимосвязи цены автомобиля с его возрастом и пробегом объясняется тем, что чем больше возраст автомобиля, тем XXXX (больше/меньше) на нем могли проехать, и все это обуславливает XXXX (больший/меньший) износ автомобиля, что будет действовать на цену в сторону ее XXXX (увеличения/уменьшения).

Вариант 1 (без ответов)

1. **Средняя оценка пользователей (2 балл)**

На одном из сайтов с оценкой недвижимости рейтинги жилых комплексов формируются как средняя оценка пользователей по пятибалльной шкале без округления. Жилой комплекс «Сердце столицы» компании «Донстрой» имеет рейтинг 4,7 по оценкам 820 пользователей. Какое наименьшее количество пользователей должно еще выставить свои оценки, чтобы рейтинг этого жилого комплекса увеличился хотя бы на 0,1 без округления?

а) 420

б) 220

в) 410

г) 210

д) Среди остальных ответов нет ни одного верного

2. **Зоопарк (3 балла)**

Владельцы одного зоопарка заметили, что с наступлением холодов 80% млекопитающих перестают покидать свои места ночлега, в то время как из северных животных таких всего 20%. Еще владельцы зоопарка выяснили, что животные, покидающие свои места ночлега с наступлением холодов, — это в точности все северные млекопитающие и только они. Известно, что число животных, не относящихся ни к северным, ни к млекопитающим, составляет 80% от общего числа животных в зоопарке.

Сколько процентов от общего числа животных в зоопарке составляют северные млекопитающие? Округлите ответ до двух знаков после запятой.

3. **Задача про торговую сеть (5 балла)**

Менеджеры одной сети розничных магазинов электроники решили изучить объемы продаж товаров в одном из магазинов сети за февраль 2022 года. Они выделили две категории покупателей:

- покупатели типа А — те, кто приобрели ровно одну единицу любого товара за месяц;
- покупатели типа Б — все остальные.

Менеджеры выяснили, что за февраль на каждых четырех покупателей типа А приходится ровно один покупатель типа Б. Известно, что за месяц данным магазином было продано не более 1020 единиц любых товаров. Какие выводы могут сделать менеджеры на основе имеющейся информации? Выберите все верные ответы.

а) Количество покупателей типа Б составляет 25% от количества всех покупателей магазина в этом месяце

б) За каждый день магазином было продано в среднем 34 единицы товаров

в) В этом месяце количество единиц товаров, проданных покупателям типа Б, не превышает количество единиц товаров, проданных покупателям типа А

г) В этом месяце покупателей типа Б было не более 170

д) Среди остальных ответов нет ни одного верного

4. Задача про настольные игры (5 балла)

Компания, занимающаяся производством и продажей настольных игр, решила изучить, как COVID-19 повлиял на ее выручку. Все свои игры эта компания делит на несколько сегментов, в каждом из которых игры стоят одинаково. Для этого аналитики компании строят одни и те же графики за период с сентября по ноябрь 2019 года, когда пандемия еще не наступила, и за период с сентября по ноябрь 2020 года, после начала пандемии, и сравнивают их. Какие из перечисленных графиков помогут компании проанализировать влияние COVID-19 на выручку компании? Выберите все подходящие варианты ответа.

а) столбчатая диаграмма, показывающая среднее количество покупателей магазина за каждый день недели
б) столбчатая диаграмма, показывающая количество проданных игр по каждому ценовому сегменту
в) гистограмма распределения расстояния от места жительства покупателей до магазина
г) круговая диаграмма с процентным соотношением суммарной стоимости проданных игр по дням недели

д) Среди остальных ответов нет ни одного верного

5. Selection bias (5 балла)

Вы консультант министерства здравоохранения и хотите выяснить, насколько хорошо работают больницы, а именно улучшают ли они состояние здоровья людей. Вам доступны результаты опрос населения, в ходе которого у людей узнавали, был ли человек хотя бы раз госпитализирован за последний год (то есть оставался ли он в больнице более чем на сутки), а также попросили оценить общее состояние своего здоровья по шкале от 1 до 5 (где 1 — очень плохо, а 5 — прекрасно). Эти результаты представлены в таблице ниже. Разница между двумя средними показателями значимая.

Группа	Размер выборки	Среднее состояние здоровья	Стандартная ошибка
Был госпитализирован	7 774	3,21	0,014
Не был госпитализирован	90 049	3,93	0,003

Вам необходимо проинтерпретировать полученные в ходе опроса результаты. Какие из приведенных ниже утверждений являются верными ?

а) Так как средняя оценка здоровья госпитализированных ниже, мы можем сделать вывод, что больницы ухудшают состояние здоровья пациентов
б) Люди с плохим состоянием здоровья скорее окажутся госпитализированными, поэтому среднее состояние в группе госпитализированных могло оказаться ниже.

в) Люди врут в опросах, и если бы состояние их здоровья было оценено объективно, то соотношение было бы другим

г) Среди остальных ответов нет ни одного верного

6. Gapminder (5 балла)

На рисунке изображена диаграмма рассеяния, показывающая взаимосвязь между экономическим развитием и продолжительностью жизни в 2018 году.

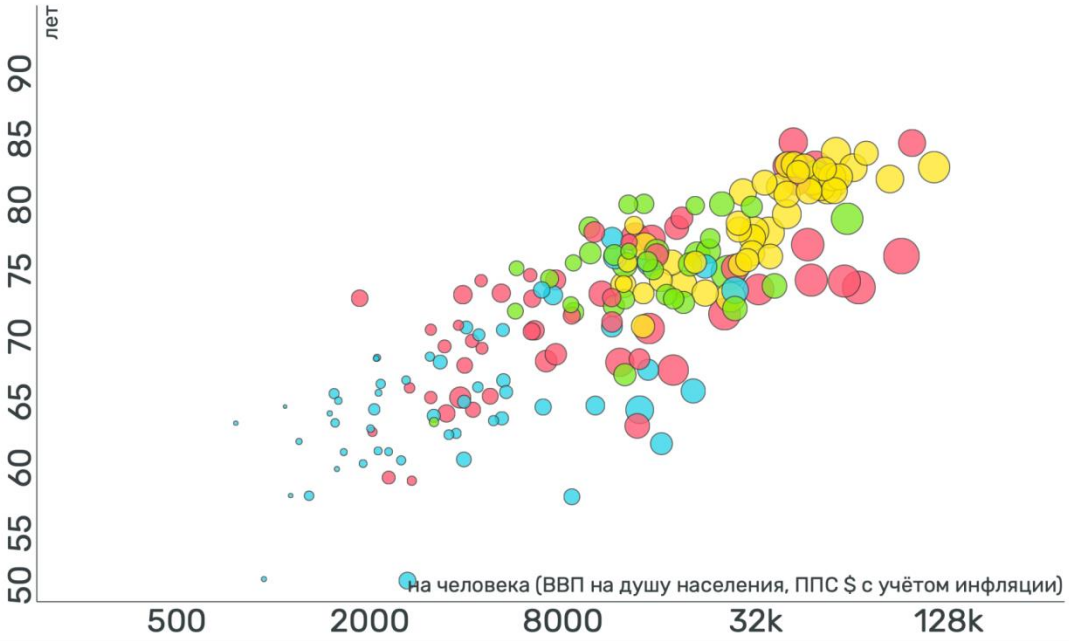
По вертикальной оси показана средняя продолжительность жизни в годах.

По горизонтальной оси отражен реальный ВВП на душу населения в долларах (показатель скорректирован на инфляцию и пересчитан по паритету покупательной способности для сопоставимости между странами). Для наглядности графика значения ВВП преобразованы специальным образом, который при этом качественно не влияет на выводы.

Размер кругов отражает третий показатель — выбросы CO_2 в атмосферу — и измеряется в метрических тоннах выбросов на человека. Чем больше размер круга, тем больше выбросы.

Цвет кругов обозначает разные регионы мира: голубой — Африка, красный — Азия (включая Австралию и Новую зеландию), зеленый — Америка (Северная и Южная вместе), желтый — Европа.

Источник: Gapminder, URL: https://www.gapminder.org



Выберите все верные утверждения, следующие из графика.

а) Существует положительная корреляция между экономическим развитием и средней продолжительностью жизни населения

б) Выбросы CO_2 влияют на продолжительность жизни населения

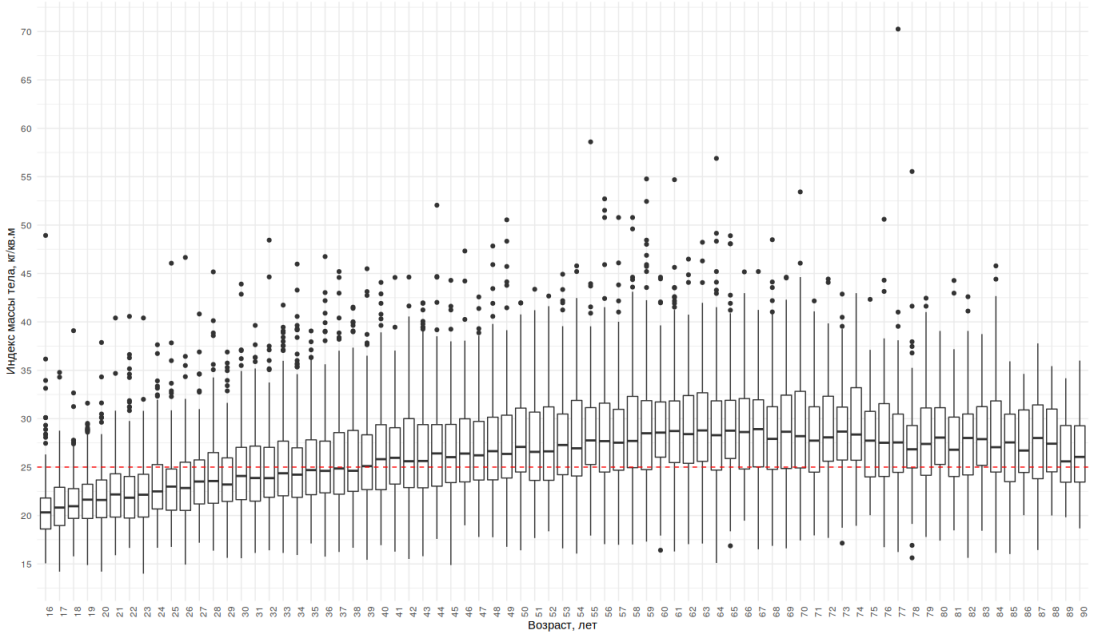
в) Средняя продолжительность жизни в странах Африки в среднем выше, чем в странах Европы

г) Среди остальных ответов нет ни одного верного

7. Индекс массы тела (5 балла)

Один из основных показателей здоровья — *индекс массы тела (ИМТ)*. Показатель рассчитывается путем деления веса в килограммах на квадрат роста в метрах. В своих исследованиях ученые используют различные уровни (или интервалы) ИМТ в качестве некоторой базы для сравнения. Здесь в качестве такого значения будет использован ИМТ, равный 25 (отмечен на графике красным пунктиром).

На рисунке представлен график распределения ИМТ среди россиян разного возраста, а именно: для каждого возраста от 16 до 90 лет построен отдельный «ящик с усами» (boxplot).



Источник: РМЭЗ, 28-я волна, данные за 2019 год

Выберите все утверждения, следующие из графика.

а) Разброс ИМТ у людей в возрасте 50 лет выше, чем у людей в возрасте 90 лет

б) Медианный уровень ИМТ превышает 25 для людей в возрасте от 39 до 90 лет

в) Первый квартиль (25-й перцентиль) ИМТ ниже 25 в любом возрасте

г) Среди остальных ответов нет ни одного верного

8. Задача про нормирование (6 баллов, по 3 на каждый способ, можно частичные баллы (если к одному способу ответ верный, а к другому нет))

Андрей слышал, что для решения задач по анализу данных бывает полезным нормировать данные. У него был набор данных, состоящий из 100 значений, — целых чисел от −1000 до 1000 (известно, что не все числа одинаковые). Он решил нормировать каждое значение из набора двумя способами, о которых недавно узнал.

Способ 1

$$x_{new} = (x - x_{min})/(x_{max} - x_{min})$$

Из каждого значения вычитается минимальное значение из набора данных x_{min} и делится на разность максимального и минимального значений из набора данных $x_{max} - x_{min}$.

Способ 2

$$x_{new} = (x - \bar{x})/\sqrt{D}$$

Из каждого значения вычитается среднее арифметическое всех значений набора данных $\bar{x}$ и делится на корень из дисперсии набора данных $\sqrt{D}$ (дисперсия равна D).

Укажите по очереди для каждого способа в алфавитном порядке все пункты, которые выполняются для этого способа (например, 1бг2аг).

Обратите внимание: не обязательно должны быть использованы все пункты, при этом некоторые свойства могут соответствовать и первому, и второму способу:

а) новое значение может оказаться меньше нуля;
б) новое значение может оказаться больше 1;
в) новое значение может оказаться больше старого значения;
г) одно из новых значений обязательно окажется равным 0.

9. Задача на графики (8 баллов, по 2 за каждое верное соотнесение, можно частичные баллы)

Аналитики международной компании, занимающейся продажей спортивного инвентаря, решили проанализировать продажи основных товаров, распространяемых компанией, — велосипедов и лыж — за каждый квартал 2021 года. Они построили графики и диаграммы продаж в четырех магазинах компании, находящихся в разных городах мира. Каждому магазину соответствует один график и одна диаграмма. Каждый график показывает продажи велосипедов и лыж по отдельности, за каждый квартал по очереди. Каждая диаграмма отображает общую долю продаж (и велосипедов, и лыж) за каждый квартал относительно суммы всех продаж (и велосипедов, и лыж) в этом магазине за год. Для каждого графика укажите диаграмму, построенную для того же магазина, что и этот график.

Примечание: секторы одного и того же цвета на разных диаграммах могут соответствовать разным кварталам.

Платежеспособность заемщика (8 баллов)

Банк заинтересован в анализе платежеспособности своих заемщиков. В идеале он хотел бы точно знать, кто вернет кредит, а кто нет, и давать кредит только первым. На

практике банки пытаются оценить вероятность невозврата кредита и используют для этого различные способы. Используя эти оценки вероятности, банк принимает решение о выдаче кредита. При этом важным оказывается выбор порогового значения вероятности. Тогда, если предсказанная вероятность больше порогового значения, будет предсказана невыплата (и банк откажет такому клиенту в выдаче средств), а если меньше — будет предсказано, что заемщик вернет кредит полностью (и такому клиенту банк выдаст кредит). Если поставить пороговое значение слишком низко (скажем, выдавать кредиты только людям, у которых вероятность невыплат составляет 0,01), то таких людей может быть слишком мало и банк не сможет получить прибыль, а если слишком высоко, то число неплатежей будет большим и банк будет терпеть убытки.

В файле ‘default.csv’ содержатся данные о 100 фактических заемщиках банка. Переменная DEFAULT принимает значение 1, если заемщик по факту не вернул кредит полностью или частично (и такого заемщика мы будем называть недобросовестным), и принимает значение 0, если заемщик полностью вернул кредит (такого заемщика мы будем называть добросовестным). Переменная PD принимает значения от 0 до 1 и показывает вероятность невозврата кредита для этих заемщиков, оцененную банком.

Сделав необходимые расчеты, выберите все верные утверждения.

а) При пороговом значении 0,45 модель верно предсказывает добросовестного заемщика в 67 случаях

б) При пороговом значении в 0,25 модель не может предсказать дефолт у 5 заемщиков

в) Чем ниже выбирается пороговое значение, тем в большем числе случаев правильно предсказываются добросовестные заемщики

г) Среди остальных ответов нет ни одного верного

10. Характеристики людей (8 баллов)

В файле gender.xlsx представлены данные, касающиеся различных физиологических параметров лица человека. Описание всех переменных приведено в файле на листе «Описание». На основании предложенных данных и ваших расчетов выберите все верные варианты ответа.

а) Стандартное отклонение в ширине лба среди мужчин больше, чем среди женщин

б) У женщин лоб в среднем выше, чем у мужчин

в) У большинства мужчин длинные волосы

г) Среди остальных ответов нет ни одного верного

11. Фильмы (8 баллов)

Вам представлены два файла. Один из них (movies_ratings.csv) содержит информацию о названиях фильмов, их популярности, бюджете, кассовых сборах, а также оценках, выставленных отдельными пользователями каждому из фильмов. Описание всех переменных находится на листе «Описание» в файле movies.xlsx. Посчитайте корреляции необходимых переменных и выберите верные утверждения из приведенных ниже.

а) чем новее фильм, тем более высокую оценку пользователей в среднем он имеет

б) более продолжительные фильмы приносят больше кассовых сборов

в) Фильм, получивший наибольшую среднюю оценку пользователей, был выпущен в 21-м веке
г) Среди остальных ответов нет ни одного верного

12. Рейтинг команд (15 баллов, по 5 за каждый верный ряд, частичные баллы (если 1 ряд верный, а 2 и 3 нет, получают 5 из 15))

В файле «Оценки.xlsx» вам представлены результаты команд, которые принимали участие в некотором соревновании.

Итоговый балл (ОБЩИЙ ИТОГ) рассчитывался как сумма трех итоговых оценок по теоретическому блоку, практическому блоку и за презентацию. Каждая из итоговых оценок складывалась из взвешенной суммы оценок по отдельным критериям по формулам, приведенным ниже. Каждый критерий оценивался по шкале от 0 до 3.

Итог за теоретический блок = 2*«Гипотеза и механизм» + 1*«Корректность и оригинальность»
Итог за практический блок = 2*«Интерпретация статанализа» + 1*«Перспективы и применимость» + 2*«Дан ответ на поставленный вопрос» + 1*«Визуализация результата»
Итого за презентацию = 1*«Командная работа» + 1*«Логика, связность и читаемость слайдов»

У жюри есть несколько вариантов подведения итогов и сложения всех оценок:

- по указанной формуле посчитать итоговую оценку каждого члена жюри, далее найти средний балл по всем членам жюри и выбрать победителем команду с наибольшим баллом;
- по указанной формуле посчитать итоговую оценку для каждого члена жюри, далее найти медианный балл и выбрать победителем команду с наибольшим баллом;
- найти медианный балл по отдельным критериям, а затем получить из них итоговую оценку по приведенным формулам.

Каждый из этих подходов имеет свои плюсы и минусы. В данном задании вам необходимо построить рейтинг команд по каждому из указанных принципов. При вводе ответа укажите номера команд через запятую, начиная с команды, набравшей наибольшее количество баллов, и далее по убыванию баллов (то есть команда, занявшая первое место, будет идти в списке первой, второе место — второй и так далее). Если у команд получается одинаковый итоговый балл, ранжируйте их по возрастанию номеров (например, если команда 1 и команда 2 набрали по 29 баллов, то в ответе необходимо указать “1, 2”).

13. Задача про машины-1 (14 баллов, по 2 за каждый пропуск)

В файле Auto.xlsx вам показаны данные по некоторым характеристикам подержанных автомобилей, представленных на рынке некой страны. Подробное описание переменных дано в файле на листе «Описание». Сами данные находятся на листе

«Данные». Проведите небольшой анализ представленных там показателей и заполните пропуски в тексте ниже.
Если ваш ответ представлен дробным числом, запишите его через запятую с округлением до 2 знаков после запятой (например, «0,33»).
Обратите внимание: запомните полученные вами результаты — они будут нужны в следующем задании.

При анализе факторов, влияющих на ценообразование подержанных автомобилей, необходимо рассчитать корреляцию с основными факторами. Так, корреляция цены с возрастом автомобиля (по состоянию на 2022 год) составляет XXXX, цены с пробегом автомобиля — XXXX, а цены с объемом двигателя — XXXX.

Отметим также, что наибольший средний возраст автомобилей наблюдается в группе с двигателями типа XXXX и составляет XXXX лет, наибольший средний пробег — в группе с двигателями XXXX и составляет XXXX.

14. Задача про машины-2 (3 балла, за все верные, иначе 0)

(продолжение задачи 14)
В любом анализе важно указать возможный механизм влияния одного фактора на другой. Ниже предлагаем вам заполнить пропуски в описании взаимосвязи цены с возрастом и пробегом автомобиля, которую вы получили в предыдущем задании, чтобы получилась верная логическая цепочка.

Наличие такой взаимосвязи цены автомобиля с его возрастом и пробегом объясняется тем, что чем больше возраст автомобиля, тем XXXX (больше/меньше) на нем могли проехать, и все это обуславливает XXXX (больший/меньший) износ автомобиля, что будет действовать на цену в сторону ее XXXX (увеличения/уменьшения).

Содержание

Вариант 2 (с ответами) 2
Вариант 2 (без ответов) 11

Вариант 2 (с ответами)

1. Средняя оценка пользователей (2 балл)

На одном из сайтов с оценкой недвижимости рейтинги жилых комплексов формируются как средняя оценка пользователей по пятибалльной шкале без округления. Жилой комплекс «Событие» компании «Донстрой» имеет рейтинг 4,7 без округления по оценкам 150 пользователей. Какое наименьшее количество пользователей должно еще выставить свои оценки, чтобы рейтинг этого жилого комплекса увеличился хотя бы на 0,1 без округления?

а) 80
б) 75 (+)
в) 105
г) 100
д) Среди остальных ответов нет ни одного верного

2. Зоопарк (3 балла)

Владельцы московского зоопарка заметили, что в жару 75% млекопитающих перестают покидать свои места ночлега, в то время как из африканских животных таких всего 25%. Еще владельцы зоопарка выяснили, что животные, покидающие свои места ночлега в жару, — это в точности все африканские млекопитающие и только они. Известно, что число животных, не относящихся ни к африканским, ни к млекопитающим, составляет 75% от общего числа животных в зоопарке.

Сколько процентов от общего числа животных в зоопарке составляют африканские млекопитающие? Округлите ответ до двух знаков после запятой.

(5,77)

3. Задача про торговую сеть (5 балла)

Менеджеры одной сети розничных книжных магазинов решили изучить объемы продаж товаров в одном из магазинов сети за февраль 2022 года. Они выделили две категории покупателей:

- покупатели типа А — те, кто приобрели ровно одну единицу любого товара за месяц;
- покупатели типа Б — все остальные.

Менеджеры выяснили, что за февраль на каждых пятерых покупателей типа А приходится ровно один покупатель типа Б. Известно, что за месяц данным магазином было продано не более 1260 единиц любых товаров. Какие выводы могут сделать менеджеры на основе имеющейся информации? Выберите все верные ответы.

а) Количество покупателей типа Б составляет 20% от количества всех покупателей магазина в этом месяце
б) За каждый день магазином было продано в среднем 42 единицы товаров

в) В этом месяце количество товаров, проданных покупателям типа Б, не превышает количество товаров, проданных покупателям типа А
г) В этом месяце покупателей типа Б было не более 180 (+)
д) Среди остальных ответов нет ни одного верного

4. Задача про настольные игры (5 балла)

Компания, занимающаяся производством и продажей настольных игр, решила изучить, как COVID-19 повлиял на ее выручку. Все свои игры эта компания делит на несколько сегментов, в каждом из которых игры стоят одинаково. Для этого аналитики компании строят одни и те же графики за период с сентября по ноябрь 2019 года, когда пандемия еще не наступила, и за период с сентября по ноябрь 2020 года, после начала пандемии, и сравнивают их. Какие из перечисленных графиков помогут компании проанализировать влияние COVID-19 на выручку компании? Выберите все подходящие варианты ответа.

а) круговая диаграмма с процентным соотношением суммарной стоимости проданных игр по дням недели
б) гистограмма распределения количества времени, проведенного покупателями в магазине перед покупкой
в) линейный график, показывающий зависимость среднего количества товаров в чеке покупателей от их возраста
г) гистограмма распределения размеров чеков покупателей магазина (+)
д) среди остальных ответов нет ни одного верного

5. Selection bias (5 балла)

Вы консультант министерства здравоохранения и хотите выяснить, насколько хорошо работают больницы, а именно улучшают ли они состояние здоровья людей. Вам доступны результаты опрос населения, в ходе которого у людей узнавали, был ли человек хотя бы раз госпитализирован за последний год (то есть оставался ли он в больнице более чем на сутки), а также попросили оценить общее состояние своего здоровья по шкале от 1 до 5 (где 1 — очень плохо, а 5 — прекрасно). Эти результаты представлены в таблице ниже. Разница между двумя средними показателями значимая.

Группа	Размер выборки	Среднее состояние здоровья	Стандартная ошибка
Был госпитализирован	7774	3,21	0,014
Не был госпитализирован	90 049	3,93	0,003

Вам необходимо проинтерпретировать полученные в ходе опроса результаты. Какие из приведенных ниже утверждений являются верными ?

а) Так как средняя оценка здоровья госпитализированных ниже, мы можем сделать вывод, что больницы ухудшают состояние здоровья пациентов

б) Количество наблюдений в разных группах значительно различается, поэтому таким результатам нельзя доверять

в) Негативный эффект госпитализации может объясняться тем, что в больнице люди рискуют заразиться разными инфекционными заболеваниями от других людей, а также столкнуться с больничными вирусами (+)
г) Среди остальных ответов нет ни одного верного

6. Gapminder (5 балла)

На рисунке изображена диаграмма рассеяния, показывающая взаимосвязь между экономическим развитием и продолжительностью жизни в 2018 году.

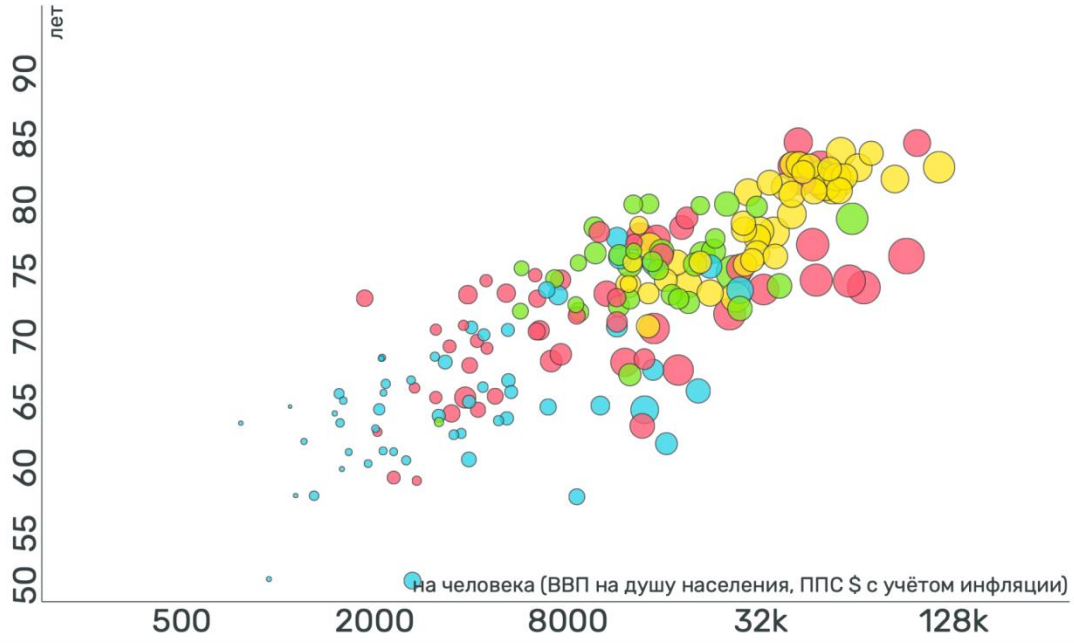
По вертикальной оси показана средняя продолжительность жизни в годах.

По горизонтальной оси отражен реальный ВВП на душу населения в долларах (показатель скорректирован на инфляцию и пересчитан по паритету покупательной способности для сопоставимости между странами). Для наглядности графика значения ВВП преобразованы специальным образом, который при этом качественно не влияет на выводы.

Размер кругов отражает третий показатель — выбросы CO_2 в атмосферу — и измеряется в метрических тоннах выбросов на человека. Чем больше размер круга, тем больше выбросы.

Цвет кругов обозначает разные регионы мира: голубой — Африка, красный — Азия (включая Австралию и Новую зеландию), зеленый — Америка (Северная и Южная вместе), желтый — Европа.

Источник: Gapminder, URL: https://www.gapminder.org



Выберите все верные утверждения, следующие из графика.

а) Существует отрицательная корреляция между средней продолжительностью жизни в стране и объемом выбросов CO_2

б) ВВП на душу населения в странах Африки в среднем ниже, чем в Европейских странах (+)

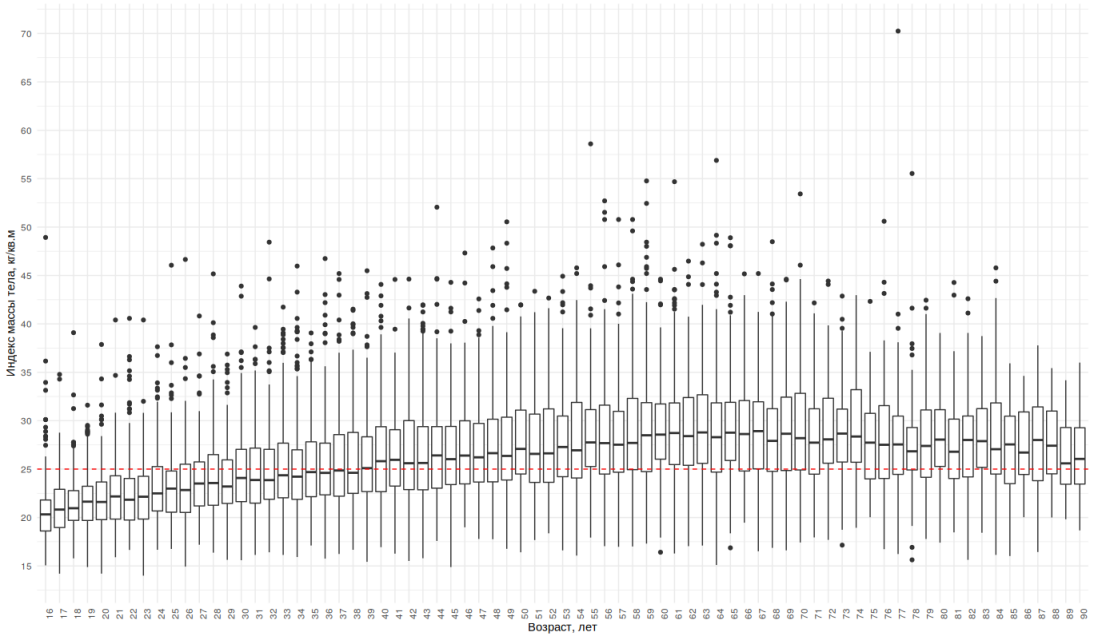
в) Выбросы CO_2 влияют на ВВП на душу населения

г) Среди остальных ответов нет ни одного верного

7. Индекс массы тела (5 балла)

Один из основных показателей здоровья — *индекс массы тела (ИМТ)*. Показатель рассчитывается путем деления веса в килограммах на квадрат роста в метрах. В своих исследованиях ученые используют различные уровни (или интервалы) ИМТ в качестве некоторой базы для сравнения. Здесь в качестве такого значения будет использован ИМТ, равный 25 (отмечен на графике красным пунктиром).

На рисунке представлен график распределения ИМТ среди россиян разного возраста, а именно: для каждого возраста от 16 до 90 лет построен отдельный «ящик с усами» (boxplot).



Источник: РМЭЗ, 28-я волна, данные за 2019 год

Выберите все утверждения, следующие из графика.

а) Медианный уровень ИМТ не превышает 25 для людей возрасте от 16 до 38 лет (+)

б) Медианный уровень ИМТ не превышает 25 для людей возрасте от 39 до 90 лет

в) Третий квартиль (75 персентиль) ИМТ превышает 25 в любом возрасте

г) Среди остальных ответов нет ни одного верного

8. Задача про нормирование (6 баллов)

Андрей слышал, что для решения задач по анализу данных бывает полезным нормировать данные. У него был набор данных, состоящий из 100 значений, — целых чисел от −1000 до 1000 (известно, что не все числа одинаковые). Он решил нормировать каждое значение из набора двумя способами, о которых недавно узнал.

Способ 1

$$x_{new} = (x - x_{min})/(x_{max} - x_{min})$$

Из каждого значения вычитается минимальное значение из набора данных x_{min} и делится на разность максимального и минимального значений из набора данных $x_{max} - x_{min}$.

Способ 2

$$x_{new} = (x - \bar{x})/\sqrt{D}$$

Из каждого значения вычитается среднее арифметическое всех значений набора данных $\bar{x}$ и делится на корень из дисперсии набора данных $\sqrt{D}$ (дисперсия равна D).

Укажите по очереди для каждого способа в алфавитном порядке все пункты, которые выполняются для этого способа (например, 1бг2аг).

Обратите внимание: не обязательно должны быть использованы все пункты, при этом некоторые свойства могут соответствовать и первому, и второму способу.

а) если два старых значения были равны, то и два соответствующих новых значения обязательно будут равны
б) одно из новых значений обязательно окажется равным 1
в) новое значение может оказаться меньше нуля
г) новое значение не может оказаться больше старого значения

Ответ: 1аб2ав

9. Задача на графики (8 баллов)

Аналитики международной компании, занимающейся продажей спортивного инвентаря, решили проанализировать продажи основных товаров, распространяемых компанией, — велосипедов и лыж — за каждый квартал 2021 года. Они построили графики и диаграммы продаж в четырех магазинах компании, находящихся в разных городах мира. Каждому магазину соответствует один график и одна диаграмма. Каждый график показывает продажи велосипедов и лыж по отдельности, за каждый квартал по очереди. Каждая диаграмма отображает общую долю продаж (и велосипедов, и лыж) за каждый квартал относительно суммы всех продаж (и велосипедов, и лыж) в этом магазине за год. Для каждого графика укажите диаграмму, построенную для того же магазина, что и этот график.

Примечание: секторы одного и того же цвета на разных диаграммах могут соответствовать разным кварталам.

(Условие общее для всех 3 вариантов, картинки лежат в отдельных папках, у парных совпадают номер)

10. Платежеспособность заемщика (8 баллов)

Банк заинтересован в анализе платежеспособности своих заемщиков. В идеале он хотел бы точно знать, кто вернет кредит, а кто нет, и давать кредит только первым. На практике банки пытаются оценить вероятность невозврата кредита и используют для этого различные способы. Используя эти оценки вероятности, банк принимает решение о выдаче кредита. При этом важным оказывается выбор порогового значения вероятности. Тогда, если предсказанная вероятность больше порогового значения, будет предсказана невыплата (и банк откажет такому клиенту в выдаче средств), а если меньше — будет предсказано, что заемщик вернет кредит полностью (и такому клиенту банк выдаст кредит). Если поставить пороговое значение слишком низко (скажем, выдавать кредиты только людям, у которых вероятность невыплат составляет 0,01), то таких людей может быть слишком мало и банк не сможет получить прибыль, а если слишком высоко, то число неплатежей будет большим и банк будет терпеть убытки.

В файле ‘default.csv’ содержатся данные о 100 фактических заемщиках банка. Переменная DEFAULT принимает значение 1, если заемщик по факту не вернул кредит полностью или частично (и такого заемщика мы будем называть недобросовестным), и принимает значение 0, если заемщик полностью вернул кредит (такого заемщика мы будем называть добросовестным). Переменная PD принимает значения от 0 до 1 и показывает вероятность невозврата кредита для этих заемщиков, оцененную банком. Если PD выше порогового значения, то модель предсказывает, что заемщик будет недобросовестным, если ниже - то, наоборот, добросовестным.

Сделав необходимые расчеты, выберите все верные утверждения.

а) При пороговом значении 0,5 модель верно предсказывает недобросовестного заемщика в 10 случаях

б) При пороговом значении в 0,9 не будет ни одного случая правильного предсказания добросовестного заемщика (+)

в) Чем ниже выбирается пороговое значение, тем в меньшем числе случаев неправильно предсказываются недобросовестные заемщики (+)

г) Среди остальных ответов нет ни одного верного

11. Характеристики людей (8 баллов)

В файле gender.xlsx представлены данные, касающиеся различных физиологических параметров лица человека. Описание всех переменных приведено в файле на листе «Описание». На основании предложенных данных и ваших расчетов выберите все верные варианты ответа.

а) Стандартное отклонение в высоте лба среди мужчин больше, чем среди женщин (+)
б) У мужчин лоб в среднем шире, чем у женщин (+)

в) У людей с широким носом чаще встречается большое расстояние между носом и губами, чем у людей с узким носом (+)
г) Среди остальных ответов нет ни одного верного

12. Фильмы (8 баллов)

Вам представлены два файла. Один из них (movies_ratings.csv) содержит информацию о названиях фильмов, их популярности, бюджете, кассовых сборах, а также оценках, выставленных отдельными пользователями каждому из фильмов. Описание всех переменных находится на листе «Описание» в файле movies.xlsx. Посчитайте корреляции необходимых переменных и выберите верные утверждения из приведенных ниже.
а) В 21 веке фильмы, вышедшие позже, получают более высокие оценки пользователей
б) Чем новее фильм, тем дольше его продолжительность
в) Чем более продолжительный фильм, там в среднем выше бюджет на его создание (+)
г) Среди остальных ответов нет ни одного верного

13. Рейтинг команд.(15 баллов)

В файле «Оценки.xlsx» вам представлены результаты команд, которые принимали участие в некотором соревновании.

Итоговый балл (ОБЩИЙ ИТОГ) рассчитывался как сумма трех итоговых оценок по теоретическому блоку, практическому блоку и за презентацию. Каждая из итоговых оценок складывалась из взвешенной суммы оценок по отдельным критериям по формулам, приведенным ниже. Каждый критерий оценивался по шкале от 0 до 3.

Итог за теоретический блок = 2*«Гипотеза и механизм» + 1*«Корректность и оригинальность»
Итог за практический блок = 2*«Интерпретация статанализа» + 1*«Перспективы и применимость» + 2*«Дан ответ на поставленный вопрос» + 1*«Визуализация результата»
Итого за презентацию = 1*«Командная работа» + 1*«Логика, связность и читаемость слайдов»

У жюри есть несколько вариантов подведения итогов и сложения всех оценок:

- по указанной формуле посчитать итоговую оценку каждого члена жюри, далее найти средний балл по всем членам жюри и выбрать победителем команду с наибольшим баллом;
- по указанной формуле посчитать итоговую оценку для каждого члена жюри, далее найти медианный балл и выбрать победителем команду с наибольшим баллом;
- найти медианный балл по отдельным критериям, а затем получить из них итоговую оценку по приведенным формулам.

Каждый из этих подходов имеет свои плюсы и минусы. В данном задании вам необходимо построить рейтинг команд по каждому из указанных принципов. При вводе ответа укажите номера команд через запятую, начиная с команды, набравшей наибольшее количество баллов, и далее по убыванию баллов (то есть команда, занявшая первое место, будет идти в списке первой, второе место — второй и так далее). Если у команд получается одинаковый итоговый балл, ранжируйте их по возрастанию номеров (например, если команда 1 и команда 2 набрали по 29 баллов, то в ответе необходимо указать “1, 2”).

При выборе победителя по принципу нахождения среднего итогового балла из оценок всех членов жюри порядок команд будет следующим: (21, 2, 6, 10, 15)
При выборе победителя по принципу нахождения медианного итогового балла порядок команд будет следующим: (2, 21, 6, 10, 15)
При выборе победителя по принципу подсчета итогового балла из медианных баллов жюри по отдельным критериям порядок команд будет следующим: (21, 2, 6, 10, 15)

14. Задача про машины-1 (14 баллов)

В файле Auto.xlsx вам показаны данные по некоторым характеристикам подержанных автомобилей, представленных на рынке некой страны. Подробное описание переменных дано в файле на листе «Описание». Сами данные находятся на листе «Данные». Проведите небольшой анализ представленных там показателей и заполните пропуски в тексте ниже.
Если ваш ответ представлен дробным числом, запишите его через запятую с округлением до 2 знаков после запятой (например, «0,33»).
Обратите внимание: запомните полученные вами результаты — они будут нужны в следующем задании.

При анализе факторов, влияющих на ценообразование подержанных автомобилей, необходимо рассчитать корреляцию с основными факторами. Так, корреляция цены с возрастом автомобиля (по состоянию на 2022 год) составляет XXXX (−0,70), цены с пробегом автомобиля — XXXX (−0,69), а цены с объемом двигателя — XXXX (0,29).

Отметим также, что наибольший средний возраст автомобилей наблюдается в группе с двигателями типа XXXX (LPG) и составляет XXXX (19,45) лет, наибольший средний пробег — в группе с двигателями XXXX (LPG) и составляет XXXX (278 549,16).

15. Задача про машины-2 (3 балла)

(продолжение задачи 12)
В любом анализе важно указать возможный механизм влияния одного фактора на другой. Ниже предлагаем вам заполнить пропуски в описании взаимосвязи цены с возрастом и пробегом автомобиля, которую вы получили в предыдущем задании, чтобы получилась верная логическая цепочка.

Наличие такой взаимосвязи цены автомобиля с его возрастом и пробегом объясняется тем, что чем больше возраст автомобиля, тем XXXX (больше/меньше) на нем могли проехать, и все это обуславливает XXXX (больший/меньший) износ автомобиля, что будет действовать на цену в сторону ее XXXX (увеличения/уменьшения).

Вариант 2 (без ответов)

1. Средняя оценка пользователей (2 балл)

На одном из сайтов с оценкой недвижимости рейтинги жилых комплексов формируются как средняя оценка пользователей по пятибалльной шкале без округления. Жилой комплекс «Событие» компании «Донстрой» имеет рейтинг 4,7 без округления по оценкам 150 пользователей. Какое наименьшее количество пользователей должно еще выставить свои оценки, чтобы рейтинг этого жилого комплекса увеличился хотя бы на 0,1 без округления?

а) 80
б) 75
в) 105
г) 100
д) Среди остальных ответов нет ни одного верного

2. Зоопарк (3 балла)

Владельцы московского зоопарка заметили, что в жару 75% млекопитающих перестают покидать свои места ночлега, в то время как из африканских животных таких всего 25%. Еще владельцы зоопарка выяснили, что животные, покидающие свои места ночлега в жару, — это в точности все африканские млекопитающие и только они. Известно, что число животных, не относящихся ни к африканским, ни к млекопитающим, составляет 75% от общего числа животных в зоопарке.

Сколько процентов от общего числа животных в зоопарке составляют африканские млекопитающие? Округлите ответ до двух знаков после запятой.

3. Задача про торговую сеть (5 балла)

Менеджеры одной сети розничных книжных магазинов решили изучить объемы продаж товаров в одном из магазинов сети за февраль 2022 года. Они выделили две категории покупателей:

- покупатели типа А — те, кто приобрели ровно одну единицу любого товара за месяц;
- покупатели типа Б — все остальные.

Менеджеры выяснили, что за февраль на каждых пятерых покупателей типа А приходится ровно один покупатель типа Б. Известно, что за месяц данным магазином было продано не более 1260 единиц любых товаров. Какие выводы могут сделать менеджеры на основе имеющейся информации? Выберите все верные ответы.

а) Количество покупателей типа Б составляет 20% от количества всех покупателей магазина в этом месяце
б) За каждый день магазином было продано в среднем 42 единицы товаров
в) В этом месяце количество товаров, проданных покупателям типа Б, не превышает количество товаров, проданных покупателям типа А

г) В этом месяце покупателей типа Б было не более 180
д) Среди остальных ответов нет ни одного верного

4. Задача про настольные игры (5 балла)

Компания, занимающаяся производством и продажей настольных игр, решила изучить, как COVID-19 повлиял на ее выручку. Все свои игры эта компания делит на несколько сегментов, в каждом из которых игры стоят одинаково. Для этого аналитики компании строят одни и те же графики за период с сентября по ноябрь 2019 года, когда пандемия еще не наступила, и за период с сентября по ноябрь 2020 года, после начала пандемии, и сравнивают их. Какие из перечисленных графиков помогут компании проанализировать влияние COVID-19 на выручку компании? Выберите все подходящие варианты ответа.

а) круговая диаграмма с процентным соотношением суммарной стоимости проданных игр по дням недели
б) гистограмма распределения количества времени, проведенного покупателями в магазине перед покупкой
в) линейный график, показывающий зависимость среднего количества товаров в чеке покупателей от их возраста
г) гистограмма распределения размеров чеков покупателей магазина
д) среди остальных ответов нет ни одного верного

5. Selection bias (5 балла)

Вы консультант министерства здравоохранения и хотите выяснить, насколько хорошо работают больницы, а именно улучшают ли они состояние здоровья людей. Вам доступны результаты опрос населения, в ходе которого у людей узнавали, был ли человек хотя бы раз госпитализирован за последний год (то есть оставался ли он в больнице более чем на сутки), а также попросили оценить общее состояние своего здоровья по шкале от 1 до 5 (где 1 — очень плохо, а 5 — прекрасно). Эти результаты представлены в таблице ниже. Разница между двумя средними показателями значимая.

Группа	Размер выборки	Среднее состояние здоровья	Стандартная ошибка
Был госпитализирован	7774	3,21	0,014
Не был госпитализирован	90 049	3,93	0,003

Вам необходимо проинтерпретировать полученные в ходе опроса результаты. Какие из приведенных ниже утверждений являются верными ?

а) Так как средняя оценка здоровья госпитализированных ниже, мы можем сделать вывод, что больницы ухудшают состояние здоровья пациентов

б) Количество наблюдений в разных группах значительно различается, поэтому таким результатам нельзя доверять

в) Негативный эффект госпитализации может объясняться тем, что в больнице люди рискуют заразиться разными инфекционными заболеваниями от других людей, а также столкнуться с больничными вирусами

г) Среди остальных ответов нет ни одного верного

6. Gapminder (5 балла)

На рисунке изображена диаграмма рассеяния, показывающая взаимосвязь между экономическим развитием и продолжительностью жизни в 2018 году.

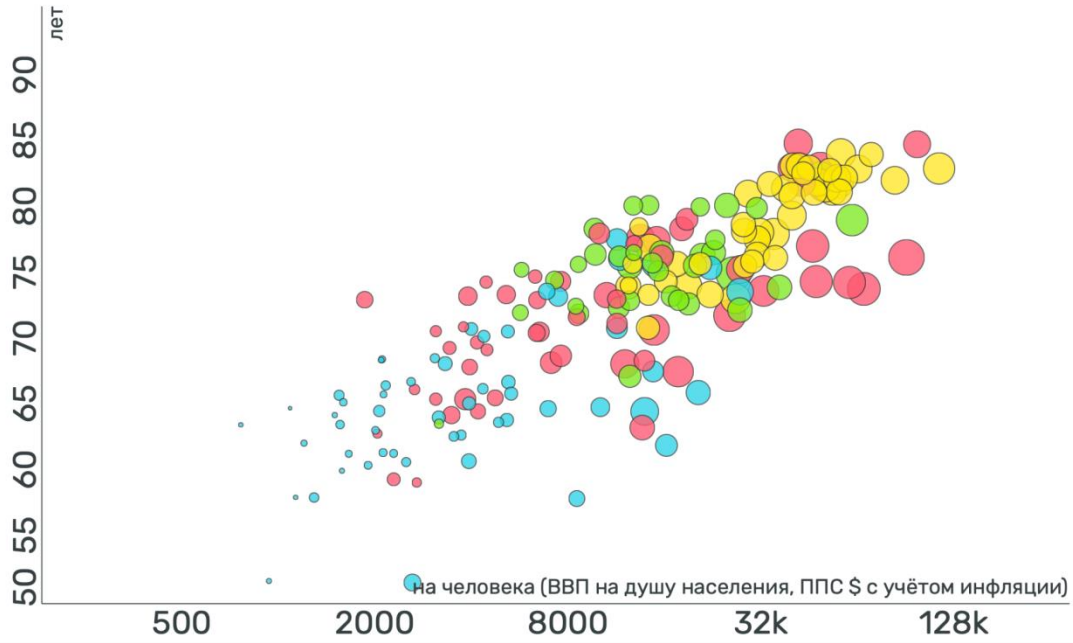
По вертикальной оси показана средняя продолжительность жизни в годах.

По горизонтальной оси отражен реальный ВВП на душу населения в долларах (показатель скорректирован на инфляцию и пересчитан по паритету покупательной способности для сопоставимости между странами). Для наглядности графика значения ВВП преобразованы специальным образом, который при этом качественно не влияет на выводы.

Размер кругов отражает третий показатель — выбросы CO_2 в атмосферу — и измеряется в метрических тоннах выбросов на человека. Чем больше размер круга, тем больше выбросы.

Цвет кругов обозначает разные регионы мира: голубой — Африка, красный — Азия (включая Австралию и Новую зеландию), зеленый — Америка (Северная и Южная вместе), желтый — Европа.

Источник: Gapminder, URL: https://www.gapminder.org



Выберите все верные утверждения, следующие из графика.

а) Существует отрицательная корреляция между средней продолжительностью жизни в стране и объемом выбросов CO_2

б) ВВП на душу населения в странах Африки в среднем ниже, чем в Европейских странах

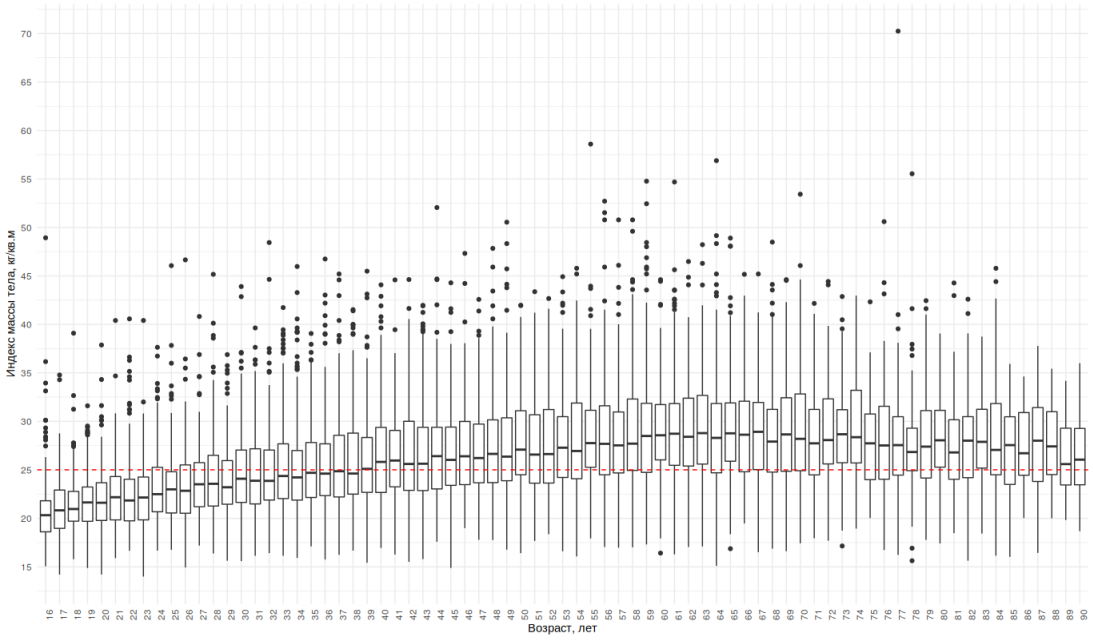
в) Выбросы CO_2 влияют на ВВП на душу населения

г) Среди остальных ответов нет ни одного верного

7. Индекс массы тела (5 балла)

Один из основных показателей здоровья — *индекс массы тела (ИМТ)*. Показатель рассчитывается путем деления веса в килограммах на квадрат роста в метрах. В своих исследованиях ученые используют различные уровни (или интервалы) ИМТ в качестве некоторой базы для сравнения. Здесь в качестве такого значения будет использован ИМТ, равный 25 (отмечен на графике красным пунктиром).

На рисунке представлен график распределения ИМТ среди россиян разного возраста, а именно: для каждого возраста от 16 до 90 лет построен отдельный «ящик с усами» (boxplot).



Источник: РМЭЗ, 28-я волна, данные за 2019 год

Выберите все утверждения, следующие из графика.

а) Медианный уровень ИМТ не превышает 25 для людей возрасте от 16 до 38 лет

б) Медианный уровень ИМТ не превышает 25 для людей возрасте от 39 до 90 лет

в) Третий квартиль (75 персентиль) ИМТ превышает 25 в любом возрасте

г) Среди остальных ответов нет ни одного верного

8. Задача про нормирование (6 баллов)

Андрей слышал, что для решения задач по анализу данных бывает полезным нормировать данные. У него был набор данных, состоящий из 100 значений, — целых чисел от −1000 до 1000 (известно, что не все числа одинаковые). Он решил нормировать каждое значение из набора двумя способами, о которых недавно узнал.

Способ 1

$$x_{new} = (x - x_{min})/(x_{max} - x_{min})$$

Из каждого значения вычитается минимальное значение из набора данных x_{min} и делится на разность максимального и минимального значений из набора данных $x_{max} - x_{min}$.

Способ 2

$$x_{new} = (x - \bar{x})/\sqrt{D}$$

Из каждого значения вычитается среднее арифметическое всех значений набора данных $\bar{x}$ и делится на корень из дисперсии набора данных $\sqrt{D}$ (дисперсия равна D).

Укажите по очереди для каждого способа в алфавитном порядке все пункты, которые выполняются для этого способа (например, 1бг2аг).

Обратите внимание: не обязательно должны быть использованы все пункты, при этом некоторые свойства могут соответствовать и первому, и второму способу.

а) если два старых значения были равны, то и два соответствующих новых значения обязательно будут равны
б) одно из новых значений обязательно окажется равным 1
в) новое значение может оказаться меньше нуля
г) новое значение не может оказаться больше старого значения

9. Задача на графики (8 баллов)

Аналитики международной компании, занимающейся продажей спортивного инвентаря, решили проанализировать продажи основных товаров, распространяемых компанией, — велосипедов и лыж — за каждый квартал 2021 года. Они построили графики и диаграммы продаж в четырех магазинах компании, находящихся в разных городах мира. Каждому магазину соответствует один график и одна диаграмма. Каждый график показывает продажи велосипедов и лыж по отдельности, за каждый квартал по очереди. Каждая диаграмма отображает общую долю продаж (и велосипедов, и лыж) за каждый квартал относительно суммы всех продаж (и велосипедов, и лыж) в этом магазине за год. Для каждого графика укажите диаграмму, построенную для того же магазина, что и этот график.

Примечание: секторы одного и того же цвета на разных диаграммах могут соответствовать разным кварталам.

10. Платежеспособность заемщика (8 баллов)

Банк заинтересован в анализе платежеспособности своих заемщиков. В идеале он хотел бы точно знать, кто вернет кредит, а кто нет, и давать кредит только первым. На практике банки пытаются оценить вероятность невозврата кредита и используют для этого различные способы. Используя эти оценки вероятности, банк принимает решение о выдаче кредита. При этом важным оказывается выбор порогового значения вероятности. Тогда, если предсказанная вероятность больше порогового значения, будет предсказана невыплата (и банк откажет такому клиенту в выдаче средств), а если меньше — будет предсказано, что заемщик вернет кредит полностью (и такому клиенту банк выдаст кредит). Если поставить пороговое значение слишком низко (скажем, выдавать кредиты только людям, у которых вероятность невыплат составляет 0,01), то таких людей может быть слишком мало и банк не сможет получить прибыль, а если слишком высоко, то число неплатежей будет большим и банк будет терпеть убытки.

В файле ‘default.csv’ содержатся данные о 100 фактических заемщиках банка. Переменная DEFAULT принимает значение 1, если заемщик по факту не вернул кредит полностью или частично (и такого заемщика мы будем называть недобросовестным), и принимает значение 0, если заемщик полностью вернул кредит (такого заемщика мы будем называть добросовестным). Переменная PD принимает значения от 0 до 1 и показывает вероятность невозврата кредита для этих заемщиков, оцененную банком. Если PD выше порогового значения, то модель предсказывает, что заемщик будет недобросовестным, если ниже - то, наоборот, добросовестным.

Сделав необходимые расчеты, выберите все верные утверждения.

а) При пороговом значении 0,5 модель верно предсказывает недобросовестного заемщика в 10 случаях

б) При пороговом значении в 0,9 не будет ни одного случая правильного предсказания добросовестного заемщика

в) Чем ниже выбирается пороговое значение, тем в меньшем числе случаев неправильно предсказываются недобросовестные заемщики

г) Среди остальных ответов нет ни одного верного

11. Характеристики людей (8 баллов)

В файле gender.xlsx представлены данные, касающиеся различных физиологических параметров лица человека. Описание всех переменных приведено в файле на листе «Описание». На основании предложенных данных и ваших расчетов выберите все верные варианты ответа.

а) Стандартное отклонение в высоте лба среди мужчин больше, чем среди женщин
б) У мужчин лоб в среднем шире, чем у женщин
в) У людей с широким носом чаще встречается большое расстояние между носом и губами, чем у людей с узким носом
г) Среди остальных ответов нет ни одного верного

12. Фильмы (8 баллов)

Вам представлены два файла. Один из них (movies_ratings.csv) содержит информацию о названиях фильмов, их популярности, бюджете, кассовых сборах, а также оценках, выставленных отдельными пользователями каждому из фильмов. Описание всех переменных находится на листе «Описание» в файле movies.xlsx. Посчитайте корреляции необходимых переменных и выберите верные утверждения из приведенных ниже.

а) В 21 веке фильмы, вышедшие позже, получают более высокие оценки пользователей

б) Чем новее фильм, тем дольше его продолжительность

в) Чем более продолжительный фильм, там в среднем выше бюджет на его создание

г) Среди остальных ответов нет ни одного верного

13. Рейтинг команд.(15 баллов)

В файле «Оценки.xlsx» вам представлены результаты команд, которые принимали участие в некотором соревновании.

Итоговый балл (ОБЩИЙ ИТОГ) рассчитывался как сумма трех итоговых оценок по теоретическому блоку, практическому блоку и за презентацию. Каждая из итоговых оценок складывалась из взвешенной суммы оценок по отдельным критериям по формулам, приведенным ниже. Каждый критерий оценивался по шкале от 0 до 3.

Итог за теоретический блок = 2*«Гипотеза и механизм» + 1*«Корректность и оригинальность»

Итог за практический блок = 2*«Интерпретация статанализа» + 1*«Перспективы и применимость» + 2*«Дан ответ на поставленный вопрос» + 1*«Визуализация результата»

Итого за презентацию = 1*«Командная работа» + 1*«Логика, связность и читаемость слайдов»

У жюри есть несколько вариантов подведения итогов и сложения всех оценок:

- по указанной формуле посчитать итоговую оценку каждого члена жюри, далее найти средний балл по всем членам жюри и выбрать победителем команду с наибольшим баллом;
- по указанной формуле посчитать итоговую оценку для каждого члена жюри, далее найти медианный балл и выбрать победителем команду с наибольшим баллом;
- найти медианный балл по отдельным критериям, а затем получить из них итоговую оценку по приведенным формулам.

Каждый из этих подходов имеет свои плюсы и минусы. В данном задании вам необходимо построить рейтинг команд по каждому из указанных принципов. При вводе ответа укажите номера команд через запятую, начиная с команды, набравшей наибольшее количество баллов, и далее по убыванию баллов (то есть команда, занявшая первое место, будет идти в списке первой, второе место — второй и так

далее). Если у команд получается одинаковый итоговый балл, ранжируйте их по возрастанию номеров (например, если команда 1 и команда 2 набрали по 29 баллов, то в ответе необходимо указать “1, 2”).

14. Задача про машины-1 (14 баллов)

В файле Auto.xlsx вам показаны данные по некоторым характеристикам подержанных автомобилей, представленных на рынке некой страны. Подробное описание переменных дано в файле на листе «Описание». Сами данные находятся на листе «Данные». Проведите небольшой анализ представленных там показателей и заполните пропуски в тексте ниже.

Если ваш ответ представлен дробным числом, запишите его через запятую с округлением до 2 знаков после запятой (например, «0,33»).

Обратите внимание: запомните полученные вами результаты — они будут нужны в следующем задании.

При анализе факторов, влияющих на ценообразование подержанных автомобилей, необходимо рассчитать корреляцию с основными факторами. Так, корреляция цены с возрастом автомобиля (по состоянию на 2022 год) составляет XXXX, цены с пробегом автомобиля — XXXX, а цены с объемом двигателя — XXXX.

Отметим также, что наибольший средний возраст автомобилей наблюдается в группе с двигателями типа XXXX и составляет XXXX лет, наибольший средний пробег — в группе с двигателями XXXX и составляет XXXX.

15. Задача про машины-2 (3 балла)

(продолжение задачи 12)

В любом анализе важно указать возможный механизм влияния одного фактора на другой. Ниже предлагаем вам заполнить пропуски в описании взаимосвязи цены с возрастом и пробегом автомобиля, которую вы получили в предыдущем задании, чтобы получилась верная логическая цепочка.

Наличие такой взаимосвязи цены автомобиля с его возрастом и пробегом объясняется тем, что чем больше возраст автомобиля, тем XXXX (больше/меньше) на нем могли проехать, и все это обуславливает XXXX (больший/меньший) износ автомобиля, что будет действовать на цену в сторону ее XXXX (увеличения/уменьшения).

Содержание

Вариант 3 (с ответами) 2
Вариант 3 (без ответов) 11

Вариант 3 (с ответами)

1. Средняя оценка пользователей (2 балл)

Компания «Донстрой» имеет на одном из сайтов с оценкой недвижимости рейтинг 4,8 из 5 по оценкам 240 пользователей. Какое наименьшее количество пользователей должно еще выставить свои оценки, чтобы рейтинг этой компании увеличился хотя бы на 0,1 без округления?

а) 165
б) 235
в) 160
г) 240 (+)
д) Среди остальных ответов нет ни одного верного

2. Зоопарк (3 балла)

Владельцы одного зоопарка заметили, что 90% ночных птиц не покидают свои места ночлега в дневное время, в то время как из европейских птиц таких всего 10%. Еще владельцы зоопарка выяснили, что все птицы, не покидающие свои места ночлега в дневное время, — это ночные европейские птицы. Известно, что число птиц, не относящихся ни к ночным, ни к европейским, составляет 90% от общего числа птиц в зоопарке.

Сколько процентов от общего числа птиц в зоопарке составляют ночные европейские птицы? Округлите ответ до двух знаков после запятой.

(0,99)

3. Задача про торговую сеть (5 балла)

Менеджеры одной сети розничных магазинов бытовой техники решили изучить объемы продаж товаров в одном из магазинов сети за февраль 2022 года. Они выделили две категории покупателей:

- покупатели типа А — те, кто приобрели ровно одну единицу любого товара за месяц;
- покупатели типа Б — все остальные.

Менеджеры выяснили, что за февраль на каждых десятерых покупателей типа А приходится ровно один покупатель типа Б. Известно, что за месяц данным магазином было продано не более 1320 единиц любых товаров. Какие выводы могут сделать менеджеры на основе имеющейся информации? Выберите все верные ответы.

а) Количество покупателей типа Б составляет 10% от количества всех покупателей магазина в этом месяце
б) За каждый день магазином было продано в среднем 44 единицы товаров
в) В этом месяце количество товаров, проданных покупателям типа Б, не превышает количество товаров, проданных покупателям типа А
г) В этом месяце покупателей типа Б было не более 120 (+)

д) Среди остальных ответов нет ни одного верного

4. Задача про настольные игры (5 балла)

Компания, занимающаяся производством и продажей настольных игр, решила изучить, как COVID-19 повлиял на ее выручку. Все свои игры эта компания делит на несколько сегментов, в каждом из которых игры стоят одинаково. Для этого аналитики компании строят одни и те же графики за период с сентября по ноябрь 2019 года, когда пандемия еще не наступила, и за период с сентября по ноябрь 2020 года, после начала пандемии, и сравнивают их. Какие из перечисленных графиков помогут компании проанализировать влияние COVID-19 на выручку компании? Выберите все подходящие варианты ответа.

а) круговая диаграмма с процентным соотношением количества проданных игр в зависимости от пола покупателя
б) гистограмма распределения количества игр в чеке
в) столбчатая диаграмма, показывающая количество проданных игр по каждому ценовому сегменту (+)
г) линейный график, показывающий зависимость количества покупателей от дня недели
д) среди остальных ответов нет ни одного верного

5. Selection bias (5 балла)

Вы консультант министерства здравоохранения и хотите выяснить, насколько хорошо работают больницы, а именно улучшают ли они состояние здоровья людей. Вам доступны результаты опрос населения, в ходе которого у людей узнавали, был ли человек хотя бы раз госпитализирован за последний год (то есть оставался ли он в больнице более чем на сутки), а также попросили оценить общее состояние своего здоровья по шкале от 1 до 5 (где 1 — очень плохо, а 5 — прекрасно). Эти результаты представлены в таблице ниже. Разница между двумя средними показателями значимая.

Группа	Размер выборки	Среднее состояние здоровья	Стандартная ошибка
Был госпитализирован	7 774	3,21	0,014
Не был госпитализирован	90 049	3,93	0,003

Вам необходимо проинтерпретировать полученные в ходе опроса результаты. Какие из приведенных ниже утверждений являются верными ?

а) Ничего нельзя сказать относительно влияния больниц на состояние здоровья исходя из данных этого опроса (+)

б) Люди с хорошим состоянием здоровья реже оказываются госпитализированными, поэтому среднее состояние в группе госпитализированных могло оказаться ниже (+)

в) Негативный эффект госпитализации может объясняться тем, что в больнице люди рискуют заразиться разными инфекционными заболеваниями от других людей, а также столкнуться с больничными вирусами (+)

г) Среди остальных ответов нет ни одного верного

6. Gapminder (5 балла)

На рисунке изображена диаграмма рассеяния, показывающая взаимосвязь между экономическим развитием и продолжительностью жизни в 2018 году.

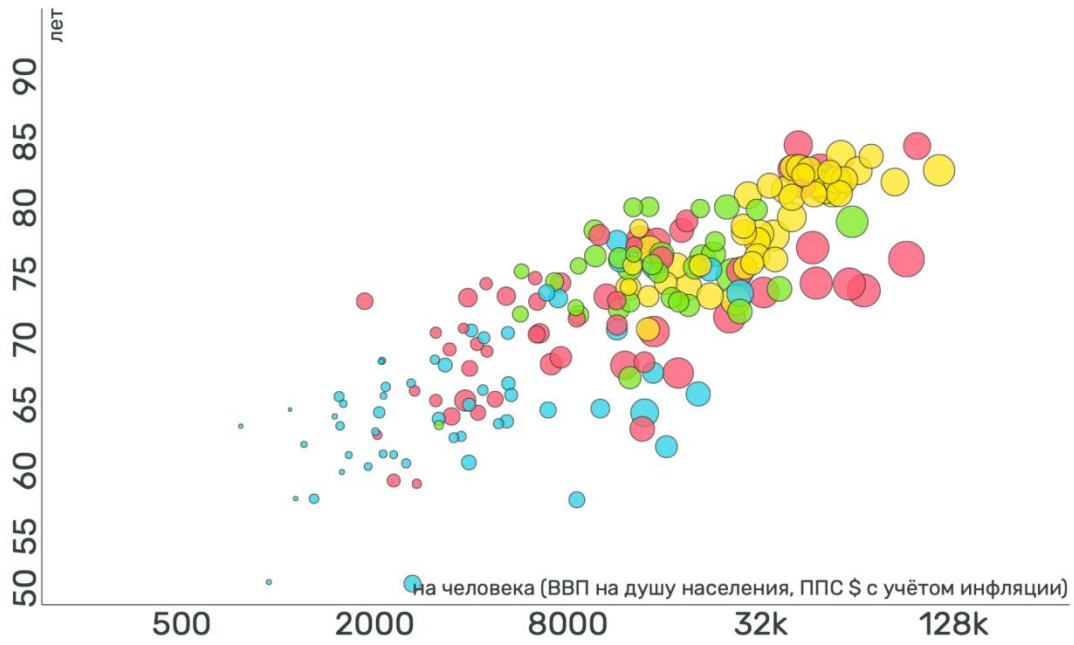
По вертикальной оси показана средняя продолжительность жизни в годах.

По горизонтальной оси отражен реальный ВВП на душу населения в долларах (показатель скорректирован на инфляцию и пересчитан по паритету покупательной способности для сопоставимости между странами). Для наглядности графика значения ВВП преобразованы специальным образом, который при этом качественно не влияет на выводы.

Размер кругов отражает третий показатель — выбросы CO_2 в атмосферу — и измеряется в метрических тоннах выбросов на человека. Чем больше размер круга, тем больше выбросы.

Цвет кругов обозначает разные регионы мира: голубой — Африка, красный — Азия (включая Австралию и Новую зеландию), зеленый — Америка (Северная и Южная вместе), желтый — Европа.

Источник: Gapminder, URL: https://www.gapminder.org



Выберите все верные утверждения, следующие из графика.

а) Существует отрицательная корреляция между объемом выборов CO_2 и ВВП на душу населения

б) Средняя продолжительность жизни в странах Европы в среднем выше, чем в странах Азии (+)

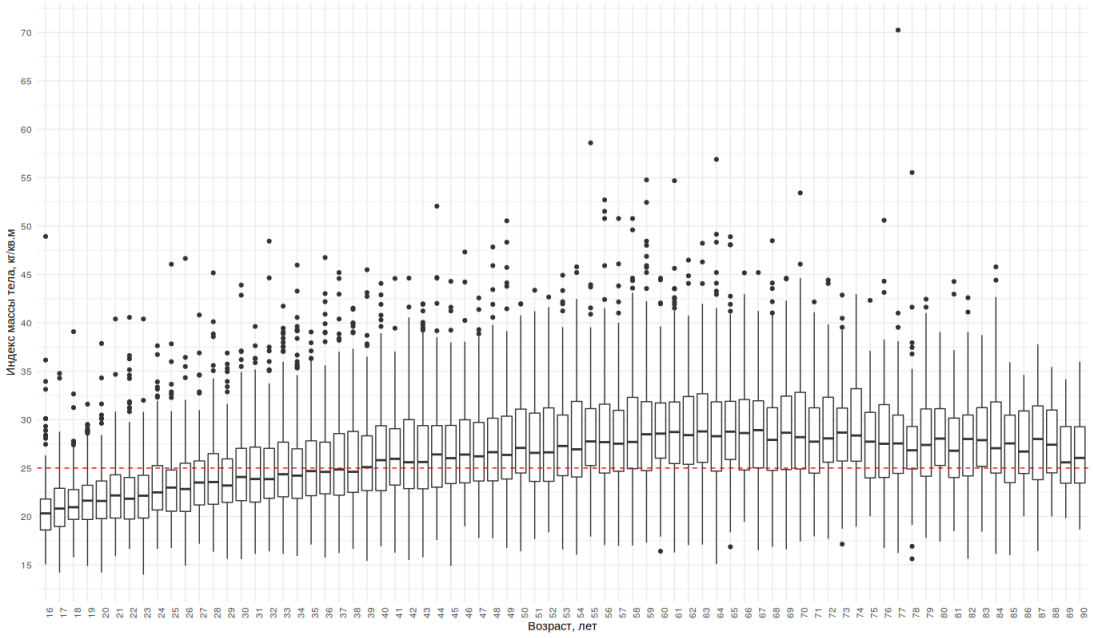
в) Средняя продолжительность жизни влияет на ВВП на душу населения

г) Среди остальных ответов нет ни одного верного

7. Индекс массы тела (5 балла)

Один из основных показателей здоровья — *индекс массы тела (ИМТ)*. Показатель рассчитывается путем деления веса в килограммах на квадрат роста в метрах. В своих исследованиях ученые используют различные уровни (или интервалы) ИМТ в качестве некоторой базы для сравнения. Здесь в качестве такого значения будет использован ИМТ, равный 25 (отмечен на графике красным пунктиром).

На рисунке представлен график распределения ИМТ среди россиян разного возраста, а именно: для каждого возраста от 16 до 90 лет построен отдельный «ящик с усами» (boxplot).



Источник: РМЭЗ, 28-я волна, данные за 2019 год

Выберите все утверждения, следующие из графика.

а) Медианный уровень ИМТ превышает 25 для людей возрасте от 16 до 38 лет

б) Средний уровень ИМТ не превышает 25 для людей возрасте от 39 до 90 лет

в) Разброс в ИМТ растет со временем

г) Нет верного варианта ответа (+)

8. Задача про нормирование (6 баллов)

Андрей слышал, что для решения задач по анализу данных бывает полезным нормировать данные. У него был набор данных, состоящий из 100 значений, — целых чисел от -1000 до 1000 (известно, что не все числа одинаковые). Он решил нормировать каждое значение из набора двумя способами, о которых недавно узнал.

Способ 1

$$x_{new} = (x - x_{min})/(x_{max} - x_{min})$$

Из каждого значения вычитается минимальное значение из набора данных x_{min} и делится на разность максимального и минимального значений из набора данных $x_{max} - x_{min}$.

Способ 2

$$x_{new} = (x - \bar{x})/\sqrt{D}$$

Из каждого значения вычитается среднее арифметическое всех значений набора данных $\bar{x}$ и делится на корень из дисперсии набора данных $\sqrt{D}$ (дисперсия равна D).

Укажите по очереди для каждого способа в алфавитном порядке все пункты, которые выполняются для этого способа (например, 1бг2аг).

Обратите внимание: не обязательно должны быть использованы все пункты, при этом некоторые свойства могут соответствовать и первому, и второму способу.

а) если старое значение было больше нуля, то и новое обязательно будет больше нуля
б) новое значение может оказаться больше старого значения
в) новое значение может оказаться меньше -1
г) одно из новых значений обязательно окажется равным 1

Ответ: 1абг2бв

9. Задача на графики (8 баллов)

Аналитики международной компании, занимающейся продажей спортивного инвентаря, решили проанализировать продажи основных товаров, распространяемых компанией, — велосипедов и лыж — за каждый квартал 2021 года. Они построили графики и диаграммы продаж в четырех магазинах компании, находящихся в разных городах мира. Каждому магазину соответствует один график и одна диаграмма. Каждый график показывает продажи велосипедов и лыж по отдельности, за каждый квартал по очереди. Каждая диаграмма отображает общую долю продаж (и велосипедов, и лыж) за каждый квартал относительно суммы всех продаж (и велосипедов, и лыж) в этом магазине за год. Для каждого графика укажите диаграмму, построенную для того же магазина, что и этот график.

Примечание: секторы одного и того же цвета на разных диаграммах могут соответствовать разным кварталам.

(Условие общее для всех 3 вариантов, картинки лежат в отдельных папках, у парных совпадают номер)

10. Платежеспособность заемщика (8 баллов)

Банк заинтересован в анализе платежеспособности своих заемщиков. В идеале он хотел бы точно знать, кто вернет кредит, а кто нет, и давать кредит только первым. На практике банки пытаются оценить вероятность невозврата кредита и используют для этого различные способы. Используя эти оценки вероятности, банк принимает решение о выдаче кредита. При этом важным оказывается выбор порогового значения вероятности. Тогда, если предсказанная вероятность больше порогового значения, будет предсказана невыплата (и банк откажет такому клиенту в выдаче средств), а если меньше — будет предсказано, что заемщик вернет кредит полностью (и такому клиенту банк выдаст кредит). Если поставить пороговое значение слишком низко (скажем, выдавать кредиты только людям, у которых вероятность невыплат составляет 0,01), то таких людей может быть слишком мало и банк не сможет получить прибыль, а если слишком высоко, то число неплатежей будет большим и банк будет терпеть убытки.

В файле ‘default.csv’ содержатся данные о 100 фактических заемщиках банка. Переменная DEFAULT принимает значение 1, если заемщик по факту не вернул кредит полностью или частично (и такого заемщика мы будем называть недобросовестным), и принимает значение 0, если заемщик полностью вернул кредит (такого заемщика мы будем называть добросовестным). Переменная PD принимает значения от 0 до 1 и показывает вероятность невозврата кредита для этих заемщиков, оцененную банком.

Сделав необходимые расчеты, выберите все верные утверждения.

а) При пороговом значении 0,5 модель будет верно предсказывать добросовестных заемщиков в 67 случаях

б) Чем выше выбирается пороговое значение, тем в большем числе случаев правильно предсказываются добросовестные заемщики (+)

в) При пороговом значении 0,35 модель не сможет предсказать недобросовестных заемщиков в 6 случаях (+)

г) Среди остальных ответов нет ни одного верного

11. Характеристики людей (8 баллов)

В файле gender.xlsx представлены данные, касающиеся различных физиологических параметров лица человека. Описание всех переменных приведено в файле на листе «Описание». На основании предложенных данных и ваших расчетов выберите все верные варианты ответа.

а) Стандартное отклонение в высоте лба среди женщин больше, чем среди мужчин
б) У людей с широким носом чаще встречаются тонкие губы, чем пухлые (+)

в) У большинства мужчин длинные волосы (+)
г) Среди остальных ответов нет ни одного верного

12. Фильмы (8 баллов)

Вам представлены два файла. Один из них (movies_ratings.csv) содержит информацию о названиях фильмов, их популярности, бюджете, кассовых сборах, а также оценках, выставленных отдельными пользователями каждому из фильмов. Описание всех переменных находится на листе «Описание» в файле movies.xlsx. Посчитайте корреляции необходимых переменных и выберите верные утверждения из приведенных ниже.

а) В отличие от 20 века в 21 веке популярность фильмов в среднем растет со временем (+)
б) Чем больше бюджет фильма, тем выше в среднем его популярность (+)
в) Бюджет на производство фильмов в среднем растет со временем
г) Среди остальных ответов нет ни одного верного

13. Рейтинг команд.(15 баллов)

В файле «Оценки.xlsx» вам представлены результаты команд, которые принимали участие в некотором соревновании.

Итоговый балл (ОБЩИЙ ИТОГ) рассчитывался как сумма трех итоговых оценок по теоретическому блоку, практическому блоку и за презентацию. Каждая из итоговых оценок складывалась из взвешенной суммы оценок по отдельным критериям по формулам, приведенным ниже. Каждый критерий оценивался по шкале от 0 до 3.

Итог за теоретический блок = 2*«Гипотеза и механизм» + 1*«Корректность и оригинальность»
Итог за практический блок = 2*«Интерпретация статанализа» + 1*«Перспективы и применимость» + 2*«Дан ответ на поставленный вопрос» + 1*«Визуализация результата»
Итого за презентацию = 1*«Командная работа» + 1*«Логика, связность и читаемость слайдов»

У жюри есть несколько вариантов подведения итогов и сложения всех оценок:

- по указанной формуле посчитать итоговую оценку каждого члена жюри, далее найти средний балл по всем членам жюри и выбрать победителем команду с наибольшим баллом;
- по указанной формуле посчитать итоговую оценку для каждого члена жюри, далее найти медианный балл и выбрать победителем команду с наибольшим баллом;
- найти медианный балл по отдельным критериям, а затем получить из них итоговую оценку по приведенным формулам.

Каждый из этих подходов имеет свои плюсы и минусы. В данном задании вам необходимо построить рейтинг команд по каждому из указанных принципов. При

вводе ответа укажите номера команд через запятую, начиная с команды, набравшей наибольшее количество баллов, и далее по убыванию баллов (то есть команда, занявшая первое место, будет идти в списке первой, второе место — второй и так далее). Если у команд получается одинаковый итоговый балл, ранжируйте их по возрастанию номеров (например, если команда 1 и команда 2 набрали по 29 баллов, то в ответе необходимо указать “1, 2”).

При выборе победителя по принципу нахождения среднего итогового балла из оценок всех членов жюри порядок команд будет следующим: (16, 11, 8, 20, 5)
При выборе победителя по принципу нахождения медианного итогового балла порядок команд будет следующим: (11, 16, 8, 5, 20)
При выборе победителя по принципу подсчета итогового балла из медианных баллов жюри по отдельным критериям порядок команд будет следующим: (16, 11, 8, 5, 20)

14. Задача про машины-1 (14 баллов)

(По Volkswagen)
В файле Auto.xlsx вам показаны данные по некоторым характеристикам подержанных автомобилей, представленных на рынке некой страны. Подробное описание переменных дано в файле на листе «Описание». Сами данные находятся на листе «Данные». Проведите небольшой анализ представленных там показателей и заполните пропуски в тексте ниже.
Если ваш ответ представлен дробным числом, запишите его через запятую с округлением до 2 знаков после запятой (например, «0,33»).
Обратите внимание: запомните полученные вами результаты — они будут нужны в следующем задании.

При анализе факторов, влияющих на ценообразование подержанных автомобилей, необходимо рассчитать корреляцию с основными факторами. Так, корреляция цены с возрастом автомобиля (по состоянию на 2022 год) составляет XXXX (–0,72), цены с пробегом автомобиля — XXXX (–0,63), а цены с объемом двигателя — XXXX (0,09).

Отметим также, что наибольший средний возраст автомобилей наблюдается в группе с двигателями типа XXXX (LPG) и составляет XXXX (17,19) лет, наибольший средний пробег — в группе с двигателями XXXX (LPG) и составляет XXXX (240 492,11).

15. Задача про машины-2 (3 балла)

(продолжение задачи 14)
В любом анализе важно указать возможный механизм влияния одного фактора на другой. Ниже предлагаем вам заполнить пропуски в описании взаимосвязи цены с возрастом и пробегом автомобиля, которую вы получили в предыдущем задании, чтобы получилась верная логическая цепочка.

Наличие такой взаимосвязи цены автомобиля с его возрастом и пробегом объясняется тем, что чем больше возраст автомобиля, тем XXXX (больше/меньше)

на нем могли проехать, и все это обуславливает XXXX (больший/меньший) износ автомобиля, что будет действовать на цену в сторону ее XXXX (увеличения/уменьшения).

Вариант 3 (без ответов)

1. Средняя оценка пользователей (2 балл)

Компания «Донстрой» имеет на одном из сайтов с оценкой недвижимости рейтинг 4,8 из 5 по оценкам 240 пользователей. Какое наименьшее количество пользователей должно еще выставить свои оценки, чтобы рейтинг этой компании увеличился хотя бы на 0,1 без округления?

а) 165
б) 235
в) 160
г) 240
д) Среди остальных ответов нет ни одного верного

2. Зоопарк (3 балла)

Владельцы одного зоопарка заметили, что 90% ночных птиц не покидают свои места ночлега в дневное время, в то время как из европейских птиц таких всего 10%. Еще владельцы зоопарка выяснили, что все птицы, не покидающие свои места ночлега в дневное время, — это ночные европейские птицы. Известно, что число птиц, не относящихся ни к ночным, ни к европейским, составляет 90% от общего числа птиц в зоопарке.

Сколько процентов от общего числа птиц в зоопарке составляют ночные европейские птицы? Округлите ответ до двух знаков после запятой.

3. Задача про торговую сеть (5 балла)

Менеджеры одной сети розничных магазинов бытовой техники решили изучить объемы продаж товаров в одном из магазинов сети за февраль 2022 года. Они выделили две категории покупателей:

- покупатели типа А — те, кто приобрели ровно одну единицу любого товара за месяц;
- покупатели типа Б — все остальные.

Менеджеры выяснили, что за февраль на каждых десятерых покупателей типа А приходится ровно один покупатель типа Б. Известно, что за месяц данным магазином было продано не более 1320 единиц любых товаров. Какие выводы могут сделать менеджеры на основе имеющейся информации? Выберите все верные ответы.

а) Количество покупателей типа Б составляет 10% от количества всех покупателей магазина в этом месяце
б) За каждый день магазином было продано в среднем 44 единицы товаров
в) В этом месяце количество товаров, проданных покупателям типа Б, не превышает количество товаров, проданных покупателям типа А
г) В этом месяце покупателей типа Б было не более 120
д) Среди остальных ответов нет ни одного верного

4. Задача про настольные игры (5 балла)

Компания, занимающаяся производством и продажей настольных игр, решила изучить, как COVID-19 повлиял на ее выручку. Все свои игры эта компания делит на несколько сегментов, в каждом из которых игры стоят одинаково. Для этого аналитики компании строят одни и те же графики за период с сентября по ноябрь 2019 года, когда пандемия еще не наступила, и за период с сентября по ноябрь 2020 года, после начала пандемии, и сравнивают их. Какие из перечисленных графиков помогут компании проанализировать влияние COVID-19 на выручку компании? Выберите все подходящие варианты ответа.

а) круговая диаграмма с процентным соотношением количества проданных игр в зависимости от пола покупателя
б) гистограмма распределения количества игр в чеке
в) столбчатая диаграмма, показывающая количество проданных игр по каждому ценовому сегменту
г) линейный график, показывающий зависимость количества покупателей от дня недели
д) среди остальных ответов нет ни одного верного

5. Selection bias (5 балла)

Вы консультант министерства здравоохранения и хотите выяснить, насколько хорошо работают больницы, а именно улучшают ли они состояние здоровья людей. Вам доступны результаты опрос населения, в ходе которого у людей узнавали, был ли человек хотя бы раз госпитализирован за последний год (то есть оставался ли он в больнице более чем на сутки), а также попросили оценить общее состояние своего здоровья по шкале от 1 до 5 (где 1 — очень плохо, а 5 — прекрасно). Эти результаты представлены в таблице ниже. Разница между двумя средними показателями значимая.

Группа	Размер выборки	Среднее состояние здоровья	Стандартная ошибка
Был госпитализирован	7 774	3,21	0,014
Не был госпитализирован	90 049	3,93	0,003

Вам необходимо проинтерпретировать полученные в ходе опроса результаты. Какие из приведенных ниже утверждений являются верными?

а) Ничего нельзя сказать относительно влияния больниц на состояние здоровья исходя из данных этого опроса

б) Люди с хорошим состоянием здоровья реже оказываются госпитализированными, поэтому среднее состояние в группе госпитализированных могло оказаться ниже

в) Негативный эффект госпитализации может объясняться тем, что в больнице люди рискуют заразиться разными инфекционными заболеваниями от других людей, а также столкнуться с больничными вирусами

г) Среди остальных ответов нет ни одного верного

6. Gapminder (5 балла)

На рисунке изображена диаграмма рассеяния, показывающая взаимосвязь между экономическим развитием и продолжительностью жизни в 2018 году.

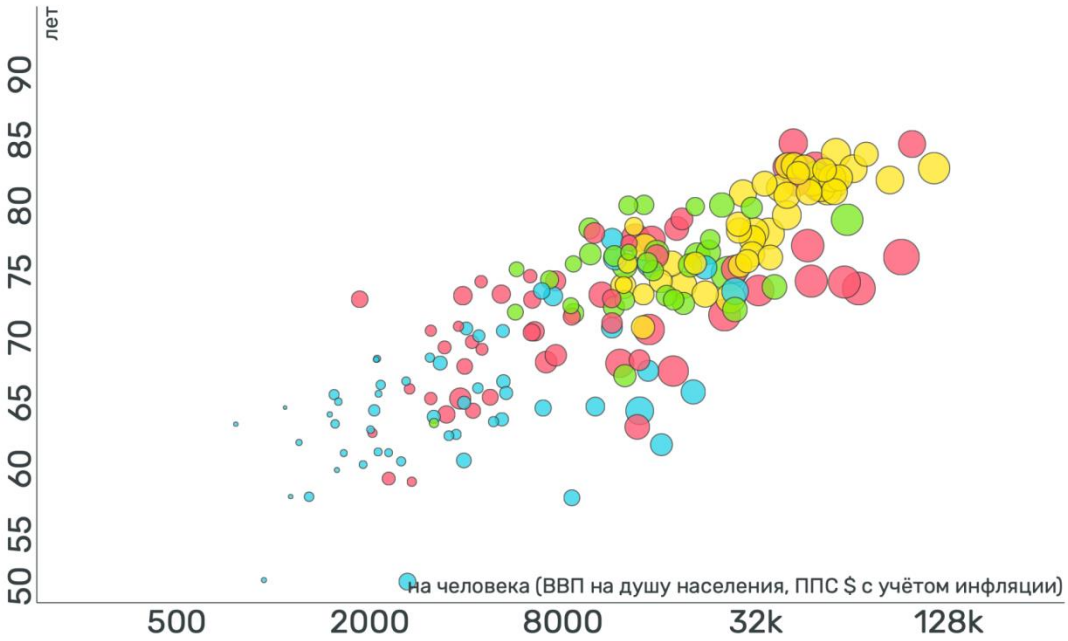
По вертикальной оси показана средняя продолжительность жизни в годах.

По горизонтальной оси отражен реальный ВВП на душу населения в долларах (показатель скорректирован на инфляцию и пересчитан по паритету покупательной способности для сопоставимости между странами). Для наглядности графика значения ВВП преобразованы специальным образом, который при этом качественно не влияет на выводы.

Размер кругов отражает третий показатель — выбросы CO_2 в атмосферу — и измеряется в метрических тоннах выбросов на человека. Чем больше размер круга, тем больше выбросы.

Цвет кругов обозначает разные регионы мира: голубой — Африка, красный — Азия (включая Австралию и Новую зеландию), зеленый — Америка (Северная и Южная вместе), желтый — Европа.

Источник: Gapminder, URL: https://www.gapminder.org



Выберите все верные утверждения, следующие из графика.

а) Существует отрицательная корреляция между объемом выборов CO_2 и ВВП на душу населения

б) Средняя продолжительность жизни в странах Европы в среднем выше, чем в странах Азии

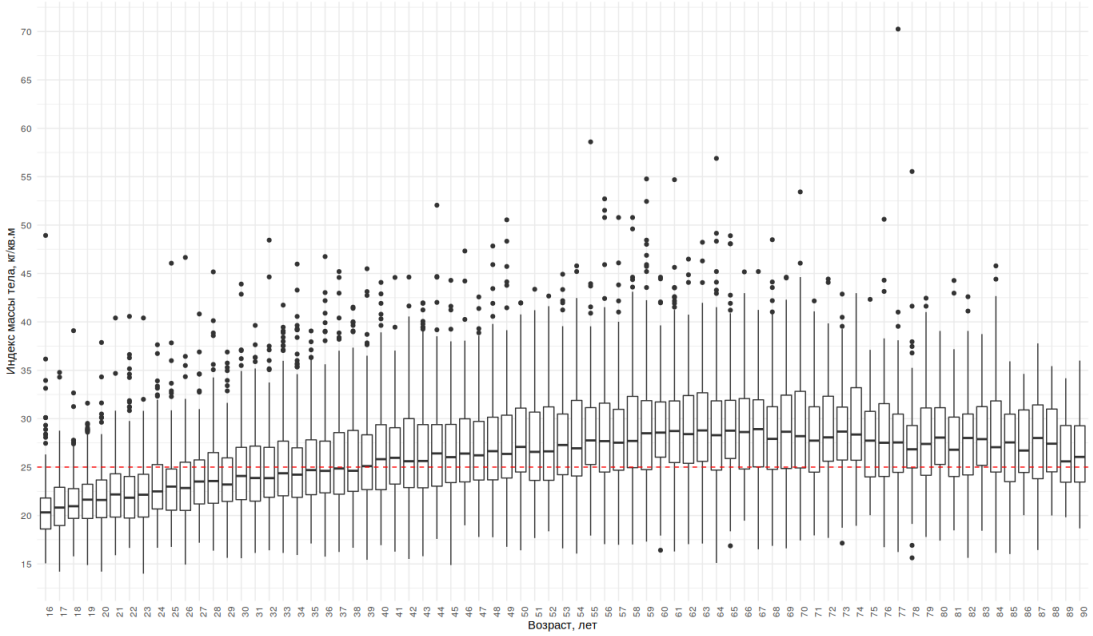
в) Средняя продолжительность жизни влияет на ВВП на душу населения

г) Среди остальных ответов нет ни одного верного

7. Индекс массы тела (5 балла)

Один из основных показателей здоровья — *индекс массы тела (ИМТ)*. Показатель рассчитывается путем деления веса в килограммах на квадрат роста в метрах. В своих исследованиях ученые используют различные уровни (или интервалы) ИМТ в качестве некоторой базы для сравнения. Здесь в качестве такого значения будет использован ИМТ, равный 25 (отмечен на графике красным пунктиром).

На рисунке представлен график распределения ИМТ среди россиян разного возраста, а именно: для каждого возраста от 16 до 90 лет построен отдельный «ящик с усами» (boxplot).



Источник: РМЭЗ, 28-я волна, данные за 2019 год

Выберите все утверждения, следующие из графика.

а) Медианный уровень ИМТ превышает 25 для людей возрасте от 16 до 38 лет

б) Средний уровень ИМТ не превышает 25 для людей возрасте от 39 до 90 лет

в) Разброс в ИМТ растет со временем

г) Нет верного варианта ответа

8. Задача про нормирование (6 баллов)

Андрей слышал, что для решения задач по анализу данных бывает полезным нормировать данные. У него был набор данных, состоящий из 100 значений, — целых чисел от -1000 до 1000 (известно, что не все числа одинаковые). Он решил нормировать каждое значение из набора двумя способами, о которых недавно узнал.

Способ 1

$$x_{new} = (x - x_{min})/(x_{max} - x_{min})$$

Из каждого значения вычитается минимальное значение из набора данных x_{min} и делится на разность максимального и минимального значений из набора данных $x_{max} - x_{min}$.

Способ 2

$$x_{new} = (x - \bar{x})/\sqrt{D}$$

Из каждого значения вычитается среднее арифметическое всех значений набора данных $\bar{x}$ и делится на корень из дисперсии набора данных $\sqrt{D}$ (дисперсия равна D).

Укажите по очереди для каждого способа в алфавитном порядке все пункты, которые выполняются для этого способа (например, 1бг2аг).

Обратите внимание: не обязательно должны быть использованы все пункты, при этом некоторые свойства могут соответствовать и первому, и второму способу.

а) если старое значение было больше нуля, то и новое обязательно будет больше нуля
б) новое значение может оказаться больше старого значения
в) новое значение может оказаться меньше -1
г) одно из новых значений обязательно окажется равным 1

9. Задача на графики (8 баллов)

Аналитики международной компании, занимающейся продажей спортивного инвентаря, решили проанализировать продажи основных товаров, распространяемых компанией, — велосипедов и лыж — за каждый квартал 2021 года. Они построили графики и диаграммы продаж в четырех магазинах компании, находящихся в разных городах мира. Каждому магазину соответствует один график и одна диаграмма. Каждый график показывает продажи велосипедов и лыж по отдельности, за каждый квартал по очереди. Каждая диаграмма отображает общую долю продаж (и велосипедов, и лыж) за каждый квартал относительно суммы всех продаж (и велосипедов, и лыж) в этом магазине за год. Для каждого графика укажите диаграмму, построенную для того же магазина, что и этот график.

Примечание: секторы одного и того же цвета на разных диаграммах могут соответствовать разным кварталам.

10. Платежеспособность заемщика (8 баллов)

Банк заинтересован в анализе платежеспособности своих заемщиков. В идеале он хотел бы точно знать, кто вернет кредит, а кто нет, и давать кредит только первым. На

практике банки пытаются оценить вероятность невозврата кредита и используют для этого различные способы. Используя эти оценки вероятности, банк принимает решение о выдаче кредита. При этом важным оказывается выбор порогового значения вероятности. Тогда, если предсказанная вероятность больше порогового значения, будет предсказана невыплата (и банк откажет такому клиенту в выдаче средств), а если меньше — будет предсказано, что заемщик вернет кредит полностью (и такому клиенту банк выдаст кредит). Если поставить пороговое значение слишком низко (скажем, выдавать кредиты только людям, у которых вероятность невыплат составляет 0,01), то таких людей может быть слишком мало и банк не сможет получить прибыль, а если слишком высоко, то число неплатежей будет большим и банк будет терпеть убытки.

В файле ‘default.csv’ содержатся данные о 100 фактических заемщиках банка. Переменная DEFAULT принимает значение 1, если заемщик по факту не вернул кредит полностью или частично (и такого заемщика мы будем называть недобросовестным), и принимает значение 0, если заемщик полностью вернул кредит (такого заемщика мы будем называть добросовестным). Переменная PD принимает значения от 0 до 1 и показывает вероятность невозврата кредита для этих заемщиков, оцененную банком.

Сделав необходимые расчеты, выберите все верные утверждения.

а) При пороговом значении 0,5 модель будет верно предсказывать добросовестных заемщиков в 67 случаях

б) Чем выше выбирается пороговое значение, тем в большем числе случаев правильно предсказываются добросовестные заемщики

в) При пороговом значении 0,35 модель не сможет предсказать недобросовестных заемщиков в 6 случаях

г) Среди остальных ответов нет ни одного верного

11. Характеристики людей (8 баллов)

В файле gender.xlsx представлены данные, касающиеся различных физиологических параметров лица человека. Описание всех переменных приведено в файле на листе «Описание». На основании предложенных данных и ваших расчетов выберите все верные варианты ответа.

а) Стандартное отклонение в высоте лба среди женщин больше, чем среди мужчин
б) У людей с широким носом чаще встречаются тонкие губы, чем пухлые
в) У большинства мужчин длинные волосы
г) Среди остальных ответов нет ни одного верного

12. Фильмы (8 баллов)

Вам представлены два файла. Один из них (movies_ratings.csv) содержит информацию о названиях фильмов, их популярности, бюджете, кассовых сборах, а также оценках, выставленных отдельными пользователями каждому из фильмов. Описание всех переменных находится на листе «Описание» в файле movies.xlsx. Посчитайте

корреляции необходимых переменных и выберите верные утверждения из приведенных ниже.
а) В отличие от 20 века в 21 веке популярность фильмов в среднем растет со временем
б) Чем больше бюджет фильма, тем выше в среднем его популярность
в) Бюджет на производство фильмов в среднем растет со временем
г) Среди остальных ответов нет ни одного верного

13. Рейтинг команд.(15 баллов)

В файле «Оценки.xlsx» вам представлены результаты команд, которые принимали участие в некотором соревновании.

Итоговый балл (ОБЩИЙ ИТОГ) рассчитывался как сумма трех итоговых оценок по теоретическому блоку, практическому блоку и за презентацию. Каждая из итоговых оценок складывалась из взвешенной суммы оценок по отдельным критериям по формулам, приведенным ниже. Каждый критерий оценивался по шкале от 0 до 3.

Итог за теоретический блок = 2*«Гипотеза и механизм» + 1*«Корректность и оригинальность»
Итог за практический блок = 2*«Интерпретация статанализа» + 1*«Перспективы и применимость» + 2*«Дан ответ на поставленный вопрос» + 1*«Визуализация результата»
Итого за презентацию = 1*«Командная работа» + 1*«Логика, связность и читаемость слайдов»

У жюри есть несколько вариантов подведения итогов и сложения всех оценок:

- по указанной формуле посчитать итоговую оценку каждого члена жюри, далее найти средний балл по всем членам жюри и выбрать победителем команду с наибольшим баллом;
- по указанной формуле посчитать итоговую оценку для каждого члена жюри, далее найти медианный балл и выбрать победителем команду с наибольшим баллом;
- найти медианный балл по отдельным критериям, а затем получить из них итоговую оценку по приведенным формулам.

Каждый из этих подходов имеет свои плюсы и минусы. В данном задании вам необходимо построить рейтинг команд по каждому из указанных принципов. При вводе ответа укажите номера команд через запятую, начиная с команды, набравшей наибольшее количество баллов, и далее по убыванию баллов (то есть команда, занявшая первое место, будет идти в списке первой, второе место — второй и так далее). Если у команд получается одинаковый итоговый балл, ранжируйте их по возрастанию номеров (например, если команда 1 и команда 2 набрали по 29 баллов, то в ответе необходимо указать “1, 2”).

14. Задача про машины-1 (14 баллов)

(По Volkswagen)

В файле Auto.xlsx вам показаны данные по некоторым характеристикам подержанных автомобилей, представленных на рынке некой страны. Подробное описание переменных дано в файле на листе «Описание». Сами данные находятся на листе «Данные». Проведите небольшой анализ представленных там показателей и заполните пропуски в тексте ниже.
Если ваш ответ представлен дробным числом, запишите его через запятую с округлением до 2 знаков после запятой (например, «0,33»).
Обратите внимание: запомните полученные вами результаты — они будут нужны в следующем задании.

При анализе факторов, влияющих на ценообразование подержанных автомобилей, необходимо рассчитать корреляцию с основными факторами. Так, корреляция цены с возрастом автомобиля (по состоянию на 2022 год) составляет XXXX, цены с пробегом автомобиля — XXXX, а цены с объемом двигателя — XXXX.

Отметим также, что наибольший средний возраст автомобилей наблюдается в группе с двигателями типа XXXX и составляет XXXX лет, наибольший средний пробег — в группе с двигателями XXXX и составляет XXXX.

15. Задача про машины-2 (3 балла)

(продолжение задачи 14)
В любом анализе важно указать возможный механизм влияния одного фактора на другой. Ниже предлагаем вам заполнить пропуски в описании взаимосвязи цены с возрастом и пробегом автомобиля, которую вы получили в предыдущем задании, чтобы получилась верная логическая цепочка.

Наличие такой взаимосвязи цены автомобиля с его возрастом и пробегом объясняется тем, что чем больше возраст автомобиля, тем XXXX (больше/меньше) на нем могли проехать, и все это обуславливает XXXX (больший/меньший) износ автомобиля, что будет действовать на цену в сторону ее XXXX (увеличения/уменьшения).

DANO

Задачный тур третьего (заключительного) этапа 2022/23 уч.года.

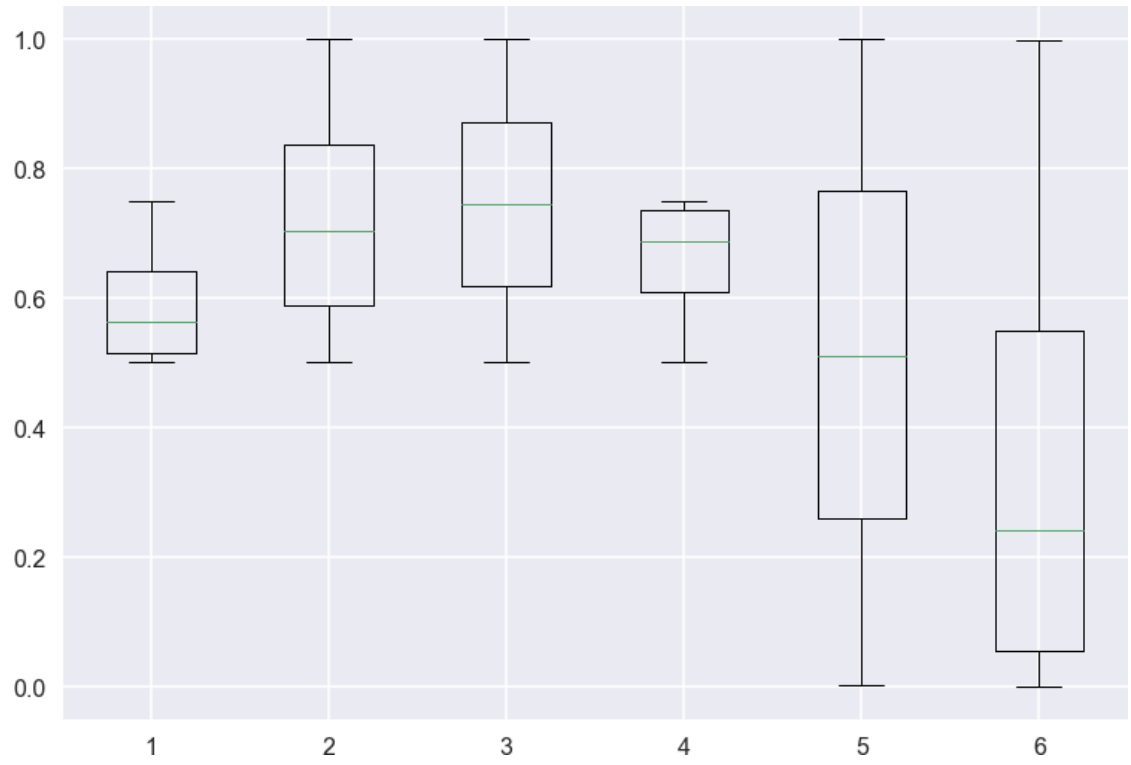
Задача 1.

1. Смотрим на распределения (80 баллов)

(i). У вас есть массив значений, равномерно распределенных между 0 и 1 (т. е. вероятность, что значение будет принадлежать конкретному отрезку, например $[0.5,\ 0.6]$, зависит только от длины отрезка).

К этому массиву были применены следующие функции, чтобы получить новые массивы:

A. $f(x) = -x^2 + x + 0.5$
B. $f(x) = 1 - x$
C. $f(x) = 2^{x-1} = \frac{2^x}{2}$
D. $f(x) = x^2$
E. $f(x) = \frac{x}{2} + 0.5$



Выше приведены ящики с усами, которые были построены на полученных массивах. Вам нужно найти соответствие между функциями и их визуализацией и обосновать свой ответ.

Решение:

Рассмотрим функцию A. Ее минимальное и максимальное значение на отрезке $[0,\ 1]$ равны 0.5 и 0.75. Значит, соответствующий ящик – либо 1, либо 4. Давайте найдем медиану для A. Для этого мы посчитаем половину максимальных значений. Половина значений в начальной выборке находится между 0.25 и 0.75, то есть после преобразования эти

значения будут от 0.6875. При этом значение функции до 0.25 и после 0.75 меньше 0.6875. Значит, 0.6875 является медианной. То есть, A – 4 график.

Заметим, что при монотонном преобразовании (т.е. применении убывающей или возрастающей функции) медианное наблюдение останется медианным, т.к. оно все еще больше половины наблюдений. Медиана изначального наблюдения равна 0.5. Применим функции к 0.5 и получим:

A.
B. 0.5
C. 0.7
D. 0.25
E. 0.75

Значит, B – 5. D – 6.

Осталось распределить C и E. Заметим, что E – линейная функция. Значит, ее ящик с усами будет подобен изначальному ящику с усами, то есть примерно симметричный относительно медианы. Значит, E – 3. А оставшейся C соответствует второй график, так как медиана должна быть равна 0.7, а максимум – единице.

Получаем

A. 4
B. 5
C. 2
D. 6
E. 3

Критерии:

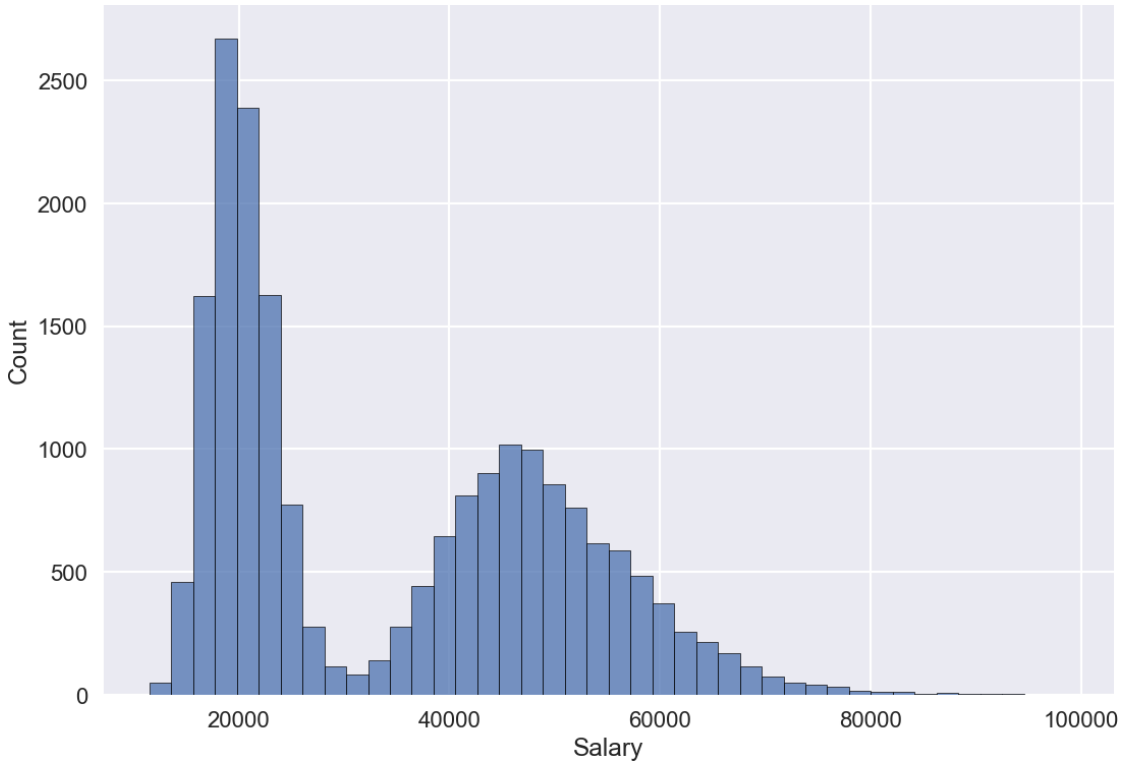
Max – **44 балла**

По 4 балла за каждое верное соответствие

8 баллов за верное объяснение соответствия A

По 4 балла за каждое верное объяснение соответствия B-E

(ii). Вы проводите исследование зарплат сотрудников некой компании. Для этого вы провели опрос, разослав всем электронное письмо. По результатам опроса вы построили распределение зарплат, которое можно увидеть ниже:



Также вы заполнили таблицу.

Средняя зарплата	34 839
Медианная зарплата	30 622
75-й персентиль	48 272
25-й персентиль	19 979
Максимальная зарплата	98 710

Но руководитель HR-департамента компании, у которого уже есть все данные о зарплатах, по секрету рассказал вам, что опрос прошли почти все сотрудники с зарплатой выше 33 тыс. рублей, но из остальных приняла участие только половина.

Оцените, какие из значений в вашей таблице завышены, а какие занижены, и почему.

Опишите, как истинное распределение зарплат будет отличаться от представленного выше.

Решение:

У нас отсутствует половина наблюдений с зарплатой ниже 33 тысяч рублей, для несмещенной оценки нам нужно их доопросить. Т.е. в выборку добавятся наблюдения до 33

тысяч рублей. Значит, средняя зарплата и 75% персентиль уменьшатся, так как они больше, чем добавляемые значения. Медианная зарплата может как измениться в любую сторону, так и не измениться, все зависит от медианного значения новых наблюдений. Если мы предположим, что вероятность ответа среди людей с низкой зарплатой не зависит от зарплаты (т.е. у всех равно 0.5), то медиана добавляемых значений будет в районе 20тыс и общая медиана уменьшится. Аналогичные рассуждения для 25% персентиля. Максимальная зарплата является оценкой снизу, так как самый высокооплачиваемый сотрудник мог не пройти опрос.

В истинном распределении зарплат часть левее 33 тысяч рублей будет выше. При равномерном распределении вероятности ответа среди людей с низкой зарплатой левый «колокольчик» будет в 2 раза выше.

Критерии:

Max – **36 баллов**

Средняя зарплата завышена – **4 балла** (**1 балл** при отсутствии обоснования)
75-й персентиль завышен – **4 балла** (**1 балл** при отсутствии обоснования)
Медиана – (неизвестно + обоснование) или (завышена + предположение о равномерном распределении вероятности ответа) – **8 баллов**. Если предположение использовано, но не обговорено отдельно – **4 балла**.
25-й персентиль – (неизвестно + обоснование) или (завышена + предположение о равномерном распределении вероятности ответа) – **8** баллов. Если предположение использовано, но не обговорено отдельно – **4** балла.
Максимум – **4** балла (**2 балла** при отсутствии обоснования)

За вторую часть максимум 8 баллов:
Если в решении использовано предположение, что вероятность ответа распределена равномерно, и обосновано удвоение левой части – **8** баллов
Если предположение не использовано и обосновано увеличение (нет части про удвоение или пропорциональный сдвиг) – **8** баллов
Если предположение использовано и обосновано увеличение (нет части про удвоение или пропорциональный сдвиг) – **4** балла
Если предположение не использовано и обосновано удвоение – **4** балла
Ответ без обоснования – **1** балл

DANO

Задачный тур третьего (заключительного) этапа 2022/23 уч.года.

Задача 2.

2. Строим регрессию (80 баллов)

Юный аналитик решил провести исследование об успеваемости своих одноклассников. Он предположил, что средний балл (переменная *grade*) зависит от пола ученика (переменная *is_male*, принимающая значение 1, если ученик мужского пола, и 0, если женского).

(i). В результате была получена следующая модель линейной регрессии:

$$grade = 4.16026667 - 0.18740000 * is_male$$

Заполните приведенную ниже таблицу, не забудьте объяснить, почему ваши расчеты верны. Если для заполнения некоторых ячеек вам необходима дополнительная информация, укажите это.

	Средний балл
Мальчики	?
Девочки	?
Все ученики	?

Считайте, что была использована классическая линейная регрессия — то есть минимизирующая сумму квадратов ошибок.

Решение:

Регрессия будет предсказывать 4.16026667 для всех девочек и 3.97286667 для всех мальчиков. Эти значения будут средними для соответствующих групп, так как сумма квадратов ошибок будет минимизирована при предсказании среднего. Для среднего балла всех учеников необходимо знать соотношение мальчиков и девочек

Критерии:

Max – **20 баллов**

Ответ – **8 баллов** если значения для девочек и для мальчиков верны. **0 баллов** если хотя бы один ответ неверен

Объяснение – **8 баллов**

Невозможность предсказания среднего – **4 балла**

(ii). Одноклассницы юного аналитика возмутились по поводу такой системы кодировки пола. Тогда он решил заменить переменную is_male на переменную is_female, принимающую значение 0, если студент мужского пола, и 1, если женского.

Какими будут коэффициенты новой регрессии и почему?

Решение:

Регрессия снова должна предсказывать 4.16026667 для всех девочек и 3.97286667 для всех мальчиков, чтобы минимизировать сумму квадратов. Это будет достигнуто, если $grade = 3.97286667 + 0.18740000 * is_female$

Критерии:

Max – **20 баллов**

Коэффициент при переменной будет другой по знаку, но такой же по модулю – **4 балла**

Свободный коэффициент – **8 баллов**

Объяснение обоих коэффициентов – **8 баллов**

(iii). Юный аналитик решил добавить в регрессию обе переменные. Будет ли полученная регрессия лучше объяснять оценки учеников и почему?

Решение:

Нет, не будет, так как никакой дополнительной информации новая переменная не даст, потому что одна переменная линейно зависит от другой.

Критерии:

Max – **8 баллов**

Объяснение + ответ – **8 баллов**

Ответ без объяснения – **1 балл**

(iv). Предположим, что аналитик вместо добавления переменной is_female решил удвоить изначальный набор наблюдений, просто дописав к каждому наблюдению ровно такое же. Как изменятся коэффициенты регрессии и ее качество? Обоснуйте свой ответ.

Решение:

Разделим выборку на две изначальные и построим две регрессии, которые будут одинаковыми. Мы знаем, что каждая регрессия будет минимизировать сумму квадратов ошибок в своей группе. Значит, общая сумма квадратов ошибок также будет минимизирована, если взять регрессию с теми же коэффициентами. При этом качество регрессии не изменится, так как доля объясненной дисперсии в итоговой выборке будет такая же, как в общей.

Критерии:

Max – **32 балла**

Объяснение + ответ для коэффициентов – **20 баллов** (**8 баллов**, если объяснение на пальцах - даны утверждения, из которых можно сделать объяснения)

Объяснение + ответ для качества регрессии – **12 баллов**

Только ответ для коэффициентов – **4 балла**

Только ответ для качества – **4 балла**

DANO

Задачный тур третьего (заключительного) этапа 2022/23 уч.года.

Задача 3.

Все баллы умножаем на 4

3. Ловим мошенников (20 баллов)

Вы аналитик заявок на кредит в одном из крупных банков. Ваша задача — построить модель, предсказывающую, данная заявка мошенническая или нет. Данная модель позволит проводить проверки не каждый раз, как сейчас, а только когда она будет предсказывать мошенников. Вы знаете, что в среднем только 2% заявок мошеннические. Для каждого пункта данной задачи вы можете использовать информацию из предыдущих пунктов, но не из последующих.

(i). Допустим, вы построили модель, точность которой (accuracy, доля верных предсказаний) равна 95%. Может ли такая модель быть хорошей с точки зрения применимости к процессам проверки? Может ли такая модель быть плохой с точки зрения применимости к процессам проверки?

Решение:

Давайте рассмотрим все наблюдения, в которых модель сделала неверное предсказание. Допустим, там только немошенники – это значит, что если мы будем использовать модель, то ни один мошенник не пройдет, а количество проверок уменьшится. То есть, модель хорошая, так как позволить проверять меньше заявок (лишь 5%) без потери качества (не выдавая кредиты мошенникам).

Рассмотрим противоположный случай – когда модель плохо предсказывает всех мошенников. Заметим, что у тривиальной «модели», которая считает все заявки не мошенническими, точность будет 98%. Тогда полученная модель будет хуже тривиальной и если ее применять, то все мошенники смогут получить кредит, а проводимые проверки будут бесполезны, так как проверяют только хороших заявителей.

Критерии:

Max – **32 балла**

Обоснование с примером для хорошей модели – **16 баллов**

Обоснование для плохой модели – **16 баллов**, если используется доля мошенников. Без использования – **0 или 8 баллов**

(ii). Ниже вы можете увидеть результаты предсказания модели на выборке заявок за прошедший месяц.

		Результат проверки	
		Мошенник	Не мошенник
Предсказание модели	Мошенник	77	374
	Не мошенник	127	9487

Посчитайте точность (accuracy, доля верных предсказаний) вашей модели. Посчитайте долю мошенников в выборке.

Решение:

Точность = (верно предсказанные)/(все заявки) = (77+9487)/(77+374+127+9487) = 0.9502

Доля мошенников = (мошенники)/(все заявки) = (77+127)/(77+374+127+9487) = 0.0203

Критерии:

Max – **4 балла**

По **2 балла** за ответ

(iii). Ваш коллега посчитал, что каждая проверка обходится нам в 100 ₽, а из-за одного мошенника мы теряем 500 ₽.

Сколько мы заработаем (сэкономим), если будем использовать модель?
Сколько мы заработаем (сэкономим), если вместо внедрения модели перестанем проводить проверки вообще?

Решение:

Предположим, что поток заявок за предыдущий месяц репрезентативен

Тогда при использовании модели мы будем проводить на 127+9487 проверок меньше, при этом пройдет 127 мошенников. Суммарный экономический эффект = (127+9487)*100 – 127*500 = 897900 рублей экономии в месяц

При прекращении проверок мы будем проводить на 77+374+127+9487 проверок меньше, при этом пройдет 77+127 мошенников. Суммарный экономический эффект = (77+374+127+9487)*100 - (77+127)*500 = 904500 рублей экономии в месяц

Критерии:

Max – **16 баллов**

Обосновано использование предыдущего месяца – **8 баллов**

Посчитано для модели – **4 балла**

Посчитано для отключения проверок – **4 балла**

(iv). Что будет, если действительно отключить все проверки начиная со следующего месяца? Значит ли это, что заработаем столько, сколько было посчитано в предыдущем пункте? Можем ли мы повлиять на поток заявок? Можем ли мы в итоге потерять деньги, а не заработать?

Решение:

Если отключить все проверки, то мошенники, которые подавали заявку на получение кредита и раньше отлавливались ручными проверками, теперь смогут получить кредит. Значит, все больше и чаще мошенники будут пользоваться данной лазейкой, доля мошенников в потоке вырастет, вычисления предыдущего пункта перестанут быть верными для новых месяцев, и мы в итоге можем потерять деньги от нововведения, если доля мошенников станет слишком большой.

Критерии:

Max – **28 баллов**

Описано влияние нашего решения на поток заявок с точки зрения мошенников – **16 баллов**

Сделан вывод об изменении потока – **4 балла**

Обоснована возможность потери денег и описаны причины столь резкого изменения потока заявок – **8 баллов**

DANO

ВЫСШАЯ ШКОЛА ЭКОНОМИКИ | ТИНЬКОФФ

БЛОК I — ПОСТАНОВКА ЗАДАЧИ (МАХ 9Б)

Критерий	0 баллов	1 балл	2 балла	3 балла	Вес
Предварительный анализ	Предварительного анализа нет или он некорректный	Исследованы основные показатели — средние значения + несколько статистик или распределения	Исследованы основные показатели - средние значения + несколько статистик или распределения И Обработаны выбросы	Исследованы основные показатели — средние значения + несколько статистик или распределения И Обработаны выбросы И Построены взаимосвязи и/ или корреляция переменных выборки	1
Гипотеза и исследовательский вопрос	Гипотеза НЕ соответствует поставленному вопросу ИЛИ Гипотезы нет ИЛИ Тривиальный вопрос	Есть исследовательский вопрос И/ИЛИ Есть гипотеза И Либо вопрос, либо гипотеза нетривиальны	Гипотеза И вопрос четко сформулированы, гипотеза соответствует поставленному вопросу И не является тривиальной	Не ставится	2
Механизм	Механизма нет	Механизм есть, но со значительными недочетами в логике	Механизм с незначительными недочетами в логике или без них	Не ставится	1

1 / 4

ВНИМАНИЕ:

1. Если за критерий «гипотеза и исследовательский вопрос» выставлена оценка 0, то за каждый критерий блоков II и III может быть выставлена оценка не более, чем 1
2. Если за критерий «гипотеза и исследовательский вопрос» выставлена оценка 1, то за каждый критерий блоков II и III может быть выставлена оценка не более, чем 2

БЛОК II — **АНАЛИТИЧЕСКИЙ БЛОК** (MAX 17Б)

Критерий	0 **баллов**	1 **балл**	2 **балла**	3 **балла**	**Вес**
Математическая модель исследования	Математические методы не представлены	Построена базовая математическая модель, НО НЕТ учёта размера выборки и вариативности	Построена базовая математическая модель И учтён размер выборки и вариативность, есть недочёты	Построена базовая математическая модель И учтён размер выборки и вариативность, недочёты незначительны, либо их нет	2
Структура данных	Исследования структуры данных нет	Исследование структуры данных присутствует, НО есть существенные недочёты	Исследование структуры данных присутствует, недочетов нет или они незначительны	Не ставится	1
Визуализация результата	В работе нет визуализации. Неподходящая визуализация	Визуализация есть, но по ней нельзя или трудно сделать выводы	Из графика можно сделать выводы, если всматриваться и разбираться	Из графиков легко делаются выводы	1
Интерпретация	Интерпретация не представлена	Проинтерпретированы результаты модели, выводы тривиальны	Интерпретация модели содержательна НО есть существенные недочёты	Интерпретация модели содержательна, недочетов нет или они незначительны	2

БЛОК III — ПРЕЗЕНТАЦИЯ (MAX 12Б)

Критерий	**0 баллов**	**1 балл**	**2 балла**	**3 балла**	**Вес**
Командная работа	Командная работа не видна (каждый участник знает только свою часть)	Командная работа видна, НО участники только частично разбираются в решении	Командная работа видна, участники хорошо разбираются во всём решении	Не ставится	2
Логика презентации	Презентация сделана с грубыми логическими нарушениями, слушатель теряется в повествовании.	Большая часть презентации логически выстроена, но есть недостатки в логике повествования	Логичное повествование; возможны небольшие недостатки	Не ставится	1
Выводы	В работе НЕ описаны перспективы/ограничения И практическая польза исследования	Перспективы/ограничения описаны, но со значительными недостатками И/ИЛИ практическая польза описана, но со значительными недостатками	Перспективы/ограничения описаны с незначительными недостатками или без них И практическая польза описана с незначительными недостатками или без них	Перспективы/ограничения описаны с незначительными недостатками или без них И практическая польза описана с незначительными недостатками или без них И описан policy implication с незначительными недостатками или без них	2

ПРОЦЕДУРА ПОДСЧЕТА ИТОГОВОГО БАЛЛА ЗА ПРОЕКТНЫЙ ТУР:

1. Каждый эксперт из комиссии выставляет команде баллы по всем критериям.
2. По каждому критерию рассчитывается медианный балл.

   Например, если эксперт 1 поставил команде за критерий «Интерпретация» 3 балла, эксперт 2—3 балла, эксперт 3—2 балла, то медианный балл по этому критерию равен 3. Именно этот балл используется для расчета итогового балла команды по критерию «Интерпретация».
3. Медианные баллы по критериям подставляются в формулы:

   Постановка задачи = Предварительный анализ + 2*Гипотеза и исследовательский вопрос + Механизм

   Аналитический блок = 2*Математическая модель исследования + Структура данных + Визуализация результата + 2*Интерпретация

Презентация = 2*Командная работа + Логика презентации + 2*Выводы

4. ИТОГ ЗА ПРОЕКТНЫЙ ТУР = (Постановка задачи + Аналитический блок + Презентация)/38 * 100

Примечание: все участники команды получают равные баллы за проектный тур.

Национальная олимпиада по анализу данных DANO. 1 этап (вариант 1)

В заданиях с 1 по 9 необходимо выбрать 1 правильный вариант ответа. Каждое задание оценивается в 2 балла.

1. В стране A проживает N > 1 человек. Каждый из N–1 жителей зарабатывает 20 тыс д.е. в месяц, а один человек— 200 тыс д.е. Чему должно быть равно N, чтобы медианный ежемесячный доход в стране был равен среднему?
   1) 80
   2) 800
   3) 120
   4) 1200
   5) Нет верного ответа

2. Работники 1-го цеха завода считают, что работа в их цеху ухудшает здоровье. Они заметили, что среди 30 заболевших пылевым бронхитом 20 было из 1-го цеха. Руководитель завода решил рассмотреть жалобы работников 1-го цеха и посмотрел на всю статистику по заводу. Какой вывод о влиянии работы в цеху 1 на здоровье можно сделать на основе данных, если известно, что распределение людей в цех случайно?

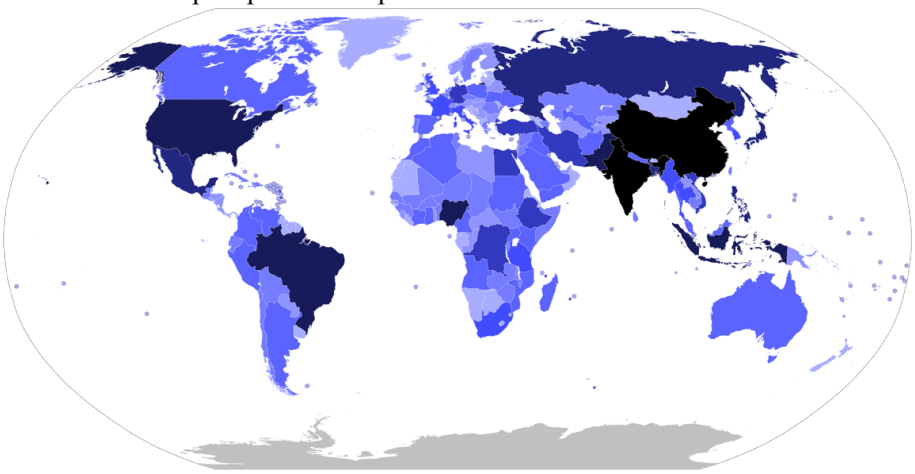
	Заболели	Не заболели
Работали в цеху 1	20	400
Не работали в цеху 1	10	200

   1) Работа в цеху 1 увеличивает вероятность заболеть пылевым бронхитом
   2) Работа в цеху 1 снижает вероятность заболеть пылевым бронхитом
   3) Работа в цеху 1 не влияет на вероятность заболеть пылевым бронхитом
   4) Доля заболевших среди работников в цеху 1 больше, чем в цеху 2.

3. В среднем успеваемость (или средний балл) студентов НИУ ВШЭ повысилась с переходом на дистанционный формат обучения. Какой вывод об успеваемости из этого следует?
   1) Успеваемость всех студентов повысилась
   2) Повысилась успеваемость большинства студентов
   3) Повысилась успеваемость меньшинства студентов
   4) Никакой из указанных в других вариантах выводов сделать нельзя

4. Кира живет в большой семье: в ней есть 3 человека младше Киры и 7 — старше. Кира заметила, что за 5 лет средний возраст младших 3 членов семьи вырос на X%, а старших 7 — на Y%. За 5 лет состав семьи не менялся. Как соотносятся X и Y?
   1) X больше Y
   2) X меньше Y
   3) X в точности равняется Y
   4) Нет верных утверждений среди других вариантов

5. Перед вами карта мира, на которой цветом показан определенный показатель. Чем темнее цвет, тем выше уровень данного показателя; чем светлее — тем ниже уровень данного показателя. Например, в Нигерии и Индонезии этот показатель высокий, а в Мавритании и Парагвае — низкий. По какому показателю раскрашены страны?



1) Доля блондинов среди населения
2) Численность населения
3) Экспорт электроники
4) Площадь полей, засеянных гречихой

6. Губернатор хочет провести опрос о негативных последствиях выгула собак в общественных местах в Свердловской области. Какая из выборок будет наиболее репрезентативной (при одинаковом количестве респондетов)?
   1) Случайные посетители зоомагазинов
   2) Все жители случайно отобранных домов в области
   3) Случайно выбранные спортсмены, бегающие в парках, где выгуливают собак
   4) Взрослые от 18 до 45 лет, опрошенные около станций метро с наибольшим трафиком

7. На графике ниже отображены реальные (как и все остальные показатели, в ценах 2019 года) военные расходы США, Китая и России за 1991–2020 годы, также указаны доли военных расходов от ВВП стран в 2020 году.



Выберите верное утверждение, следующее из графика:

1) Максимальная величина военных расходов России наблюдалась в 2010 году
2) В 2020 году ВВП Китая был больше ВВП России.
3) На протяжении всего рассматриваемого периода Россия тратила на военные расходы больше, чем Китай
4) В 2010 ВВП США был больше 20 триллионов долларов
5) Нет верного ответа среди других вариантов

8. Ученик Арсений переходит в 10 класс и выбирает новую школу. Он нашел интервью учителя и ученика об одной школе. В интервью учитель утверждает, что сейчас в среднем в 10-х классах по 15 человек в классе. Ученик же, зная, что вероятность оказаться в определенном классе пропорциональна количеству учеников в нем, утверждает, что математическое ожидание количества одноклассников у поступающего будет 20. Такая ситуация

1) Невозможна в любом случае
2) Возможна, если есть 4 класса с 10, 10, 10 и 30 учениками соответственно
3) Возможна, если есть 2 класса с 15 и 20 учениками соответственно
4) Возможна, если есть 3 класса с 10, 15 и 20 учениками соответственно

9. В городе М от станции А до станции Б целый день с разными интервалами ходят трамваи, других остановок в городе нет. Исследователь Вася решил измерить средний интервал между трамваями интересным способом: он целый день стоял у остановки Б и опрашивал случайные 20% пассажиров (для простоты считайте, что количество пассажиров в трамвае всегда кратно 5),

выходящих из каждого прибывшего трамвая, о том, сколько они ждали свой трамвай. Затем он посчитал среднее по всем полученным данным и умножил на 2. Будем считать, что пассажиры приходят равномерно по 1 человеку за 10 секунд, поэтому количество пассажиров в трамвае прямо пропорционально времени ожидания. Каким получился результат Васи по отношению к реальному среднему интервалу между двумя трамваями?

1) Результат Васи равен реальному среднему
2) Результат Васи завышен по отношению к реальному среднему
3) Результат Васи занижен по отношению к реальному среднему
4) Результат Васи может быть как завышен, так и занижен

В заданиях с 10 по 22 необходимо выбрать один или несколько правильных вариантов ответа. Каждое задание оценивается в 5 баллов.

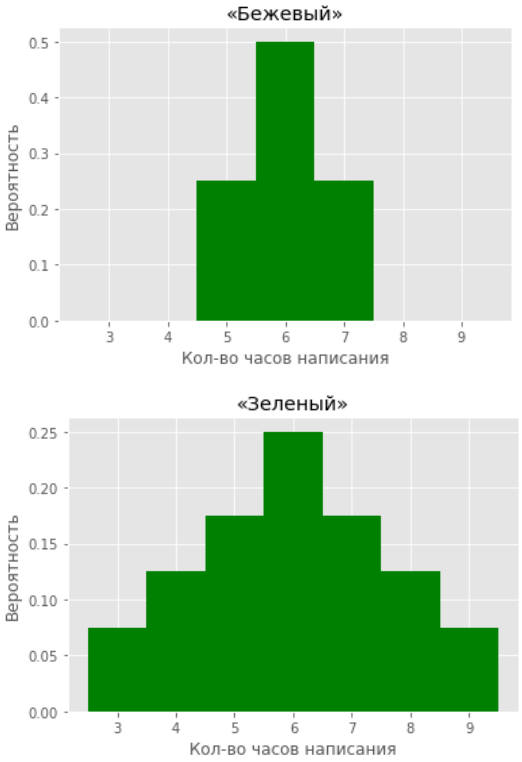
10. Выберите все верные утверждения:
    1) Медиана выборки не может быть выше среднего значения этой выборки.
    2) У выборки может быть несколько медиан.
    3) У выборки может быть несколько мод.
    4) Для выборок работает правило «невозможной тройки», из которого следует, что мода, медиана и среднее значение выборки не могут быть одновременно равны друг другу.
    5) Если в выборку {5; 1; 4; 3; 0; 1} добавить число 2, то медиана выборки не изменится

11. В таблице представлено количество учеников, посмотревших лекции по анализу данных по каждой теме, и количество учеников, решивших задачи из листочков. Решать листочки можно только после просмотра лекций. Какие выводы не противоречат данным в таблице?

ТЕМЫ	Видео	Листочки
Исследовательский вопрос	388	178
Анкетирование	236	156
Статистика	218	81
Визуализация	130	83

1) Чем больше учеников, смотревших видео по темам, тем больше учеников, решавших листочки с задачами по ним
2) Видео посмотрело больше учеников, чем решило листочки
3) Между количеством посмотревших видео и количеством решавших листки наблюдается положительная взаимосвязь (корреляция)
4) Нет верного ответа среди остальных вариантов

12. На графиках представлено распределение количества часов написания одной статьи в журналах «Бежевый» и «Зеленый» соответственно



Выберите все верные утверждения про эти распределения

1) Среднее время написания одной статьи в этих журналах
2) Медианное время в «Зеленый» больше, чем в «Бежевый»
3) Дисперсия времени написания статьи в «Зеленый» меньше, чем в «Бежевый»
4) Дисперсии времени написания статьи в обоих журналах совпадают
5) Если статья должна быть написана не более чем через 7 часов, то в «Зеленый» сделают это с меньшей вероятностью.

13. Коля скрывает от мамы свою оценку за недавно написанный тест. Мама Коли знает, что среднее за прошлые три теста равно 3, при этом мода этих оценок была равна 2. Коля подсказал маме, что при добавлении новой оценки в выборку оценок Коли за тест медиана выборки не изменится. Какую оценку мог получить Коля за тест (оценкой может быть лишь натуральное число, не превосходящее пять)?
    1) 1
    2) 2
    3) 3
    4) 4
    5) 5

14. Университет ЭШВ практикует программу обмена с иностранными учебными заведениями. За рубеж ЭШВ отправляет лишь своих самых сильных студентов (с самым высоким уровнем образования среди всех). Но иностранные вузы,

наоборот, отправляют студентов с самым низким уровнем образования. Предположим, осуществился обмен студента ЭШВ на студента из зарубежного университета. Как в таком случае могли поменяться средние уровни образования в ЭШВ и иностранном вузе, соответственно?

1) Увеличиться, увеличиться
2) Уменьшиться, уменьшиться
3) Увеличиться, уменьшиться
4) Уменьшиться, увеличиться
5) Не измениться, не измениться

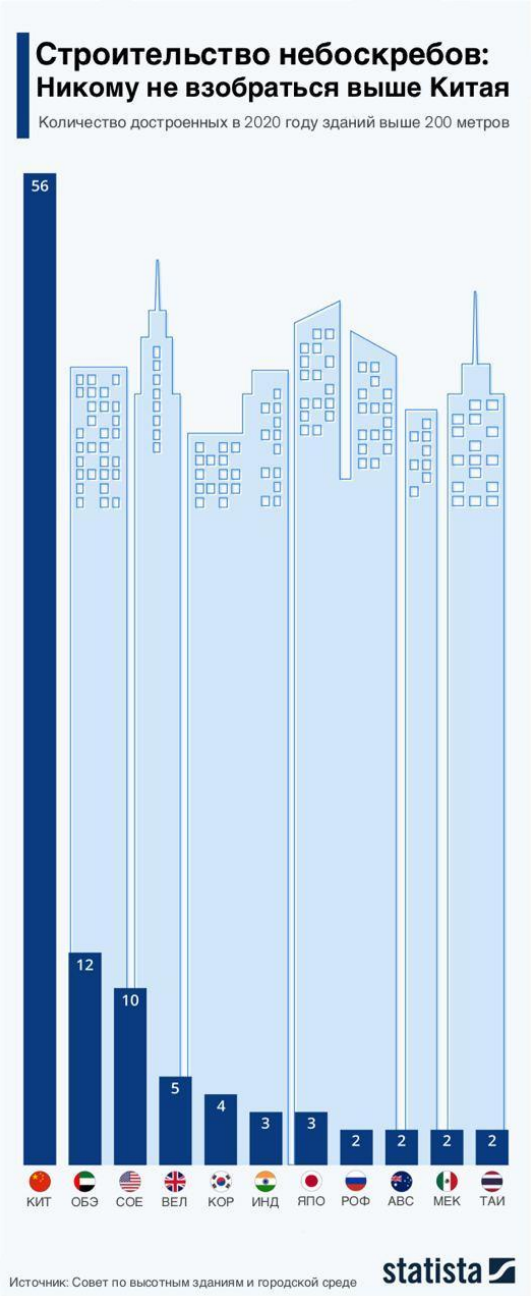
15. Перед Вами диаграмма, показывающая долю жителей, имеющих антитела к коронавирусу, для четырёх частей Соединенного королевства по состоянию на 17.05.2021.



Выберите все верные утверждения, о которых можно сделать вывод из графика:

1) Больше всего людей с антителами в Соединенном королевстве проживает в Уэльсе
2) Около 79% жителей Соединенного королевства имеют антитела
3) В среднем на каждые 200 человек в Северной Ирландии приходится на 14–15 жителей с антителами больше, чем в Шотландии
4) Доля населения с антителами в Соединенном королевстве больше 72,6% и меньше 82,7%
5) Нет верных утверждений среди других вариантов

16. Перед Вами диаграмма, отображающая количество зданий высотой более 200 метров (небоскребов), построенных в 2020 году в различных странах мира. Ира знает приведенную в задаче статистику по странам, а Катя и Маша знают только среднее и медианное значения. Ира предложила девушкам игру: она называет каждую из 11 приведенных стран, а Маша и Катя угадывают, сколько там небоскребов. Та, кто назовет число более близкое к настоящему, получает 1 балл. Маша решила всегда называть медиану, а Катя — среднее, округленное до целого числа по правилам арифметики.

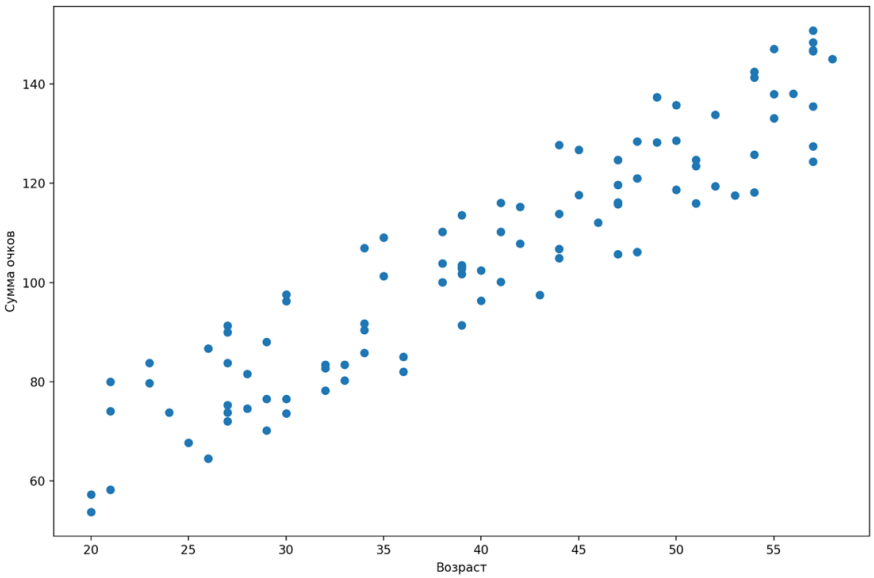


Выберите все верные утверждения, следующие из графика:

1) В такой игре Маша наберет больше баллов, чем Катя.

2) Из всех представленных в выборке стран самое высокое построенное здание находится в Китае
3) Всего в мире есть 101 здание выше 200 м
4) Если бы в России в 2020 году построили 8 небоскребов, то число построенных небоскребов в Китае было бы меньше суммарного количества построенных небоскребов во всех других странах, представленных в выборке
5) Медианное количество построенных в 2020 году небоскребов в странах в выборке равно 3

17. Исследователь Данил любит играть в боулинг. Но больше, чем играть в боулинг, Данил любит собирать статистику, поэтому в один день он собрал статистику, как другие играют в боулинг. Данил нарисовал диаграмму рассеяния в координатах (возраст, сумма очков), где каждая точка — показатели одного человека в этот день.



Выберите все верные утверждения

1) Между суммой набранных баллов и возрастом есть положительная взаимосвязь.
2) Количество набранных баллов можно однозначно угадать, зная возраст
3) Возраст человека можно однозначно угадать, зная количество набранных баллов
4) Нет верных утверждений среди остальных вариантов

18. Спортсмен Виталий очень любит йогу. Он решил измерить влияние своих тренировок по йоге на скорость бега. Для этого Виталий семь дней подряд после каждой тренировки измерял время, за которое он пробегал 100 м. Оказалось, что с каждым днём оно сокращалось. От радости Виталий забыл о своём эксперименте и вспомнил о нем лишь через месяц. Он снова провёл забеги на 100 м после каждой из семи тренировок по йоге, которые

проводились в разные дни. Снова выяснилось, что с каждым днём время преодоления 100 м Виталием уменьшалось. Выберите все верные утверждения:

1) Время преодоления Виталием 100 м в самом последнем забеге больше времени самого первого забега
2) Время преодоления Виталием 100 м в самом последнем забеге меньше времени самого первого забега
3) Время преодоления Виталием 100 м в самом последнем забеге может быть как больше, так и меньше времени самого первого забега
4) Если Виталий продолжит заниматься йогой, то время, за которое он пробежит 100 м, уменьшится
5) Нет верного ответа среди остальных вариантов

19. Из всех обращений взрослых людей к врачу-терапевту города Атлетус 90% составляют жалобы на суставы после бега. Выберите выводы, которые **НЕ** следуют из этого факта.
    1) Жители города Атлетус, которые старше 18 лет, более склонны к травмам из-за бега, чем подростки
    2) Бегунам города Атлетус нужно составлять равномерный план тренировок на начальных этапах, чтобы избежать резких напряжений и травм впоследствии
    3) Неправильный подбор обуви может приводить к проблемам со здоровьем при беге
    4) Большинство жителей города Атлетус испытывает неприятные ощущения после бега
    5) По причине того, что в городе Атлетус бег является травмоопасным для более, чем 50% бегунов, стоит проводить просветительские кампании о безопасном подходе к тренировкам

20. Перед вами четыре обнаруженные корреляции между парами признаков. Выберите все случаи, когда корреляция, скорее всего, возникает из-за прямой причинно-следственной связи между признаками:
    1) Чем больше пожарных приехало на вызов, тем больше пострадавших от пожара
    2) Чем больше количество рабочих дней в месяце, тем больше прибыль общественного транспорта
    3) Чем больше аистов гнездится в деревне, тем больше в деревне будет детей
    4) Чем больше электроэнергии выработано атомными электростанциями, тем больше смертей от утопления в бассейнах

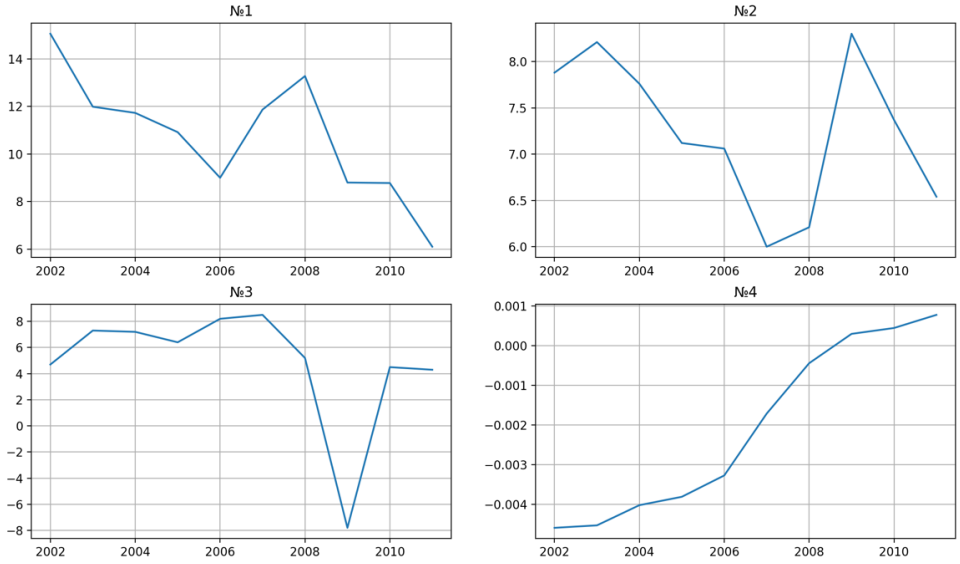
21. В одном из начальных классов городской школы в Конго дети, которые воспитываются мусульманских семьях, учатся в среднем лучше тех, кто воспитывается в христианских. На какие генеральные совокупности можно распространить этот вывод?
    1) Городская школа в Конго
    2) Конго
    3) Африка
    4) Весь мир

5) Ни на какую из них

22. Студенты проводят исследование, пытаясь ответить на вопрос: «Как прием пищи во время просмотра онлайн лекций влияет на успеваемость?» Какие из механизмов могут описывать гипотезу, выдвигаемую в качестве ответа на него?
    1) При приеме пищи увеличивается приток энергии за счет поступления микроэлементов, что позволяет концентрироваться лучше и улучшает успеваемость
    2) Во время приема пищи теряется концентрация, что приводит к потере внимания, плохому запоминанию материала и уменьшает успеваемость
    3) Прием пищи никак не влияет на умственную концентрацию, поэтому успеваемость от этого не меняется
    4) Просмотр дополнительных лекций во время приема пиши повышает успеваемость
    5) Нет верного ответа среди других вариантов

Открытые вопросы. Каждое задание оценивается в 5 баллов.

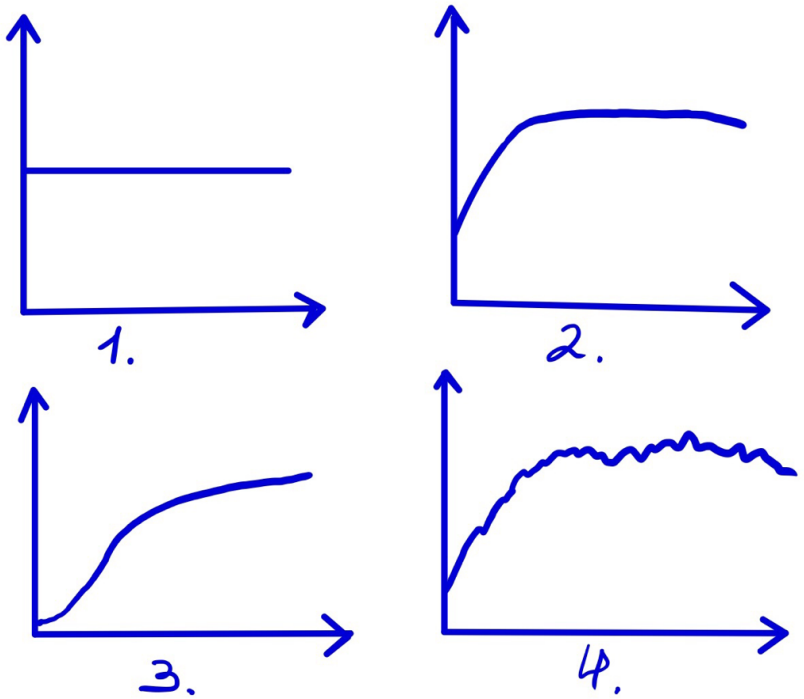
23. Перед Вами четыре графика, отражающих уровень безработицы (А), а также годовые темпы прироста ВВП (Б), населения (В) и уровня цен (Г) в России за 2002–2011 года (все показатели измерялись в %). Соотнесите показатели с соответствующими графиками их динамики и выпишите верный порядок букв, обозначающих показатели (пример ответа: АБВГ; такой ответ означает, что графику 1 ставится в соответствие показатель А, графику 2 — показатель Б и



т.д.).

Ответ: ГАБВ

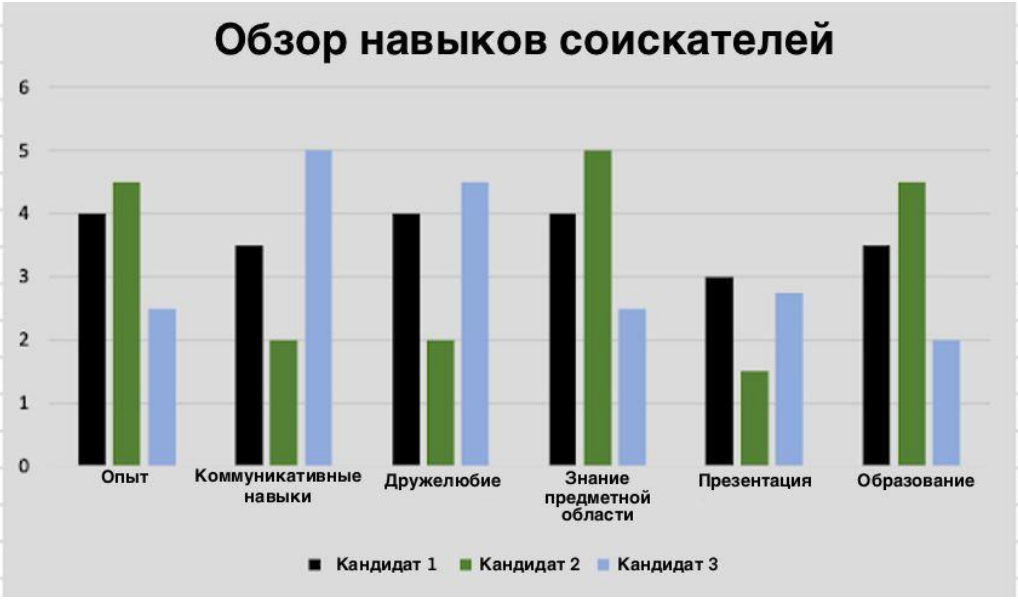
24. Исследователь Вася провёл четыре исследования о зависимости различных показателей от возраста, на основе которых от руки нарисовал графики найденных им функций для одного человека. Но забыл подписать графики и



теперь не знает, какой рисунок относится к какому исследованию. Взгляните на графики, а затем соотнесите исследования с номерами соответствующих визуализаций. Названия исследований представлены в виде пары «возраст — признак зависимый», на графиках возраст всегда отображаются по оси абсцисс.

- «Возраст — рост»: 2
- «Возраст — уровень образования»: 3
- «Возраст — размер глаза»: 1
- «Возраст — вес»: 4

25. Работодатель занимается подбором кандидатов на вакансию, где коммуникативные навыки в два раза важнее, чем каждая из характеристик: опыт, дружелюбие и знание предметной области. Остальные навыки для вакансии не важны. У работодателя есть 3 кандидата, чьи способности отражены на графиках ниже. Работодатель ранжирует кандидатов, используя сумму всех баллов с учетом важности каждой характеристики, от большей суммы к меньшей. Приведите в ответе это ранжирование кандидатов (сначала самый привлекательный кандидат).


Обзор навыков соискателей
6
5
4
3
2
1
0
Опыт
Коммуникативные навыки
Дружелюбие
Знание предметной области
Презентация
Образование
Кандидат 1
Кандидат 2
Кандидат 3

312

Национальная олимпиада по анализу данных DANO. 1 этап (вариант 2)

В заданиях с 1 по 9 необходимо выбрать 1 правильный вариант ответа. Каждое задание оценивается в 2 балла.

1. В стране A проживает N > 1 человек. Каждый из N–1 жителей зарабатывает 50 тыс д.е. в месяц, а один человек— 250 тыс д.е. Чему должно быть равно N, чтобы медианный ежемесячный доход в стране был равен среднему?
   1) 150
   2) 1500
   3) 200
   4) 2000
   5) Нет верного ответа

2. Машинисты Красной ветки метро города H считают, что работа на этой ветке ухудшает здоровье. Они заметили, что среди 50 заболевших вибрационной болезнью 40 работали на Красной ветке. Руководитель метро решил рассмотреть жалобы работников Красной ветки и посмотрел на всю статистику по метро города H. Какой вывод о влиянии работы на красной ветке на здоровье можно сделать на основе данных, если известно, что распределение людей на определенную ветку случайно?

	Заболели	Не заболели
Красная ветка	40	400
Синяя ветка	10	100

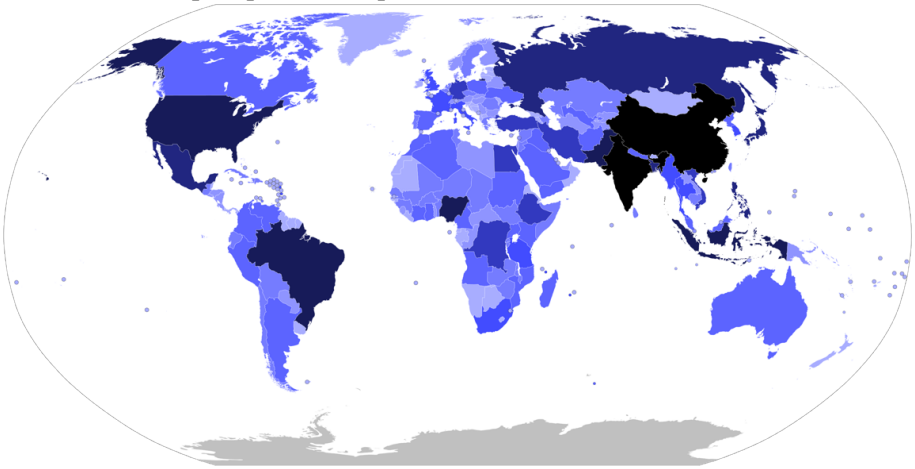
   1) Работа на Красной ветке увеличивает вероятность заболеть вибрационной болезнью
   2) Работа на Красной ветке снижает вероятность заболеть вибрационной болезнью
   3) Работа на Красной ветке не влияет на вероятность заболеть вибрационной болезнью
   4) Доля заболевших среди машинистов на Красной ветке больше, чем среди машинистов на Синей ветке

3. В городе M. среднее время прогулок в парках во время самоизоляции увеличилось. Какой вывод о времени прогулок в парках из этого следует?
   1) Все люди города M. стали больше гулять
   2) Большинство людей стали предпочитать гулять в парках, а не по улицам
   3) Большинство людей стали больше гулять
   4) Никакой из указанных в других вариантах выводов сделать нельзя

4. У Андрея 20 коллег: 11 человек старше Андрея как минимум на 1 год и 9 — младше как минимум на 2 года. Андрей заметил, что за 3 года средний возраст младших 9 коллег вырос на X%, а 11 старших — на Y%. Коллектив за 3 года не изменялся. Как соотносятся X и Y?
   1) X больше Y

2) X меньше Y
3) X в точности равняется Y
4) Нет верных утверждений среди других вариантов

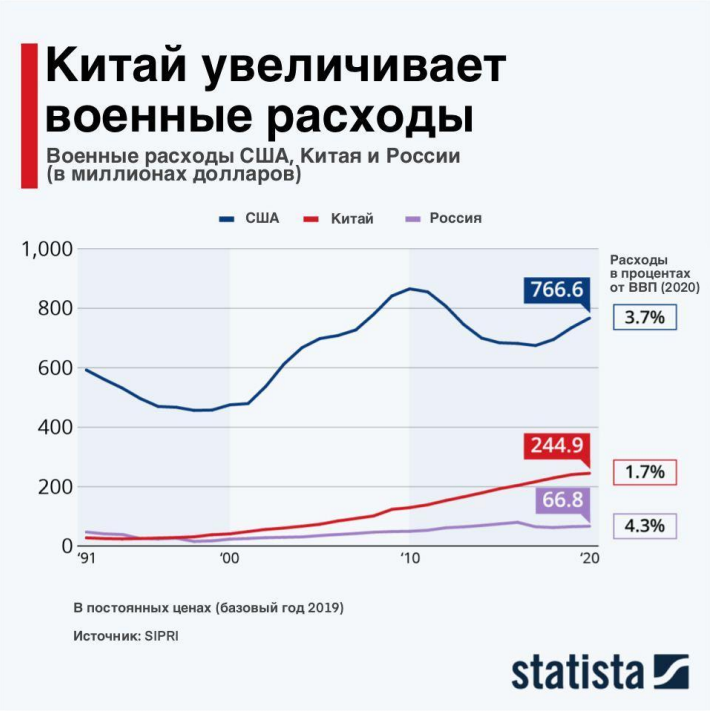
5. Перед вами карта мира, на которой цветом показан определенный показатель. Чем темнее цвет, тем выше уровень данного показателя; чем светлее — тем ниже уровень данного показателя. Например, в Нигерии и Индонезии этот показатель высокий, а в Мавритании и Парагвае — низкий. По какому показателю раскрашены страны?



1) Средний рост взрослого населения (от 18 лет)
2) Численность населения
3) ВВП на душу населения
4) Объем добываемого золота в год

6. Мэр одного крупного города хочет провести опрос о последствиях пробок и выхлопных газов в городе. Какая из выборок будет наиболее репрезентативной (при одинаковом количестве респондентов)?
   1) Случайные посетители главной площади города
   2) Все жители случайно отобранных домов в городе
   3) Случайно выбранные выходящие из метро
   4) Случайно выбранные люди на парковке у крупного торгового центра

7. На графике ниже отображены реальные (как и все остальные показатели, в ценах 2019 года) военные расходы США, Китая и России за 1991–2020 годы, также указаны доли военных расходов от ВВП стран в 2020 году.



Выберите верное утверждение, следующее из графика:

1) Максимальная величина военных расходов Китая наблюдалась в 2010 году
2) В 2020 году ВВП США был больше ВВП Китая.
3) На протяжении всего рассматриваемого периода Китай тратил на военные расходы больше, чем Россия
4) В 2010 ВВП России был больше 20 триллионов долларов
5) Нет верного ответа среди других вариантов

8. Ученик Арсений переходит в 10 класс и выбирает новую школу. Он нашел интервью учителя и ученика об одной школе. В интервью учитель утверждает, что сейчас в среднем в 10-х классах по 18 человек в классе. Ученик же, зная, что вероятность оказаться в определенном классе пропорциональна количеству учеников в нем, утверждает, что математическое ожидание количества одноклассников у поступающего будет 22. Такая ситуация

1) Невозможна в любом случае
2) Возможна, если есть 4 класса с 10, 12, 20 и 30 учениками соответственно
3) Возможна, если есть 2 класса с 15 и 21 учениками соответственно
4) Возможна, если есть 3 класса с 6, 24 и 24 учениками соответственно

9. В городе М от станции А до станции Б целый день с разными интервалами ходят трамваи, других остановок в городе нет. Исследователь Вася решил измерить средний интервал между трамваями интересным способом: он целый день стоял у остановки Б и опрашивал случайную треть пассажиров (для

простоты считайте, что количество пассажиров в трамвае всегда кратно 3), выходящих из каждого прибывшего трамвая, о том, сколько они ждали свой трамвай. Затем он посчитал среднее по всем полученным данным и умножил на 2. Будем считать, что пассажиры приходят равномерно по 1 человеку за 5 секунд, поэтому количество пассажиров в трамвае прямо пропорционально времени ожидания. Каким получился результат Васи по отношению к реальному среднему интервалу между двумя трамваями?

1) Результат Васи равен реальному среднему
2) Результат Васи завышен по отношению к реальному среднему
3) Результат Васи занижен по отношению к реальному среднему
4) Результат Васи может быть как завышен, так и занижен

В заданиях с 10 по 22 необходимо выбрать один или несколько правильных вариантов ответа. Каждое задание оценивается в 5 баллов.

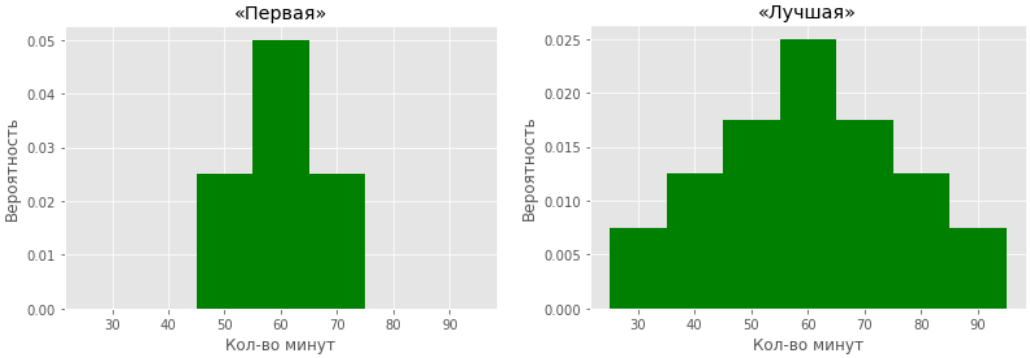
10. Выберите все верные утверждения:
    1) Медиана выборки не может быть меньше среднего значения этой выборки.
    2) У выборки может быть несколько средних значений.
    3) У выборки может быть только одна медиана.
    4) Для выборок работает правило «невозможной тройки», из которого следует, что мода, медиана и среднее значение выборки не могут быть одновременно равны друг другу.
    5) Если в выборку {6; 18; 4; 20; 0; –1} добавить число 5, то медиана выборки не изменится

11. В таблице представлено количество учеников, посмотревших лекции по анализу данных по каждой теме, и количество учеников, решивших задачи из листочков. Решать листочки можно только после просмотра лекций. Какие выводы не противоречат данным в таблице?

ТЕМЫ	Видео	Листочки
Исследовательский вопрос	388	178
Анкетирование	236	156
Статистика	218	81
Визуализация	130	83

    1) По каждой теме листки решают от 37% до 67% от смотрящих видео по соответствующей теме
    2) По теме «Анкетирование» доля учеников, решавших листочки после просмотра видео по этой теме, выше, чем аналогичная доля по теме «Визуализация»
    3) Между количеством посмотревших видео и количеством решавших листки наблюдается отрицательная взаимосвязь (корреляция)
    4) Нет верного ответа среди остальных вариантов

12. На графиках представлено распределение количества минут, за которые спортсменки из спортивных школ «Первая» и «Лучшая» пробегают полумарафон.



Выберите все верные утверждения про эти распределения

1) В среднем спортсменки из «Первой» спортивной школы пробегают марафон быстрее, чем из «Лучшей»
2) Дисперсия скорости в спортивной школе «Первая» меньше, чем в «Лучшей»
3) Если норматив на звание Кандидат в мастера спорта составляет 1 час 21 минута, то в «Первой» спортивной школе все спортсменки имеют как минимум этот разряд, а в «Лучшей» — нет
4) Медианное время в «Лучшей» больше, чем в «Первой»
5) Если соревнуются спортсмены из обеих школ, то первое место гарантированно займет спортсменка из «Лучшей» школы

13. Коля скрывает от мамы свою оценку за недавно написанный тест. Оценка может составлять любое целое число от 1 до 100. Мама Коли знает, что среднее за прошлые три теста равно 50, при этом мода этих оценок была равна 30. Коля подсказал маме, что при добавлении новой оценки в выборку оценок Коли за тест медиана выборки не изменится. Какую оценку из предложенных мог получить Коля за тест?

    1) 12
    2) 48
    3) 29
    4) 94
    5) 50

14. Университет ЭШВ практикует программу обмена с иностранными учебными заведениями. За рубеж ЭШВ отправляет лишь своих самых сильных студентов (с самым высоким уровнем образования среди всех). Но иностранные вузы, наоборот, отправляют студентов с самым низким уровнем образования. Предположим, осуществился обмен студента ЭШВ на студента из зарубежного университета. Как в таком случае могли поменяться средние уровни образования в ЭШВ и иностранном вузе, соответственно?

    1) Увеличиться, увеличиться
    2) Уменьшиться, уменьшиться
    3) Увеличиться, уменьшиться
    4) Уменьшиться, увеличиться
    5) Не измениться, не измениться

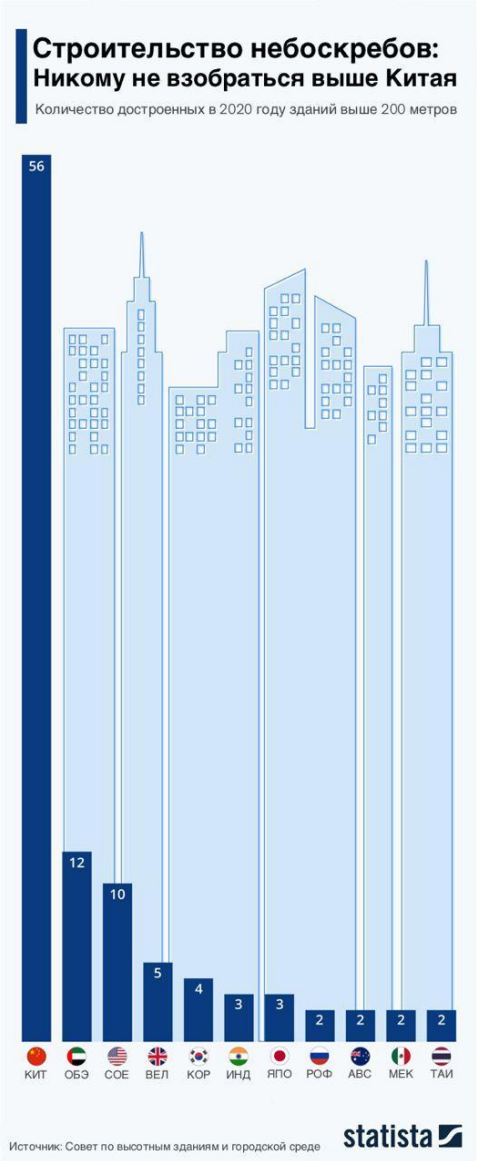
15. Перед Вами диаграмма, показывающая долю жителей, имеющих антитела к коронавирусу, для четырёх частей Соединенного королевства по состоянию на 17.05.2021.



Выберите все верные утверждения, о которых можно сделать вывод из графика:

1) Меньше всего людей с антителами в Шотландии проживает в Уэльсе
2) Около 76% жителей Соединенного королевства имеют антитела
3) В среднем на каждые 300 человек в Уэльсе приходится на 8–9 жителей с антителами больше, чем в Северной Ирландии
4) Доля населения с антителами в Соединенном королевстве может составлять 82,7% и больше
5) Нет верных утверждений среди других вариантов

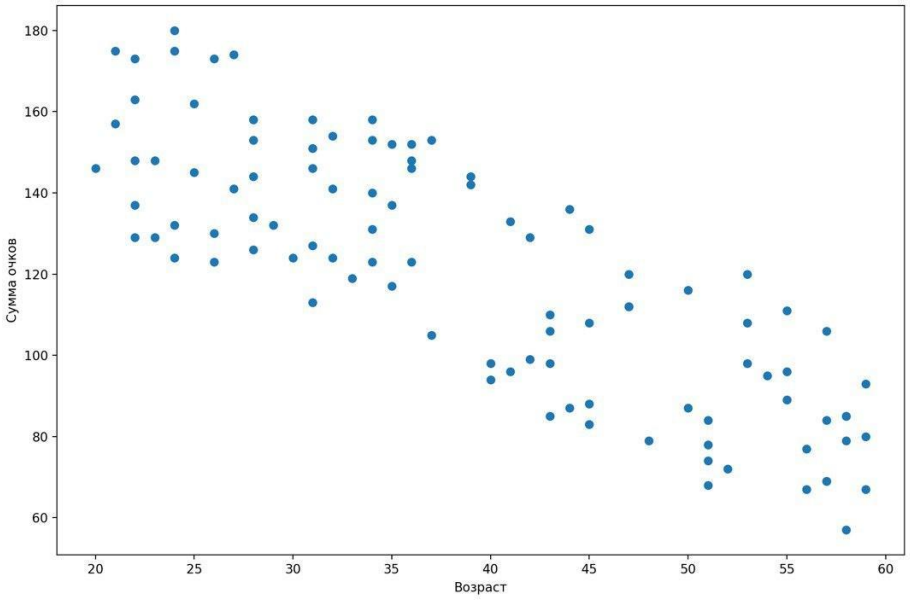
16. Перед Вами диаграмма, отображающая количество зданий высотой более 200 метров (небоскребов), построенных в 2020 году в различных странах мира. Ира знает приведенную в задаче статистику по странам, а Катя и Маша знают только среднее и медианное значения. Ира предложила девушкам игру: она называет каждую из 11 приведенных стран, а Маша и Катя угадывают, сколько там небоскребов. Та, кто назовет число более близкое к настоящему, получает 1 балл. Маша решила всегда называть медиану, а Катя — среднее, округленное до целого числа по правилам арифметики.



Выберите все верные утверждения, следующие из графика:

1) В такой игре Маша наберет больше баллов, чем Катя.
2) Из всех представленных в выборке стран самое низкое построенное здание находится в Тайланде
3) Всего в Китае и ОАЭ есть 68 зданий выше 200 м
4) Если бы в Японии в 2020 году построили 15 небоскребов, то число построенных небоскребов в Китае было бы меньше суммарного количества построенных небоскребов во всех других странах, представленных в выборке
5) Мода построенных в 2020 году небоскребов в странах в выборке равна 2

17. Исследователь Данил любит играть в боулинг. Но больше, чем играть в боулинг, Данил любит собирать статистику, поэтому в один день он собрал статистику, как другие играют в боулинг. Данил нарисовал диаграмму рассеяния в координатах (возраст, сумма очков), где каждая точка — показатели одного человека в этот день.



Выберите все верные утверждения

1) Между суммой набранных баллов и возрастом есть отрицательная взаимосвязь.
2) Количество набранных баллов можно однозначно угадать, зная возраст
3) Возраст человека можно однозначно угадать, зная количество набранных баллов
4) Нет верных утверждений среди остальных вариантов

18. Отличница Карина очень любит математику. Она решила измерить влияние подготовки к ЕГЭ по математике на результаты тестовой части ЕГЭ по русскому языку. Для этого Карина 2 недели подряд после 2 часов подготовки к ЕГЭ по математике решала тестовую часть ЕГЭ по русскому языку. Оказалось, что с каждым днем Карина допускала все меньше ошибок в ЕГЭ по русскому языку. Получив такие результаты, Карина решила готовиться только к ЕГЭ по математике, а результаты по русскому языку улучшатся сами собой. Через месяц Карина снова решила повторить свое исследование и еще 2 недели каждый день после математики решала ЕГЭ по русскому языку. Снова выяснилось, что результаты с каждым днем улучшались. Выберите все верные утверждения:

1) Количество ошибок в самом последнем тесте меньше, чем в самом первом

2) Количество ошибок в самом последнем тесте больше, чем в самом первом
3) Количество ошибок в первом тесте может быть как больше, так и меньше, чем в последнем тесте
4) Если Карина продолжит заниматься математикой, ее результаты по русскому языку улучшатся
5) Нет верного ответа среди остальных вариантов

19. Из всех опозданий студентов на пары 80% составляют опоздания на пары по физкультуре. Выберите выводы, которые **НЕ** следуют из этого факта.
    1) Студенты чаще опаздывают на физкультуру, чем школьники
    2) Пары по физкультуре следует перенести на более позднее время для уменьшения количества опозданий
    3) Большинство студентов опаздывает на пары по физкультуре
    4) До спортивного зала дольше добираться, чем до учебных аудиторий, поэтому студенты чаще опаздывают
    5) Так как большинство студентов опаздывает на первую часть пары, самые важные объявления преподаватель должен делать в конце пары

20. Перед вами четыре обнаруженные корреляции между парами признаков. Выберите все случаи, когда корреляция, скорее всего, возникает из-за прямой причинно-следственной связи между признаками:
    1) Чем больше полицейских в городе, тем больше преступлений в этом городе
    2) Чем выше человеческий капитал в стране, тем выше ВВП на душу населения в этой стране.
    3) Чем больше домашнего задания задают школьникам, тем выше средний балл в школе
    4) Чем больше средний рост население страны, тем меньше детей приходится на 1 взрослого

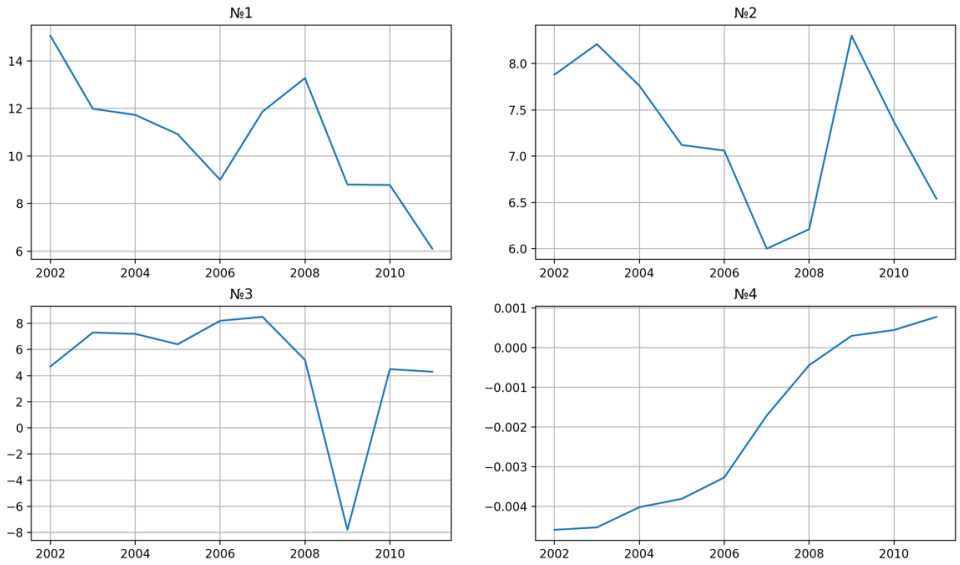
21. В случайно выбранных 20% школ в Конго дети, которые воспитываются мусульманских семьях, учатся в среднем лучше тех, кто воспитывается в христианских. На какие генеральные совокупности можно распространить этот вывод?
    1) Школа в Конго
    2) Конго
    3) Африка
    4) Весь мир
    5) Ни на какую из них

22. Студенты проводят исследование, пытаясь ответить на вопрос: «Как физические упражнения во время просмотра онлайн лекций влияют на успеваемость?» Какие из механизмов могут описывать гипотезу, выдвигаемую в качестве ответа на него?
    1) При физических упражнениях улучшается кровообращение, поэтому улучшается мозговая деятельность и успеваемость повышается

2) Во время физических упражнений теряется концентрация, поэтому успеваемость снижается
3) Физические упражнения не влияют на умственную концентрацию, поэтому успеваемость не меняется
4) Просмотр дополнительных лекций во время физических упражнений повышает успеваемость
5) Нет верного ответа среди других вариантов

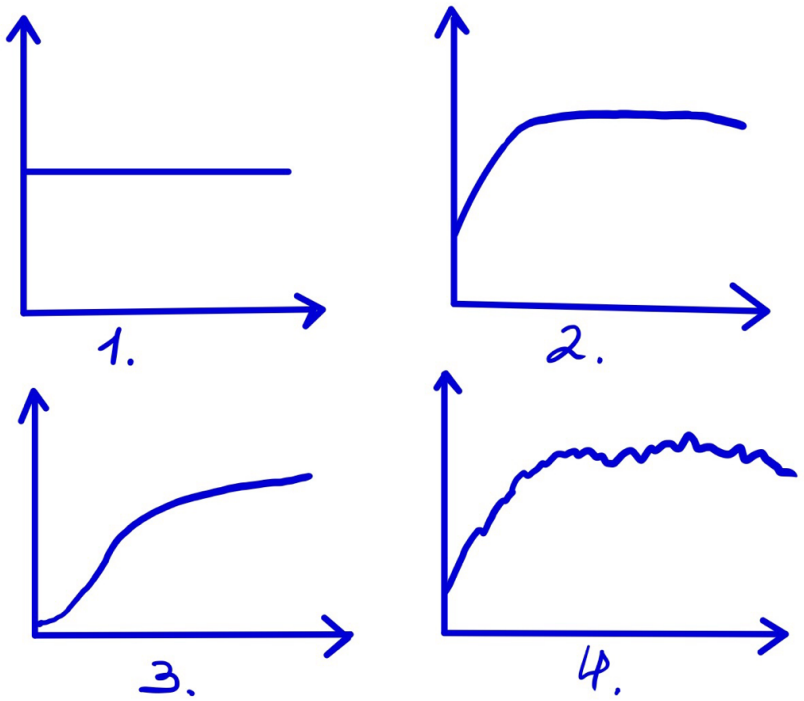
Открытые вопросы. Каждое задание оценивается в 5 баллов.

23. Перед Вами четыре графика, отражающих уровень безработицы (А), а также годовые темпы прироста ВВП (Б), населения (В) и уровня цен (Г) в России за 2002–2011 года (все показатели измерялись в %). Соотнесите показатели с соответствующими графиками их динамики и выпишите верный порядок букв, обозначающих показатели (пример ответа: АБВГ; такой ответ означает, что графику 1 ставится в соответствие показатель А, графику 2 — показатель Б и



т.д.).
Ответ: ГАБВ

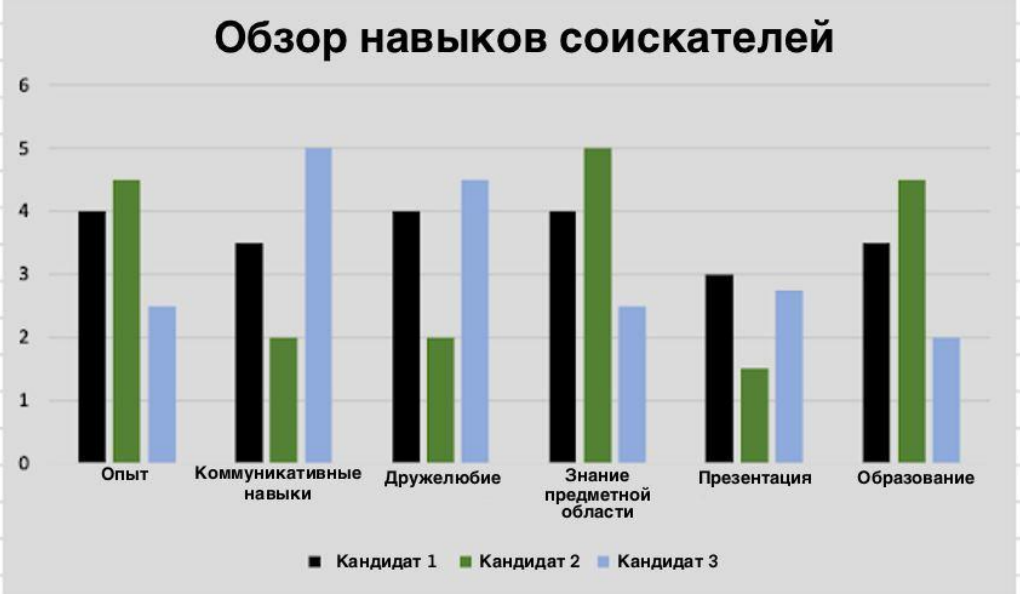
24. Исследователь Вася провёл четыре исследования о зависимости различных показателей от возраста, на основе которых от руки нарисовал графики найденных им функций для одного человека. Но забыл подписать графики и



теперь не знает, какой рисунок относится к какому исследованию. Взгляните на графики, а затем соотнесите исследования с номерами соответствующих визуализаций. Названия исследований представлены в виде пары «возраст — признак зависимый», на графиках возраст всегда отображаются по оси абсцисс.

- «Возраст — длина руки»: 2
- «Возраст — словарный запас»: 3
- «Возраст — количество хромосом»: 1
- «Возраст — длина волос на голове»: 4

25. Работодатель занимается подбором кандидатов на вакансию, где опыт в три раза важнее, чем каждая из характеристик: коммуникативные навыки, знание предметной области и образование. Остальные навыки для вакансии не важны. У работодателя есть 3 кандидата, чьи способности отражены на графиках ниже. Работодатель ранжирует кандидатов, используя сумму всех баллов с учетом важности каждой характеристики, от большей суммы к меньшей. Приведите в ответе это ранжирование кандидатов (сначала самый привлекательный кандидат).



213